



## Apuntes del Curso (FG) v2016

Probabilidad y Estadística (Universidad Técnica Federico Santa María)



messages.pdf\_cover\_qr\_code\_label




Universidad Técnica Federico Santa María  
Departamento de Matemáticas

---

# PROBABILIDAD y ESTADÍSTICA

---

*Apuntes del curso*



Recopilado por: Francisca González López,  
María José González y Enzo Hernández

Santiago, noviembre de 2015



---

**Universidad Técnica Federico Santa María**

Departamento de Matemática

---

# Probabilidad y Estadística

Apuntes del curso

*Recopilado por:* Francisca González López, María José González y Enzo Hernández.

---

Santiago, noviembre de 2015



# PREFACIO

El siguiente documento corresponde a una recopilación del material utilizado en los cursos de Probabilidad y Estadística del Campus Santiago de la Universidad.

Esta es una *recopilación* ya que su contenido corresponde a una selección de material de diversas fuentes: el material enunciado en la bibliografía, material disponible en internet, e, incluso, nuestros apuntes de clases.

Esta recopilación ha sido puesta a disposición de los alumnos como material complementario a las clases en el marco del desarrollo de nuevas metodologías de enseñanza-aprendizaje donde se quiere estimular en los alumnos el aprendizaje autónomo y la investigación para que así el trabajo del profesor en el aula sea como guía y tutor, maximizando así el tiempo de la clase dedicado a ejercitar y resolver dudas.

Este curso cuenta con una gran cantidad de contenidos, algunos de alta dificultad, por lo que es de utilidad tanto para alumnos/as como profesores contar con este material de apoyo como texto guía, ya que incluye de manera precisa los tópicos del curso, dejando al alumno/a la opción de avanzar e investigar en aquellos temas en los que se interese.

Los contenidos generales de este texto corresponden al desarrollo de las unidades principales del curso: estadística descriptiva, regresión lineal, probabilidades, inferencia estadística, control de calidad, y ANOVA y diseño de experimentos. Se incluye además en los anexos los formularios utilizados en el desarrollo del curso.

Agradecemos el apoyo de Editorial USM, el aporte de los profesores Tonino Costa y Andrés Fielbaum en la revisión del texto y los contenidos, al profesor Nicolás Meza por la construcción de la gráfica de la portada, y, principalmente, a todos los alumnos y ayudantes que han utilizado y revisado este material, ya que ellos son quienes motivan nuestro trabajo.



# Índice general

|                                                                                   |           |
|-----------------------------------------------------------------------------------|-----------|
| <b>1. INTRODUCCION</b>                                                            | <b>11</b> |
| 1.1. ESTADÍSTICA DESCRIPTIVA E INFERENCIAL . . . . .                              | 12        |
| 1.2. ETAPAS DE UNA INVESTIGACIÓN ESTADÍSTICA . . . . .                            | 12        |
| 1.3. MUESTREO . . . . .                                                           | 12        |
| 1.3.1. Conceptos básicos . . . . .                                                | 12        |
| 1.3.2. El Muestreo . . . . .                                                      | 13        |
| 1.3.3. Muestreo Probabilístico . . . . .                                          | 13        |
| 1.3.4. Muestreo No Probabilístico . . . . .                                       | 14        |
| 1.4. CLASIFICACIÓN DE VARIABLES . . . . .                                         | 15        |
| <b>2. ESTADÍSTICA DESCRIPTIVA</b>                                                 | <b>17</b> |
| 2.1. ORGANIZACIÓN DE LA INFORMACIÓN . . . . .                                     | 17        |
| 2.1.1. Variables Cuantitativas . . . . .                                          | 17        |
| 2.1.2. Variables Cualitativas . . . . .                                           | 20        |
| 2.2. MEDIDAS DE RESUMEN . . . . .                                                 | 21        |
| 2.3. ESTADÍSTICA BIVARIADA . . . . .                                              | 27        |
| 2.3.1. Descripción de variables: variables intervalares y/o cualitativas. . . . . | 27        |
| 2.3.2. Descripción de variables: cuantitativa versus cualitativa. . . . .         | 29        |
| 2.3.3. Descripción de variables: variables cuantitativas. . . . .                 | 31        |
| 2.3.4. Ajuste de Curvas . . . . .                                                 | 34        |
| <b>3. PROBABILIDADES</b>                                                          | <b>37</b> |
| 3.1. INTRODUCCIÓN . . . . .                                                       | 37        |
| 3.2. MÉTODOS DE CONTEO . . . . .                                                  | 38        |
| 3.3. MODELO DE PROBABILIDAD . . . . .                                             | 42        |
| 3.3.1. Espacio Muestral . . . . .                                                 | 42        |
| 3.3.2. Eventos . . . . .                                                          | 42        |
| 3.3.3. Medida de Probabilidad . . . . .                                           | 44        |
| 3.3.4. Espacios Probabilísticos Finitos . . . . .                                 | 45        |
| 3.4. PROBABILIDAD CONDICIONADA E INDEPENDENCIA . . . . .                          | 48        |
| 3.4.1. Probabilidad Condicional . . . . .                                         | 48        |
| 3.4.2. Independencia . . . . .                                                    | 49        |
| 3.5. VARIABLES ALEATORIAS . . . . .                                               | 53        |
| 3.5.1. Introducción . . . . .                                                     | 53        |
| 3.5.2. Variables Aleatorias Discretas . . . . .                                   | 55        |
| 3.5.3. Variables Aleatorias Continuas . . . . .                                   | 56        |
| 3.5.4. Localización y dispersión de una variable aleatoria . . . . .              | 57        |



|           |                                                                           |            |
|-----------|---------------------------------------------------------------------------|------------|
| 3.5.5.    | Casos especiales de distribuciones de probabilidad . . . . .              | 60         |
| 3.5.6.    | Momentos y funciones generadoras de momentos . . . . .                    | 66         |
| 3.5.7.    | Transformación de variables . . . . .                                     | 68         |
| 3.5.8.    | Aproximación de distribuciones . . . . .                                  | 70         |
| 3.6.      | VECTORES ALEATORIOS . . . . .                                             | 71         |
| 3.6.1.    | Distribución Conjunta . . . . .                                           | 71         |
| 3.6.2.    | Distribuciones conjuntas especiales . . . . .                             | 74         |
| 3.6.3.    | Distribución de probabilidad condicional . . . . .                        | 76         |
| 3.6.4.    | Esperanza y Varianza Condicional . . . . .                                | 77         |
| 3.6.5.    | Teorema de cambio de variable . . . . .                                   | 79         |
| 3.6.6.    | Secuencias de variables aleatorias . . . . .                              | 80         |
| 3.7.      | NOCIONES DE CONVERGENCIA . . . . .                                        | 81         |
| <b>4.</b> | <b>INFERENCIA ESTADÍSTICA</b>                                             | <b>83</b>  |
| 4.1.      | INTRODUCCIÓN . . . . .                                                    | 83         |
| 4.2.      | ESTIMACIÓN PUNTUAL . . . . .                                              | 85         |
| 4.2.1.    | Método de Momentos . . . . .                                              | 85         |
| 4.2.2.    | Método de Máxima Verosimilitud . . . . .                                  | 86         |
| 4.2.3.    | Inssegamiento y eficiencia de los estimadores . . . . .                   | 88         |
| 4.3.      | ESTIMACIÓN INTERVALAR . . . . .                                           | 91         |
| 4.3.1.    | Intervalo de Confianza para la media . . . . .                            | 92         |
| 4.3.2.    | Intervalo de Confianza para una proporción . . . . .                      | 92         |
| 4.3.3.    | Intervalo de Confianza para la varianza . . . . .                         | 93         |
| 4.3.4.    | Intervalo de Confianza para la diferencia de medias . . . . .             | 93         |
| 4.3.5.    | Intervalo de Confianza para la comparación de varianzas . . . . .         | 95         |
| 4.4.      | PRUEBAS DE HIPÓTESIS . . . . .                                            | 96         |
| 4.4.1.    | Prueba de Hipótesis para la media . . . . .                               | 98         |
| 4.4.2.    | Prueba de Hipótesis para la proporción . . . . .                          | 99         |
| 4.4.3.    | Prueba de Hipótesis para la varianza . . . . .                            | 99         |
| 4.4.4.    | Prueba de Hipótesis para la diferencia de medias . . . . .                | 100        |
| 4.4.5.    | Prueba de Hipótesis para la diferencia de proporciones . . . . .          | 102        |
| 4.4.6.    | Prueba de Hipótesis para la comparación de varianzas . . . . .            | 102        |
| <b>5.</b> | <b>REGRESIÓN LINEAL</b>                                                   | <b>105</b> |
| 5.1.      | INTRODUCCIÓN . . . . .                                                    | 105        |
| 5.2.      | LA RECTA DE REGRESIÓN . . . . .                                           | 106        |
| 5.3.      | BONDAD DE AJUSTE . . . . .                                                | 108        |
| <b>6.</b> | <b>CONTROL DE CALIDAD</b>                                                 | <b>115</b> |
| 6.1.      | INTRODUCCIÓN . . . . .                                                    | 115        |
| 6.2.      | DEFINICIONES . . . . .                                                    | 116        |
| 6.3.      | CONTROL DE FABRICACIÓN POR VARIABLES . . . . .                            | 117        |
| 6.3.1.    | Gráfica $\bar{X}$ basada en valores conocidos de los parámetros . . . . . | 117        |
| 6.3.2.    | Gráfica $\bar{X}$ basada en parámetros estimados . . . . .                | 118        |
| 6.4.      | CONTROL DE FABRICACIÓN POR ATRIBUTOS . . . . .                            | 120        |
| 6.4.1.    | Gráfica $p$ para fracción defectuosa . . . . .                            | 120        |
| 6.4.2.    | Gráfica $c$ para el número de defectos . . . . .                          | 121        |
| 6.5.      | CONSTRUCCIÓN DE UN GRÁFICO DE CONTROL . . . . .                           | 121        |

|                                                                      |            |
|----------------------------------------------------------------------|------------|
| <b>7. ANOVA Y DISEÑO DE EXPERIMENTOS</b>                             | <b>127</b> |
| 7.1. INTRODUCCIÓN . . . . .                                          | 127        |
| 7.1.1. Definiciones . . . . .                                        | 128        |
| 7.1.2. Notación . . . . .                                            | 128        |
| 7.2. Modelo de un factor con efectos fijos (ANOVA one-way) . . . . . | 128        |
| 7.2.1. Interpretación de una media de celda $\mu_i$ . . . . .        | 129        |
| 7.2.2. Interpretación de la varianza $\sigma^2$ . . . . .            | 129        |
| 7.2.3. Residuos del modelo . . . . .                                 | 130        |
| 7.3. TABLA ANOVA . . . . .                                           | 132        |
| <b>8. ANEXOS</b>                                                     | <b>137</b> |
| 8.1. ANEXO I: Formulario Distribuciones de Probabilidad . . . . .    | 138        |
| 8.2. ANEXO II: Formulario Intrevalos de Confianza . . . . .          | 139        |
| 8.3. ANEXO III: Formulario Pruebas de Hipótesis . . . . .            | 142        |
| <b>9. BIBLIOGRAFÍA</b>                                               | <b>147</b> |



---

# INTRODUCCIÓN

La estadística ayuda a tomar decisiones ante circunstancias cuyas características distintivas son incertidumbre y variabilidad. La primera característica se origina en la imposibilidad de considerar todos los factores involucrados dada la complejidad del entorno en general. La segunda se debe a una variación inherente en todo aquello que ocurre natural o cotidianamente, e incluso, en aquello que se fabrica, independientemente del rigor con que se fijen y se lleven a cabo las condiciones de producción.

Con el fin de abordar la incertidumbre, la estadística se vale del cálculo de probabilidades, creando modelos que permiten estimar los riesgos implicados en la toma de decisiones.

Lo primordial es contar con un conjunto de datos u observaciones, al que llamaremos muestra, que deberán ser procesadas para obtener información del fenómeno de estudio y así dar paso a la toma de decisiones.

## 1.1. ESTADÍSTICA DESCRIPTIVA E INFERENCIAL

La estadística puede subdividirse en dos amplias ramas: estadística deductiva o descriptiva y estadística inductiva o inferencial.

**Estadística Descriptiva o Deductiva.** Entendemos por estadística descriptiva si al analizar una muestra sólo se pueden obtener conclusiones válidas para la muestra sin que se puedan o se requieran generalizar sus resultados para todo el universo. Por medio de gráficas y valores numéricos calculados algebraicamente caracterizamos al conjunto de datos en estudio.

**Estadística Inductiva o Inferencial.** Entendemos por estadística inductiva si a partir de una muestra, suficientemente representativa del universo, podemos inferir (inducir) conclusiones estadísticamente válidas para todo el universo. Esto obliga a plantear simultáneamente las condiciones bajo las cuales dichas conclusiones son válidas.

## 1.2. ETAPAS DE UNA INVESTIGACIÓN ESTADÍSTICA

Aún cuando los tipos de problemas a los cuales puede aplicarse la estadística matemática son bastante heterogéneos, en muchos casos los pasos de una investigación estadística son similares.

- a) **Formulación del problema.** Para investigar con éxito un problema dado, primero tenemos que crear conceptos precisos, formular preguntas claras e imponer limitaciones adecuadas al problema, tomando en cuenta el tiempo y dinero disponible y la habilidad de los investigadores. Algunos conceptos tales como: Artículo defectuoso, servicio satisfactorio a la clientela, observaciones demográficas, grados de pureza de un mineral, tipo de tráfico, etc., pueden variar de caso en caso, y en cada situación específica necesitamos coincidir en definiciones apropiadas para los términos que se incluyen.
- b) **Diseño del experimento.** Es deseable obtener un máximo de información empleando un mínimo de costo y tiempo. Esto implica determinar el tamaño de la muestra o la cantidad y tipo de datos.
- c) **Experimentación o colección de datos.** En toda investigación esta etapa es la que consume más tiempo. Ésta debe aplicarse con reglas estrictas y con pautas preestablecidas.
- d) **Tabulación y descripción de los resultados.** Los datos experimentales se ilustran en diagramas, gráficos, pictogramas, etc, obteniéndose, además, medidas descriptivas que representen el proceso efectuado.
- e) **Inferencia estadística y formulación de la respuesta.** Al aplicar el método estadístico seleccionado en la etapa b) podemos inferir conclusiones obtenidas de la muestra acerca de la población respectiva.

## 1.3. MUESTREO

### 1.3.1. Conceptos básicos

- **Universo.** Es el conjunto de todos los datos u observaciones de un suceso. El universo puede ser finito, infinito contable e infinito no numerable (dependiendo del tipo de universo es el tipo de análisis del problema).
- **Población.** Elementos del universo que tienen una característica común y es la que tratamos de estudiar.

- **Marco Muestral.** es el conjunto de unidades del cual se seleccionará una muestra.
- **Unidades de Muestreo.** Las unidades del marco muestral se llaman unidades de muestreo. Es importante notar que toda unidad de la población debe estar asociada a una y sólo una unidad del marco muestral. Esto nos permitirá diseñar mecanismos de selección de la muestra de tal forma que toda unidad de la población se encontrará en al menos una de las posibles muestras seleccionadas y, en el caso del Muestreo Probabilístico, nos permitirá inducir una probabilidad de selección a cada elemento de la población.
- **Muestra Aleatoria (m.a.).** Es un subconjunto de la población donde sus elementos son escogidos al azar (no existe relación en la elección de los elementos).

### 1.3.2. El Muestreo

El Muestreo es la disciplina que trata con el conjunto de métodos, técnicas y procedimientos para tomar u obtener una particular muestra a efecto de realizar inferencias inductivas a partir de la misma. Existen dos grandes categorías de muestreo: el Muestreo Probabilístico y el Muestreo No Probabilístico.

### 1.3.3. Muestreo Probabilístico

Como su nombre lo dice, involucra el cálculo de probabilidad de selección de cada individuo en la población. Este muestreo supone que contamos con una “lista” de la población y que de acuerdo a la información previa que tengamos respecto del fenómeno de estudio es mecanismo que utilizaremos. Dos muestreos probabilísticos muy usados son:

#### Muestreo Aleatorio Simple

Es un diseño muestral bastante utilizado cuando se cuenta con una lista o directorio para usar como Marco Muestral. Se distinguen dos casos de m.a.s.: Muestreo sin Reemplazo y Muestreo con Reemplazo. De las  $N$  unidades de la población se selecciona “al azar” (igual probabilidad para cada unidad) una unidad. Ésta se separa (sin reposición) y de las  $N-1$  restantes unidades de la población se selecciona, también al azar, una segunda unidad. De las  $N-2$  unidades restantes se vuelve a seleccionar al azar una tercera unidad y así sucesivamente hasta completar las  $n$  unidades de la muestra.

#### Muestreo Aleatorio Estratificado

El Muestreo Estratificado se presenta cuando la población se encuentra particionada en  $L$  grupos y en todos y cada uno de estos grupos se aplica en forma independiente un diseño muestral no necesariamente igual en todos ellos. En tal caso, los grupos de la partición se llaman **estratos** y la partición se dice que es una **estratificación**. La estratificación puede tener su origen en los propios objetivos del estudio o en la intención de contar con estratos homogéneos que pueden hacer más eficiente el diseño muestral.

Ejemplos de estratificaciones en función de los objetivos del estudio son, por ejemplo, las divisiones político administrativas (los Estratos pueden ser Regiones, Provincias, Departamentos o Distritos, etc.) en una Encuesta Nacional, Ramas de Actividad Económica

en una Encuesta Industrial, Público y Privado en una Encuesta sobre Educación, etc.

Ejemplos de estratos creados para obtener una mayor homogeneidad en cada uno de ellos son: Empresas Grandes, Medianas, Pequeñas y Micro; en una Encuesta Industrial: Manzanas con hogares de ingresos mayoritariamente altos, medios y bajos, etc.

#### **1.3.4. Muestreo No Probabilístico**

En estos tipos de muestreo pueden existir unidades de la población que no pueden ser seleccionadas en ninguna de las muestras posibles, o bien, aunque exista una probabilidad de selección positiva para cada una de estas unidades de la población, esta probabilidad es desconocida.

##### **Muestreo por Cuotas**

Esta técnica se utiliza para sondeos de intención de voto y en las investigaciones de mercado. Se divide la población en grupos o cuotas de acuerdo con ciertas características o variables: área geográfica, edad, sexo, estado civil, ingresos económicos, nivel educativo, etc. Después se determinan las proporciones en cada grupo de acuerdo con la representación que tiene en la población. Pueden hacerse combinaciones de cuotas, tales como sexo y estado civil, profesión e ingresos, etc. En la selección de los casos interviene el criterio o juicio de entrevistador. Por lo general se eligen aquellos de más fácil acceso hasta completar la muestra.

##### **Muestreo Autoselectivo**

Cuando la gente participa en un estudio y responde voluntariamente una encuesta, ya sea impresa en un diario, a través de una llamada telefónica o por medio de internet, conforman lo que se llama una muestra autoselectiva. La gente que decide responder puede no ser representativa de la población. Por ejemplo, en estudios para responder por correo de los lectores de ciertas revistas se ha encontrado que quienes participan son quienes se preocupan o se interesan por el tema y que no necesariamente representan al universo de lectores.

Con el Muestreo No Probabilístico, en general, las observaciones para una muestra particular se obtienen más rápidamente y a menor costo que en el Muestreo Probabilístico. Por otra parte, los errores “ajenos al muestreo” (errores en las operaciones de recolección y procesamiento de la información) son más fáciles de controlar cuando se utiliza Muestreo Probabilístico. En todo caso, sólo con el Muestreo Probabilístico es posible obtener indicadores de confiabilidad del error inferencial de cada estimación obtenida a través de la muestra.

## 1.4. CLASIFICACIÓN DE VARIABLES

Como variable consideraremos todos aquellos atributos que pueden cambiar de individuo a individuo. Las variables pueden clasificarse como cualitativas o cuantitativas.

Una variable **cualitativa** describe un atributo del individuo generando así grupos o categorías. Existen dos tipos de variable cualitativa:

**Nominal:** la variable induce en la población una subdivisión y los datos se pueden clasificar en clases, donde cada clase está completamente definida y diferenciada de las demás.

**Ordinal:** la variable induce en la población una subdivisión que tiene una jerarquía implícita (admite grados de calidad u ordenamiento) entre grupos o clases, lo que significa que existe una relación de orden entre las clases. No es posible cuantificar la diferencia entre los individuos pertenecientes a una misma clase.

Por otro lado, una variable **cuantitativa** corresponde a una “medición”, esto es, los valores observados son números con los que tiene sentido realizar operaciones algebraicas. También podemos identificar dos tipos:

**Discreta:** la variable toma valores en un subconjunto finito o infinito numerable, es decir, es posible identificar todos y cada uno de los valores.

**Continua:** la variable está generalmente definida en conjuntos infinitos no-numerables, como por ejemplo, intervalos de números reales.

Adicionalmente, surge como una mezcla entre variables cualitativas y cuantitativas las variables **intervalares**, ya que poseen las características de variables ordinales con la propiedad adicional de que los nombres asignados a cada grupo son números que tienen una unidad de medida común y constante. En este caso se considera no sólo la información perteneciente al orden, sino además el tamaño relativo de los intervalos a los que pertenece cada uno de los individuos. Además, es posible cuantificar la diferencia de dos individuos pertenecientes al mismo intervalo y también a intervalos distintos.

Es necesario destacar que dependerá de cada caso en particular el cómo clasificar las variables de estudio, ya que en algunas ocasiones podrían considerarse discretas y en otras continuas e incluso ordinales. Todo esto dependerá del contexto del problema, el tipo de análisis a realizar, y de la opinión de quien clasifica las variables.





---

# ESTADÍSTICA DESCRIPTIVA

Como hemos mencionado anteriormente, la estadística descriptiva consiste en organizar y resumir la información contenida en nuestro conjunto de datos. Dependiendo del tipo de datos se aplicarán diferentes técnicas y cálculos.

## 2.1. ORGANIZACIÓN DE LA INFORMACIÓN

Una colección de datos tomados de un suceso (sometido a estudio) nada nos dice si no procesamos los datos recolectados para extraer así la información que éstos nos entregan.

Ya sabemos que las variables pueden ser clasificadas y esta clasificación determinará qué estadísticos corresponde calcular y reportar.

### 2.1.1. Variables Cuantitativas

Consideremos una variable cuantitativa de la que hemos tomado  $n$  mediciones. La información contenida en esta variable será resumida en una *tabla de distribución de frecuencia*, que consiste en organizar dicha información según clases o intervalos. La construcción de dichas clases puede estar determinada a priori por el investigador. Por ejemplo, al analizar la edad de los participantes de un estudio, y para efectos de comparabilidad, se podrían utilizar las tres clases utilizadas en otro estudio: 15 a 24 años, 25 a 44 años, y 45 a 65 años.

Consideremos que hemos determinado subdividir nuestra variable en  $k$  clases. La tabla de distribución de frecuencias se construirá con los siguientes elementos:

**Clase o Intervalo.** Una subdivisión del rango en componentes (de acuerdo a la magnitud, atributos, etc.) se denomina **clases**, categorías o intervalos. Se designan por la letra  $C$  con un subíndice que indica la clase a la cual nos referimos, por ejemplo  $C_1, C_2, \dots, C_k$ .

**Marca de la Clase.** Corresponde al punto medio de cada clase o intervalo. Se designa por las letras  $MC_i$  (el subíndice indica la clase a la que le corresponde), es decir,

$$MC_i = \frac{\max_i - \min_i}{2}$$

donde  $\max_i$  corresponde al límite superior de la clase  $i$ , y  $\min_i$  al límite inferior.

**Frecuencia Absoluta.** Corresponde al número de datos que pertenecen a una clase. Se designa por la letra  $n$  con un subíndice que indica la clase a que pertenece:  $n_1, n_2, \dots, n_k$ .

Notar que la suma de todas las frecuencias absolutas debe ser igual al número total de datos, es decir,

$$\sum_{i=1}^k n_i = n$$

.

**Frecuencia Relativa.** Corresponde a la proporción de datos que pertenecen a una clase con respecto al total, es decir,  $f_i = n_i/n$ . Se designa por la letra  $f$  con un subíndice que indica la clase a la que pertenece:  $f_1, f_2, \dots, f_k$ .

Notar que la suma de todas las frecuencias relativas debe ser igual a 1, es decir,

$$\sum_{i=1}^k f_i = 1$$

.

**Frecuencia Absoluta Acumulada.** Corresponde a la cantidad de datos que están desde la primera hasta la  $i$ -ésima clase, es decir, es la suma de las frecuencias absolutas de las primeras  $i$  clases. Se designa por la letra  $N$  con un subíndice que indica la clase a que pertenece:  $N_1, N_2, \dots, N_k$ .

Notar que

$$\begin{aligned} N_1 &= n_1 \\ N_2 &= n_1 + n_2 = N_1 + n_2 \end{aligned}$$

en resumen,

$$N_i = n_1 + n_2 + \dots + n_i = N_{i-1} + n_i, \quad \forall i = 1, 2, \dots, k.$$

y debe verificarse que  $N_k = n$ .

**Frecuencia Relativa Acumulada.** Corresponde a la proporción de datos que están desde la primera hasta la  $i$ -ésima clase, es decir, es la suma de las frecuencias relativas de las  $i$  primeras clases. Se designa por la letra  $F$  con un subíndice que indica la clase a que pertenece:  $F_1, F_2, \dots, F_k$ .

Notar que

$$\begin{aligned} F_1 &= f_1 = \frac{N_1}{n} \\ F_2 &= f_1 + f_2 = F_1 + f_2 = \frac{N_2}{n} \end{aligned}$$

en resumen

$$F_i = f_1 + f_2 + \dots + f_i = F_{i-1} + f_i = \frac{N_i}{n}, \quad \forall i = 1, 2, \dots, k.$$

y debe verificarse que  $F_k = 1$ .

La tabla resumen debe verse más o menos así:

| Clases        | $MC_i$ | $n_i$ | $N_i$ | $f_i$ | $F_i$ |
|---------------|--------|-------|-------|-------|-------|
| $[l_1 - L_1]$ | $MC_1$ | $n_1$ | $N_1$ | $f_1$ | $F_1$ |
| $[l_2 - L_2]$ | $MC_2$ | $n_2$ | $N_2$ | $f_2$ | $F_2$ |
| $\vdots$      |        |       |       |       |       |
| $[l_k - L_k]$ | $MC_k$ | $n_k$ | $N_k$ | $f_k$ | $F_k$ |
| Total         |        | $n$   |       | 1     |       |

Si el investigador no posee información a priori de cómo definir las clases, entonces podría tomar como referencia los siguientes conceptos:

**Rango.** Corresponde a la diferencia entre el valor mayor y el valor menor en la muestra y se denota por la letra **R**. El rango representa un primer intento de medir cuán dispersos están los datos.

**Número de clases o intervalos.** Es una subdivisión del rango en varios grupos o intervalos. Se designa por la letra **k** y se obtiene utilizando la fórmula de Struges:

$$k = 1 + 3,3 \cdot \log_{10}(n)$$

Como el número de clases debe ser un número entero, este se aproxima al entero superior, identificándolo con la letra **k**.

Para valores de **n** menores a 20 se suele calcular el número de clases como  $k = \sqrt{n}$ .

**Ancho de la clase.** El ancho de la clase es la diferencia entre el límite superior e inferior de la clase. Se designa por la letra **I**. El ancho de cada clase puede o no ser del mismo tamaño. En el caso de que se quiera construir anchos de clase iguales, el valor de **I** se define como:

$$I = \frac{R + 1}{k}$$

Cuando los datos son enteros se recomienda que el valor de **I** se aproxime al entero superior.

Notar que si la variable es discreta y toma valores en un conjunto con alrededor de 10 elementos, podemos calcular frecuencias para cada valor de la variable, por lo que no será necesario calcular número de clases, rango, ni marca de clase.

## Ejercicios 1

1. Las notas obtenidas en un examen, en escala 1 a 7, fueron:

3, 5, 6, 3, 4, 4, 7, 2, 1, 2, 3, 3, 4, 4, 6, 2, 7, 5, 3, 4, 4, 1, 2, 2, 3, 5, 4, 6, 5, 5.

Construya una tabla de distribución de frecuencias y genere un gráfico adecuado.

2. En una empresa se considera la siguiente muestra correspondiente a la resistencia de 50 lotes de algodón, medida en libras, necesaria hasta romper una madeja.

74 87 99 88 90 101 91 83 97 94  
 105 110 99 94 104 97 90 88 89 90  
 79 105 96 93 93 90 91 102 94 106  
 101 96 97 103 108 90 102 91 76 109  
 110 94 101 97 106 86 88 97 107 107

*Construya una tabla de distribución de frecuencias y genere un gráfico adecuado.*

### 2.1.2. Variables Cualitativas

Consideremos una variable cualitativa de la que hemos tomado  $n$  mediciones. Ordenaremos esta información en una tabla de *distribución de frecuencia* siguiendo como referencia los conceptos anteriormente descritos de frecuencia absoluta y relativa.

La tabla resumen debe verse más o menos así:

|               | $n_i$ | $f_i$ |
|---------------|-------|-------|
| Categoría 1   | $n_1$ | $f_1$ |
| Categoría 2   | $n_2$ | $f_2$ |
| $\vdots$      |       |       |
| Categoría $k$ | $n_k$ | $f_k$ |
| Total         | $n$   | 1     |

En el caso de que la variable sea ordinal, tendrá sentido agregar además la columna con frecuencias acumuladas (tanto absolutas como relativas), siendo la más utilizada la de frecuencia acumulada relativa.

**Ejercicios 2** *Se identificó una muestra de estudiantes que poseía automóviles producidos por la General Motors y se registró la marca de cada automóvil. A continuación se presenta la muestra que se obtuvo (Ch = Chevrolet, P = Pontiac, O = Oldsmobile, B = Buick, Ca = Cadillac):*

Ch B Ch P O B Ch Ch Ca Ch  
 B P O P P Ch P O O Ca  
 Ch B Ch B P O Ca P Ch Ch  
 O Ch Ch B P Ch Ca O Ch B  
 B O Ch Ch O Ch Ch B Ch B

*Construya una tabla de distribución de frecuencias para la variable “marca del automóvil” y genere un gráfico de barras.*

## 2.2. MEDIDAS DE RESUMEN

La idea es resumir los datos en un valor que represente a todo un conjunto de datos. Éste tiene que ser un número o una clase hacia el cual tienen tendencia a concentrarse mayoritariamente el conjunto de datos. Usualmente este se ubica en las clases más o menos centrales, o sea, es un valor central o de posición central alrededor del cual se distribuyen todos los datos del conjunto, de allí el nombre de Medidas de Tendencia Central. Las más comunes son la mediana, moda, media o promedio para variables cuantitativas y porcentajes en el caso de variables cualitativas.

Una vez determinadas las medidas de tendencia central de una distribución, nos interesa determinar cómo se reparten (dispersan, desvían) los datos a uno y otro lado de la medida central. O sea, es necesario cuantificar la representatividad de la medida de tendencia para poder caracterizar la distribución. Si la dispersión es pequeña indica que los datos tienden a concentrarse en torno a la medida central; por el contrario, una gran dispersión indica que los datos están alejados de ella. Las medidas de dispersión más usuales son: desviación media, desviación típica o estándar, rango, rango semi-intercuartílico, rango percentil.

Existen también las medidas de posición que nos dirán dónde se ubican nuestros datos. Las más usadas son los percentiles.

Estas y otras medidas nos sirven para resumir la información presentada en cuadros y poder relacionar y comparar entre sí, de manera sencilla, un conjunto de distribuciones de frecuencias.

Es importante destacar que la correcta descripción de un conjunto de datos no puede basarse en el análisis de sólo una de estas medidas, ya que es en conjunto cuando podemos apreciar en detalle la distribución de los datos. Para una correcta descripción debería tener al menos una medida de tendencia central, una de dispersión y dos de posición.

Para cada una de las medidas que presentaremos se distinguirán dos casos: cuando los datos no están agrupados (usamos la variable como continua o discreta) y cuando están agrupados (variables intervalares).

### Promedio

La medida central más usada es el promedio o media muestral. Como tal valor tiende a situarse en el centro del conjunto de los datos ordenados según su magnitud, el promedio se conoce también como *medidas de centralización*.

El promedio o media aritmética de un conjunto de  $n$  números  $x_1, x_2, \dots, x_n$  se denota por  $\bar{x}$  y se define como

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

para datos no agrupados. Para datos agrupados donde se conocen las respectivas marcas de clase  $MC_i$ , y ellas se presentan con frecuencias absolutas  $n_i$ , el promedio o media muestral es:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^k n_i \cdot MC_i$$

El promedio es único para un conjunto de datos y presenta una desventaja: es “sensible” a la existencia de datos extremos, lo que repercute en la “representatividad” que tiene respecto del conjunto de datos. Esto último quiere decir que su valor cambia si agregamos un nuevo dato que esté alejado (es muy alto o muy bajo) del conjunto original.

## Mediana

Es el valor de la variable que ocupa la posición central en un conjunto de datos ordenados.

Si el número de observaciones es impar, es la observación central de los valores, una vez que éstos han sido ordenados en orden creciente o decreciente. Si el número de las observaciones es par, se calcula como el promedio de las dos observaciones centrales.

Para datos agrupados, la mediana viene dada por:

$$Me = l_{Me} + \frac{\frac{n}{2} - N_{Me}^-}{n_{Me}} \cdot I_{Me}$$

donde:

- $n$ : número total de datos
- $l_{Me}$ : límite inferior del intervalo de la clase mediana
- $n_{Me}$ : es la frecuencia de la clase mediana
- $N_{Me}^-$ : frecuencia absoluta acumulada hasta la clase anterior a la clase mediana
- $I_{Me}$ : ancho del intervalo de la clase mediana.

Notar que:

- La mediana en un conjunto de datos es única.
- La mediana no es sensible a la presencia de datos extremos.
- En un conjunto de datos, la mitad de ellos son iguales o menores que la mediana, y la otra mitad iguales o mayores que la mediana.

## Moda

La moda de un conjunto de números es aquel que se presenta con la mayor frecuencia, es decir, es el valor más repetido.

Una distribución que tiene una sola moda se llama unimodal (caso más usual). Es posible encontrar variables bimodales, trimodales, etc.

Para datos agrupados, la moda puede obtenerse mediante el número dado por:

$$Moda = l_{mo} + \frac{\Delta_1}{\Delta_1 + \Delta_2} I_{mo}$$

donde:

- $mo$ : clase modal (clase con mayor frecuencia absoluta)
- $l_{mo}$ : límite inferior del intervalo de la clase modal
- $\Delta_1$ :  $n_{mo} - n_{mo}^-$
- $\Delta_2$ :  $n_{mo} - n_{mo}^+$
- $n_{mo}$ : es la frecuencia de la clase modal
- $n_{mo}^+$ : es la frecuencia de la clase posterior a la clase modal
- $n_{mo}^-$ : es la frecuencia de la clase anterior a la clase modal
- $I_{mo}$ : ancho del intervalo de la clase modal.

Notar que:

- La moda puede no existir y cuando existe no es necesariamente única.
- El valor de la moda no se ve afectado por la presencia de valores extremos.

### Percentiles

El percentil  $q$  es un valor de la variable tal que el  $q\%$  de los datos es menor que él y, por lo tanto, el  $(100-q)\%$  es mayor. Son una medida de posición que no reflejan la tendencia central.

Si  $x_1, x_2, \dots, x_n$  es una secuencia ordenada de datos, el percentil  $q$  se encuentra en la **posición**

$$\frac{q(n+1)}{100}$$

Para datos agrupados, nos referimos a la clase en el cual se encuentra al menos el  $q\%$  de los datos, digamos  $C_p$ , por lo que

$$P_q = l_p + \frac{n \cdot q/100 - N_p^-}{n_p} \cdot I_p$$

donde:

- $n$  = número total de datos
- $l_p$  = límite inferior de la clase a la cual pertenece el percentil  $q$
- $n_p$  = es la frecuencia de  $C_p$
- $N_p^-$  = frecuencia absoluta acumulada hasta la clase anterior a  $C_p$
- $I_p$  = ancho de  $C_p$ .

### Varianza

Es una constante que representa cuán dispersos están los datos respecto del promedio o media muestral. Puede interpretarse como medida de “variabilidad” de la variable.

Se define la varianza de una serie de observaciones  $x_1, \dots, x_n$  como

$$\sigma^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

o equivalentemente (se sugiere demostrarlo)

$$\sigma^2 = \frac{1}{n} \sum_{i=1}^n x_i^2 - \bar{x}^2$$

La varianza para datos agrupados con sus respectivas frecuencias absolutas  $n_i$ , y las marcas de clase  $MC_i$ , se representa por:

$$\sigma^2 = \frac{1}{n} \sum_{i=1}^k n_i (MC_i - \bar{x})^2$$

o equivalentemente (se sugiere demostrarlo)

$$\sigma^2 = \frac{1}{n} \sum_{i=1}^k n_i MC_i^2 - \bar{x}^2$$



La unidad de medida de la varianza es el cuadrado de la unidad de medida de la variable. Esto quiere decir que si la variable está medida en centímetros, la varianza estará medida en “centímetros al cuadrado”, lo que genera magnitudes muy grandes y no interpretables.

Es por esto que se define la **desviación estándar**,  $\sigma = \sqrt{\sigma^2}$ , que también es una medida de dispersión de los datos respecto del promedio o media muestral. Esta medida de dispersión es la más utilizada, ya que a diferencia de la varianza, la desviación estándar sí está en la unidad de medida de los datos.

Se sugiere investigar acerca de otras medidas de dispersión como el rango intercuartílico, rango semi-intercuartílico, etc.

### Ejemplo 2.2.1

*Las últimas 100 ventas facturadas por un establecimiento se habían agrupado en cuatro intervalos de clase, de los que recordamos tan sólo la siguiente información:*

- *El primer intervalo tiene seis semanas como extremo superior, una frecuencia relativa de 0,2 y una amplitud de cuatro semanas.*
- *La marca de clase del segundo y cuarto intervalo son ocho y cincuenta semanas respectivamente.*
- *Hasta el segundo intervalo se acumulan sesenta ventas.*
- *El tercer intervalo presenta una frecuencia de treinta ventas y una amplitud de treinta semanas.*

*Con esta información:*

- a) *Construya la distribución de frecuencias.*
- b) *Calcule promedio y mediana de la variable “ventas facturadas”.*

#### Desarrollo:

- a) *Con la información entregada podemos ir completando la tabla (en rojo se encuentran los datos entregados):*

| <i>Ventas</i> | <i>MC<sub>i</sub></i> | <i>n<sub>i</sub></i> | <i>N<sub>i</sub></i> | <i>f<sub>i</sub></i> | <i>F<sub>i</sub></i> |
|---------------|-----------------------|----------------------|----------------------|----------------------|----------------------|
| 2 – <b>6</b>  | 4                     | 20                   | 20                   | <b>0,2</b>           | 0,2                  |
| 6 – 10        | <b>8</b>              | 40                   | <b>60</b>            | 0,4                  | 0,6                  |
| 10 – 40       | 25                    | <b>30</b>            | 90                   | 0,3                  | 0,9                  |
| 40 – 60       | <b>50</b>             | 10                   | 100                  | 0,1                  | 1                    |

*La amplitud o ancho del intervalo se define como  $I = L_i - l_i$  en donde  $L_i$  e  $l_i$  son los límites superior e inferior del intervalo respectivamente. Por lo tanto tenemos que  $4 = 6 - l_1 \Rightarrow l_1 = 2$*

Con esto,

$$MC_1 = \frac{2+6}{2} = 4$$

$$n_1 = f_1 \cdot n = 0,2 \cdot 100 = 20$$

$$MC_2 = 8 = \frac{6+L_2}{2} \Rightarrow L_2 = 10$$

$$MC_3 = \frac{10+40}{2} = 25$$

$$MC_4 = 50 = \frac{40+L_4}{2} \Rightarrow L_4 = 60$$

b) La media de las ventas se define, entonces:

$$\bar{x} = \sum_{i=1}^4 f_i \cdot MC_i = 0,2 \cdot 4 + 0,4 \cdot 8 + 0,3 \cdot 25 + 0,1 \cdot 50 = 16,5$$

La mediana la definimos como:

$$Me = l_{Me} + \left[ \frac{\frac{n}{2} - N_{Me}^-}{n_{Me}} \right] \cdot I_{Me}$$

Donde la clase mediana es la que tiene  $F_{Me} \geq 0,5$ , en este caso la clase 2.

$$Me = 6 + \left[ \frac{\frac{100}{2} - 20}{40} \right] \cdot 4 = 9$$

### Ejercicios 3

1. Un policía de una ciudad, usando radar, verificó la velocidad de los automóviles que circulaban por una calle de la ciudad:

|    |    |    |    |    |    |
|----|----|----|----|----|----|
| 27 | 23 | 22 | 38 | 43 | 24 |
| 25 | 23 | 22 | 52 | 31 | 30 |
| 29 | 28 | 27 | 25 | 29 | 28 |
| 26 | 33 | 25 | 27 | 25 |    |
| 21 | 23 | 24 | 18 | 23 |    |

Construya una tabla de distribución de frecuencias, calcule medidas de tendencia central y genere un gráfico adecuado.

2. Considere los datos de consumo de energía eléctrica de 80 usuarios que se muestran en la siguiente tabla:

| Consumo (Kwh) | Nº de usuarios |
|---------------|----------------|
| 5 - 25        | 4              |
| 25 - 45       | 6              |
| 45 - 65       | 14             |
| 65 - 85       | 26             |
| 85 - 105      | 14             |
| 105 - 125     | 8              |
| 125 - 145     | 6              |
| 145 - 165     | 2              |
| Total         | 80             |

- Construya un histograma de la variable consumo
  - Determine la media y mediana de la variable consumo.
  - Calcule el percentil 25 y 75 para la variable consumo.
  - Calcule la varianza de la variable consumo.
  - ¿Qué porcentaje de usuarios consumen más de 100 Kwh?
  - ¿Qué porcentaje de los usuarios consume entre 50 y 150 Kwh?
3. Los datos que se muestran a continuación representan el costo (en dólares) de la energía eléctrica durante el mes de julio del 2006 para una muestra aleatoria de 50 departamentos con dos recamaras en una ciudad grande.

96 171 202 178 147 102 153 197 127 82  
 157 185 90 116 172 111 148 213 130 165  
 141 149 206 175 123 128 144 168 109 167  
 95 163 206 175 130 143 187 166 139 149  
 108 119 150 154 114 135 191 137 129 158

Construya una tabla de distribución de frecuencias, calcule medidas de tendencia central y genere un gráfico adecuado.

## 2.3. ESTADÍSTICA BIVARIADA

Supongamos que queremos estudiar el comportamiento conjunto de las variables  $X$  e  $Y$  en una muestra de tamaño  $n$  de la población, más específicamente, cómo se relacionan estas dos variables en el sentido de si los valores que toma una determinan de alguna manera los valores de la otra. Dependiendo del tipo de variables es el tipo de análisis que corresponderá.

### 2.3.1. Descripción de variables: variables intervalares y/o cualitativas.

Sean  $X$  e  $Y$  dos variables categóricas con  $A_1, \dots, A_r$  las clases de  $X$ , y  $B_1, \dots, B_s$ , las de  $Y$ . La información conjunta de  $X$  e  $Y$  la resumiremos en una **tabla de contingencia** que corresponde a un cuadro de doble entrada como se muestra a continuación:

|   |          | Y        |          |          |          | Total    |
|---|----------|----------|----------|----------|----------|----------|
|   |          | $B_1$    | $B_2$    | $\dots$  | $B_s$    |          |
| X | $A_1$    | $n_{11}$ | $n_{12}$ | $\dots$  | $n_{1s}$ | $n_{1+}$ |
|   | $A_2$    | $n_{21}$ | $n_{22}$ | $\dots$  | $n_{2s}$ | $n_{2+}$ |
|   | $\vdots$ | $\vdots$ | $\vdots$ | $\vdots$ | $\vdots$ | $\vdots$ |
|   | $A_r$    | $n_{r1}$ | $n_{r2}$ | $\dots$  | $n_{rs}$ | $n_{r+}$ |
|   | Total    | $n_{+1}$ | $n_{+2}$ | $\dots$  | $n_{+s}$ | $n$      |

donde

$n_{ij}$  es el número de elementos de la muestra que pertenecen simultáneamente a la clase  $A_i$  y la clase  $B_j$ , esto es, la frecuencia absoluta del número de elementos pertenecientes a  $A_i \cap B_j$ .

Definimos

$n_{i+}$ : número de elementos de la muestra que pertenecen a la clase  $A_i$ , sin importar la clase  $B_j$  a la que estén asociados (suma de los valores de la fila  $i$ -ésima de la tabla de contingencia)

$$n_{i+} = \sum_{j=1}^s n_{ij}, \quad \forall i = 1, \dots, r.$$

$n_{+j}$ : es el número de elementos de la muestra que pertenecen a la clase  $B_j$  según  $Y$ , sin importar la clase  $A_i$  a la que estén asociados (suma de los valores de la columna  $j$ -ésima de la tabla de contingencia)

$$n_{+j} = \sum_{i=1}^r n_{ij}, \quad \forall j = 1, \dots, s.$$

De esta tabla también podemos calcular

$$f_{ij} = \frac{n_{ij}}{n}, \quad \forall i = 1, \dots, r; \quad \forall j = 1, \dots, s.$$

que corresponde a la frecuencia relativa del número de elementos en  $A_i \cap B_j$  con respecto al total  $n$ .

$f_{i+}$ : frecuencia relativa de las clases  $A_i$  sin importar las clases  $B_j$ .

$$f_{i+} = \frac{n_{i+}}{n}, \quad \forall i = 1, \dots, r.$$

$f_{+j}$ : frecuencia relativa de las clases  $B_j$  sin importar las clases  $A_i$ .

$$f_{+j} = \frac{n_{+j}}{n}, \quad \forall j = 1, \dots, s$$

### Distribuciones Condicionales

La distribución condicional consiste en estudiar el comportamiento de una variable dado un valor fijo de la otra. Para calcular la proporción de individuos muestrales que según  $Y$  caen en  $B_j$ , conociendo que según  $X$  ya pertenecían a  $A_i$ , se debe evaluar la distribución de frecuencia condicional de  $X$  dado  $Y$  que se define como

$$f_{i/j} = \frac{n_{ij}}{n_{+j}} \quad \forall i = 1, \dots, r.$$

y se debe considerar que

$$\sum_{i=1}^r f_{i/j} = 1$$

Análogamente es posible definir la distribución condicional de  $Y$  dado  $X$ .

### Ejercicios 4

1. Sean  $X$  la edad e  $Y$  la categoría correspondiente al puesto de trabajo. Dada la siguiente tabla de contingencia:

| $X \backslash Y$ | I  | II | III | $n_{i+}$ |
|------------------|----|----|-----|----------|
| 15-20            | 20 | 20 | 5   | 45       |
| 20-25            | 15 | 12 | 8   | 35       |
| 25-30            | 10 | 15 | 10  | 35       |
| 30-35            | 5  | 20 | 25  | 50       |
| 35-40            | 5  | 10 | 30  | 45       |
| $n_{+j}$         | 55 | 77 | 78  | 210      |

- a) Calcular la distribución condicional de  $Y$ , dado que  $X$  es 25-30 y dado que  $X$  es 35-45.
- b) ¿Es posible afirmar que habría una relación entre la edad y la categoría de puesto de trabajo?

2. Una muestra aleatoria de 1000 votantes registrados se clasificaron de acuerdo con su posición en la categorías de ingreso bajo, medio o alto, y si están a favor o no de la nueva reforma de impuestos. Los resultados se muestran en la tabla a continuación:

| Reforma de impuestos | Nivel de ingreso |       |      | Total |
|----------------------|------------------|-------|------|-------|
|                      | Bajo             | Medio | Alto |       |
| A favor              | 182              | 213   | 203  | 598   |
| En contra            | 154              | 138   | 110  | 402   |
| Total                | 336              | 351   | 313  | 1000  |

- a) Determine distribuciones marginales por filas.  
 b) ¿Es posible afirmar que las variables están relacionadas?

## Independencia

Dada la información de una tabla de contingencia, se dirá que las variables  $X$  e  $Y$  son independientes si y solo si la frecuencia relativa conjunta es igual al producto de las frecuencias relativas marginales, esto es,

$$f_{ij} = f_{i+} \cdot f_{+j} \quad \forall i = 1, \dots, r \quad \forall j = 1, \dots, s$$

Si las variables  $X$  e  $Y$  no son independientes entre sí se dice que existe una asociación entre ellas, de modo que el conocimiento de una de las variables presente alguna información respecto de la otra.

### 2.3.2. Descripción de variables: cuantitativa versus cualitativa.

Sean  $X$  una variable cualitativa e  $Y$  una variable cuantitativa. La información conjunta de estas variables puede ser resumida a través del cálculo de medidas de resumen para  $Y$  para cada subgrupo generado por las categorías de  $X$ , como se muestra a continuación:

|                      | n        | Promedio ( $s$ ) | Mín -Máx          | Mediana  |
|----------------------|----------|------------------|-------------------|----------|
| Categoría 1 de $X$   | $n_1$    | $\bar{y}_1(s_1)$ | $\min_1 - \max_1$ | $Me_1$   |
| Categoría 2 de $X$   | $n_2$    | $\bar{y}_2(s_2)$ | $\min_2 - \max_2$ | $Me_2$   |
| $\vdots$             | $\vdots$ | $\vdots$         | $\vdots$          | $\vdots$ |
| Categoría $k$ de $X$ | $n_k$    | $\bar{y}_k(s_k)$ | $\min_k - \max_k$ | $Me_k$   |
| Total                | $n$      | $\bar{y}(s)$     | $\min - \max$     | $Me$     |

Esto permitirá comparar la distribución de  $Y$  para cada nivel de  $X$  y además con el total (considerando todas las categorías de  $X$ ). En esta tabla se pueden agregar además otros estadísticos como percentiles y/o coeficiente de variación.

Si por ejemplo observáramos que los promedios son distintos y van en aumento conforme aumenta la categoría de  $X$ , sería un indicador de que hay una relación entre las variables, pero esta comparación no es tan simple ya que depende de que los grupos tengan tamaños similares, y por sobretodo, de las desviaciones estándar.

En el capítulo de **Inferencia Estadística** analizaremos este caso en detalle. Por ahora, recordar que los análisis son descriptivos, y por tanto, nos dan una idea del comportamiento de las variables en la muestra.

**Ejemplo 2.3.1** Considere las estadísticas entregadas para las temporadas de calor (primavera y verano) y de frío (otoño e invierno)

|          | Frío  | Calor |
|----------|-------|-------|
| $n$      | 18    | 12    |
| Promedio | 0.152 | 0.193 |
| DE       | 0.019 | 0.029 |
| Mín      | 0.121 | 0.155 |
| P25      | 0.136 | 0.176 |
| Mediana  | 0.150 | 0.189 |
| P75      | 0.170 | 0.207 |
| Máx      | 0.183 | 0.259 |

¿Cómo se distribuyen las ventas de acuerdo a la temporada?

**Desarrollo:** Para la época de “frío” la ventas promedio son de 0.152 con una desviación estándar de 0.019. Se observan valores entre 0.121 y 0.183, habiendo un 25 % de ventas inferiores a 0.136 y un 75 % inferior a 0.170. Por la cercanía del promedio con la mediana, los datos se concentran en torno a la media. Las distancias entre los cuartiles ( $Q_1$ -Mín=0.015; Med- $Q_1$ =0.014;  $Q_3$ -Med=0.020; Máx- $Q_3$ =0.013) indican que los datos se distribuyen de manera homogénea en cada cuartil, es decir, de manera casi uniforme.

Para la época de “calor” la ventas promedio son de 0.193 con una desviación estándar de 0.029. Se observan valores entre 0.155 y 0.259, habiendo un 25 % de ventas inferiores a 0.176 y un 75 % inferior a 0.207. Por la cercanía del promedio con la mediana, los datos se concentran en torno a la media. Las distancias entre los cuartiles ( $Q_1$ -Mín=0.021; Med- $Q_1$ =0.013;  $Q_3$ -Med=0.018; Máx- $Q_3$ =0.052) indican que los datos se distribuyen de manera homogénea en los primeros tres cuartiles, siendo la distribución asimétrica a la derecha.

## Ejercicios 5

Un alumno está interesado en estudiar el costo de los libros de texto de Estadística (E) y Finanzas (F). Para esto, recoge información de 13 libros actualmente a la venta. Los datos se muestran a continuación:

| Materia | E  | F  | F  | F  | E  | E  | F  | E  | F  | F  | E  | E  | F  |
|---------|----|----|----|----|----|----|----|----|----|----|----|----|----|
| Y       | 84 | 75 | 50 | 62 | 58 | 78 | 42 | 99 | 72 | 69 | 81 | 63 | 93 |

La pregunta que se plantea el alumno es ¿existen diferencias en los precios de los libros de Estadística y los de Finanzas? Para responder a esto, construya una tabla con los estadísticos descriptivos para los precios de los libros de cada materia y compare.

¿Qué le puede responder al alumno?

### 2.3.3. Descripción de variables: variables cuantitativas.

Sean  $X$  e  $Y$  dos variables cuantitativas. La información conjunta de estas variables ya no podrá ser tabulada, por lo que necesitamos magnitudes que den cuenta de la relación de estas variables.

Como las variables representan magnitudes, diremos que estas variables “están asociadas”, “son dependientes”, o “están correlacionadas” si cuando se aumentan los valores de una variable, los valores de la otra tienden a:

- i) aumentar y se dice que la asociación o dependencia es directa o que la correlación es positiva.
- ii) disminuir y se dice que la asociación o dependencia es inversa o que la correlación es negativa.

Cuando no se presenta esta tendencia se dice que las variables no están asociadas, no son dependientes o no están correlacionadas.

La asociación, correlación o dependencia estadística no implica relación causa-efecto. En otras palabras, si cuando una variable aumenta la otra tiende a aumentar (o a disminuir) no es posible afirmar que esta última aumenta (o disminuye) **porque** la primera variable aumenta.

#### Indicadores de Asociación: Covarianza

La covarianza entre dos variables  $X$  e  $Y$  está dada por:

$$\text{cov}(X, Y) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

o equivalentemente (se sugiere demostrar)

$$\text{cov}(X, Y) = \frac{1}{n} \sum_{i=1}^n x_i \cdot y_i - \bar{x}\bar{y}$$

La covarianza es una medida de asociación lineal, pero tiene la desventaja de que su interpretación depende de las unidades de medición. Por lo tanto, su interpretación será en cuanto a su signo:

Si  $\text{cov}(X, Y) > 0$ , la asociación es directa o positiva.

Si  $\text{cov}(X, Y) < 0$ , la asociación es inversa o negativa.

Si  $\text{cov}(X, Y) \approx 0$ , no hay asociación lineal.

#### Indicadores de Asociación: Correlación

La correlación lineal entre dos variables se define como

$$\text{corr}(X, Y) = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}}$$



Una fórmula alternativa para calcular correlación es

$$\text{corr}(X, Y) = \frac{\sigma_{XY}}{\sigma_X \cdot \sigma_Y}$$

donde  $\sigma_X$  y  $\sigma_Y$  son las desviaciones estándar de  $X$  e  $Y$ , respectivamente, y  $\sigma_{XY}$  es la covarianza entre  $X$  e  $Y$ .

Podemos también abordar este concepto desde el punto de vista geométrico. Sean los vectores

$$\begin{aligned}\vec{x} &= (x_1 - \bar{x}, x_2 - \bar{x}, \dots, x_n - \bar{x}) \\ \vec{y} &= (y_1 - \bar{y}, y_2 - \bar{y}, \dots, y_n - \bar{y})\end{aligned}$$

Entonces

$$\text{corr}(X, Y) = \frac{\vec{x} \cdot \vec{y}}{\|\vec{x}\| \cdot \|\vec{y}\|}$$

que corresponde al producto interno entre los vectores, y por lo tanto la correlación corresponde al coseno del ángulo entre  $\vec{x}$  e  $\vec{y}$ .


De lo anterior se desprende que  $|\text{corr}(X, Y)| \leq 1$ , y

Si  $\text{corr}(X, Y) = 1$ , la correlación es la máxima correlación positiva o directa.

Si  $\text{corr}(X, Y) = -1$ , la correlación es la máxima correlación negativa o inversa.

Si  $\text{corr}(X, Y) \approx 0$ , no existe correlación o dependencia.

Si bien no existe una regla general para decir si una correlación es alta, media o baja, en este curso podemos adoptar el siguiente criterio:



## Ejercicios 6

1. Consideremos los siguientes datos, donde  $X$  indica la temperatura media diaria medida en grados Fahrenheit, e  $Y$  que corresponde al consumo diario correspondiente de gas natural, medido en pies cúbicos.

|                |     |     |     |     |     |     |     |
|----------------|-----|-----|-----|-----|-----|-----|-----|
| $X, F^{\circ}$ | 50  | 45  | 40  | 38  | 32  | 40  | 55  |
| $Y, ft^3$      | 2.5 | 5.0 | 6.2 | 7.4 | 8.3 | 4.7 | 1.8 |

Realice un diagrama de dispersión y calcule el coeficiente de correlación  $\rho_{X,Y}$  si además cuenta con las siguientes medidas de resumen:

$$\sum_{i=1}^7 x_i = 300; \quad \sum_{i=1}^7 y_i = 35,9; \quad \sum_{i=1}^7 x_i^2 = 13218; \quad \sum_{i=1}^7 y_i^2 = 218,67; \quad \sum_{i=1}^7 x_i y_i = 1431,8$$

2. Considere los siguientes datos donde  $X$  representa el número de sucursales que 10 bancos diferentes tienen en un área metropolitana, e  $Y$  es la correspondiente cuota del total de depósitos mantenidos por los bancos.

|     |      |      |      |      |      |     |     |     |     |     |
|-----|------|------|------|------|------|-----|-----|-----|-----|-----|
| $X$ | 198  | 186  | 116  | 89   | 120  | 109 | 28  | 58  | 34  | 31  |
| $Y$ | 22.7 | 16.6 | 15.9 | 12.5 | 10.2 | 6.8 | 6.8 | 4.0 | 2.7 | 2.8 |

- a) Construya un diagrama de dispersión entre  $X$  e  $Y$ .  
 b) Calcule covarianza y correlación.

### 2.3.4. Ajuste de Curvas


Dado un par de variables  $(X, Y)$  que suponemos relacionadas, queremos encontrar una curva (también llamada modelo) que se ajuste de la mejor manera a la distribución de los datos. La curva está definida en forma paramétrica y se deben encontrar los valores de sus parámetros para hacer que alguna medida de error se minimice.

#### Ajuste Lineal

También conocido como regresión lineal simple, tiene por objeto construir una recta que describa la relación entre dos variables con alta asociación lineal. En algunos casos también es de interés predecir valores futuros de  $Y$  dados los valores de  $X$ .

Supongamos que un diagrama de dispersión de los datos  $(x_i, y_i)$  indica una relación lineal entre las variables  $X$  e  $Y$  o, alternativamente, que el coeficiente de correlación es cercano a 1 o -1. Entonces, el siguiente paso es encontrar la recta  $L$  que en algún sentido ajuste los datos.

Observemos el siguiente gráfico:



Estos datos presentan un coeficiente de correlación de 0.92 y debemos determinar la ecuación de la recta que “mejor se ajuste”.

En teoría, podríamos decir que

$$y_i = a + bx_i + \epsilon_i, \quad \forall i$$

donde lo que hacemos es descomponer el valor  $y_i$  en una parte “fija”  $(a + bx_i)$  y una parte “aleatoria”,  $\epsilon_i$ . Esta última se puede interpretar como la diferencia entre el valor que observamos y lo que esperaríamos observar,  $\epsilon_i = y_i - (a + bx_i)$ , llamando a esta cantidad error. Desde el punto de vista geométrico, este error es la distancia entre la recta planteada y el valor observado.

Como en todo proceso, queremos que el error (o la suma de las distancias de nuestras observaciones a la recta) sea mínimo, por lo que la recta debiera pasar lo más cerca posible de todos los puntos. Así, los coeficientes de la recta se obtienen mediante un proceso de optimización, llamado **mínimos cuadrados ordinarios** que determina los valores de  $a$  y  $b$  que minimizan la distancia de los valores observados a la recta.

$$\hat{a} = \bar{y} - \hat{b}\bar{x}, \quad \hat{b} = \text{Corr}(X, Y) \cdot \frac{\sigma_Y}{\sigma_X} = \frac{\text{Cov}(X, Y)}{\sigma_X^2}$$

En general, el ajuste lineal simple lo podemos plantear como la recta :

$$\hat{y}_i = \hat{a} + \hat{b}x_i, \quad i = 1, \dots, n. \quad (2.1)$$

donde

$\hat{y}_i$  : es el valor ajustado de la variable respuesta o dependiente para el individuo  $i$ ;

$x_i$  : es la variable explicativa o independiente para el individuo  $i$ ,

$\hat{a}$  : representa el intercepto con el eje Y y se interpreta como el valor que toma  $y$  cuando  $x=0$ .

$\hat{b}$  : representa la pendiente de la recta y se interpreta como la cantidad que aumenta(disminuye)  $y$  cuando  $x$  aumenta(disminuye) en una unidad.

## Ejercicios 7

1. Considere los datos del ejercicio 5.1 y encuentre la recta que se ajusta a los datos.
2. Considere los datos del ejercicio 5.2 y encuentre la recta que se ajusta a los datos.
3. Un gerente de una empresa automotriz piensa que si aumentan el porcentaje de comisión pagada al vendedor de automóviles, aumenta la venta. Para verificar este supuesto se realizó un estudio sobre 13 concesionarios similares. Sean  
 $X$ : Comisiones pagadas a vendedores de autos en un mes (%)  
 $Y$ : Ganancias netas por ventas, en el mismo mes (Millones de \$)

| Obs | 1    | 2    | 3    | 4    | 5    | 6    | 7   | 8    | 9   | 10   | 11   | 12   | 13   |
|-----|------|------|------|------|------|------|-----|------|-----|------|------|------|------|
| $X$ | 3.6  | 5.2  | 5.3  | 7.3  | 5.0  | 5.2  | 3.0 | 3.1  | 3.2 | 7.5  | 8.3  | 6.1  | 4.9  |
| $Y$ | 11.3 | 14.7 | 18.5 | 20.0 | 12.4 | 15.4 | 9.6 | 11.3 | 8.1 | 27.9 | 24.6 | 18.8 | 13.9 |

Realice un gráfico de dispersión, calcule covarianza y correlación. ¿Se cumple el supuesto del gerente?

Algunas veces el diagrama de puntos no indica una relación lineal entre las variables  $X$  e  $Y$  pero se podrá observar alguna otra curva típica y bien conocida  $Y = f(X)$  la que puede aproximar los datos y se conoce como *curva de aproximación*. Algunas de esas curvas típicas son las siguientes:

## Ajuste Exponencial

Si entre  $\log(y)$  y  $x$  observamos una relación lineal, usaremos una curva exponencial del tipo:

$$y_i = ae^{bx_i}, \quad i = 1, \dots, n.$$

Este ajuste se puede reducir a una regresión lineal de la siguiente forma

$$\log(y_i) = a' + b'x_i, \quad i = 1, \dots, n.$$

donde

$$a' = \log(a)$$

$$b' = b$$

## Ajuste Polinomial

En este caso lo que hacemos es ajustar la relación entre  $x$  e  $y$  a través de un polinomio de grado  $p$ :

$$y_i = \beta_0 + \beta_1 x_i + \beta_2 x_i^2 + \beta_3 x_i^3, \dots, \beta_p x_i^p \quad i = 1, \dots, n.$$

Al incluir potencias de  $X$  logramos mayor flexibilidad en el modelo.

Si  $p=1$ , estamos en el caso de regresión lineal.

Si  $p=2$ , la regresión se llama cuadrática.

## Otros Ajustes

### Hipérbola

Si entre  $1/y$  y  $x$  observamos una relación lineal usaremos la hipérbola:

$$y = \frac{1}{a + bx} \quad o \quad \frac{1}{y} = a + bx$$

### Potencial

Si entre  $\log(y)$  y  $\log(x)$  observamos una relación lineal usaremos la curva potencial:

$$y = ax^b \quad o \quad \log(y) = \log(a) + b \cdot \log(x)$$

---

# PROBABILIDADES

## 3.1. INTRODUCCIÓN

En el estudio de la estadística interesa, básicamente, la presentación e interpretación de resultados aleatorios que se dan en un estudio planeado o en una investigación científica. Por ejemplo, es posible registrar el número de accidentes que ocurren mensualmente en una determinada intersección de calles, con el propósito de justificar la instalación de un semáforo, clasificar los artículos que salen de una línea de ensamble como “defectuosos” o “no defectuosos”, o bien, conocer el volumen de gas que se libera durante una reacción química cuando la concentración de un ácido varía. Es por esto que surge la necesidad de contar con datos experimentales, que representan la ocurrencia de un fenómeno, mediciones, o tal vez datos que puedan clasificarse de acuerdo con algún criterio.

Necesitamos entonces una forma matemática para cuantificar la incertidumbre. Esta forma es la que llamaremos modelos no determinísticos o probabilísticos.

## 3.2. MÉTODOS DE CONTEO

Uno de los problemas que deberemos considerar e intentar evaluar es el elemento de aleatoriedad que se asocia a la ocurrencia de ciertos eventos cuando se lleva a cabo un experimento. En muchos casos debe tenerse la capacidad de resolver un problema de probabilidad mediante el conteo del número de casos posibles sin realmente anotar cada uno de ellos.<sup>1</sup> Para esto, se presentan métodos de conteo que pueden ser utilizados en ciertos escenarios.

**Teorema 3.2.1 (Principio Aditivo)** *Si una operación puede realizarse de  $n_1$  formas y una segunda operación puede realizarse de  $n_2$  formas, y no es posible que ambas operaciones se hagan juntas. Entonces el número de maneras que se puede hacer la primera o la segunda operación es  $n_1 + n_2$ .*

**Ejemplo 3.2.1** *Si se lanza un dado o una moneda, hay 6 resultados posibles para el dado y 2 posibles resultados para la moneda, por lo que si se lanza sólo uno de los dos, habrá en total 8 posibles resultados.*

Lo anterior puede extenderse a la realización de  $k$  operaciones distintas, cada una de ellas se puede llevar a cabo de  $n_k$  formas, entonces el número de maneras como podemos hacer la operación 1, o la operación 2, ..., o la operación  $k$  es  $n_1 + n_2 + \dots + n_k$ .

**Teorema 3.2.2** *Si una operación puede realizarse de  $n_1$  formas, y si por cada una de éstas una segunda operación puede llevarse a cabo de  $n_2$  formas, entonces las dos operaciones pueden realizarse juntas de  $n_1 n_2$  formas.*

**Ejercicios 8** *¿Cuál es el número total de resultados posibles al lanzar un dado dos veces?*

**Teorema 3.2.3 (Principio Multiplicativo)** *Si una operación puede realizarse de  $n_1$  formas, y si por cada una de éstas puede efectuarse una segunda en  $n_2$  formas, y para cada una de las dos primeras se puede efectuar una tercera de  $n_3$  formas, y así sucesivamente, entonces la secuencia de  $k$  operaciones pueden realizarse de  $n_1 n_2 \dots n_k$  formas.*

### Ejercicios 9

1. *¿Cuántos menús que consisten de sopa, postre y bebida existen si se puede seleccionar entre 4 sopas diferentes, 5 clases de postres y 4 bebidas?*
2. *¿Cuántos números pares de tres dígitos pueden formarse con los dígitos 1, 2, 5, 6 y 9?*

Con frecuencia interesará un conjunto que contiene como elementos todos los posibles órdenes o arreglos de un grupo de objetos. Por ejemplo, se puede desear conocer cuántos arreglos diferentes son posibles para sentar a 6 personas alrededor de una mesa, o bien, cuántas formas diferentes existen de tomar 5 ramos de un total de 8.

**Definición 3.2.1** *Una **permutación** es un arreglo de todo, o parte de, un conjunto de objetos.*

Considérense las tres letras a, b y c. Las permutaciones posibles son  $abc$ ,  $acb$ ,  $bca$ ,  $cab$ ,  $bac$  y  $cba$ . Se puede ver que hay 6 distintos arreglos. Con el principio multiplicativo se puede llegar a que la respuesta es 6 sin escribir todas las posibles combinaciones. Hay  $n_1 = 3$  posibilidades para la primera posición, después  $n_2 = 2$  para la segunda y únicamente  $n_3 = 1$  posibilidades para la última, lo que da un total

<sup>1</sup>Esta sección corresponde al capítulo 1 del libro *Probabilidad y Aplicaciones Estadísticas* de Paul Meyer.

de  $n_1 n_2 n_3 = 3 \cdot 2 \cdot 1 = 6$  permutaciones.

En general, se pueden acomodar  $n$  objetos distintos en  $n \cdot (n-1) \cdot (n-2) \cdot \dots \cdot (3) \cdot (2) \cdot (1)$  formas. Este producto se representa por el símbolo  $n!$ , que se lee “ $n$  factorial”. Por definición,  $1! = 1$  y  $0! = 1$ . Además, recordar que  $n! = (n-1)! \cdot n$ .

Una de las definiciones importantes de este capítulo se enuncia a continuación:

**Teorema 3.2.4** *El número de permutaciones de  $n$  distintos objetos es  $n!$*

El número de permutaciones de las cuatro letras  $a, b, c$  y  $d$  será de  $4! = 24$ .

Considérese ahora el número posible de ellas al tomar las cuatro letras, pero de dos a la vez. Serían  $ab, ad, ac, ba, ca, bc, cb, bd, db, cd, dc$ . De manera similar a como vimos antes, ahora se tienen dos posiciones para llenar con la  $n_1 = 4$  posibilidades para la primera y, por lo tanto,  $n_2 = 3$  posibilidades para la segunda, para un total de  $n_1 n_2 = 4 \cdot 3 = 12$  permutaciones. En general,  $n$  objetos distintos, si se toman  $r$  a la vez, pueden acomodarse en  $n \cdot (n-1) \cdot (n-2) \cdot \dots \cdot (n-r+1)$  formas.

**Teorema 3.2.5** *El número de permutaciones de  $n$  objetos distintos tomando  $r$  a la vez, es:*

$${}_n P_r = \frac{n!}{(n-r)!}$$

**Ejercicios 10** *¿De cuántas maneras se puede jugar Loto y obtener 3 puntos?*

Las permutaciones que se dan al acomodar objetos en un círculo se llaman **permutaciones circulares**. Dos de éstas no se consideran diferentes a menos que a los objetos correspondientes en los dos arreglos les preceda o les siga un objeto diferente al avanzar en el sentido de las manecillas del reloj. Por ejemplo, si 4 personas juegan a las cartas, no se tiene una nueva permutación si todas se mueven una posición en esa dirección. Al considerar a una en un lugar fijo y acomodar a las otras tres en  $3!$  formas diferentes, se encuentra que hay 6 acomodados distintos para el juego de cartas.

**Teorema 3.2.6** *El número de permutaciones de  $n$  objetos distintos agregados en un círculo es  $(n-1)!$*

Hasta ahora se han considerado permutaciones de objetos diferentes. Esto es, todos los objetos eran distintos o totalmente distinguibles. Si consideramos la palabra  $OSO$ , entonces las 6 permutaciones de las letras de esta palabra son  $O_1 S O_2, O_1 O_2 S, S O_1 O_2, O_2 S O_1, O_2 O_1 S, S O_2 O_1$ , por lo que únicamente tres son distintas. Por lo tanto, con tres letras, siendo dos iguales, se tienen  $3!/2! = 3$  diferentes permutaciones.

**Teorema 3.2.7** *El número de permutaciones diferentes de  $n$  objetos de los cuales  $n_1$  son de un tipo,  $n_2$  son de un tipo, ...,  $n_k$  de un  $k$ -ésimo tipo, es:*

$$\frac{n!}{n_1! n_2! \cdots n_k!}$$

**Ejercicios 11** *¿De cuántas formas diferentes pueden acomodarse 3 ampolletas rojas, 4 amarillas y 2 azules en un panel con 9 espacio para 9 luces?*



Con frecuencia interesa el número de formas en que se pueden repartir  $n$  objetos en  $r$  subconjuntos llamados **celdas**. La partición se logra si la intersección de cada par posible de  $r$  subconjuntos es el conjunto vacío y si la unión de todos los subconjuntos da como resultado el conjunto original. No importa el

**Teorema 3.2.8** *El número de formas de partir un conjunto de  $n$  objetos en  $r$  celdas con  $n_1$  elementos en la primera celda,  $n_2$  elementos en la segunda, y así sucesivamente, es:*

$$\binom{n}{n_1 n_2 \cdots n_r} = \frac{n!}{n_1! n_2! \cdots n_r!}$$

donde  $n_1 + n_2 + \cdots + n_r = n$

**Ejercicios 12** ¿De cuántas formas distintas pueden 7 científicos acomodarse en un laboratorio para tres personas y dos laboratorios para dos personas?

En muchos problemas interesa el número de formas posibles de *seleccionar*  $r$  objetos de un total de  $n$  sin importar el orden. Estas selecciones se llaman **combinaciones**. Una combinación es realmente una partición en dos celdas, una de las cuales contiene los  $r$  objetos que se seleccionaron y la otra, los  $(n - r)$  objetos restantes.

**Teorema 3.2.9** *El número de combinaciones de  $n$  objetos distintos, tomando  $r$  a la vez, es*

$$\binom{n}{r} = \frac{n!}{r!(n - r)!}$$

**Ejemplo 3.2.2** Encuentre el número de comités que pueden formarse con 4 químicos y 3 físicos y que comprendan 2 químicos y 1 físico.

Algunas propiedades de la combinatoria

$$\begin{aligned} a) \quad \binom{n}{k} &= \binom{n}{n - k} \\ b) \quad \binom{n + 1}{k + 1} &= \binom{n}{k} + \binom{n}{k + 1} \end{aligned}$$

**Ejemplo 3.2.3** Un naípe contiene cuatro pintas distintas, cada una con 13 números distintos, lo que da un total de 52 cartas. Un experimento consiste en sacar diez cartas al azar del naípe. A esta selección de 10 cartas la llamaremos “juego”.

- Si la extracción es hecha con reemplazo, determinar el número de juegos en que no hayan dos cartas con el mismo valor numérico.
- Si la extracción es hecha sin reemplazo, determinar el número de juegos en que al menos nueve cartas sean de la misma pinta.

### Desarrollo:

- a) El experimento  $E$  corresponde a sacar 10 cartas de un naipe, con reemplazo.

Por cada número hay 4 opciones y debemos escoger 10 números, por lo tanto hay en total  $4^{10} \times \binom{13}{10}$  juegos donde no hay dos cartas con el mismo valor numérico.

- b) En este caso el experimento  $E$  corresponde a sacar 10 cartas de un naipe, sin reemplazo. Hay  $\binom{4}{1}$  maneras de escoger una pinta para un número en particular, por lo tanto hay

$$\binom{4}{1} \cdot \binom{13}{9} \cdot \binom{39}{1} + \binom{4}{1} \cdot \binom{13}{10} \cdot \binom{39}{0}$$

juegos distintos donde se obtienen al menos nueve cartas de la misma pinta.

### **Ejercicios 13** Considerando los teoremas anteriores, desarrolle los siguientes ejercicios:

- Si un experimento consiste en lanzar un dado y después seleccionar aleatoriamente una letra del alfabeto, ¿cuáles son los posibles resultados?
- Un estudiante debe responder siete de las diez preguntas de un examen. De cuántas formas puede hacer su elección si:
  - No hay ninguna restricción
  - Debe contestar las dos primeras preguntas
  - Debe responder al menos cuatro de las seis primeras preguntas
- En una caja hay 12 libros de historia, 15 libros de matemáticas y 17 libros de química. Se deben disponer en un librero linealmente y para ello se ha determinado que se escogerán 7 libros de historia, 5 de matemáticas y 6 de química. Considere que todos los libros son distintos entre sí. ¿De cuántas formas se pueden disponer en el librero?
  - Sin restricciones.
  - Si están juntos por temas: los de matemáticas juntos, los de química juntos y los de historia juntos.
  - Si están juntos por temas y primero los de matemáticas, luego los de química y finalmente los de historia.
  - Si están juntos por temas y primero los de matemáticas, luego los de química y finalmente los de historia y además dentro de esos grupos ordenados por abecedario de los nombres de los autores.
- ¿De cuántas formas pueden plantarse, a lo largo de la línea divisoria de una propiedad, 3 robles, 4 pinos y 2 arces, si uno no distingue entre los árboles de la misma clase?

### 3.3. MODELO DE PROBABILIDAD

Utilizaremos la palabra **experimento**,  $E$ , para describir cualquier proceso que genere un conjunto de datos. Un ejemplo muy simple de un experimento consiste en el lanzamiento de una moneda al aire. En este caso sólo existen dos resultados posibles: cara o sello. Otro experimento podría ser el lanzamiento de un proyectil y la observación de su velocidad en un período de tiempo. Las opiniones de los votantes respecto de un candidato a alcalde también pueden considerarse como observaciones de un experimento. Aquí interesan particularmente las observaciones que se obtienen en la repetición de un experimento. En la mayor parte de los casos los resultados dependerán del azar y, por lo tanto, no pueden pronosticarse con certidumbre. Si un químico realiza varias veces un análisis bajo las mismas condiciones y obtiene diferentes mediciones, ello indica la existencia de un elemento de aleatoriedad en el procedimiento experimental. Incluso cuando una moneda se lanza al azar repetidamente, no es posible garantizar que en un lanzamiento dado se obtendrá como resultado una cara. No obstante, sí se conoce el conjunto completo de posibilidades para cada lanzamiento.

#### 3.3.1. Espacio Muestral

**Definición 3.3.1** *Al conjunto de todos los resultados posibles de un experimento estadístico se le llama **espacio muestral** y se representa por la letra  $\Omega$ .*

A cada resultado en un espacio muestral se le llama **elemento** del espacio muestral o simplemente **punto muestral** y se denotan en general por la letra  $\omega$ .

**Ejercicios 14** *Determine el espacio muestral del siguiente experimento: se lanza una moneda y, si sale cara, se lanza un dado y se observa el resultado. Si sale sello, se lanza otra vez la moneda y se observa el resultado.*

#### 3.3.2. Eventos

**Definición 3.3.2** *Un **evento**  $A$ , respecto a un espacio muestral  $\Omega$ , asociado a un experimento  $E$ , es un subconjunto de resultados posibles.*

Es claro que  $\Omega$  en sí mismo es un evento y también lo es el conjunto vacío. Cualquier resultado individual también puede considerarse como un evento.

**Definición 3.3.3** *El **complemento** de un evento  $A$  con respecto a  $\Omega$  es el conjunto de todos los elementos de  $S$  que no están en  $A$ , es decir, es el suceso que se da si  $A$  no ocurre. Denotamos el complemento de  $A$  por el símbolo  $A^c$ , también escrito  $\bar{A}$ .*

**Definición 3.3.4** *La **intersección** de dos eventos  $A$  y  $B$ ,  $A \cap B$ , es el evento que contiene a todos los elementos comunes a  $A$  y a  $B$ , es decir, es el evento que ocurre si  $A$  y  $B$  ocurren simultáneamente.*

**Definición 3.3.5** *Dos eventos  $A$  y  $B$  son **mutuamente excluyentes** o **disjuntos** si  $A \cap B = \emptyset$ , esto es, si  $A$  y  $B$  no tienen elementos comunes.*

**Definición 3.3.6** *La **unión** de los dos eventos  $A$  y  $B$ ,  $A \cup B$  es el evento que contiene a todos los elementos que pertenecen a  $A$ , o a  $B$  o a ambos, es decir, al menos uno de ellos ocurre.*

**Ejemplo 3.3.1** Sean  $A$  y  $B$  eventos aleatorios. Sea  $C$  el evento en que ocurre  $A$  y  $B$  pero no ambos simultáneamente. Expresa  $C$  en términos de  $A$  y  $B$  utilizando cualquiera de las operaciones básicas de unión, intersección y complemento.

El evento pedido puede escribirse como

$$C = (A \cap B^c) \cup (A^c \cap B)$$

## Ejercicios 15

1. Sea el experimento  $E$  lanzar un dado y observar el número que sale, y sean los eventos:

- A: sale un número par.
- B: sale un número impar.
- C: sale un número primo.

Determinar el espacio muestral y los elementos de los siguientes conjuntos:

- a)  $A \cup C$
- b)  $B \cap C$
- c)  $C^c$

2. Sean tres eventos  $A$ ,  $B$  y  $C$ . Encuentre expresiones para los siguientes eventos en lenguaje de conjuntos.

- a) Sólo ocurre  $A$ .
- b) Ocurren tanto  $B$  como  $C$ , pero no así  $A$ .
- c) Los tres eventos ocurren.
- d) Ninguno de los tres eventos ocurre.
- e)  $A$  lo más dos de ellos ocurren.
- f) Al menos dos de los eventos ocurren.
- g) Al menos uno de los eventos ocurre.
- h) Exactamente dos de ellos ocurren.

Las siguientes dos definiciones son necesarias para la teoría planteada en lo sucesivo, pero no son el objetivo de este curso.

**Definición 3.3.7** Sea  $\mathcal{A}$  la clase de eventos (aleatorios) de  $\Omega$ .  $\mathcal{A}$  es un  $\sigma$ -álgebra de subconjuntos de  $S$  (no vacío) si:

- i)  $S \in \mathcal{A}$
- ii)  $A \in \mathcal{A} \rightarrow A^c \in \mathcal{A}$
- iii)  $A_1, A_2, \dots \in \mathcal{A} \rightarrow \bigcup_{i=1}^{\infty} A_i \in \mathcal{A}$

Nota:  $(\Omega, \mathcal{A})$  se llama **espacio medible**.

**Definición 3.3.8** Se llama  $\sigma$ -álgebra de Borel, y se denota por  $\mathcal{B}$ , al conjunto generado por  $\{(-\infty, a] : a \in \mathbb{R}\}$  a través de uniones, intersecciones y complementos. FALTA

### 3.3.3. Medida de Probabilidad

Finalmente, dado un  $\sigma$ -álgebra  $\mathcal{A}$  de eventos de  $\Omega$ , para concretar nuestro modelo debemos introducir una medida de probabilidad sobre  $(\Omega, \mathcal{A})$ .

**Definición 3.3.9** Una *medida de probabilidad*  $\mathbf{P}$  sobre  $(\Omega, \mathcal{A})$  es una función

$$\mathbf{P} : \mathcal{A} \rightarrow [0, 1]$$

tal que cumple con los siguientes tres axiomas de Kolmogorov:

A1.  $\mathbf{P}(A) \geq 0 \quad \forall A \in \mathcal{A}.$

A2.  $\mathbf{P}(\Omega) = 1$

A3. Si  $A_1, A_2, \dots \in \mathcal{A}$  son disjuntos dos a dos, entonces

$$\mathbf{P}\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i)$$

$(\Omega, \mathcal{A}, \mathbf{P})$  se llama *modelo de probabilidad*.

**Lema 1** Sea  $(\Omega, \mathcal{A}, \mathbf{P})$  un modelo de probabilidad. Entonces valen las siguientes propiedades:

a)  $\mathbf{P}(\emptyset) = 0$

b) Si  $A_1, \dots, A_n \in \mathcal{A}$  son disjuntos dos a dos, entonces

$$\mathbf{P}\left(\bigcup_{i=1}^n A_i\right) = \sum_{i=1}^n P(A_i)$$

Dado un modelo de probabilidad  $(\Omega, \mathcal{A}, \mathbf{P})$  se desprenden de los axiomas de probabilidad las siguientes propiedades:

a)  $\mathbf{P}(A^c) = 1 - \mathbf{P}(A)$

b)  $A \subseteq B \rightarrow \mathbf{P}(A) \leq \mathbf{P}(B)$

c)  $\mathbf{P}(A \cup B) = \mathbf{P}(A) + \mathbf{P}(B) - \mathbf{P}(A \cap B)$

d)  $\mathbf{P}\left(\bigcup_{i=1}^{\infty} A_i\right) \leq \sum_{i=1}^{\infty} \mathbf{P}(A_i)$

La demostración de estas propiedades queda como ejercicio para los alumnos.

## Ejercicios 16

1. Un espacio muestral  $\Omega$  se compone de cuatro elementos, es decir,  $S = \{a_1, a_2, a_3, a_4\}$ . ¿Bajo cuáles de las siguientes funciones  $S$  podría ser un espacio probabilístico?

a)

$$\mathbf{P}(a_1) = 1/2 \quad \mathbf{P}(a_2) = 1/3 \quad \mathbf{P}(a_3) = 1/4 \quad \mathbf{P}(a_4) = 1/5$$

b)

$$\mathbf{P}(a_1) = 1/2 \quad \mathbf{P}(a_2) = 1/4 \quad \mathbf{P}(a_3) = 1/4 \quad \mathbf{P}(a_4) = 1/2$$

c)

$$\mathbf{P}(a_1) = 1/2 \quad \mathbf{P}(a_2) = 1/4 \quad \mathbf{P}(a_3) = 1/8 \quad \mathbf{P}(a_4) = 1/8$$

d)

$$\mathbf{P}(a_1) = 1/2 \quad \mathbf{P}(a_2) = -1/4 \quad \mathbf{P}(a_3) = 1/4 \quad \mathbf{P}(a_4) = 0$$

2. Supongamos que  $A$  y  $B$  son eventos con

$$\mathbf{P}(A) = 0,6; \quad \mathbf{P}(B) = 0,3 \quad \text{y} \quad \mathbf{P}(A \cap B) = 0,2$$

Hallar la probabilidad de que:

a)  $A$  no ocurra.

b)  $B$  no ocurra.

c)  $A$  o  $B$  ocurran.

d) Ni  $A$  ni  $B$  ocurran.

### 3.3.4. Espacios Probabilísticos Finitos

Consideremos un espacio muestral  $\Omega$  y la clase  $\mathcal{A}$  de todos los sucesos.  $\Omega$  se convierte en un espacio probabilístico asignando probabilidades a los sucesos de  $\mathcal{A}$  de tal forma que satisfaga los axiomas de probabilidad.

Supongamos que  $\Omega$  es un espacio muestral finito con  $n$  elementos y supongamos que las características físicas del experimento sugieren que a varios de los resultados se les asignen probabilidades iguales. Entonces,  $\Omega$  se convierte en un espacio probabilístico, llamado **espacio finito equiprobable**, si a cada punto se le asigna probabilidad  $1/n$ . Esto indica que si un suceso  $A$  contiene  $r$  elementos del espacio muestral, entonces la probabilidad de  $A$  es  $\frac{\#A}{n} = \frac{r}{n}$ , donde  $\#$  representa la cardinalidad del conjunto.

Por lo tanto,

$$\mathbf{P}(A) = \frac{\#(A)}{\#(\Omega)} = \frac{\text{casos favorables}}{\text{casos totales}}$$

**Teorema 3.3.1** Sea  $S$  un espacio muestral finito, y para cualquier  $A \in S$  sea

$$\mathbf{P}(A) = \frac{\#(A)}{\#(\Omega)}$$

entonces  $\mathbf{P}$  cumple los axiomas  $A1$ ,  $A2$  y  $A3$ .

**Ejercicios 17** Supongamos que se elige aleatoriamente a un estudiante de un grupo de 80, de los cuales 30 estudian matemáticas, 20 química y 10 ambas. Hallar la probabilidad que un estudiante está estudiando matemáticas o química.

Sea  $\Omega$  un espacio muestral finito, digamos  $\Omega = \{a_1, a_2, \dots, a_n\}$  un **espacio probabilístico finito**, o modelo probabilístico finito, se obtiene asignando a cada punto  $a_i$  de  $S$  un número real  $p_i$  llamado probabilidad de  $a_i$ , que cumple con las siguientes propiedades:

a) cada  $p_i$  es no negativo.

b) 
$$\sum_{i=1}^n p_i = 1$$

**Ejemplo 3.3.2** Un naipe contiene cuatro pintas distintas, cada una con 13 números distintos, lo que da un total de 52 cartas. Un experimento consiste en sacar diez cartas al azar del naipe. A esta selección de 10 cartas la llamaremos “juego”.

a) Si la extracción es hecha con reemplazo, calcule la probabilidad de que no hayan dos cartas con el mismo valor numérico.

b) Si la extracción es hecha sin reemplazo, calcule la probabilidad de que al menos nueve cartas sean de la misma pinta.

**Desarrollo:**

a) Sea  $A$  el evento “no hay dos cartas con el mismo valor numérico”, que es equivalente a decir que todas las cartas son de distinto número.

Como el experimento es con reemplazo  $\# \Omega = 52^{10}$ .

$$\# A = 4^{10} \times \binom{13}{10}$$

Entonces

$$\mathbf{P}(A) = \frac{1}{52^{10}} \cdot 4^{10} \cdot \binom{13}{10} = \left(\frac{4}{52}\right)^{10} \cdot \binom{13}{10}$$

b) Sea  $B$  el evento “al menos 9 cartas son de la misma pinta”. Como el experimento es sin reemplazo

$$\# \Omega = \binom{52}{10}$$

Entonces

$$\mathbf{P}(B) = \frac{\binom{4}{1} \cdot \binom{13}{9} \cdot \binom{39}{1} + \binom{4}{1} \cdot \binom{13}{10} \cdot \binom{39}{0}}{\binom{52}{10}}$$

**Ejemplo 3.3.3** Consideremos el experimento de extraer dos cartas de una baraja. ¿Cuál es la probabilidad de extraer dos reyes?

- a) Sin devolver la 1ª carta.
- b) Con devolución.

### Ejercicios 18

1. En un grupo de personas hay 25 hombres y 13 mujeres. Se sacan 12 personas al azar. Determinar la probabilidad que entre las doce personas hayan 6 hombres.
2. Un naipe inglés consta de 52 cartas agrupadas en cuatro pintas (corazón, pique, trébol y diamante) y 13 “números” (As, 2, ..., 9, 10, J, Q, K). Se eligen consecutivamente al azar y sin reemplazo cinco cartas de este naipe. Calcule las probabilidades de los siguientes eventos o sucesos:
  - a) Las primeras tres cartas son diamantes y las dos últimas son trébol.
  - b) Hay exactamente cuatro cartas del mismo “número”.
  - c) Hay tres cartas de un mismo “número” y dos de otro.



## 3.4. PROBABILIDAD CONDICIONADA E INDEPENDENCIA

### 3.4.1. Probabilidad Condicional

Al calcular la probabilidad de un evento  $A$  es posible que haya otros eventos que aporten información respecto a su probabilidad de ocurrencia. Por ejemplo, si queremos determinar la probabilidad de que un cliente se atrase en un pago, podríamos observar la magnitud de esta probabilidad entre quienes tienen antecedentes de atraso en el último año versus quienes no. Si estas probabilidades difieren, quiere decir que la ocurrencia del evento “antecedente de atraso en el último año” afecta de alguna manera<sup>2</sup> la ocurrencia del evento “atraso en el pago”.

**Definición 3.4.1** Supongamos que  $A, B$  son eventos de un espacio muestral  $\Omega$ . La **probabilidad condicional** que  $A$  ocurra dado que  $B$  ha ocurrido,  $\mathbf{P}(A | B)$ , se define como

$$\mathbf{P}(A | B) = \frac{\mathbf{P}(A \cap B)}{\mathbf{P}(B)}, \quad \mathbf{P}(B) > 0$$

si  $\mathbf{P}(B) = 0$  entonces diremos que  $\mathbf{P}(A | B) = 0$ .

$\mathbf{P}(A | B)$  mide en cierto modo la probabilidad relativa de  $A$  con respecto al espacio reducido de  $B$ .

**Teorema 3.4.1** Supongamos que  $\Omega$  es un espacio equiprobable, y que  $A$  y  $B$  son eventos. Entonces

$$\mathbf{P}(A | B) = \frac{\#(A \cap B)}{\#(B)}$$

es una medida de probabilidad.

**Ejemplo 3.4.1** En base a las definiciones anteriores resuelva lo siguiente:

1. Hallar  $\mathbf{P}(B | A)$  si:

- a)  $A$  es un subconjunto de  $B$ .
- b)  $A$  y  $B$  son mutuamente excluyentes. Asumimos que  $\mathbf{P}(A) > 0$ .

2. Se tiran un par de dados y se define

$A$ : salga 2 en al menos uno de los dados

$B$ : la suma es 6.

Encontrar  $\mathbf{P}(A | B)$  y  $\mathbf{P}(A)$

3. En un colegio hay 60 alumnos de enseñanza media. De ellos 40 estudian inglés, 24 estudian francés y 12 los dos idiomas. Se elige al azar un alumno. Determinar las probabilidades de los siguientes eventos:

- a) Estudia al menos un idioma.
- b) No estudia inglés o estudia francés.
- c) Estudia francés sabiendo que también estudia inglés.
- d) Estudia francés sabiendo que estudia algún idioma.
- e) Estudia inglés sabiendo que no estudia francés.

<sup>2</sup>No necesariamente hay una relación causal entre los eventos, ya que la causalidad debe definirse en el contexto de los sucesos en cuestión.

El siguiente teorema se desprende de la definición de probabilidad condicional:

**Teorema 3.4.2** (*Multiplicación para la probabilidad condicional*)

$$\mathbf{P}(A \cap B) = \mathbf{P}(B \mid A)\mathbf{P}(A)$$

que se puede extender también a más de dos eventos, por ejemplo

$$\mathbf{P}(A \cap B \cap C) = \mathbf{P}(C \mid A \cap B) \cdot \mathbf{P}(B \mid A) \cdot \mathbf{P}(A)$$

## Ejercicios 19

1. Un lote contiene 12 objetos de los cuales 4 son defectuosos. Se sacan tres objetos al azar del lote, uno detrás de otro. Hallar la probabilidad de que los tres no sean defectuosos.
2. Urna de Polya  
Una urna contiene  $a$  fichas azules y  $r$  fichas rojas. El experimento consiste en:
  - (i) Extraer una ficha y observar su color.
  - (ii) Devolver la ficha con  $t$  fichas adicionales del mismo color.
  - (iii) Seguir iterando.

Para tres extracciones defina:

$A_i$  : la  $i$ -ésima ficha es azul,  $i = 1, 2, 3$ .

Calcule  $\mathbf{P}(A_1 \cap A_2 \cap A_3)$ .

## 3.4.2. Independencia

**Definición 3.4.2** Los eventos  $A$  y  $B$  son *independientes* si

$$\mathbf{P}(A \cap B) = \mathbf{P}(A)\mathbf{P}(B),$$

de cualquier otra forma serían dependientes.

Esta definición nos lleva a concluir que  $A$  y  $B$  son eventos independientes si

$$\mathbf{P}(A \mid B) = \mathbf{P}(A) \quad \text{y} \quad \mathbf{P}(B \mid A) = \mathbf{P}(B)$$

Notar que:

1. Se dice que  $A_1, A_2, \dots, A_n \in \mathcal{A}$  son dos a dos independientes si y sólo si

$$\mathbf{P}(A_i \cap A_j) = \mathbf{P}(A_i) \cdot \mathbf{P}(A_j), \quad \forall i < j$$

2. Independencia dos a dos no implica que todos los eventos sean independientes entre si (independencia completa).
3. Si dos eventos  $A$  y  $B$  son independientes, entonces también lo serán sus complementos, esto es:  $A$  independiente de  $B^c$ ,  $A^c$  independiente de  $B$  y  $A^c$  independiente de  $B^c$ .

4. Sea  $C \in \mathcal{A}$  un evento tal que  $\mathbf{P}(C) > 0$ . Entonces  $A$  y  $B$  son condicionalmente independientes dado  $C$ , que se denota por  $A \perp B \mid C$  si y sólo si

$$\mathbf{P}(A \cap B \mid C) = \mathbf{P}(A \mid C) \cdot \mathbf{P}(B \mid C)$$

5. Observemos que los eventos disjuntos no son independientes a menos que uno de ellos tenga probabilidad cero. Es decir, supongamos  $A \cap B = \emptyset$  y  $A$  y  $B$  son independientes. Entonces

$$\mathbf{P}(A)\mathbf{P}(B) = \mathbf{P}(A \cap B) = 0$$

y, por lo tanto

$$\mathbf{P}(A) = 0 \quad \text{ó} \quad \mathbf{P}(B) = 0.$$

## Ejercicios 20

1. Demostrar que si  $A$  y  $B$  son eventos independientes, entonces  $A^c$  y  $B^c$  son eventos independientes.
2. Juan y Pedro juegan a obtener la puntuación más alta lanzando sus dados. El dado de Juan tiene cuatro caras con la puntuación 5 y las otras dos caras con el 1. El dado de Pedro tiene dos caras con el 6, otras dos con el 4 y las otras dos con el 1. Hallar:
  - a) La probabilidad de que gane Pedro.
  - b) La probabilidad de empatar.

Consideremos nuevamente el evento que ocurre cuando un cliente se atrasa en un pago. Si efectivamente la probabilidad de ocurrencia de este evento cambia cuando observamos a clientes que tienen “antecedente de atraso en el último año” y clientes que no, ¿cómo podemos determinar la probabilidad de que un cliente cualquiera se atrase en un pago? Esto requeriría considerar tanto a quienes tienen antecedentes de atraso y quienes no, ponderando de alguna manera las probabilidades en ambos grupos.

Antes de enunciar el teorema correspondiente, una definición necesaria:

**Definición 3.4.3** Una familia de eventos  $B_1, \dots, B_k \in \mathcal{A}$  se llama **partición** de  $\Omega$  si cumplen las siguientes dos condiciones:

$$\bigcup_{i=1}^k B_i = \Omega, \quad \text{y,} \quad B_i \cap B_j = \emptyset, \quad \forall i \neq j.$$

### Teorema 3.4.3 Probabilidad Total.

Supongamos que los eventos  $B_1, B_2, \dots, B_k$  forman una partición de  $\Omega$ . Entonces para cualquier evento  $A$  se tiene que

$$\mathbf{P}(A) = \sum_{i=1}^k \mathbf{P}(A \mid B_i) \mathbf{P}(B_i)$$

Recordemos que  $\sum_{i=1}^k \mathbf{P}(B_i) = 1$ , por lo que la “probabilidad total” corresponde a una suma ponderada de la probabilidad de ocurrencia de  $A$  dados los eventos  $B_i$ .

### Teorema 3.4.4 Teorema de Bayes.

Bajo las mismas condiciones del teorema anterior se tiene que

$$\mathbf{P}(B_i | A) = \frac{\mathbf{P}(A | B_i)\mathbf{P}(B_i)}{\sum_{j=1}^k \mathbf{P}(B_j)\mathbf{P}(A | B_j)}$$

**Ejemplo 3.4.2** Una caja contiene una moneda con dos caras, una moneda con dos sellos, y una moneda corriente con cara y sello. Se elige una moneda al azar, se lanza, y se observa que sale cara. ¿Cuál es la probabilidad de que la moneda elegida sea la de dos caras?

#### Desarrollo:

En primer lugar se definen los eventos de interés:

$M_1$ : se escoge la moneda con 2 caras.

$M_2$ : se escoge la moneda con 2 sellos.

$M_3$ : se escoge la moneda con 1 cara y 1 sello.

$C_1$ : sale cara en el primer lanzamiento.

Al realizar el experimento observamos como resultado una cara. Como se pide la probabilidad de que este resultado provenga de haber lanzado la moneda 1, se establece que corresponde a una probabilidad condicional. Se pide  $\mathbf{P}(M_1 | C_1)$  y ésta será calculada usando el teorema de Bayes. Primero, utilizamos el teorema de probabilidad total para calcular  $\mathbf{P}(C_1)$ .

$$\begin{aligned} \mathbf{P}(C_1) &= \mathbf{P}(C_1 | M_1) \cdot \mathbf{P}(M_1) + \mathbf{P}(C_1 | M_2) \cdot \mathbf{P}(M_2) + \mathbf{P}(C_1 | M_3) \cdot \mathbf{P}(M_3) \\ &= 1 \cdot \frac{1}{3} + 0 \cdot \frac{1}{3} + \frac{1}{2} \cdot \frac{1}{3} \\ &= \frac{1}{2} \end{aligned}$$

Con esto

$$\mathbf{P}(M_1 | C_1) = \frac{\mathbf{P}(C_1 | M_1) \cdot \mathbf{P}(M_1)}{\mathbf{P}(C_1)} = \frac{1 \cdot \frac{1}{3}}{\frac{1}{2}} = \frac{2}{3}$$

**Ejercicios 21** Utilizando los teoremas anteriores, resuelva los siguientes ejercicios:

1. Un estudiante cuenta, para un examen, con la ayuda de un despertador, el cual consigue despertarlo en un 80 % de los casos. Diremos que cuando el estudiante oye el despertador, se despierta. Si oye el despertador, la probabilidad de que realice el examen es 0,9 y, en caso contrario, de 0,5.
  - a) Si va a realizar el examen, ¿cuál es la probabilidad de que haya oído el despertador?
  - b) Si no realiza el examen, ¿cuál es la probabilidad de que no haya oído el despertador?

2. *En una ciudad el 40 % de la gente se considera conservadora (C), el 35 % liberales (L), y el 25 % independientes (I). Durante las elecciones votaron el 45 % de los conservadores, el 45 % de los liberales y el 60 % de los independientes. Si se elige un votante al azar, hallar la probabilidad de que el votante sea conservador, liberal o independiente.*
  
3. *Supongamos que tenemos las tres cajas siguientes:*  
*La caja A tiene 3 fichas rojas y 5 blancas.*  
*La caja B tiene 2 rojas y una blanca.*  
*La caja C tiene 2 rojas y 3 blancas.*  
*Se escoge una caja al azar, y una ficha de dicha caja. Si la ficha es roja, hallar la probabilidad de que sea de la caja A.*
  
4. *En una casa hay tres llaveros A, B y C; el primero con 5 llaves, el segundo con 7 y el tercero con 8, de las que sólo una de cada llavero abre la puerta del trastero. Se escoge al azar un llavero y, de él, una llave para intentar abrir el trastero. Se pide:*
  - a) *¿Cuál será la probabilidad de que se acierte con la llave?*
  - b) *¿Cuál será la probabilidad de que el llavero escogido sea el tercero y la llave no abra?*
  - c) *Si la llave escogida es la correcta, ¿cuál es la probabilidad de que pertenezca al primer llavero A?*
  
5. *En un concurso se dispone de cinco sobres, dos de ellos contienen premio y los otros tres no. Se pide a un primer concursante que escoja un sobre y observe si tiene premio, y a un segundo concursante que elija otro de los restantes y observe si tiene premio.*
  - a) *Escriba el conjunto de resultados posibles asociado a este experimento e indique la probabilidad de cada uno de ellos.*
  - b) *¿Qué probabilidad tiene el segundo concursante de obtener premio?*
  - c) *¿Cuál es la probabilidad de que ambos concursantes obtengan premio?*

## 3.5. VARIABLES ALEATORIAS

### 3.5.1. Introducción

Informalmente una variable aleatoria puede definirse como una función numérica sobre el espacio muestral  $\Omega$  como:

$$X : \Omega \rightarrow \mathbb{R}$$

$X$  es una función tal que asigna a cada  $\omega \in \Omega$  un número.

Usualmente, el recorrido de  $X$ ,  $\text{Rec}(X)$ , es un subconjunto de  $\mathbb{R}$ .

**Ejemplo 3.5.1** Sea  $\Omega = \{CC, CS, SC, SS\}$ , y sea la variable aleatoria definida por

$$X(\omega) = \text{número de caras}, \omega \in \Omega$$

¿Cuál es el recorrido de la variable aleatoria  $X$ ?

Para cada elemento de  $\Omega$  contamos el número de caras:

$$\begin{aligned} X(CC) &= 2, & X(CS) &= 1, \\ X(SC) &= 1, & X(SS) &= 0. \end{aligned}$$

Por lo tanto  $\text{Rec}(X) = \{0, 1, 2\}$

Si bien basta con la definición anterior para efectos de nuestros cursos, quienes quieran profundizar en la teoría de probabilidades pueden además considerar las siguientes dos definiciones formales:

**Definición 3.5.1** Dado un modelo de probabilidad  $(\Omega, \mathcal{A}, \mathbf{P})$ , diremos que una función

$$X : \Omega \rightarrow \mathbb{R}$$

es una **variable aleatoria** si y sólo si

$$\{\omega \in \Omega : X(\omega) \leq x\} \in \mathcal{A}, \forall x \in \mathbb{R}$$

**Definición 3.5.2** Sea  $S$  un espacio muestral con  $\sigma$ -álgebra  $\Sigma$  y  $\mathbb{R}$  con la  $\sigma$ -álgebra de Borel  $B$ . Se define una variable aleatoria  $X$  a la función  $X : S \rightarrow \mathbb{R}$  que satisface:

$$\forall B \in B : X^{-1}(B) \in \Sigma$$

con  $X^{-1}(B) = \{w \in S / X(w) \in B\}$

Notación: Si el valor de la variable aleatoria se denota por una letra minúscula, la variable se denota por la letra mayúscula correspondiente. Normalmente se utilizan las últimas letras del alfabeto.

El suceso “el valor  $x$  de  $X$  pertenece al conjunto  $B$ ” se denota por  $X \in B$ . Cuando  $B = \{x\}$  se simplifica la notación a  $\{X = x\}$ .

**Definición 3.5.3** Dada una variable aleatoria  $X$  definida en  $(\Omega, \mathcal{A}, \mathbf{P})$ , la **distribución de probabilidad** inducida por  $X$  en  $\mathbb{R}$  se define, para un evento  $B$  en la  $\sigma$ -álgebra de Borel  $\mathcal{B}$ , como:

$$\mathbf{P}_X(B) = \mathbf{P}(X^{-1}(B))$$

donde  $X^{-1}(B) = \{\omega \in \Omega : X(\omega) \in B\}$  es un evento en  $\Omega$ .

Conocer la distribución de probabilidad para un subconjunto  $B$  implica que podemos calcular  $\mathbf{P}_X$  para cualquier  $B \subset \mathbb{R}$  medible.

En general, cada  $B \subset \mathbb{R}$  medible puede generarse a partir de uniones y/o intersecciones de intervalos de la forma  $[a_n, b_n]$ . La colección de estos intervalos de la forma  $(a, b]$  genera una  $\sigma$ -álgebra en  $\mathbb{R}$  llamada  **$\sigma$ -álgebra de Borel** y denotada por  $\mathcal{B}$ . Los elementos de  $\mathcal{B}$  se llaman **Borelianos** y son subconjuntos medibles de  $\mathbb{R}$ .

$\mathbf{P}_X$  es una medida de probabilidad en  $(\mathbb{R}, \mathcal{B}) \rightarrow (\mathbb{R}, \mathcal{B}, \mathbf{P}_X)$ , inducida por la variable aleatoria  $X$ .

Luego de las definiciones formales, podemos decir que si  $X$  e  $Y$  son variables aleatorias entonces

- a)  $X + \alpha Y$  son variables aleatorias,  $\forall \alpha \in \mathbb{R}$ .
- b)  $|X|$  es una variable aleatoria.
- c)  $X \cdot Y$  es una variable aleatoria.

**Definición 3.5.4** La función definida por

$$\begin{aligned} F_X(x) &= \mathbf{P}_X((-\infty, x]) \\ &= \mathbf{P}(X \leq x), \quad x \in \mathbb{R} \end{aligned}$$

se llama **función de distribución de probabilidad acumulada**, *f.d.a.*, de la variable aleatoria  $X$ .

En general, en este capítulo denotaremos  $F_X$  simplemente por  $F$ , y en caso de que haya más de una variable aleatoria involucrada, diferenciaremos las funciones de probabilidad acumulada indicando a qué variable corresponde, por ejemplo,  $F_X$ ,  $F_Y$ , etc.

Conocer la función de probabilidad acumulada de una variable aleatoria  $X$  es suficiente para conocer el comportamiento aleatorio de  $X$ , es decir, nos permite conocer el valor de  $\mathbf{P}(X \in B)$ , para cualquier conjunto  $B$ .

Sea  $F(x)$ ,  $x \in \mathbb{R}$ , la función de probabilidad acumulada de  $X$ . Esta debe cumplir que

- 1.) Si  $x_1 < x_2$ , entonces  $F(x_1) \leq F(x_2)$ , es decir, la función  $F$  es no decreciente en  $\mathbb{R}$ .
- 2.)  $\lim_{x \rightarrow -\infty} F(x) = 0$ , y  $\lim_{x \rightarrow \infty} F(x) = 1$ , que sumado a lo anterior indica que  $0 \leq F(x) \leq 1$ ,  $\forall x \in \mathbb{R}$ .
- 3.)  $\lim_{x \rightarrow x_0^+} F(x) = F(x_0)$ ,  $\forall x_0 \in \mathbb{R}$ . Esto quiere decir que la función  $F$  es continua por la derecha.

### 3.5.2. Variables Aleatorias Discretas

Sea  $X : \Omega \rightarrow \mathbb{R}$  una variable aleatoria, diremos que es una variable aleatoria discreta si y sólo si  $\text{Rec}(X)$  es de cardinalidad finita o a lo más numerable.

En este caso,  $F(x), x \in \mathbb{R}$ , puede representarse como:

$$F(x) = \sum_{t \leq x} \mathbf{P}(X = t)$$

donde  $\mathbf{P}(X = k), k \in \mathbb{R}$ , se llama **función de distribución de probabilidad** o **función de cuantía**.

Sigue de la definición de  $\mathbf{P}(X = k)$ , que:

- i)  $\mathbf{P}(X = k) \geq 0, \quad \forall k \in \mathbb{R}.$
- ii)  $\sum_{k \in \mathbb{R}} \mathbf{P}(X = k) = 1$
- iii)  $\mathbf{P}_X(B) = \mathbf{P}(X \in B) = \sum_{k \in B} \mathbf{P}(X = k)$

### Ejercicios 22

- 1) Considere un estuche con 5 lápices rojos, 3 azules y 2 verdes. Se definen las siguientes variables aleatorias:

$X_1$  : número de lápices azules al extraer 5 lápices, con reposición.

$X_2$  : número de lápices azules al extraer 5 lápices, sin reposición.

$X_3$  : números de extracciones necesarias hasta obtener el primer lápiz rojo.

$X_4$  : número de extracciones necesarias hasta obtener el tercer lápiz verde, con reposición.

- a) Determine la función de probabilidad de cada variable definida.
- b) Considere ahora la siguiente situación. Se extraen 6 lápices al azar y con reposición. ¿Cuál es la probabilidad de obtener 3 rojos, 2 azules y 1 verde?

- 2) Un dado no equilibrado asigna a la cara con el número  $x, x = 1, \dots, 6$ , probabilidades dadas por

$$p(x) = c \times 0,7^x \times 0,3^{6-x}, x = 1, \dots, 6$$

- a) Calcule el valor de  $c$ .
- b) Haga una tabla con los valores de la función de distribución  $F$ .
- c) Utilice la tabla para calcular la probabilidad que
  - (i) El número esté entre 2 y 4.
  - (ii) El número sea mayor que 2.

- 3) Si 50 % de los automóviles extranjeros que vende una agencia está equipado para trabajar con diésel, encuentre una fórmula para la distribución de probabilidad del número de modelos diésel entre los próximos 4 automóviles que venda esta agencia. Determine la f.d.a de la variable de interés.



### 3.5.3. Variables Aleatorias Continuas

Sea  $X : \Omega \rightarrow \mathbb{R}$  una variable aleatoria. Diremos que es una variable aleatoria continua si y sólo si  $\text{Rec}(X)$  es de cardinalidad no numerable.

En este caso para una función no negativa  $f(x), x \in \mathbb{R}$ , se define  $F(x)$  como:

$$F(x) = \int_{-\infty}^x f(t)dt, \quad \forall x \in \mathbb{R}$$

y por el teorema fundamental del cálculo se demuestra que

$$f(x) = \frac{d}{dx}F(x)$$

donde  $f(x)$  se denomina **función de densidad** de la variable aleatoria  $X$ .

Note que

$$\text{i) } f(x) \geq 0, \quad \forall x \in \mathbb{R}.$$

$$\text{ii) } \int_{-\infty}^{\infty} f(x) dx = 1$$

$$\text{iii) } \mathbf{P}_X(B) = \mathbf{P}(X \in B) = \int_B f(x)dx$$

Si  $B = \{a\}$ , entonces:

$$\mathbf{P}(X \in B) = \int_B f(x)dx = \int_a^a f(x)dx = 0,$$

por lo tanto, si la variable aleatoria es continua, la probabilidad puntual es igual a 0.

Si  $B$  es un intervalo, por ejemplo  $B = (a, b)$ , entonces :

$$\begin{aligned} \mathbf{P}_X(B) &= \mathbf{P}(X \in (a, b)) \\ &= \mathbf{P}(a < X < b) \\ &= \mathbf{P}(a < X \leq b), \quad \text{pues } \mathbf{P}(X = b) = 0, \\ &= F(b) - F(a) \\ &= \int_{-\infty}^b f(x) dx - \int_{-\infty}^a f(x) dx = \int_B f(x) dx \end{aligned}$$

**Ejercicios 23** Suponga que el error de la temperatura de reacción, en  $^{\circ}\text{C}$ , para un experimento controlado de laboratorio es una variable aleatoria continua  $X$ , que tiene función de densidad de probabilidad:

$$f(x) = \begin{cases} \frac{x^2}{3}, & -1 < x < 2 \\ 0, & \text{e.o.c.} \end{cases}$$

a) Verifique la condición (ii).

b) Encuentre  $\mathbf{P}(0 < X \leq 1)$  directamente y, luego, usando  $F(x)$ .

### 3.5.4. Localización y dispersión de una variable aleatoria

**Definición 3.5.5** Sea  $X$  una variable aleatoria discreta con función de probabilidad  $p(x)$ . El **valor esperado** o **esperanza** de  $X$  se define como

$$E(X) = \sum_{i=1}^{\infty} x_i \cdot p(x_i)$$

y su existencia está sujeta a la convergencia de dicha sumatoria.

**Ejemplo 3.5.2** Sea  $A$  un evento en  $(\Omega, \mathcal{A}, \mathbf{P})$ , con  $\mathbf{P}(A) = p$ ,  $0 \leq p \leq 1$ . Usted paga \$1 si  $A$  ocurre y \$0 si  $A^c$  ocurre. Sea  $X$  la ganancia obtenida en un ensayo de este experimento. Determine la esperanza  $X$ .

**Definición 3.5.6** Sea  $X$  una variable aleatoria continua con función de densidad  $f(x)$ . El **valor esperado** o **esperanza** de  $X$  se define como

$$E(X) = \int_{-\infty}^{\infty} x \cdot f(x) \, dx$$

siempre que

$$\int_{-\infty}^{\infty} |x| \cdot f(x) \, dx < \infty$$

Si la integral diverge, el valor esperado no está definido.

**Ejemplo 3.5.3** Suponga que el error de la temperatura de reacción, en  $^{\circ}\text{C}$ , para un experimento controlado de laboratorio es una variable aleatoria continua  $X$  que tiene función de densidad de probabilidad:

$$f(x) = \begin{cases} \frac{x^2}{3}, & -1 < x < 2 \\ 0, & \text{e.o.c.} \end{cases}$$

Calcule el valor esperado del error de medición.

$E(X)$  también es llamada la **media** de  $X$  y representa el centro de masa de la función de cuantía (caso discreto) o de la función densidad (caso continuo). Una notación usual es  $\mu_X = E(X)$

Algunas propiedades del valor esperado son

- El valor esperado es un operador lineal, esto es, si  $E(X)$  está bien definida, entonces

$$E(aX + b) = a \cdot E(X) + b$$

- Si  $X$  e  $Y$  son variables aleatorias, entonces

$$E(X + Y) = E(X) + E(Y)$$

- Si  $X$  e  $Y$  son variables aleatorias con esperanzas bien definidas, y tales que  $X(\omega) \leq Y(\omega)$ ,  $\forall \omega \in \Omega$ , entonces  $E(X) \leq E(Y)$

**Definición 3.5.7** Sea  $X$  una variable aleatoria discreta con función de probabilidad  $p(x)$  y sea  $g$  una función con dominio en  $\Omega$  y valores en  $\mathbb{R}$ . El valor esperado de  $g(X)$  está dado por

$$E(g(X)) = \sum_{i=1}^{\infty} g(x_i) \cdot p(x_i)$$

siempre que

$$\sum_{i=1}^{\infty} |g(x_i)| \cdot p(x_i)$$

exista.

**Definición 3.5.8** Sea  $X$  una variable aleatoria continua con función densidad  $f(x)$  y sea  $g$  una función con dominio en  $\Omega$  y valores en el conjunto de los números reales. El valor esperado de  $g(X)$  está dado por

$$E(g(X)) = \int_{-\infty}^{\infty} g(x) \cdot f(x) dx$$

siempre que

$$\int_{-\infty}^{\infty} |g(x)| \cdot f(x) dx$$

exista.

**Definición 3.5.9** La **mediana** de una variable aleatoria  $X$  es algún número  $m$  tal que:

$$\mathbf{P}(X \geq m) \geq 1/2 \quad \text{y} \quad \mathbf{P}(X \leq m) = 1/2$$

Notar que

- i) Si  $X$  tiene distribución simétrica en torno a un valor  $\mu_X$ , esto es  $f(\mu_X - c) = f(\mu_X + c)$ , y  $E(X) < \infty$ , entonces  $\mu_X$  es una mediana para  $X$ .
- ii) Si  $X$  tiene distribución asimétrica, la mediana de  $X$  puede ser una mejor medida de localización para  $f(x)$ .

Dos distribuciones pueden tener la misma localización y ser completamente diferentes, por lo que hay que considerar una medida de dispersión de la variable, la más común de estas es la varianza.

**Definición 3.5.10** La **varianza** de una variable aleatoria  $X$  se define como

$$V(X) = E[(X - E(X))^2]$$

siempre que  $E(X)$  exista. La notación usual es  $\sigma_X^2 = V(X)$ .

La **desviación estándar** de  $X$ ,  $\sigma_X$ , corresponde a la raíz cuadrada de la varianza.

Propiedades de la varianza.

- $V(X) = E(X^2) - (E(X))^2$
- $V(X) \geq 0$ , y  $V(X) = 0 \Leftrightarrow X$  es una constante.
- $V(aX + b) = a^2 V(X)$

- Si  $X$  e  $Y$  son variables aleatorias, entonces

$$V(X + Y) = V(X) + V(Y) + 2 \cdot Cov(X, Y)$$

donde

$$Cov(X, Y) = E(XY) - E(X) \cdot E(Y)$$

El concepto de covarianza será profundizado en la sección de vectores aleatorios, ya que involucra para su cálculo la función de probabilidad de  $(X, Y)$ . Por ahora, sólo cabe notar que el cálculo de la varianza de la suma no corresponde a la suma de las varianzas.

**Ejemplo 3.5.4** Sean  $X$  e  $Y$  variables aleatorias y  $a, b$  constantes. Determine una expresión para  $V(aX + bY)$ .

En particular, si  $X$  es una variable aleatoria discreta con función de probabilidad  $p(x)$  y valor esperado  $E(X)$ ,

$$V(X) = \sum_{i=1}^{\infty} (x_i - E(X))^2 \cdot p(x_i)$$

Si  $X$  es una variable aleatoria continua con función densidad  $f(x)$  y valor esperado  $E(X)$ ,

$$V(X) = \int_{-\infty}^{\infty} (x - E(X))^2 \cdot f(x) dx$$

**Ejemplo 3.5.5** Sea  $X$  una variable aleatoria y

|        |   |      |      |      |      |     |
|--------|---|------|------|------|------|-----|
| $k$    | 0 | 1    | 2    | 3    | 4    | 5   |
| $p(k)$ | 0 | 0.02 | 0.04 | 0.06 | 0.08 | 0.8 |

Calcule  $E(X)$  y  $V(X)$ .

**Desarrollo:** Usamos la definición de valor esperado y

$$E(X) = \sum x \cdot p(x) = 1 \cdot 0,02 + 2 \cdot 0,04 + 3 \cdot 0,06 + 4 \cdot 0,08 + 5 \cdot 0,8 = 4,6$$

$$E(X^2) = \sum x^2 \cdot p(x) = 1^2 \cdot 0,02 + 2^2 \cdot 0,04 + 3^2 \cdot 0,06 + 4^2 \cdot 0,08 + 5^2 \cdot 0,8 = 22$$

Entonces,  $E(X) = 4,6$  y  $V(X) = 22 - 4,6^2 = 0,84$ .

## Ejercicios 24

Sea  $X$  una variable aleatoria con función densidad dada por

$$f(x) = \frac{1}{b-a} \cdot I_{(a,b)}(x)$$

- Calcule  $E(X)$  y  $V(X)$ .
- Obtenga una expresión para el percentil  $p$  de la distribución. Interprete geométicamente este resultado.
- Para  $n$  entero positivo, determine  $E(X^n)$ .

### 3.5.5. Casos especiales de distribuciones de probabilidad

#### Distribución Bernoulli

Consideremos un experimento con sólo dos resultados posibles, uno que se llame *éxito* ( $E$ ) y otro, *fracaso* ( $F$ ). Los resultados sucesivos e independientes de tal experimento se llaman pruebas o **experimentos Bernoulli**.

En realidad, cualquier experimento puede ser usado para definir un ensayo Bernoulli simplemente denotando algún evento de interés,  $A$ , como éxito y su complemento,  $A^c$ , como fracaso.

**Definición 3.5.11** Decimos que la variable aleatoria  $X$  que cuenta el número de éxitos al realizar un experimento Bernoulli tiene (o sigue) una distribución Bernoulli de parámetro  $p$  que denotamos por

$$X \sim \text{Bernoulli}(p)$$

y su función de probabilidad está dada por

$$\mathbf{P}(X = k) = p^k(1 - p)^{1-k}, \quad k = 0, 1.$$

**Teorema 3.5.1** La esperanza y varianza de la distribución Bernoulli están dadas por

$$\mathbf{E}(X) = p, \quad \mathbf{V}(X) = p(1 - p)$$

#### Distribución Binomial

Un experimento que consiste de  $n$  ensayos Bernoulli independientes, cada uno con probabilidad de éxito  $p$ , se llama un experimento Binomial con  $n$  ensayos y parámetro  $p$ .

El decir “ensayos independientes” significa que lo que ocurra en un ensayo no tiene efecto en el resultado observado para cualquier otro ensayo.

**Definición 3.5.12** Sea  $X$  el número total de éxitos observados en un experimento Binomial con  $n$  ensayos y parámetro  $p$ . Entonces,  $X$  se llama **variable aleatoria Binomial** con parámetros  $n$  y  $p$  y se denota

$$X \sim \text{Bin}(n, p)$$

y su función de probabilidad está dada por

$$\mathbf{P}(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}, \quad k = 0, 1, \dots, n.$$

La función de probabilidad Binomial está compuesta por:

- i) La probabilidad de una secuencia con  $k$  éxitos y  $n - k$  fracasos,  $p^k(1 - p)^{n-k}$ .
- ii) El número de secuencias de este tipo que corresponde a calcular el número de maneras de ordenar  $n$  objetos donde hay  $k$  de un tipo, los éxitos, y  $n - k$  de otro, los fracasos. Como los objetos del mismo tipo no son diferenciables, entonces el total de maneras de ordenar los  $n$  objetos es

$$\frac{n!}{k! \cdot (n - k)!} = \binom{n}{k}$$

**Teorema 3.5.2** La esperanza y varianza de la distribución Binomial están dadas por:

$$E(X) = n \cdot p, \quad V(X) = n \cdot p \cdot (1 - p)$$

**Ejemplo 3.5.6** .

- 1) El gerente de un restaurante que sólo da servicio mediante reservas sabe, por experiencia, que el 20 % de las personas que reservan una mesa no asistirán. Si el restaurante acepta 25 reservas pero sólo dispone de 20 mesas, ¿cuál es la probabilidad de que a todas las personas que asistan al restaurante se les asigne una mesa?
- 2) Se sabe que el número de pacientes graves en una urgencia es una variable aleatoria Binomial con una media de 12 pacientes graves y una varianza de 3. Determine la probabilidad que en un día haya a lo menos 2 pacientes en estado grave.

## Distribución Geométrica

**Definición 3.5.13** Si se realizan repetidos experimentos Bernoulli independientes con probabilidad de éxito  $p$ , entonces la distribución de la variable aleatoria  $X$ , el número de experimentos necesarios hasta encontrar el primer éxito, sigue una **distribución geométrica** de parámetro  $p$  y se denota por:

$$X \sim \text{Geo}(p)$$

con función de probabilidad dada por

$$P(X = k) = (1 - p)^{k-1}p, \quad k = 1, 2, 3, \dots$$

**Teorema 3.5.3** La esperanza y varianza de la distribución geométrica están dadas por:

$$E(X) = \frac{1}{p}, \quad V(X) = \frac{1 - p}{p^2}$$

**Ejemplo 3.5.7** Calcule la probabilidad de que deba lanzar un dado por lo menos 6 veces hasta obtener un 5.

## Distribución Binomial Negativa

**Definición 3.5.14** Consideremos ensayos Bernoulli independientes con probabilidad de éxito  $p$  en cada ensayo. Si  $X$  es el número de ensayos necesarios para observar el  $r$ -ésimo éxito, entonces  $X$  se llama variable aleatoria **Binomial negativa** con parámetros  $r$ , y  $p$  su función de probabilidad está dada por

$$P(X = k) = \binom{k-1}{r-1} p^r (1-p)^{k-r}, \quad x = r, r+1, \dots$$

y se denota por

$$X \sim \text{BinNeg}(r, p)$$

**Teorema 3.5.4** La esperanza y varianza de la distribución Binomial Negativa están dadas por:

$$E(X) = \frac{r}{p}, \quad V(X) = \frac{r(1-p)}{p^2}$$

**Ejemplo 3.5.8** Calcule la probabilidad de que deba lanzar un dado por lo menos 6 veces hasta obtener 5 tres veces.

## Distribución Poisson

**Definición 3.5.15** Una variable aleatoria  $X$  que cuenta el número de eventos que ocurren en una unidad de medida (generalmente esta unidad es el tiempo) tiene **distribución Poisson** de parámetro  $\lambda > 0$ , y su función de probabilidad está dada por

$$\mathbf{P}(X = k) = \frac{e^{-\lambda} \lambda^k}{k!}, \quad k = 0, 1, \dots$$

y se denota por

$$X \sim \text{Poisson}(\lambda)$$

**Teorema 3.5.5** La esperanza y varianza de la distribución Poisson están dadas por:

$$\mathbf{E}(X) = \lambda, \quad \mathbf{V}(X) = \lambda$$

### Ejemplo 3.5.9 .

- 1) Se sabe que los pacientes llegan de acuerdo a una distribución Poisson con  $\lambda = 3$  pacientes/minuto. Cuando llegan más de 4 pacientes por minuto la secretaria se ve sobrepasada y el servicio de atención es calificado como deficiente. ¿Cuál es la probabilidad de que el sistema sea calificado como no deficiente?
- 2) Una empresa electrónica observa que el número de componentes que fallan antes de cumplir 100 horas de funcionamiento es una variable aleatoria de Poisson. Si el número promedio de estos fallos es ocho,
  - a) ¿cuál es la probabilidad de que falle un componente en 25 horas?
  - b) ¿y de que fallen no más de dos componentes en 50 horas?
  - c) ¿cuál es la probabilidad de que fallen por lo menos diez en 125 horas?

## Distribución Uniforme

**Definición 3.5.16** Una variable aleatoria  $X$  tiene **distribución uniforme** si su densidad se distribuye por igual entre dos valores cualquiera  $a$  y  $b$ . Su función de densidad está dada por

$$f(x) = \begin{cases} \frac{1}{b-a}, & a < x < b, \\ 0, & \text{e.o.c.} \end{cases}$$

con  $a, b \in \mathbb{R}$  y se denota por

$$X \sim \mathcal{U}(a, b)$$

**Teorema 3.5.6** La esperanza y varianza de la distribución Uniforme están dadas por:

$$\mathbf{E}(X) = \frac{a+b}{2}, \quad \mathbf{V}(X) = \frac{(b-a)^2}{12}$$

**Ejemplo 3.5.10** En los días del verano,  $X$ , el tiempo de retraso de un tren del Metro se puede modelar como distribuida uniformemente entre 0 y 20 minutos.

- a) Calcule la probabilidad de que el tren llegue por lo menos con 8 minutos de retraso.
- b) Calcule la desviación estándar del tiempo de retraso del tren.

## Distribución Exponencial

**Definición 3.5.17** Una variable aleatoria  $X$  tiene **distribución exponencial** de parámetro  $\lambda > 0$  si su función densidad está dada por

$$f(x) = \begin{cases} \lambda e^{-\lambda x}, & x > 0, \\ 0, & \text{e.o.c.} \end{cases}$$

y se denota por

$$X \sim \exp(\lambda)$$

En general, la distribución exponencial es utilizada para modelar el tiempo hasta la ocurrencia de un evento. En ese caso, y al combinarla con el proceso de conteo del número de eventos, se construye el llamado **Proceso de Poisson** que ud. puede (debe) investigar como complemento a su estudio.

### Ejemplo 3.5.11

En un centro rural para la atención de emergencias el tiempo entre llegadas sigue una distribución exponencial con un tiempo media de llegadas de 1.25 horas. Encuentre la probabilidad de que el tiempo entre llegadas sea mayor a 1 hora. Encuentre la probabilidad de que el tiempo entre llegadas sea mayor a 2 horas.

## Distribución Gama

**Definición 3.5.18** Una variable aleatoria  $X$  tiene **distribución Gama** de parámetros  $k > 0$  y  $\lambda > 0$  si su función densidad está dada por

$$f(x) = \begin{cases} \frac{\lambda^k}{\Gamma(k)} \cdot x^{k-1} e^{-\lambda x}, & x > 0, \\ 0, & \text{e.o.c.} \end{cases}$$

donde

$$\Gamma(k) = \begin{cases} (k-1)!, & k \in \mathbb{Z}, \\ \int_0^\infty t^{k-1} \cdot e^{-t} dt, & k \notin \mathbb{Z} \end{cases}$$

y se denota por

$$X \sim \text{Gama}(k, \lambda)$$

En general la distribución Gama es utilizada para modelar el tiempo hasta la ocurrencia del  $k$ -ésimo evento.

**Teorema 3.5.7** La esperanza y varianza de la distribución Gama están dadas por:

$$E(X) = \frac{k}{\lambda}, \quad V(X) = \frac{k}{\lambda^2}$$

La siguiente distribución de probabilidad es la base de la inferencia estadística, como veremos en el capítulo siguiente, pues es la distribución “ideal” tanto por sus propiedades como por el fácil acceso a probabilidades y percentiles. Es también llamada “distribución Gaussiana” en honor a Carl Friedrich Gauss.



## Distribución Normal

**Definición 3.5.19** La variable aleatoria  $X$  tiene **distribución normal** con parámetros  $\mu$  y  $\sigma^2$  si su función de densidad está dada por

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2\sigma^2}(x-\mu)^2}, \quad -\infty < x < \infty$$

y se denota por

$$X \sim \mathbf{N}(\mu, \sigma^2)$$

Note que la función  $f(x)$  es una función simétrica respecto del valor  $\mu$ .

**Teorema 3.5.8** La esperanza y varianza de la distribución Normal están dadas por:

$$E(X) = \mu, \quad V(X) = \sigma^2$$

Un caso particular de la distribución Normal se presenta a continuación:

**Definición 3.5.20** Si  $Z$  es una variable aleatoria normal con media 0 y varianza 1, entonces  $Z$  se llama variable aleatoria **normal estándar**.

Cualquier variable aleatoria normal  $X$  se puede transformar en una variable aleatoria normal estandarizada  $Z$ , sustrayendo el valor esperado  $\mu$  y dividiendo el resultado por  $\sigma$ , esto es, si  $X \sim N(\mu, \sigma^2)$ , entonces

$$Z = \frac{X - \mu}{\sigma} \sim N(0, 1)$$

dicho proceso se denomina *estandarización* o *normalización*.

### Ejemplo 3.5.12 .

1. Considere la distribución normal estándar con media  $\mu = 0$  y desviación  $\sigma = 1$ .
  - a) ¿Cuál es la probabilidad que  $z$  sea mayor que 2,6?
  - b) ¿Cuál es la probabilidad que  $z$  sea menor que 1,3?
  - c) ¿Cuál es la probabilidad que  $z$  esté entre -1.7 y 3.1?
  - d) ¿Cuál es el valor de  $z$  que corta el 15 % menor de la distribución?
2. La temperatura  $T$  durante el mes de agosto está distribuida normalmente con una media  $\mu = 36^\circ$  y desviación estándar  $\sigma = 6^\circ$ . Calcular la probabilidad de que la temperatura de un día de agosto
  - a) este entre  $40^\circ$  y  $44^\circ$ .
  - b) sea menor que  $32^\circ$ .
3. Se ha comprobado que la distribución del índice de colesterol para un gran número de personas es la siguiente: inferior a 165 centigramos, 58 %; comprendido entre 165 y 180 centigramos, 38 %. Se sabe que dicha variable sigue una distribución normal.
  - a) Calcular el valor medio del índice de colesterol y su desviación típica.
  - b) Se admite que las personas cuyo índice es superior a 183 centigramos deben ser sometidas a tratamiento. ¿Cuál es el número de personas a tratar en una población de 100000 individuos?

Otras distribuciones continuas muy utilizadas se presentan a continuación.

## Distribución $\chi^2$

**Definición 3.5.21** Una variable aleatoria  $X$  tiene **distribución  $\chi^2$**  de parámetro  $k > 0$  si su función densidad está dada por

$$f(x) = \begin{cases} \frac{2^{(-k/2)}}{\Gamma(k/2)} \cdot x^{(k/2)-1} e^{-x/2}, & x > 0, \\ 0, & \text{e.o.c.} \end{cases}$$

y se denota por

$$X \sim \chi_k^2$$

**Teorema 3.5.9** La esperanza y varianza de la distribución  $\chi^2$  están dadas por:

$$E(X) = k, \quad V(X) = 2k$$

## Distribución $t$ -Student

**Definición 3.5.22** Una variable aleatoria  $X$  tiene **distribución  $t$ -Student** de parámetro  $k > 0$  si su función densidad está dada por

$$f(x) = \frac{\Gamma\left(\frac{k+1}{2}\right)}{\sqrt{k\pi} \cdot \Gamma(k/2)} \cdot \left(1 + \frac{x^2}{k}\right)^{-(k+1)/2}, \quad x \in \mathbb{R}$$

y se denota por

$$X \sim t_k$$

**Teorema 3.5.10** La esperanza y varianza de la distribución  $t$ -Student están dadas por:

$$E(X) = 0, \quad V(X) = \frac{k}{k-2}, \quad k > 2$$

## Distribución $F$ de Fisher

**Definición 3.5.23** Una variable aleatoria  $X$  tiene **distribución  $F$  de Fisher** de parámetro  $n, m > 0$  si su función densidad está dada por

$$f(x) = \frac{\Gamma\left(\frac{n}{2} + \frac{m}{2}\right)}{x \cdot \Gamma\left(\frac{n}{2}\right) \Gamma\left(\frac{m}{2}\right)} \cdot \sqrt{\frac{(nx)^n \cdot m^m}{(nx+m)^{n+m}}}, \quad x \in \mathbb{R}^+$$

y se denota por

$$X \sim F_{n,m}$$

**Teorema 3.5.11** La esperanza y varianza de la distribución  $F$  de Fisher están dadas por:

$$E(X) = \frac{m}{m-2} \quad m > 2, \quad V(X) = \frac{2m(n+m-2)}{n(m-2)^2(m-4)}, \quad m > 4$$

### 3.5.6. Momentos y funciones generadoras de momentos

**Definición 3.5.24** Dada una variable aleatoria  $X$  se definen:

- (i)  $E([X - E(X)]^k)$  como el  $k$ -ésimo momento centrado, en torno a  $E(X)$ , de  $X$ .
- (ii)  $E(X^k)$  como el  $k$ -ésimo momento no centrado de  $X$ .

Para el caso discreto, los momentos centrados y no centrados se calculan como

$$E(X^k) = \sum_{i=1}^{\infty} x_i^k \cdot \mathbf{P}(X = x_i),$$

y

$$E([X - E(X)]^k) = \sum_{i=1}^{\infty} (x_i - E(X))^k \cdot \mathbf{P}(X = x_i).$$

Análogamente, para el caso continuo

$$E(X^k) = \int_{-\infty}^{\infty} x^k \cdot f(x) dx,$$

y

$$E([X - E(X)]^k) = \int_{-\infty}^{\infty} (x - E(X))^k \cdot f(x) dx$$

De las definiciones se desprende que el primer momento no centrado corresponde a la media o valor esperado y el segundo momento centrado a la varianza.

**Definición 3.5.25** La **función generadora de momentos** (f.g.m.) de una variable aleatoria  $X$  se define como

$$M_X(t) = E(e^{Xt})$$

con  $t \in \mathbb{R}$ .

Utilizando la definición de valor esperado para funciones de variables aleatorias, el cálculo de la función generadora de momentos se traduce en

$$M_X(t) = \sum_{i=1}^{\infty} e^{tx_i} \cdot \mathbf{P}(X = x_i),$$

para el caso discreto y

$$M_X(t) = \int_{-\infty}^{\infty} e^{tx} \cdot f(x) dx,$$

para el caso continuo.

En ambos casos es importante notar que la f.g.m. debe quedar solo en términos de  $t$  y los parámetros de la distribución de probabilidad correspondiente.

**Ejemplo 3.5.13** Determine su función generadora de momentos para las siguientes distribuciones:

- a)  $X \sim \text{Bin}(n, p)$
- b)  $X \sim \text{N}(0, 1)$

**Teorema 3.5.12** Sea  $X$  una variable aleatoria con función generadora de momentos  $M_X(t)$ . Entonces

$$E(X^k) = \left. \frac{d^k}{dt^k} M_X(t) \right|_{t=0}$$

**Ejemplo 3.5.14** Utilizando las respectivas f.g.m. calcule la media de  $X$  si

- a)  $X \sim \text{Bin}(n, p)$
- b)  $X \sim \text{N}(0, 1)$

**Teorema 3.5.13 (Teorema de Unicidad)** Sean  $X$  e  $Y$  dos variables aleatorias con funciones generadoras de momentos  $M_X(t)$  y  $M_Y(t)$  respectivamente. Si  $M_X(t) = M_Y(t)$  para todos los valores de  $t$ , entonces  $X$  e  $Y$  tienen la misma distribución de probabilidad.

**Teorema 3.5.14** Si  $Y = cX + d$ , entonces  $M_Y(t) = e^{td} M_X(ct)$

**Ejemplo 3.5.15** Sea  $X$  una variable aleatoria con distribución normal estándar. Determine la f.g.m. de  $Y = \mu + \sigma X$ .

## Ejercicios 25

1. Suponga que la v.a.  $X$  sólo puede asumir los valores  $-1$  y  $1$  con probabilidad  $1/2$ . Encuentre
  - a) La función generadora de momentos de  $X$ .
  - b) Los primeros cuatro momentos centrados de  $X$ .
2. Una v.a. tiene función densidad dada por:

$$f(x) = \begin{cases} 2e^{-2x}, & x \geq 0 \\ 0, & \text{e.o.c.} \end{cases}$$

Determine:

- a) La función generadora de momentos de  $X$ .
  - b) Los primeros cuatro momentos centrados de  $X$ .
3. La función de probabilidad de  $X$ , número de defectos importantes en un electrodoméstico seleccionado al azar, es

| $x$        | 0    | 1     | 2    | 3    | 4     |
|------------|------|-------|------|------|-------|
| $P(X = x)$ | 0.08 | 0.015 | 0.45 | 0.27 | 0.185 |

Determine la función generadora de momentos de  $X$  y, a partir de ella, su esperanza y varianza.

### 3.5.7. Transformación de variables

Frecuentemente, en estadística, se presenta la necesidad de deducir la distribución de probabilidad de una función de una o más variables aleatorias. Por ejemplo, supongamos que  $X$  es una variable aleatoria con función de probabilidad  $f(x)$  y supongamos, además, que  $Y = g(X)$  y el objetivo es encontrar la distribución de probabilidad de  $Y$ .

**Teorema 3.5.15** *Suponga que  $X$  es una variable aleatoria continua con distribución de probabilidad  $f(x)$ . Sea  $Y = g(X)$  con  $g$  una función uno a uno entre los valores de  $X$  e  $Y$ . Entonces la distribución de probabilidad de  $Y$  está dada por*

$$f_Y(y) = f_X(g^{-1}(y))|J|,$$

donde

$$J = \frac{d}{dy} (g^{-1}(y))$$

y recibe el nombre de Jacobiano de la transformación. Es muy importante notar que como la función  $g$  es uno a uno podemos también construir el recorrido de la nueva variable en base al recorrido de la variable original.

#### Ejercicios 26

1. Sea  $X$  una variable aleatoria continua con función densidad

$$f(x) = \frac{x}{12}, \quad 1 < x < 5$$

Encuentre la distribución de probabilidad de la variable aleatoria  $Y = 2X - 3$ .

2. Sea  $X$  una variable aleatoria con densidad Beta( $a, b$ ), es decir,

$$f(x) = \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} x^{a-1}(1-x)^{b-1}, \quad 0 < x < 1.$$

Determinar la distribución de  $Y = 1 - X$ .

**Teorema 3.5.16** *Sea  $X$  una variable aleatoria continua con función densidad  $f(x)$ . Si  $Y = g(X)$  es una transformación entre los valores de  $X$  e  $Y$  que no es uno a uno, es decir, para cada  $y \in \mathbb{R}$  existen  $k$  inversas,  $x_i = g_i^{-1}(y)$ ,  $i = 1, \dots, k$ , entonces la distribución de probabilidad de  $Y$  es*

$$f(y) = \sum_{i=1}^k f_X(g_i^{-1}(y))|J_i|, \quad \text{donde} \quad J_i = \frac{d}{dy} (g_i^{-1}(y)) \quad i = 1, \dots, k.$$

#### Ejercicios 27

1. Si  $X \sim U(0, 1)$ , encontrar la función densidad de  $Y = e^X$ .
2. Se dice que  $X$  tiene distribución Weibull si

$$f_X(x) = \begin{cases} \lambda \alpha x^{\alpha-1} \exp(-\lambda x^\alpha), & x > 0; \\ 0, & \text{e.o.c.} \end{cases}$$

Se asume que  $\alpha > 0$  y  $\lambda > 0$ . ¿Cuál es la distribución de  $Y = X^\alpha$ ?

3. Sea  $X$  una variable aleatoria con densidad

$$f(x) = \frac{1}{2}e^{-|x|}, \quad -\infty < x < \infty.$$

Determinar la distribución de  $Y = |X|$ .

4. Sea  $X \sim N(\mu, \sigma^2)$ . Determine la distribución de probabilidad de  $Y = (X - \mu)/\sigma$ .

### 3.5.8. Aproximación de distribuciones

Suponga que quiere recoger la opinión de una muestra de 1000 electores para saber su sentir en pro del fortalecimiento del gobierno de la ciudad. ¿Cuál es la probabilidad de encontrar 460 o menos electores a favor del fortalecimiento si suponemos que el 50 % de la población está a favor de él?

Definamos la variable aleatoria  $X$ , el número de electores en pro del fortalecimiento, con  $X \sim \text{Bin}(1000, 1/2)$ . Entonces para calcular la probabilidad pedida  $\mathbf{P}(X \leq 460)$  debemos sumar 461 términos, lo que no parece una tarea fácil.

En este tipo de situaciones, donde el número de ensayos es demasiado grande ( $\geq 20$ ), aproximaremos nuestra distribución de probabilidad a otra distribución, dependiendo del valor de  $p$  la probabilidad de éxito.

#### Aproximación Poisson a la distribución Binomial

Se sugiere aproximar a la distribución Poisson una distribución Binomial para valores de  $n$  “muy grandes” y de  $p$  “muy pequeña”. La regla es aproximar si  $p < 0,05$  y  $n \geq 20$ . Si  $n \geq 100$  la aproximación es buena siempre y cuando  $np > 10$ .

En ambos casos  $\lambda = np$  y en vez de utilizar  $X \sim \text{Bin}(n, p)$  usamos  $X \sim P(np)$ .

**Ejemplo 3.5.16** *Se sabe que el 5 % de los libros encuadernados en cierto taller tienen encuadernaciones defectuosas. Determine la probabilidad de que 2 de 100 libros encuadernados en ese taller tengan encuadernaciones defectuosas, usando,*

- a) *la fórmula de la distribución Binomial,*
- b) *la aproximación de Poisson a la distribución Binomial.*

*Compare ambos resultados.*

#### Aproximación Normal a la distribución Binomial

Se sugiere aproximar a la distribución Normal una distribución Binomial cuando  $n$  es “muy grande” y los valores de  $p$  son cercanos a 0.5. Esta aproximación debería utilizarse sólo si  $np \geq 5$  y  $n(1 - p) \geq 5$ .

En tal caso,  $\mu = np$  y  $\sigma^2 = np(1 - p)$ .

**Ejemplo 3.5.17** *Se considera un sindicato laboral en el cual el 40 % miembros está a favor de la huelga. Si se seleccionan 15 miembros de manera aleatoria, ¿cuál es la probabilidad de que 10 apoyen un paro? Calcule dicha probabilidad utilizando las distribuciones Binomial y Normal por separado y compare.*

**Ejercicios 28** *El 45 % de todos los empleados del centro de capacitación gerencial tiene títulos universitarios. ¿Cuál es la probabilidad de que de los 150 empleados seleccionados aleatoriamente 72 tengan un título universitario?*

## 3.6. VECTORES ALEATORIOS

En la mayoría de los fenómenos de estudio es interesante estudiar el comportamiento no de una sino que de varias variables al mismo tiempo y cómo interactúan entre ellas.

**Definición 3.6.1**  $X = (X_1, X_2, \dots, X_n)$  es un **vector aleatorio** definido en  $(\Omega, \mathcal{A}, \mathbf{P})$  si y sólo si  $X_1, X_2, \dots, X_n$  son variables aleatorias definidas en el mismo modelo  $(\Omega, \mathcal{A}, \mathbf{P})$ .

Para este curso, estudiaremos la distribución en dos variables, siendo fácilmente extensible a más dimensiones.

### 3.6.1. Distribución Conjunta

**Definición 3.6.2** La función definida por

$$F(x, y) = \mathbf{P}(X \leq x, Y \leq y), \quad (x, y) \in \mathbb{R}^2$$

se llama **función de probabilidad acumulada conjunta** de  $X$  e  $Y$ .

**Definición 3.6.3** Sea  $(X, Y)$  un vector aleatorio en  $(\Omega, \mathcal{A}, \mathbf{P})$ . Diremos que:

a)  $(X, Y)$  es **discreto** si y sólo si  $\text{Rec}(X) \times \text{Rec}(Y)$  es un subconjunto contable (finito o no) de  $\mathbb{R}^2$ .

En tal caso, la distribución de probabilidad puede representarse mediante

$$\mathbf{P}(X = x, Y = y) = \mathbf{P}(\{X = x\} \cap \{Y = y\})$$

Así,

$$(i) \quad \mathbf{P}(X = x, Y = y) \geq 0, \quad \forall (x, y) \in \mathbb{R}^2$$

$$(ii) \quad \sum_x \sum_y \mathbf{P}(X = x, Y = y) = 1$$

**Ejemplo 3.6.1** Considere el lanzamiento de 3 monedas honestas y defina las siguientes variables aleatorias:

$X$ : número de caras en 3 lanzamientos.

$Y$ : número de caras en el primer lanzamiento.

Determine la función de probabilidad conjunta de  $(X, Y)$ .

b)  $(X, Y)$  es **continuo** si y sólo si existe una función  $f : \mathbb{R}^2 \rightarrow \mathbb{R}$  no negativa tal que

$$F(x, y) = \int_{-\infty}^x \int_{-\infty}^y f(t_1, t_2) dt_2 dt_1, \quad \forall (x, y) \in \mathbb{R}^2$$

En tal caso

$$f(x, y) = \frac{\partial^2}{\partial x \partial y} F(x, y)$$



Así,

$$(i) f(x, y) \geq 0, \quad \forall (x, y) \in \mathbb{R}^2.$$

$$(ii) \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(x, y) dx dy = 1.$$

**Ejemplo 3.6.2** Sea  $(X, Y)$  el resultado de escoger al azar un punto de la región de dos dimensiones acotada por las rectas  $x = -1$ ,  $x = 2$ ,  $y = 1 - x$ ,  $y = -1 - x$ . Determine  $f(x, y)$ .

Nuevamente, una definición formal que sustenta la teoría que utilizaremos.

**Definición 3.6.4** La **función de probabilidad conjunta** de  $X = (X_1, X_2, \dots, X_n)$  se define como:

$$\mathbf{P}_X(B) = \mathbf{P}(X \in B), \quad \forall B \subset \mathcal{B}^n$$

Así,  $\mathbf{P}_X(B)$ ,  $B \subset \mathcal{B}^n$  es una medida de probabilidad y, por tanto,  $(\mathbf{P}_X, \mathcal{B}^n, \mathbb{R}^n)$  es un modelo de probabilidad.

Entonces

a) Si  $X$  es un vector aleatorio discreto

$$\mathbf{P}_X(B) = \mathbf{P}(X \in B) = \sum_{x \in B} \mathbf{P}(X = x), \quad \forall B \in \mathcal{B}^n$$

b) Si  $X$  es un vector aleatorio continuo

$$\mathbf{P}_X(B) = \mathbf{P}(X \in B) = \int_{x \in B} f_X(x) dx, \quad \forall B \in \mathcal{B}^n$$

## Ejercicios 29

1. En un experimento se necesitan dos scanners. De los cinco disponibles, dos tienen desperfectos electrónicos, otro tiene un defecto de memoria y dos se hallan en buenas condiciones de operación. Si se seleccionan dos unidades al azar, determinar:

a) La función de distribución (o cuantía) conjunta de las variables aleatorias  $X$  e  $Y$ , en donde:

$X$ : número de unidades con defectos electrónicos.

$Y$ : número de unidades con defecto de memoria.

b) Determine la probabilidad de que entre las dos unidades seleccionadas se produzcan 0 ó 1 defectos en total.

2. Sea  $(X, Y)$  el resultado de escoger al azar un punto de la región de dos dimensiones acotada por las rectas  $x = -1$ ,  $x = 2$ ,  $y = 1 - x$ ,  $y = -1 - x$ . Calcule  $\mathbf{P}(XY > 0)$ .

Dada la distribución de probabilidad conjunta  $f(x, y)$  de las variables aleatorias  $X$  e  $Y$ , la distribución de probabilidad  $f(x)$  de  $X$  se obtiene al sumar  $f(x, y)$  sobre todos los valores de  $Y$ . De la misma forma, la distribución de probabilidad  $f(y)$  se obtiene al sumar  $f(x, y)$  sobre todos los valores de  $X$ . Cuando  $X$  e  $Y$  son variables aleatorias continuas, las sumas se reemplazan por integrales.

**Definición 3.6.5** Las *distribuciones marginales* de  $X$  e  $Y$  están dadas por

$$p_X(x) = \sum_y f_{XY}(x, y) \quad y \quad p_Y(y) = \sum_x f_{XY}(x, y)$$

para el caso discreto y

$$f_X(x) = \int_y f_{XY}(x, y) dy \quad y \quad f_Y(y) = \int_x f_{XY}(x, y) dx$$

para el caso continuo.

### Ejercicios 30

1. Sea el vector aleatorio discreto  $(X, Y)$  con función de distribución

$$p(x, y) = k \cdot I_{\{1,2,3\} \times \{2,3,4\}}(x, y)$$

- a) Determinar el valor de  $k$ .
- b) Calcular las distribuciones marginales de  $X$  e  $Y$ .

2. Sea

$$f(x, y) = \begin{cases} c(x + y), & \text{si } x + y < 1, x > 0, y > 0, \\ 0, & \text{e.o.c.} \end{cases}$$

- a) Calcular  $c$ .
- b) Encontrar las densidades marginales de  $X$  e  $Y$ .

3. Suponga que la fracción  $X$  de atletas hombres y la fracción  $Y$  de atletas mujeres que terminan la carrera del maratón puede describirse por la función densidad conjunta

$$f_{XY}(x, y) = 8xy, \quad 0 \leq x \leq 1, 0 \leq y \leq x.$$

Encuentre  $f(x)$  y  $f(y)$ .

### 3.6.2. Distribuciones conjuntas especiales

Algunas distribuciones multivariadas conocidas se enuncian a continuación:

Suponga que realiza  $N$  experimentos independientes, en cada uno de los cuales puede obtener uno de los  $k$  resultados posibles, cada uno con probabilidad  $p_1, p_2, \dots, p_k$  respectivamente, y desea contar cuántas repeticiones de cada resultado obtuvo.

**Definición 3.6.6** Las variables aleatorias  $X_1, X_2, \dots, X_k$  tienen una **distribución multinomial** si y sólo si su distribución de probabilidad conjunta está dada por

$$\mathbf{P}(X_1 = x_1, X_2 = x_2, \dots, X_k = x_k) = \binom{n}{x_1 \ x_2 \ \dots \ x_k} p_1^{x_1} p_2^{x_2} \dots p_k^{x_k}$$

donde

$$\sum_{j=1}^k x_j = n \quad y \quad \sum_{i=1}^k p_i = 1$$

Lo que se denota como

$$(X_1, \dots, X_k) \sim \text{Mult}(n, p_1, p_2, \dots, p_k)$$

**Ejemplo 3.6.3** Suponga que los errores de cierto procedimiento de medición tienen distribución normal de media 0 y desviación estándar 2 en milímetros. Suponga que se toman 10 mediciones independientes. Calcule la probabilidad de que por lo menos 9 mediciones tengan errores menores a los 2 milímetros y que no más de una medición tenga un error mayor a los 3 milímetros.

Considere un conjunto de  $N$  elementos, de los cuales  $M_1$  son de la primera clase,  $M_2$  de la segunda clase, y así sucesivamente hasta  $M_k$  de la  $k$ -ésima clase, donde  $\sum M_i = N$ .

**Definición 3.6.7** Las variables aleatorias  $X_1, \dots, X_k$  tienen una distribución **hipergeométrica multivariada** si y sólo si su distribución de probabilidad conjunta está dada por

$$\mathbf{P}(X_1 = x_1, \dots, X_k = x_k) = \frac{\binom{M_1}{x_1} \dots \binom{M_k}{x_k}}{\binom{N}{n}}$$

donde

$$\sum_{i=1}^k x_i = n, \quad y \quad \sum_{i=1}^k M_i = N$$

Lo que se denota como

$$(X_1, \dots, X_k) \sim \text{HM}(N, n, M_1, M_2, \dots, M_k)$$

**Ejemplo 3.6.4** En un panel de jurados participan 6 hombres casados, tres hombres solteros, siete mujeres casadas y cuatro mujeres solteras. Si la selección es al azar, ¿cuál es la probabilidad de que el jurado consista de 4 hombres casados, un soltero, cinco mujeres casadas y dos solteras?

Entre las distribuciones multivariadas continuas la distribución normal multivariada es de especial importancia ya que es una generalización de la distribución normal en una variable.

**Definición 3.6.8** El vector aleatorio  $(X, Y)$  tiene una distribución **normal bivariada** si y sólo si su función densidad conjunta está dada por

$$f(x, y) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \exp \left\{ -\frac{1}{2(1-\rho^2)} \left[ \left( \frac{x-\mu_1}{\sigma_1} \right)^2 + \left( \frac{y-\mu_2}{\sigma_2} \right)^2 - 2\rho \left( \frac{x-\mu_1}{\sigma_1} \right) \left( \frac{y-\mu_2}{\sigma_2} \right) \right] \right\}$$

para  $(x, y) \in \mathbb{R}^2$ ,  $\mu_X, \mu_Y \in \mathbb{R}$ ,  $\sigma_1 > 0, \sigma_2 > 0$ ,  $-1 < \rho < 1$ .

Donde  $\mu_X, \sigma_X$  corresponden a la media y varianza de  $X$ ,  $\mu_Y, \sigma_Y$  corresponden a la media y varianza de  $Y$ , y  $\rho$  corresponde al coeficiente de correlación entre  $X$  e  $Y$ .

De manera matricial, lo anterior se escribe como

$$\begin{pmatrix} X \\ Y \end{pmatrix} \sim N_2 \left( \begin{pmatrix} \mu_X \\ \mu_Y \end{pmatrix}, \begin{pmatrix} \sigma_X^2 & \rho\sigma_X\sigma_Y \\ \rho\sigma_X\sigma_Y & \sigma_Y^2 \end{pmatrix} \right)$$

o bien

$$\begin{pmatrix} X \\ Y \end{pmatrix} \sim N_2(\vec{\mu}, \Sigma)$$

en cuyo caso  $\vec{\mu}$  se llama *vector de medias* y  $\Sigma$ , *matriz de varianzas-covarianzas*.

### Ejemplo 3.6.5

Demuestre que si  $(X, Y)$  distribuye conjuntamente  $N_2(\vec{\mu}, \Sigma)$ ,  $X$  tiene distribución normal univariada.

### 3.6.3. Distribución de probabilidad condicional

**Definición 3.6.9** Sean  $X$  e  $Y$  dos variables aleatorias discretas o continuas. La **distribución condicional** de la variable aleatoria  $Y$ , dado que  $X=x$ , está dada por:

$$f_{Y|X}(y) = \frac{f_{XY}(x, y)}{f_X(x)}, \quad f_X(x) > 0$$

**Ejemplo 3.6.6** Suponga que la fracción  $X$  de atletas hombres y la fracción  $Y$  de atletas mujeres que terminan la carrera del maratón puede describirse por la función densidad conjunta

$$f_{XY}(x, y) = 8xy, \quad 0 \leq x \leq 1, 0 \leq y \leq x.$$

Encuentre  $f_{Y|X}$  y determine la probabilidad de que menos de  $1/8$  de las mujeres que se inscribieron para un maratón en particular la finalicen, si se sabe que exactamente  $1/2$  de los atletas hombres terminaron la carrera.

**Definición 3.6.10** Sean  $X$  e  $Y$  dos variables aleatorias, discretas o continuas, con distribución de probabilidad conjunta  $f(x, y)$  y distribuciones marginales  $f(x)$  y  $f(y)$  respectivamente. Las variables aleatorias  $X$  e  $Y$  se dice que son **independientes estadísticamente**, si y sólo si

$$f(x, y) = f(x) \cdot f(y), \quad \forall x, y \in \mathbb{R}$$

### Ejercicios 31

1. Sea

$$f(x, y) = \begin{cases} c(x + y), & \text{si } x + y < 1, x > 0, y > 0, \\ 0, & \text{e.o.c.} \end{cases}$$

¿Son  $X$  e  $Y$  independientes?

2. Sea  $(X, Y)$  un vector aleatorio con distribución normal bivariada. Determine la distribución condicional de  $Y | X$ .

3. Suponga que la calificación promedio de los estudiantes en las asignaturas  $X$  y  $Y$  están bien ajustadas por una distribución Normal Bivariada con un coeficiente de correlación de 0.9 y una estructura de media y varianza dada por:

$$\mu = \begin{pmatrix} 61 \\ 68 \end{pmatrix}, \quad \sigma^2 = \begin{pmatrix} 196 & \\ & 169 \end{pmatrix}$$

Si un estudiante obtuvo una calificación promedio en la asignatura  $Y$  de 60, ¿cuál es la probabilidad que apruebe la asignatura  $X$  (Nota  $> 55$ )?

### 3.6.4. Esperanza y Varianza Condicional

**Definición 3.6.11** Dado un vector aleatorio  $(X, Y)$ , la **esperanza condicional** de  $Y$  dado  $X=x$  se define como

$$E(Y|X = x) = \begin{cases} \sum_y y \cdot \mathbf{P}(Y = y|X = x), & X \text{ discreta,} \\ \int_{-\infty}^{\infty} y \cdot f_{Y|X}(y) \, dy, & X \text{ continua.} \end{cases}$$

Más generalmente, si  $g : \mathbb{R} \rightarrow \mathbb{R}$

$$E(g(Y)|X = x) = \begin{cases} \sum_y g(y) \cdot \mathbf{P}(Y = y|X = x), & X \text{ discreta,} \\ \int_{-\infty}^{\infty} g(y) \cdot f_{Y|X}(y) \, dy, & X \text{ continua.} \end{cases}$$

**Teorema 3.6.1** Si  $E(|Y|) < \infty$

$$E[E(Y | X)] = E(Y)$$

**Ejemplo 3.6.7** Sea  $Y|X = x \sim U(0, 1 - x)$  y  $f_X(x) = 2(1 - x)$ , si  $0 < x < 1$ . Determine  $E(Y)$ .

Algunas propiedades del valor esperado condicional

- i)  $E(c|X = x) = c$
- ii)  $E(Y_1 + Y_2|X = x) = E(Y_1|X = x) + E(Y_2|X = x)$
- iii)  $E(cY|X = x) = c \cdot E(Y|X = x)$
- iv)  $E(g(X, Y)|X = x) = E(g(x, Y))$   
En particular,  
 $E(g_1(X)g_2(Y)|X = x) = g_1(x)E(g_2(Y)|X = x)$
- v)  $E(g(Y)|X = x) = E(g(Y)) \Leftrightarrow X$  es independiente de  $Y$ .

**Definición 3.6.12** La **varianza condicional** de  $Y$  dado  $X=x$  se define como

$$V(Y|X = x) = E[(Y - E(Y|X = x))^2|X = x]$$

$$= \begin{cases} \sum_y (y - E(Y|X = x))^2 \mathbf{P}(Y = y|X = x), & X \text{ discreta,} \\ \int_{-\infty}^{\infty} (y - E(Y|X = x))^2 f_{Y|X}(y) \, dy, & X \text{ continua.} \end{cases}$$

**Teorema 3.6.2** Suponga que  $E(Y^2) < \infty$

$$V(Y) = E(V(Y|X)) + V(E(Y|X))$$

### Ejercicios 32

1. Sean  $X$  e  $Y$  variables aleatorias continuas tales que  $X \sim U(0, 1)$  e  $Y|X = x \sim U(x, x + 1)$ .  
Calcule:
  - a)  $E(Y|X = x)$  y  $V(Y|X = x)$ .
  - b)  $E(Y)$  y  $V(Y)$ .
  - c) La densidad condicional de  $X$  dado  $Y = y$ .
  - d)  $E(X|Y = y)$  y  $V(X|Y = y)$ .
  - e) Considere las funciones de variables aleatorias  $h(Y) = E(X|Y)$  y  $k(X) = E(Y|X)$ . Calcule la función de densidad de  $h(Y)$  y la función de densidad de  $k(X)$ .
2. Sean  $X$  e  $Y$  variables aleatorias tales que  $Y|X = x \sim \text{Bin}(x, p)$  y  $X \sim \text{Poisson}(\lambda)$ . Determine la distribución de  $Y$  y calcule su esperanza.
3. Sea  $(X, Y)$  un vector aleatorio con distribución normal bivariada. Determine  $f_{Y|X}(y)$ .

### Definición 3.6.13

- a) Se define la covarianza entre dos variables aleatorias  $X$  e  $Y$  como

$$\text{Cov}(X, Y) = E(XY) - E(X) \cdot E(Y)$$

- b) Se define la correlación entre dos variables aleatorias  $X$  e  $Y$  como

$$\text{Corr}(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{V(X) \cdot V(Y)}}$$

**Teorema 3.6.3** Si dos variables aleatorias son independientes, entonces  $\text{Corr}(X, Y) = 0$ .

**Nota:** La distribución Normal cumple además con el recíproco.

**Teorema 3.6.4** Si dos variables aleatorias tienen una distribución normal bivariada, son independientes si y sólo si  $\rho = 0$ .

**Teorema 3.6.5** Sean  $X$  e  $Y$  dos variables aleatorias independientes, y sean  $g$  y  $h$  dos funciones, entonces las variables aleatorias  $Z = g(X)$  y  $T = h(Y)$  también son independientes.

### 3.6.5. Teorema de cambio de variable

**Teorema 3.6.6** Sea  $X$  un vector aleatorio continuo  $n$ -dimensional con densidad  $f_X(x)$ . Sea  $g : \mathbb{R}^n \rightarrow \mathbb{R}^n$  una función invertible y continuamente diferenciable. Considere el vector aleatorio  $Y = g(X)$ . Entonces la función de densidad de  $Y$  es

$$f_Y(y) = f_X(g^{-1}(y)) \cdot |J|, \quad y \in \mathbb{R}^n$$

donde  $J$  corresponde a la matriz Jacobiana.

### Ejercicios 33

1. Sean  $X$  e  $Y$  dos variables aleatorias continuas con distribución de probabilidad conjunta

$$f(x, y) = \begin{cases} 4xy, & 0 < x < 1, 0 < y < 1; \\ 0, & \text{e.o.c.} \end{cases}$$

Encuentre la densidad conjunta de  $W = X^2$  y  $Z = XY$ .

2. Sea  $X$  e  $Y$  variables aleatorias independientes con funciones densidades marginales

$$f_X(x) = xe^{-x}, \quad x > 0 \quad y \quad f_Y(y) = e^{-y} \quad y > 0$$

Sean

$$Z = X + Y, \quad y \quad W = \frac{X}{X + Y}$$

- a) Determine las respectivas densidades marginales de  $Z$  y  $W$ .
- b) ¿Son  $Z$  y  $W$  variables aleatorias independientes?

3. Sean  $X$  y  $Y$  dos variables aleatorias independientes con distribución exponencial de parámetro  $\lambda$ . Determine la distribución de probabilidad de  $Z = X + Y$ .



### 3.6.6. Secuencias de variables aleatorias

**Definición 3.6.14** Las variables aleatorias  $X_1, \dots, X_n$  corresponden a una **muestra aleatoria** de tamaño  $n$  de una población con función densidad  $f(x)$  si

- i)  $X_1, \dots, X_n$  son mutuamente independientes y
- ii)  $X_1, \dots, X_n$  tienen función densidad marginal  $f(x)$ .

Las variables  $X_1, \dots, X_n$  se denominan independientes e idénticamente distribuidas, *iid*, y escribimos

$$X_i \stackrel{iid}{\sim} f(x), \quad i = 1, \dots, n.$$

**Teorema 3.6.7** Si  $X_1, \dots, X_n$  son una muestra aleatoria, entonces

$$\mathbf{P}(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n) = \prod_{i=1}^n \mathbf{P}(X_i = x_i)$$

Dada una muestra aleatoria  $X_1, \dots, X_n$ , nos interesa conocer la distribución de probabilidad de  $Y = \bar{X}$ , la que es posible determinar a partir de su función generadora de momentos.

$$\begin{aligned} M_{\bar{X}}(t) &= \mathbf{E} \left( e^{\bar{X} \cdot t} \right) \\ &= \mathbf{E} \left( e^{(X_1 + X_2 + \dots + X_n) \cdot \frac{t}{n}} \right) \\ &= \mathbf{E} \left( \prod_{i=1}^n e^{X_i \cdot \frac{t}{n}} \right) \\ &= \prod_{i=1}^n \mathbf{E} \left( e^{X_i \cdot \frac{t}{n}} \right), \quad \text{ya que las } X_i \text{ son independientes} \\ &= \prod_{i=1}^n M_{X_i} \left( \frac{t}{n} \right) \\ &= \left( M_X \left( \frac{t}{n} \right) \right)^n, \quad \text{ya que las } X_i \text{ están igualmente distribuidas.} \end{aligned}$$

Por lo tanto, si conocemos la f.g.m. de  $X_1, \dots, X_n$ , podemos conocer la f.g.m. de  $\bar{X}$  a través de

$$M_{\bar{X}}(t) = \left( M_X \left( \frac{t}{n} \right) \right)^n$$

**Ejercicios 34** Utilizando el resultado anterior resuelva los siguientes ejercicios:

1. Sea  $X_1, \dots, X_n \stackrel{iid}{\sim} \text{Poisson}(\lambda)$ . Determine la distribución de  $Y = \sum_{i=1}^n X_i$ .
2. Sea  $X_1, \dots, X_n \stackrel{iid}{\sim} N(\mu, \sigma^2)$ . Determine la distribución de  $Y = \frac{1}{n} \sum_{i=1}^n X_i$ .

### 3.7. NOCIONES DE CONVERGENCIA

El objetivo de esta sección es estudiar el comportamiento de una secuencia de variables aleatorias,  $\{Z_1, Z_2, \dots, Z_n\}$ , cuando  $n \rightarrow \infty$ .

**Definición 3.7.1** Sea  $\{Z_n, n \geq 1\}$  una secuencia de variables aleatorias en  $(\Omega, \mathcal{A}, \mathbf{P})$  y sea  $\theta \in \mathbb{R}$  una constante.

Diremos que  $Z_n$  **converge en probabilidad** a  $\theta$  si y sólo si

$$\forall \varepsilon > 0, \quad \mathbf{P}(|Z_n - \theta| \geq \varepsilon) \rightarrow 0, \quad \text{cuando } n \rightarrow \infty$$

Notación:  $Z_n \xrightarrow{P} \theta$

Además, note que  $Z_n \xrightarrow{P} \theta \Leftrightarrow (Z_n - \theta) \xrightarrow{P} 0$

**Definición 3.7.2** Sea  $\{Z_n, n \geq 1\}$  una secuencia de variables aleatorias definidas en  $(\Omega, \mathcal{A}, \mathbf{P})$  y sea  $Z$  otra variable aleatoria cuya distribución no depende de  $n$ , la cual no necesita estar definida sobre el mismo espacio de probabilidad donde se encuentran definidas las  $Z_n$ 's.

Diremos que  $Z_n$  **converge en distribución** para  $Z$  si y sólo si

$$F_{Z_n}(z) = \mathbf{P}(Z_n \leq z) \rightarrow \mathbf{P}(Z \leq z) = F_Z(z)$$

cuando  $n \rightarrow \infty$ ,  $\forall z$  donde  $F_Z$  es continua.

Notación:  $Z_n \xrightarrow{D} Z$  o  $F_{Z_n} \rightarrow F_Z$

Las definiciones anteriores motivan el siguiente teorema:

**Teorema 3.7.1** (del Límite Central)

Sean  $X_1, X_2, \dots, X_n$  una secuencia de variables aleatorias independientes con media  $\mu$  y varianza  $\sigma^2 < \infty$ . Entonces,

$$\sqrt{n} \frac{\bar{X}_n - \mu}{\sigma} \xrightarrow{D} N(0, 1)$$

donde

$$\bar{X}_n = \sum_{i=1}^n \frac{X_i}{n}$$

Aplicación: para  $n$  “suficientemente grande”<sup>3</sup> se cumple que

$$\bar{X}_n \rightarrow N(\mu, \sigma^2/n)$$

<sup>3</sup>Se describe en la literatura que a partir de  $n = 30$  se puede asegurar la convergencia.

**Ejercicios 35** *La distribución de las pérdidas mensuales de una empresa en unidades monetarias (u.m.) es aproximadamente normal, con una media de  $\mu = 3500$  y una varianza de  $\sigma^2 = 184900$ .*

- a) *¿Cuál es la probabilidad de que las pérdidas mensuales sean inferiores a 2500 u.m.?*
- b) *¿Qué valor separa el 5 % inferior de la distribución de las pérdidas mensuales?*
- c) *Describe la distribución de medias muestrales de tamaño 5 tomadas de esta población.*
- d) *¿Qué valor separa el 5 % inferior de la distribución muestral de tamaño 5?*
- e) *Dada una muestra de las pérdidas de 5 meses, ¿cuál es la probabilidad de que las pérdidas mensuales sean inferiores a 2500 u.m.?*
- f) *¿Cuál es la probabilidad de que sólo uno de los cinco meses se tenga una pérdida menor a 2500 u.m.?*

---

# INFERENCIA ESTADÍSTICA

## 4.1. INTRODUCCIÓN

La teoría de la *inferencia estadística* consiste en aquellos métodos por los que se realizan generalizaciones acerca de una población. Estas generalizaciones se basan en los resultados obtenidos en una (o más de una) muestra.

La tendencia actual es la distinción entre el *método clásico* de estimación de un parámetro en la población, por medio del cual las inferencias se basan de manera estricta en información que se obtiene de una muestra aleatoria seleccionada de la población, y el *método bayesiano*, que utiliza el conocimiento subjetivo previo sobre la distribución de probabilidad de los parámetros desconocidos junto con la información que proporcionan los datos de la muestra. En este curso desarrollaremos los métodos clásicos para estimar los parámetros de la población desconocidos

como la media, proporción y varianza mediante el cálculo de estadísticos en muestras aleatorias.

La inferencia estadística se puede dividir en dos áreas principales: estimación y pruebas de hipótesis. La estimación de un parámetro poblacional  $\theta$  puede ser puntual, es decir, por algún método determinamos una fórmula en función de los datos para calcular el valor de éste en la muestra, o intervalar, donde además de calcular el valor del parámetro en la muestra establecemos un grado de precisión de nuestra estimación. Con las pruebas de hipótesis lo que queremos es llegar a la decisión correcta acerca de una hipótesis preestablecida, con alguna medición de la precisión de nuestra decisión.

Algunos conceptos de interés se definen a continuación.

**Definición 4.1.1** Sea  $Z_1, \dots, Z_k$  un muestra aleatoria de la distribución  $N(0, 1)$ .

Sea  $Y = \sum_{i=1}^k Z_i^2$ . Entonces

$$Y = \sum_{i=1}^k Z_i^2$$

tiene distribución **chi-cuadrado de Pearson** con  $k$  grados de libertad y se denota por  $Y \sim \chi_k^2$ .

**Teorema 4.1.1** La esperanza y varianza de una variable aleatoria  $Y$  con distribución  $\chi^2$  están dadas por

$$\begin{aligned} E(Y) &= k \\ V(Y) &= 2k \end{aligned}$$

**Definición 4.1.2** Sea  $Z$  una variable aleatoria con distribución  $N(0, 1)$ , e independiente de ella,  $Y$  una variable aleatoria con distribución  $\chi_k^2$ . Entonces

$$X = \frac{Z}{\sqrt{Y/k}}$$

tiene distribución **t-Student** con  $k$  grados de libertad y se denota por  $X \sim t_k$ .

**Teorema 4.1.2** Si  $X_1, \dots, X_n$  es una muestra aleatoria de  $X \sim N(\mu, \sigma^2)$  entonces:

$$a) \quad \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i, \quad y \quad s^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 \text{ son variables aleatorias independientes.}$$

$$b) \quad \frac{(n-1)s^2}{\sigma^2} \sim \chi_{n-1}^2$$

Queda como desafío para el estudiante la demostración de estas dos afirmaciones.

**Definición 4.1.3** Sean  $X, Y$  dos variables aleatorias independientes que tienen distribución  $\chi^2$  con  $n$  y  $m$  grados de libertad respectivamente, es decir,

$$X \sim \chi_n^2 \text{ e } Y \sim \chi_m^2$$

Entonces la variable aleatoria

$$Z = \frac{X/n}{Y/m}$$

se tiene distribución **F de Fisher** con  $n$  y  $m$  grados de libertad y se denota por  $Z \sim F_{n,m}$ .

## 4.2. ESTIMACIÓN PUNTUAL

**Definición 4.2.1** Un *estimador puntual* de un parámetro  $\theta$  corresponde a cualquier función de la muestra  $g(X_1, X_2, \dots, X_n)$ .

Ejemplos de estimadores puntuales pueden ser el promedio, la mediana, la moda, el promedio entre el mínimo y el máximo, etc.

En principio uno podría utilizar cualquiera de las cantidades anteriores, u otras, pero teniendo en cuenta que queremos aproximarnos al verdadero valor del parámetro, ¿cuál será la mejor cantidad para estimar el parámetro? Veremos entonces dos métodos que proveen estimadores puntuales y además una serie de características que podemos analizar para evaluar la calidad de dichos estimadores.

### 4.2.1. Método de Momentos

**Definición 4.2.2** Sea  $X_1, X_2, \dots, X_n$  una muestra aleatoria de una variable  $X$ , proveniente de una población con función de densidad  $f(x)$ , con

$$\theta = (\theta_1, \theta_2, \dots, \theta_k)$$

El *estimador de momentos*  $\tilde{\theta}$  de  $\theta$  corresponde a la solución del sistema de ecuaciones

$$E(X^j) = \frac{1}{n} \sum_{i=1}^n X_i^j, \quad k = 1, 2, \dots, k,$$

debiéndose plantear tantas ecuaciones como parámetros se desea estimar.

**Ejemplo 4.2.1** Sean  $X_1, \dots, X_n$  variables aleatorias independientes con distribución  $\text{Bin}(k, p)$ . determinar el estimador de momentos para  $p$ .

**Desarrollo:** Notar que si  $X \sim \text{Bin}(k, p)$ ,  $E(X) = kp$  entonces

$$kp = \frac{1}{n} \sum_{i=1}^n X_i \Rightarrow \hat{p} = \frac{1}{nk} \sum_{i=1}^n X_i$$

**Ejercicios 36** Si  $X_1, X_2, \dots, X_n \stackrel{iid}{\sim} f$ , encuentre los estimadores de momentos de los parámetros involucrados si  $f$  es

1.  $U(\theta, 2\theta)$
2.  $N(\mu, \sigma^2)$

### 4.2.2. Método de Máxima Verosimilitud

**Definición 4.2.3** Sean  $X_1, \dots, X_n$  una muestra de una variable  $X$  proveniente de una población con función de probabilidad  $f$ . Se define la **función de verosimilitud** como la función de probabilidad conjunta del vector  $X_1, \dots, X_n$  que está dada por

$$L(\theta, x) = \mathbf{P}(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n)$$

**Ejercicios 37** Si  $X_1, X_2, \dots, X_n \stackrel{iid}{\sim} f$ , encuentre una expresión simplificada para la función de verosimilitud si  $f$  es

- a)  $\exp(\lambda)$
- b)  $\Gamma(\alpha, \beta)$ , con  $\alpha$  conocido.
- c)  $\text{Bin}(n, p)$ , con  $n$  conocido.
- d)  $\text{Poisson}(\lambda)$

**Definición 4.2.4** Un **estimador máximo verosímil, EMV**, de  $\theta$ , basado en una muestra aleatoria de  $X$  corresponde a la solución del sistema

$$\frac{\partial}{\partial \theta_j} \log(L(\theta, x)) = 0 \Big|_{\theta_j = \hat{\theta}_j} \quad j = 1, 2, \dots, k,$$

debiéndose plantear tantas ecuaciones como parámetros se desea estimar.

**Ejemplo 4.2.2** Sea  $X_1, \dots, X_n$  una muestra aleatoria de la distribución Rayleigh, es decir,

$$f(x) = \frac{x}{\theta^2} \exp \left\{ -\frac{x^2}{2\theta^2} \right\}, \quad x > 0, \quad \theta > 0.$$

Determine el estimador de máxima verosimilitud de  $\theta^2$ ,  $\hat{\theta}^2$ .

**Desarrollo:** Planteamos la función de verosimilitud para resolverla en función de  $\hat{\theta}^2$ .

$$\begin{aligned} L(x, \theta^2) &= \prod_{i=1}^n \frac{x_i}{\theta^2} \exp \left\{ -\frac{x_i^2}{2\theta^2} \right\} \\ &= \prod (x_i) \frac{1}{\theta^{2n}} \exp \left\{ -\frac{\sum x_i^2}{2\theta^2} \right\} \\ \log L &= \sum \log(x_i) - 2n \log(\theta) - \frac{\sum x_i^2}{2\theta^2} \\ \frac{d \log L}{d\theta} &= -\frac{2n}{\theta} + \frac{\sum x_i^2}{\theta^3} = 0 \end{aligned}$$

Por lo tanto

$$\hat{\theta}^2 = \frac{1}{2n} \sum x_i^2$$

**Ejercicios 38** Si  $X_1, X_2, \dots, X_n \stackrel{iid}{\sim} f$ , encuentre los estimadores de máxima verosimilitud de los parámetros involucrados si  $f$  es

- a)  $\exp(\lambda)$
- b)  $\Gamma(\alpha, \beta)$ , con  $\alpha$  conocido.
- c)  $\text{Bin}(n, p)$  con  $n$  conocido.
- d)  $\text{Poisson}(\lambda)$

**Definición 4.2.5** Consideremos una familia de distribuciones con parámetro  $\theta \in \Theta$  para una variable aleatoria  $X$  y con función de verosimilitud asociada  $L(\theta, x)$ . Se dice que la log- verosimilitud de  $X$  pertenece a una **familia exponencial** sí y sólo si existen funciones  $\omega_1, \dots, \omega_k \in \Theta$  y  $t_1, \dots, t_k \in \mathbb{R}$ , tales que

$$\log L(\theta, x) = \log h(x) + \log c(\theta) + \sum_{j=1}^k \omega_j(\theta) t_j(x)$$

con  $h$  y  $c$  funciones positivas definidas en  $\mathbb{R}$

### Ejercicios 39

1. Sea la variable aleatoria  $X$  con función densidad

$$f(x) = \begin{cases} \theta(1 - \theta)^{x-1}, & x = 1, 2, \dots, \theta \in (0, 1); \\ 0, & \text{e.o.c.} \end{cases}$$

Determine si  $f(x)$  pertenece a la familia exponencial.

2. Sea  $X_1, \dots, X_n$  una muestra aleatoria de  $X$  cuya densidad es

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma^2} \exp \left\{ -\frac{1}{2\sigma^2}(x - \mu)^2 \right\}$$

con  $x \in \mathbb{R}, \theta = (\mu, \sigma^2), \infty < \mu < \infty, \sigma^2 > 0$ , desconocidos. Determine si esta distribución pertenece a la familia exponencial.



### 4.2.3. Insesgamiento y eficiencia de los estimadores

**Definición 4.2.6** Un estimador puntual  $g(X)$  de  $\theta$  es **insesgado** si  $E(g(X)) = \theta$ . Si  $\hat{\theta}$  no es insesgado, se denomina **sesgo** de  $g(X)$  a

$$b[g(X)] = E(g(X)) - \theta$$

Por lo tanto, un estimador es insesgado si su distribución tiene como valor esperado al parámetro que se desea estimar.

**Ejercicios 40** Si  $X_1, X_2, \dots, X_n \stackrel{iid}{\sim} f$ , determine si los estimadores de momentos y máxima verosimilitud son insesgados para las siguientes funciones:

- a)  $\exp(\lambda)$
- b)  $\Gamma(\alpha, \beta)$ , con  $\alpha$  conocido.
- c)  $\text{Bin}(n, p)$  con  $n$  conocido.
- d)  $\text{Poisson}(\lambda)$

**Definición 4.2.7** El **error cuadrático medio** de un estimador  $g(X)$  de  $\theta$  corresponde a

$$\begin{aligned} \text{ECM}(g(X)) &= E[g(X) - \theta]^2 \\ &= V(g(X)) + (b[g(X)])^2 \end{aligned}$$

**Ejemplo 4.2.3** Sea  $X_1, \dots, X_n \stackrel{iid}{\sim} \exp(1/\theta)$  y consideremos  $\hat{\theta} = \bar{x}$ . Calcule el  $\text{ECM}(\hat{\theta})$ .

**Definición 4.2.8** Se define la matriz de **información de Fisher** para el vector de parámetros  $\theta$  como

$$I(\theta) = E\left(\frac{\partial}{\partial \theta} \log L(\theta, X)\right)^2$$

**Lema 2** Sea la función  $f$  tal que

$$\frac{d}{d\theta} E\left(\frac{\partial}{\partial \theta} \log L(\theta, x)\right) = \int \frac{\partial}{\partial \theta} \left[ \left( \frac{\partial}{\partial \theta} \log f_\theta(x) \right) f_\theta(x) \right] dx$$

entonces,

$$E\left(\frac{\partial}{\partial \theta} \log L(\theta, x)\right)^2 = -E\left(\frac{\partial^2}{\partial \theta^2} \log L(\theta, x)\right)$$

**Teorema 4.2.1** *Cramér - Rao.*

Sea  $X_1, \dots, X_n$  una muestra aleatoria de una variable  $X$  con función densidad  $f$  que satisface la conmutatividad entre el operador integral y diferencial, y sea  $g(X) = g(X_1, \dots, X_n)$  un estimador donde  $E(g(X))$  es diferenciable como función de  $\theta$ . Entonces

$$V(g(X)) \geq \frac{\left( \frac{d}{d\theta} E(g(X)) \right)^2}{E \left( \frac{\partial}{\partial \theta} \log L(\theta, x) \right)^2}$$

Observación: La cantidad de la derecha se llama **cota de Cramér-Rao** y todo estimador que alcance esta cota será llamado **eficiente**.

Es claro que si  $g(X)$  es un estimador insesgado para  $\theta$  entonces se cumple que

$$V(g(X)) \geq \frac{1}{E \left( \frac{\partial}{\partial \theta} \log L(\theta, x) \right)^2}$$

Es decir, la cota de Cramér- Rao es igual a  $I^{-1}(\theta)$ .

**Ejemplo 4.2.4** Sea  $X_1, \dots, X_n$  una muestra aleatoria de  $X$  que tiene función densidad Gama de parámetros  $\alpha$  y  $\lambda$ , donde  $\alpha \in \mathbb{Z}$  es un valor conocido.

Dado el estimador de máxima verosimilitud de  $\beta = 1/\lambda$ ,

$$\hat{\beta} = \frac{1}{n\alpha} \sum_{i=1}^n X_i$$

Determine si  $\hat{\beta}$  alcanza la cota de Cramer-Rao.

**Desarrollo:**

Calculamos primero la primera y segunda derivada de la función de log- verosimilitud para determinar la cota de Cramer-Rao.

$$\begin{aligned} \frac{d \log L(x, \beta)}{d\beta} &= -\frac{n\alpha}{\beta} + \frac{1}{\beta^2} \sum_{i=1}^n x_i \\ \frac{d^2 \log L(x, \beta)}{d\beta^2} &= \frac{n\alpha}{\beta^2} - \frac{2}{\beta^3} \sum_{i=1}^n x_i \end{aligned}$$

Entonces

$$\begin{aligned}
 I(\beta) &= -E \left[ \frac{d^2 \text{Log } L(x, \beta)}{d\beta^2} \right] \\
 &= -\frac{n\alpha}{\beta^2} + \frac{2}{\beta^3} \sum_{i=1}^n E(X_i) \\
 &= -\frac{n\alpha}{\beta^2} + \frac{2}{\beta^3} \sum_{i=1}^n \alpha\beta \\
 &= -\frac{n\alpha}{\beta^2} + \frac{2n\alpha}{\beta^2} = \frac{n\alpha}{\beta^2}
 \end{aligned}$$

La cota de Cramer-Rao es  $I^{-1}(\beta) = \frac{\beta^2}{n\alpha}$ .

Por otro lado, la varianza de  $\hat{\beta}$  es

$$V(\hat{\beta}) = V\left(\frac{1}{n\alpha} \sum_{i=1}^n X_i\right) = \frac{1}{n^2\alpha^2} \sum_{i=1}^n V(X_i) = \frac{1}{n^2\alpha^2} \sum_{i=1}^n \alpha\beta^2 = \frac{\beta^2}{n\alpha}$$

Como  $V(\hat{\beta}) = I^{-1}(\beta)$ , decimos que el estimador  $\hat{\beta}$  alcanza la cota.

**Definición 4.2.9** Un estimador  $g(X)$  de  $\theta$  se dice **eficiente** si

$$\frac{I(\theta)^{-1}}{V(\hat{\theta})} = 1$$

**Teorema 4.2.2** (Principio de Invarianza de los estimadores de máxima verosimilitud)  
Si  $\hat{\theta}$  es el EMV de  $\theta$ , entonces para cualquier función  $g(\theta)$ , el EMV de  $g(\theta)$  es  $g(\hat{\theta})$ .

## Ejercicios 41

Sea  $X_1, \dots, X_n$  una muestra aleatoria con función densidad

$$f(x) = \frac{x}{\theta^2} e^{-x/\theta} \cdot I_{(0, \infty)}(x), \quad \theta > 0$$

- Determine el estimador de momentos y el EMV de  $\theta$ .
- Determine si  $\hat{\theta}$  es insesgado, calcule su varianza y compárela con la cota de Cramér- Rao. ¿Es este estimador eficiente?

### 4.3. ESTIMACIÓN INTERVALAR

Además de las estimaciones puntuales de un parámetro, hay estimaciones por intervalos que estipulan, con un cierto grado de confianza, que el parámetro se encuentra entre dos valores del estadístico estimado. Supongamos una variable aleatoria poblacional  $X$  que tiene media  $\mu$  cuyo valor es desconocido. De una muestra aleatoria de tamaño  $n$ , el valor  $\bar{x}$  de la media muestral  $\bar{X}$  se puede usar para estimar  $\mu$  al 95 % de confianza como sigue:

Definido  $E$ , el margen de error y la significancia  $\alpha$ , tal que

$$\mathbf{P}(\mu - E \leq \bar{x} \leq \mu + E) = 1 - \alpha$$

lo que es equivalente a la ecuación

$$\mathbf{P}(\bar{x} - E \leq \mu \leq \bar{x} + E) = 1 - \alpha$$

Entonces  $(\bar{x} - E, \bar{x} + E)$  se llama intervalo de confianza del  $100(1 - \alpha)\%$  para  $\mu$ .

Formalmente:

**Definición 4.3.1** Un **estimador intervalar** para un parámetro  $\theta$ , dados los valores  $x = (x_1, \dots, x_n)$  de una variable aleatoria  $X$ , es cualquier par de funciones  $L(x_1, \dots, x_n)$  y  $U(x_1, \dots, x_n)$  que satisface  $L(x) \leq U(x)$  para todo  $x$ .

El intervalo aleatorio<sup>1</sup>  $[L(X), U(X)]$  se denomina un **estimador intervalar**.

**Definición 4.3.2** Para un parámetro cualquiera  $\theta$ , se define un **intervalo de confianza**  $1 - \alpha$  como el intervalo  $[L(X), U(X)]$  tal que

$$\mathbf{P}(\theta \in [L(X), U(X)]) = 1 - \alpha$$

La resolución de la ecuación anterior se basa en el cálculo de percentiles, por lo que necesitamos que la variable aleatoria tenga una distribución de probabilidad con parámetros conocidos. Para esto, es de utilidad la siguiente definición.

**Definición 4.3.3** Una variable aleatoria  $Q(X, \theta)$  corresponde a un **pivote** si su distribución no depende de ningún parámetro. Es decir, la distribución de  $Q(X, \theta)$  es la misma, para todo  $\theta$ .

**Ejercicios 42** Si  $X_1, \dots, X_n$  conforman una muestra aleatoria de  $X \sim N(\mu, \sigma^2)$ ,

- Encuentre una cantidad pivotal  $Q$ .
- A partir de lo anterior, construya un intervalo de confianza para la media poblacional.

<sup>1</sup>ya que depende de la variable aleatoria  $X$

### 4.3.1. Intervalo de Confianza para la media

Sea  $X_1, \dots, X_n \stackrel{iid}{\sim} N(\mu, \sigma^2)$ . Un intervalo de confianza para la media poblacional  $\mu$  cuando la varianza poblacional es conocida es

$$\bar{x} \pm E$$

donde  $E = z_{1-\alpha/2} \cdot \sigma / \sqrt{n}$ .

**Ejercicios 43** Una aerolínea necesita estimar el número medio de pasajeros en un vuelo de reciente apertura. Para ello, toma una muestra de 40 días y encuentra una media muestral de 112.0 pasajeros. Suponga que la desviación estándar es 25. Encuentre un intervalo de confianza al 95 % para la media poblacional.

Sea  $X_1, \dots, X_n \stackrel{iid}{\sim} N(\mu, \sigma^2)$ . Un intervalo de confianza para la media poblacional  $\mu$  cuando la varianza poblacional es desconocida es

$$\bar{x} \pm E$$

donde  $E = t_{n-1, 1-\alpha/2} \cdot s / \sqrt{n}$ .

**Ejercicios 44** Se utilizaron 9 sujetos en un experimento para determinar si una atmósfera que implica la exposición a monóxido de carbono (CO) tiene un impacto sobre la capacidad respiratoria. Se presenta la frecuencia respiratoria en número de respiraciones por minuto:

30   45   26   25   34   51   46   32   30

Estime con un 95 % de confianza la frecuencia respiratoria media.

### 4.3.2. Intervalo de Confianza para una proporción

Sea  $Y \sim \text{Bin}(n, p)$ . Por teorema del límite central sabemos que

$$\hat{p} \sim N(E(\hat{p}), V(\hat{p}))$$

Se puede mostrar que  $E(\hat{p}) = p$  y  $V(\hat{p}) = \frac{p(1-p)}{n}$ .

Así, el intervalo de confianza al  $(1 - \alpha)100\%$  para una proporción está dado por

$$\hat{p} \pm E$$

donde  $E = z_{1-\alpha/2} \cdot \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$ .

**Ejercicios 45** En un colegio de enseñanza media hay matriculados 800 alumnos. A una muestra seleccionada aleatoriamente de un 15 % de ellos se les preguntó si utilizaban la cafetería del colegio. Contestaron negativamente un total de 24 alumnos.

- a) Estime con un 95 % de confianza el porcentaje de alumnos que utilizan la cafetería del colegio.
- b) Determine, con una confianza del 99 %, el error máximo cometido con dicha estimación.

### 4.3.3. Intervalo de Confianza para la varianza

Sea  $X_1, \dots, X_n$  una muestra aleatoria de una población normal con media  $\mu$  y varianza  $\sigma^2$ . Un intervalo de confianza para la varianza poblacional  $\sigma^2$  está dado por

$$\left( \frac{(n-1)s^2}{\chi_{(n-1, 1-\alpha/2)}^2}, \frac{(n-1)s^2}{\chi_{n-1, \alpha/2}^2} \right)$$

donde  $s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$ .

**Ejercicios 46** *Un vendedor de muebles de madera para armar (desarmados) importa las piezas desde el norte de Europa para abaratar costos. En cierto modelo, el cliente debe insertar cuatro patas redondas en hoyos ya perforados. Para un ajuste adecuado, el diámetro de las patas debe ser ligeramente menor que un centímetro. Inevitablemente, hay cierta variación en los diámetros de las patas. El vendedor compra patas a un proveedor bajo la especificación de que el diámetro medio debe ser de 0.995 cm y desviación estándar menor que 0.03 cm. Como parte del control de calidad se obtuvo una muestra aleatoria de 121 patas la cual arrojó una media de 0.99516 y desviación estándar de 0.01825. Calcule un IC al 95 % para la desviación estándar del lote.*

En caso de contar dos grupos, puede ser de interés comparar si en promedio se comportan de la misma manera o no, por lo que se presentan a continuación intervalos de confianza para la comparación de parámetros en dos muestras aleatorias.

### 4.3.4. Intervalo de Confianza para la diferencia de medias

Sean  $X_1, \dots, X_n \stackrel{iid}{\sim} N(\mu_X, \sigma_X^2)$  e  $Y_1, \dots, Y_m \stackrel{iid}{\sim} N(\mu_Y, \sigma_Y^2)$ , ambas muestras independientes. Un intervalo de confianza para la diferencia de media entre poblaciones está dado por

$$(\bar{x} - \bar{y}) \pm E$$

donde E cambiará de acuerdo a la información con respecto a la varianza de cada muestra.

Podemos identificar 3 casos:

a)  $\sigma_X^2$  y  $\sigma_Y^2$  conocidas.

$$E = z_{1-\alpha/2} \cdot \sqrt{\frac{\sigma_X^2}{n} + \frac{\sigma_Y^2}{m}}$$

es decir

$$(\mu_X - \mu_Y) \in \left( (\bar{x} - \bar{y}) \pm z_{1-\alpha/2} \cdot \sqrt{\frac{\sigma_X^2}{n} + \frac{\sigma_Y^2}{m}} \right)$$

b)  $\sigma_X^2$  y  $\sigma_Y^2$  desconocidas pero iguales ( $\sigma_X^2 = \sigma_Y^2 = \sigma^2$ ).

Se utiliza el estimador de  $\sigma^2$  dado por

$$s_p^2 = \frac{(n-1)s_X^2 + (m-1)s_Y^2}{n+m-2}$$

con

$$s_X^2 = \frac{1}{n-1} \sum (X_i - \bar{X})^2 \quad y \quad s_Y^2 = \frac{1}{m-1} \sum (Y_i - \bar{Y})^2$$

El margen de error está dado por

$$E = t_{(n+m-2, 1-\alpha/2)} \cdot s_p \sqrt{\frac{1}{n} + \frac{1}{m}}$$

Por lo tanto, el IC para la diferencia de medias cuando las varianzas son iguales pero desconocidas está dado por

$$(\mu_X - \mu_Y) \in \left( (\bar{x} - \bar{y}) \pm t_{(n+m-2, 1-\alpha/2)} \cdot s_p \sqrt{\frac{1}{n} + \frac{1}{m}} \right)$$

c)  $\sigma_X^2$  y  $\sigma_Y^2$  desconocidas y distintas.

Se define

$$E = t_{(\nu, 1-\alpha/2)} \cdot \sqrt{\frac{s_X^2}{n} + \frac{s_Y^2}{m}}$$

donde

$$\nu = \frac{\left( \frac{s_x^2}{n} + \frac{s_y^2}{m} \right)^2}{\frac{(s_x^2/n)^2}{n-1} + \frac{(s_y^2/m)^2}{m-1}}$$

Así, el IC para la diferencia de medias cuando las varianzas son desconocidas y distintas está dado por

$$(\mu_X - \mu_Y) \in \left( (\bar{x} - \bar{y}) \pm t_{(\nu, 1-\alpha/2)} \cdot \sqrt{\frac{s_X^2}{n} + \frac{s_Y^2}{m}} \right)$$

## Ejercicios 47

1. Se realiza un estudio para comparar los contenidos de nicotina de dos marcas de cigarrillos. 10 cigarrillos de la marca A dieron un contenido promedio de nicotina de 3,1ml/gr, con una desviación estándar de 0,5ml/gr, mientras que 8 cigarrillos de la marca B dieron un contenido promedio de nicotina de 2,7ml/gr, con una desviación estándar de 0,7ml/gr. Suponiendo que los datos son muestras aleatorias provenientes de dos poblaciones normales con varianzas iguales, encuentre un IC del 95 % para la verdadera diferencia en el contenido de nicotina de las dos marcas.
2. Una compañía tiene dos departamentos que producen idénticos productos. Se sospecha que las producciones por hora son diferentes en los dos departamentos. Para averiguar esto se consideran muestras aleatorias de horas de producción que proporcionan la siguiente información:

|                |            |                   |                    |
|----------------|------------|-------------------|--------------------|
| Departamento 1 | $n_1 = 64$ | $\bar{x}_1 = 100$ | $\sigma_1^2 = 256$ |
| Departamento 2 | $n_2 = 49$ | $\bar{x}_2 = 90$  | $\sigma_2^2 = 196$ |

Hallar un IC del 95 % para la diferencia verdadera entre las producciones medias de los departamentos. Comente.

#### 4.3.5. Intervalo de Confianza para la comparación de varianzas

Sean  $X_1, \dots, X_n \stackrel{iid}{\sim} N(\mu_X, \sigma_X^2)$  e  $Y_1, \dots, Y_m \stackrel{iid}{\sim} N(\mu_Y, \sigma_Y^2)$ , ambas muestras independientes y de media desconocida. Para comparar las varianzas de ambas muestras podemos utilizar el intervalo de confianza para el cociente  $\sigma_x^2/\sigma_y^2$  dado por

$$\left[ \frac{s_x^2}{s_y^2} \cdot F_{(n-1, m-1, \alpha/2)}, \frac{s_x^2}{s_y^2} \cdot F_{(n-1, m-1, 1-\alpha/2)} \right]$$

**Ejercicios 48** Se realiza un estudio para comparar los contenidos de nicotina de dos marcas de cigarrillos. 10 cigarrillos de la marca A dieron un contenido promedio de nicotina de 3,1ml/gr, con una desviación estándar de 0,5ml/gr, mientras que 8 cigarrillos de la marca B dieron un contenido promedio de nicotina 2,7ml/gr, con una desviación estándar de 0,7ml/gr. Suponiendo que los datos son todos independientes, encuentre un IC del 95 % para la diferencia de varianzas.



## 4.4. PRUEBAS DE HIPÓTESIS

A menudo los datos muestrales sugieren que algo relevante está sucediendo en la población o proceso subyacente. Como suponemos que los datos provienen de una muestra aleatoria y, por lo mismo, están sujetos a cierto grado de variación aleatoria, la pregunta es si el resultado o el efecto aparente en la muestra es una indicación de que algo está sucediendo en la población (o proceso) subyacente o si el resultado observado es posiblemente una casualidad, producto de la variación aleatoria.

Por esta razón es que postulamos una conjetura (o varias) que nos permita estimar si los resultados aparentes en una muestra indican que en realidad algo está pasando. De manera formal, la conjetura puede postular en forma de hipótesis estadística.

**Definición 4.4.1** Una *hipótesis estadística* es una aseveración o conjetura con respecto a una o más poblaciones.

En nuestro caso en particular, una *hipótesis* es una afirmación sobre un parámetro poblacional.

La verdad o falsedad de una hipótesis estadística nunca se sabe con absoluta certeza a menos que examinemos toda la población. Esto, por supuesto, sería poco práctico en la mayoría de las situaciones. En su lugar, tomamos una muestra aleatoria de la población de interés y utilizamos los datos contenidos en esta muestra para proporcionar evidencia que apoye o no la hipótesis. La evidencia de la muestra que es inconsistente con la hipótesis que se establece conduce al rechazo de ésta.

La estructura de la prueba de hipótesis se formulará con el uso del término hipótesis nula ( $H_0$ ), hipótesis que deseamos rechazar. Si esto ocurre, estamos aceptando como verdadera la hipótesis alternativa ( $H_1$ ), que en general escribimos como

$$H_0 : \theta \in \Theta_0 \quad \text{vs} \quad H_1 : \theta \in \Theta_0^c$$

**Definición 4.4.2** Una *prueba de hipótesis* es una regla de decisión que especifica para qué valores de la muestra la decisión es rechazar que  $H_0$  es verdadera.

Para verificar que  $H_0$  es falsa debemos resumir la información de los datos en un **estadístico de prueba**. Este estadístico es una función de los datos y se calcula para ver si la información que entregan los datos es razonablemente compatible con la hipótesis nula.

Para decidir en contra de la hipótesis nula debemos establecer una **región de rechazo**, la cual identificará los valores del estadístico de prueba que son relativamente probables dada la hipótesis nula y los valores que no lo son. ¿En qué valor del estadístico de la prueba comenzamos a decir que los datos apoyan a la hipótesis alternativa? Para contestar esta pregunta se requiere conocer la distribución muestral del estadístico de prueba.

Cuando realizamos una prueba, podemos tomar dos decisiones. Por tanto, podemos cometer dos tipos de error:

**Error de tipo I:** rechazar la hipótesis nula  $H_0$  dado que esta es verdadera.

**Error de tipo II:** no rechazar la hipótesis nula  $H_0$  dado que la hipótesis alternativa  $H_1$  es verdadera.

**Ejemplo 4.4.1** *Determine los errores de tipo I y II.*

- a)  $H_0$ : el acusado es culpable  
 $H_1$ : el acusado es inocente
- b)  $H_0$ : el paciente está enfermo  
 $H_1$ : el paciente está sano

La prueba adecuada sería aquella que minimizara la probabilidad de cometer los dos tipos de error simultáneamente, lo cual, con estadística clásica, es imposible.

En consecuencia, se trata de minimizar la probabilidad de cometer Error de tipo II, sujeto a que la probabilidad de cometer Error de tipo I no exceda un valor predeterminado  $\alpha$ . Este último error es también llamado **nivel de significancia**.

Algunas propiedades importantes respecto de estos errores son:

- Los errores de tipo I y tipo II están relacionados. Una disminución en la probabilidad de uno por lo general tiene como resultado un aumento en la probabilidad del otro.
- El tamaño de la región de rechazo, y por tanto la probabilidad de cometer error tipo I, siempre se puede reducir al ajustar el o los valores críticos.
- Un aumento en el tamaño muestral  $n$  reducirá  $\alpha$  y  $\beta$  (error tipo II) de forma simultánea.
- Si la hipótesis nula es falsa,  $\beta$  es un máximo cuando el valor real de un parámetro se aproxima al valor hipotético. Entre más grande sea la distancia entre el valor real y el valor hipotético, menor será  $\beta$ .

**Definición 4.4.3** La **potencia** de una prueba es la probabilidad de rechazar  $H_0$  dado que una alternativa específica es verdadera y se puede calcular como  $1 - \beta$ .

A pesar de estar fijo, la probabilidad de cometer error de tipo I puede ser calculada y recibe el nombre de *valor-p*.

**Definición 4.4.4** El **valor-p** de una prueba de hipótesis es el menor valor de  $\alpha$  para el cual rechazamos la hipótesis nula.

Calculado este valor, la regla será rechazar la hipótesis nula si  $\text{valor} - p < \alpha$ .

En este curso estudiaremos pruebas de hipótesis para tres parámetros poblacionales: media, varianza y proporción.

#### 4.4.1. Prueba de Hipótesis para la media

Sea  $X_1, \dots, X_n$  una muestra aleatoria de una distribución con media  $\mu$  y varianza  $\sigma^2 > 0$ . Considere las hipótesis generales

$$H_0 : \mu \in \Theta_0 \quad vs \quad H_1 : \mu \in \Theta_0^c$$

Es decir, queremos probar algún valor o rango de valores para la media, cuando la varianza es conocida. La estadística de prueba apropiada se basa en la variable  $\bar{X}$ , que por TCL sabemos distribuye  $N(\mu, \sigma^2/n)$  y que si estandarizamos obtenemos

$$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$$

Entonces distinguiremos tres casos:

| Hipótesis Nula   | Hipótesis Alternativa | Rechazo $H_0$ si            |
|------------------|-----------------------|-----------------------------|
| $\mu = \mu_0$    | $\mu \neq \mu_0$      | $ z_0  \geq z_{1-\alpha/2}$ |
| $\mu \leq \mu_0$ | $\mu > \mu_0$         | $z_0 \geq z_{1-\alpha}$     |
| $\mu \geq \mu_0$ | $\mu < \mu_0$         | $z_0 \leq -z_{1-\alpha}$    |

donde

$$z_0 = \frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}}$$

Sea  $X_1, \dots, X_n$  una muestra aleatoria de una distribución con media  $\mu$ , desconocida y varianza  $s^2 > 0$ . Esto quiere decir que la varianza es estimada en la muestra. Considere las hipótesis generales

$$H_0 : \mu \in \Theta_0 \quad vs \quad H_1 : \mu \in \Theta_0^c$$

Es decir, queremos probar algún valor o rango de valores para la media cuando la varianza es desconocida, por lo que la reemplazamos por  $s^2$ , el estimador insesgado de la varianza. La estadística de prueba apropiada se basa en la variable  $\bar{X}$ , que por TCL sabemos distribuye  $N(\mu, \sigma^2/n)$  y además  $\frac{n-1}{\sigma^2} s^2 \sim \chi^2$ , con las que podemos construir el estadístico

$$Z = \frac{\bar{X} - \mu}{s/\sqrt{n}} \sim t_{(n-1)}$$

Entonces distinguiremos tres casos:

| Hipótesis Nula   | Hipótesis Alternativa | Rechazo $H_0$ si            |
|------------------|-----------------------|-----------------------------|
| $\mu = \mu_0$    | $\mu \neq \mu_0$      | $ t_0  \geq t_{1-\alpha/2}$ |
| $\mu \leq \mu_0$ | $\mu > \mu_0$         | $t_0 \geq t_{1-\alpha}$     |
| $\mu \geq \mu_0$ | $\mu < \mu_0$         | $t_0 \leq -t_{1-\alpha}$    |

donde

$$t_0 = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}$$

### Ejemplo 4.4.2

1. Una muestra aleatoria de 100 muertes registradas en un servicio el año pasado muestra una vida promedio de 71.8 años. Suponga una desviación estándar poblacional de 8.9 años. ¿Se puede considerar esto como un indicador de que la vida media hoy en día es mayor a 70 años? Utilice un nivel de significancia de 5 %.
2. Se afirma que una aspiradora gasta en promedio 46 kilowatt-hora al año. Se toma una muestra aleatoria de 12 hogares que indica que las aspiradoras gastan un promedio de 42 kilowatt-hora al año con una desviación estándar de 11.9 kilowatt-hora, ¿sugiere este hallazgo que las aspiradoras gastan, en promedio, menos de 46 kilowatt-hora anualmente con 5 % de significancia?

### 4.4.2. Prueba de Hipótesis para la proporción

Es de interés probar la hipótesis que la proporción de éxitos de un experimento binomial es igual a un valor específico o está en un rango de valores. Sea  $X$  la variable aleatoria que cuenta el número de éxitos y sea  $\hat{p} = X/n$  la estimación del parámetro  $p$ . Entonces, para  $n$  grande, podemos establecer que

$$Z = \frac{x - np}{\sqrt{np(1-p)}} = \frac{\hat{p} - p}{\sqrt{\frac{p(1-p)}{n}}} \sim N(0, 1)$$

Entonces distinguiremos tres casos:

| Hipótesis Nula | Hipótesis Alternativa | Rechazo $H_0$ si            |
|----------------|-----------------------|-----------------------------|
| $p = p_0$      | $p \neq p_0$          | $ z_0  \geq z_{1-\alpha/2}$ |
| $p \leq p_0$   | $p > p_0$             | $z_0 \geq z_{1-\alpha}$     |
| $p \geq p_0$   | $p < p_0$             | $z_0 \leq -z_{1-\alpha}$    |

donde

$$z_0 = \frac{\hat{p} - p_0}{\sqrt{p_0(1-p_0)/n}}$$

**Ejemplo 4.4.3** Un medicamento que se prescribe actualmente se considera efectivo en un 60 %. Un nuevo fármaco se administró a una muestra aleatoria de 100 personas, de las cuales 70 se aliviaron. ¿Es esta evidencia suficiente para concluir que el nuevo medicamento es superior al que se receta actualmente? Use  $\alpha = 5\%$

### 4.4.3. Prueba de Hipótesis para la varianza

Sea  $X_1, \dots, X_n$  una muestra de una variable aleatoria con distribución  $N(\mu, \sigma^2)$ , ambos parámetros desconocidos. Sabemos que si  $s^2$  es el estimador insesgado de  $\sigma^2$ , es decir,

$$s^2 = \frac{1}{n-1} \sum (x_i - \bar{x})^2$$

entonces

$$\frac{(n-1)s^2}{\sigma^2} \sim \chi^2_{(n-1)}$$

Entonces, si es de interés probar que la varianza poblacional está en un intervalo dado, distinguiremos tres casos:

| Hipótesis Nula             | Hipótesis Alternativa      | Rechazo $H_0$ si                                                        |
|----------------------------|----------------------------|-------------------------------------------------------------------------|
| $\sigma^2 = \sigma_0^2$    | $\sigma^2 \neq \sigma_0^2$ | $Q_0 \geq \chi_{n-1, 1-\alpha/2}^2$ ó $Q_0 \leq \chi_{n-1, \alpha/2}^2$ |
| $\sigma^2 \leq \sigma_0^2$ | $\sigma^2 > \sigma_0^2$    | $Q_0 \geq \chi_{n-1, 1-\alpha}^2$                                       |
| $\sigma^2 \geq \sigma_0^2$ | $\sigma^2 < \sigma_0^2$    | $Q_0 \leq \chi_{n-1, \alpha}^2$                                         |

donde

$$Q_0 = \frac{(n-1)s^2}{\sigma_0^2}$$

**Ejemplo 4.4.4** Se tienen los pesos de 10 paquetes de semillas de pasto distribuidas por cierta compañía, de la cuales se obtuvo  $\bar{x} = 46,12$  y  $s^2 = 0,286$ . La empresa desea saber si los pesos registrados presentan evidencia para asegurar que la varianza poblacional es mayor a 0.2, con un nivel de significancia de 5 %.

#### 4.4.4. Prueba de Hipótesis para la diferencia de medias

Si tenemos dos muestras de tamaño  $n$  y  $m$  de poblaciones independientes,  $X$  e  $Y$ , con medias  $\mu_X$  y  $\mu_Y$ , éstas pueden ser comparadas usando la diferencia  $\mu_1 - \mu_2$ , cuyo estimador es  $\bar{x} - \bar{y}$ . La distribución de esta diferencia dependerá de la información respecto de la relación entre las varianzas poblacionales  $\sigma_X^2$  y  $\sigma_Y^2$ , de los cuales podemos identificar tres casos.

##### Varianzas conocidas.

El estadístico de prueba es

$$\frac{(\bar{X} - \bar{Y}) - d}{\sqrt{\frac{\sigma_X^2}{n} + \frac{\sigma_Y^2}{m}}} \sim N(0, 1)$$

Las hipótesis a contrastar son:

| Hipótesis Nula         | Hipótesis Alternativa  | Rechazo $H_0$ si            |
|------------------------|------------------------|-----------------------------|
| $\mu_X - \mu_Y = d$    | $\mu_X - \mu_Y \neq d$ | $ z_0  \geq z_{1-\alpha/2}$ |
| $\mu_X - \mu_Y \leq d$ | $\mu_X - \mu_Y > d$    | $z_0 \geq z_{1-\alpha}$     |
| $\mu_X - \mu_Y \geq d$ | $\mu_X - \mu_Y < d$    | $z_0 \leq -z_{1-\alpha}$    |

donde

$$Z_0 = \frac{(\bar{x} - \bar{y}) - d}{\sqrt{\frac{\sigma_X^2}{n} + \frac{\sigma_Y^2}{m}}}$$

**Ejemplo 4.4.5** Una muestra aleatoria de tamaño  $n_1 = 25$ , que se toma de una población normal con una desviación estándar  $\sigma_1 = 5,2$ , tiene una media  $\bar{x}_1 = 81$ . Una segunda muestra aleatoria de tamaño  $n_2 = 36$ , que se toma de una población normal diferente con una desviación estándar  $\sigma = 3,4$ , tiene una media  $\bar{x}_2 = 76$ . Pruebe la hipótesis de las medias son iguales con un nivel de significancia del 5 %.

### Varianzas desconocidas pero iguales. $\sigma_X^2 = \sigma_Y^2 = \sigma$ .

Si las varianzas desconocidas debemos estimarlas incorporando el hecho que sean iguales, entonces, dados  $s_X^2$  y  $s_Y^2$ , los estimadores insesgados de  $\sigma_X^2$  y  $\sigma_Y^2$  respectivamente, definimos

$$s_p^2 = \frac{(n-1)s_X^2 + (m-1)s_Y^2}{n+m-2}$$

El estadístico de prueba es

$$\frac{(\bar{X} - \bar{Y}) - d}{s_p \sqrt{\frac{1}{n} + \frac{1}{m}}} \sim t_\nu$$

con  $\nu = n + m - 2$ .

Las hipótesis a contrastar son:

| Hipótesis Nula         | Hipótesis Alternativa  | Rechazo $H_0$ si               |
|------------------------|------------------------|--------------------------------|
| $\mu_X - \mu_Y = d$    | $\mu_X - \mu_Y \neq d$ | $T_0 \geq t_{\nu, 1-\alpha/2}$ |
| $\mu_X - \mu_Y \leq d$ | $\mu_X - \mu_Y > d$    | $T_0 \geq t_{\nu, 1-\alpha}$   |
| $\mu_X - \mu_Y \geq d$ | $\mu_X - \mu_Y < d$    | $T_0 \leq -t_{\nu, 1-\alpha}$  |

donde

$$T_0 = \frac{(\bar{x} - \bar{y}) - d}{s_p \sqrt{\frac{1}{n} + \frac{1}{m}}}$$

**Ejemplo 4.4.6** Una compañía armadora de automóviles grande trata de decidir si compra llantas de la marca A o de la marca B para sus nuevos modelos. Se lleva a cabo un experimento para ayudar a llegar a una decisión en el que se usan 12 llantas de cada marca. Las llantas se utilizan hasta que se acaban. Los resultados son

$$\text{Marca A : } \bar{x}_1 = 37900 \text{ km} \quad s_1 = 5100 \text{ km}$$

$$\text{Marca B : } \bar{x}_2 = 39800 \text{ km} \quad s_2 = 5900 \text{ km}$$

Pruebe la hipótesis que no hay diferencias entre las dos marcas de llantas con un nivel de significancia del 5%, suponiendo que las varianzas poblacionales son iguales.

### Varianzas desconocidas y distintas.

Si las varianzas son desconocidas y distintas, el estimador de la varianza de  $\mu_X - \mu_Y$  es

$$s_p^2 = \frac{s_X^2}{n} + \frac{s_Y^2}{m}$$

El estadístico de prueba es

$$\frac{(\bar{X} - \bar{Y}) - d}{s_p} \sim t_\nu$$

con

$$\nu = \frac{\left( \frac{s_X^2}{n} + \frac{s_Y^2}{m} \right)^2}{\left[ \frac{(s_X^2/n)^2}{n-1} + \frac{(s_Y^2/m)^2}{m-1} \right]}$$

Las hipótesis a contrastar son:

| Hipótesis Nula         | Hipótesis Alternativa  | Rechazo $H_0$ si                 |
|------------------------|------------------------|----------------------------------|
| $\mu_X - \mu_Y = d$    | $\mu_X - \mu_Y \neq d$ | $ T_0  \geq t_{\nu, 1-\alpha/2}$ |
| $\mu_X - \mu_Y \leq d$ | $\mu_X - \mu_Y > d$    | $T_0 \geq t_{\nu, 1-\alpha}$     |
| $\mu_X - \mu_Y \geq d$ | $\mu_X - \mu_Y < d$    | $T_0 \leq -t_{\nu, 1-\alpha}$    |

donde

$$T_0 = \frac{(\bar{x} - \bar{y}) - d}{s_p} \sim t_\nu$$

**Ejemplo 4.4.7** Para el ejemplo anterior, realice la prueba para la hipótesis que las llantas de la marca A son mejores que las de B, suponiendo que las varianzas poblacionales son distintas.

#### 4.4.5. Prueba de Hipótesis para la diferencia de proporciones

Si tenemos dos muestras independientes  $X_1, \dots, X_n$  y  $Y_1, \dots, Y_m$  de poblaciones Bernoulli de parámetros  $p_1$  y  $p_2$ , respectivamente, éstas pueden ser comparadas usando la diferencia  $p_1 - p_2$  utilizando que

$$\frac{(p_1 - p_2) - d}{\sqrt{\frac{p_1(1-p_1)}{n} + \frac{p_2(1-p_2)}{m}}} \sim N(0, 1)$$

Las hipótesis a contrastar son:

| Hipótesis Nula     | Hipótesis Alternativa | Rechazo $H_0$ si            |
|--------------------|-----------------------|-----------------------------|
| $p_1 - p_2 = d$    | $p_1 - p_2 \neq d$    | $ z_0  \geq z_{1-\alpha/2}$ |
| $p_1 - p_2 \leq d$ | $p_1 - p_2 > d$       | $z_0 \geq z_{1-\alpha}$     |
| $p_1 - p_2 \geq d$ | $p_1 - p_2 < d$       | $z_0 \leq -z_{1-\alpha}$    |

donde

$$z_0 = \frac{(\hat{p}_1 - \hat{p}_2) - d}{\sqrt{\frac{\hat{p}_1(1-\hat{p}_1)}{n} + \frac{\hat{p}_2(1-\hat{p}_2)}{m}}}$$

**Ejemplo 4.4.8** En un estudio para estimar la proporción de residentes de cierta ciudad y sus suburbios que están a favor de la construcción de una planta de energía nuclear se encuentra que 63 de 100 residentes urbanos están a favor de la construcción mientras que sólo 59 de 125 residentes suburbanos la favorecen. ¿Hay una diferencia significativa entre las proporción de residentes urbanos y suburbanos que favorecen la construcción de la planta nuclear? Use  $\alpha = 0,05$ .

#### 4.4.6. Prueba de Hipótesis para la comparación de varianzas

Sea  $X_1, \dots, X_n$  una muestra aleatoria de la distribución  $N(\mu_X, \sigma_X^2)$ , independiente de  $Y_1, \dots, Y_m$ , una muestra aleatoria con distribución  $N(\mu_Y, \sigma_Y^2)$ , con todos los parámetros desconocidos. Las varianzas poblacionales pueden ser comparadas usando el cociente  $\sigma_X^2/\sigma_Y^2$ , cuyo estimador es  $s_X^2/s_Y^2$ . Entonces

$$\frac{\sigma_X^2}{\sigma_Y^2} k \sim F_{n-1, m-1}$$

Entonces, si es de interés probar que las varianzas poblacionales están en una razón dada, las hipótesis a contrastar son:

| Hipótesis Nula                                   | Hipótesis Alternativa                            | Rechazo $H_0$ si                                                        |
|--------------------------------------------------|--------------------------------------------------|-------------------------------------------------------------------------|
| $\frac{\sigma_X^2}{\sigma_Y^2} = \frac{1}{k}$    | $\frac{\sigma_X^2}{\sigma_Y^2} \neq \frac{1}{k}$ | $F_0 \geq F_{n-1, n-2, 1-\alpha/2}$ ó $F_0 \leq F_{n-1, n-2, \alpha/2}$ |
| $\frac{\sigma_X^2}{\sigma_Y^2} \leq \frac{1}{k}$ | $\frac{\sigma_X^2}{\sigma_Y^2} > \frac{1}{k}$    | $F_0 \geq F_{n-1, n-2, 1-\alpha}$                                       |
| $\frac{\sigma_X^2}{\sigma_Y^2} \geq \frac{1}{k}$ | $\frac{\sigma_X^2}{\sigma_Y^2} < \frac{1}{k}$    | $F_0 \leq F_{n-1, n-2, \alpha}$                                         |

donde

$$F_0 = \frac{s_X^2}{s_Y^2} k$$

**Ejemplo 4.4.9** Para el ejemplo 4.4.6, determine si las varianzas son iguales o distintas con 2.5 % de confianza.





---

# REGRESIÓN LINEAL

## 5.1. INTRODUCCIÓN

El análisis de la regresión lineal es una técnica estadística que permite estudiar la relación que tienen dos variables. Se utiliza en una amplia variedad de situaciones, y por tanto, en distintas disciplinas.


Por ejemplo, en la investigación social se utiliza para predecir fenómenos relacionados con el comportamiento humano al mismo tiempo que se utiliza para estudiar las ventas o ganancias de una empresa.

El análisis de regresión es una representación de la relación entre dos o más variables a través de una expresión matemática que resume esa relación. Tendremos una variable respuesta que interesa predecir y variables explicativas que intentan predecirla. Algunos ejemplos en el área de la ingeniería:

- a) Modelo para explicar el rendimiento de un proceso químico a través de temperatura, presión, humedad relativa, tiempo de operación, operario que controla el proceso, etc.
- b) Modelo para explicar las retribuciones de los empleados a una empresa a través de la edad, titulación, experiencia, cargo, nivel de responsabilidad, jornada laboral, etc.
- c) Modelo para explicar el precio del alquiler de viviendas en una ciudad a través de superficie, altura, número de habitaciones, orientación, comuna, antigüedad del edificio, etc.
- d) Modelo para explicar el rendimiento académico de los estudiantes a través del curso que realiza, prioridad académica, porcentaje de asistencia a clase, tiempo medio semanal dedicado al estudio, etc.

## 5.2. LA RECTA DE REGRESIÓN

Considere el siguiente diagrama de dispersión bidimensional de la circunferencia de la cabeza en función del periodo de gestación en una muestra de 100 niños con bajo peso.



Se puede observar que la relación entre la edad gestacional y la circunferencia de la cabeza tienen una dependencia positiva, ya que a mayor edad gestacional aumenta la circunferencia de la cabeza.

Como se observa en el gráfico anterior, un diagrama de dispersión entrega una idea aproximada de la relación que tienen ambas variables. También entrega una percepción del grado de correlación lineal que presentan las variables, ya que basta con observar cuánto se ajusta la nube de puntos a una línea recta.

Aun cuando podamos observar esta relación lineal a través de un gráfico de dispersión, es necesario cuantificar esta relación ya que ésta no es perfecta ni tampoco inexistente, encontrándose por lo general en un estado intermedio.

Según el gráfico de dispersión entre la edad gestacional y la circunferencia de la cabeza se puede observar una relación lineal entre ambas variables, pero no podemos decir cuál es la relación entre ellas ni menos decir cómo impacta la medida de la circunferencia de la cabeza si aumentamos la edad gestacional.

Dado que una línea recta posee la forma:

$$y_i = \beta_0 + \beta_1 x_i$$

con  $i = 1, \dots, n$ .

Donde:

- $n$  : número de observaciones.
- $i$  : índice de la observación.
- $Y_i$  : variable dependiente o variable respuesta para la  $i$ -ésima observación.
- $X_i$  : variable independiente o variable explicativa para la  $i$ -ésima observación.

Luego, podemos decir que  $\beta_1$  corresponde a la pendiente de la recta, que indica el cambio que se produce en  $y$  cuando aumenta en una unidad  $x$ . De la misma manera, el coeficiente  $\beta_0$  es el punto donde la recta corta al eje vertical. Conociendo estos coeficientes se puede conocer detalladamente el grado de relación lineal entre las variables.

Idealmente nos gustaría que la relación lineal existente sea perfecta, es decir, la recta pase por todos los puntos. Esto no es posible ya que en una nube de puntos múltiples rectas pueden ser escogidas como una recta de regresión. Entonces, de todas las posibles rectas que se pueden ajustar, ¿cuál es la que mejor se ajusta a los datos? La metodología para seleccionar la “mejor recta” es el **Método de Mínimos Cuadrados** (Gauss y Legendre, 1800).

Si  $y_i$  es el resultado observado de  $Y$  para un valor particular de  $x_i$  e  $\hat{y}_i$  es el punto correspondiente a la recta de ajuste, entonces,

$$e_i = y_i - \hat{y}_i$$

A continuación, debemos escoger un método que reduzca los residuos ( $e_i$ ) tanto como sea posible. Si todos los residuos son iguales a 0, esto implica que todos los puntos caen sobre la recta de mejor ajuste. No obstante, debido a que esto es improbable, elegimos un criterio que reduzca los residuos tanto como sea posible. La suma de los cuadrados de los residuos es:

$$\sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

La recta de regresión de mínimos cuadrados se construye de tal forma que la suma de cuadrados de los errores se reduzca al mínimo. Por lo tanto, minimizamos  $S$ ,

$$S = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

$$\frac{\partial S}{\partial \beta_0} = 0 \implies n\hat{\beta}_0 + \hat{\beta}_1 \sum_{i=1}^n X_i = \sum_{i=1}^n Y_i$$

$$\frac{\partial S}{\partial \beta_1} = 0 \implies \hat{\beta}_0 \sum_{i=1}^n X_i + \hat{\beta}_1 \sum_{i=1}^n X_i^2 = \sum_{i=1}^n X_i Y_i$$

A través de la segunda derivada debe demostrarse que es un mínimo, por lo que obtenemos las estimaciones para  $\beta_0$  y  $\beta_1$ :

$$\hat{\beta}_1 = \frac{\sum_i X_i Y_i - \sum_i X_i \sum_i Y_i / n}{\sum_i X_i^2 - (\sum_i X_i)^2 / n}$$

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}$$

Por otra parte, si definimos  $S_{xx} = \sum_{i=1}^n (X_i - \bar{X})^2$ , y  $S_{xy} = \sum_{i=1}^n (Y_i - \bar{Y})(X_i - \bar{X})$ , entonces la estimación de  $\beta_1$  se puede re-escribir como sigue:

$$\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}}$$

Dado que definimos  $e_i = y_i - \hat{y}_i$ , la variación de los datos en torno a la media puede descomponerse de la siguiente manera:

$$Y_i - \bar{Y} = (Y_i - \hat{Y}_i) + (\hat{Y}_i - \bar{Y})$$

Si sumamos y elevamos al cuadrado a ambos lados (el término cruzado es igual a cero), se obtiene:

$$\begin{array}{ccccc} \sum_{i=1}^n (Y_i - \bar{Y})^2 & = & \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 & + & \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2 \\ \downarrow & & \downarrow & & \downarrow \\ \boxed{SCT} & & \boxed{SCReg} & & \boxed{SCE} \end{array}$$

Donde:

SCT: suma de cuadrados totales.

SCReg.: suma de cuadrados de la regresión.

SCE: suma de cuadrados de los residuos.

Puede demostrarse que (queda propuesto para el alumno):

$$SCReg = \hat{\beta}_1^2 \cdot S_{xx} = \frac{S_{xy}^2}{S_{xx}}$$

### 5.3. BONDAD DE AJUSTE

Siempre es útil conocer el grado en que la recta ajustada se adapta a la nube de puntos. Para ello debe cuantificarse este ajuste, lo que se realiza con el coeficiente de determinación de la regresión denominado  $R^2$ .

$R^2$  mide la proporción de la varianza de la variable  $Y$  explicada por la variable  $X$ . Es una medida de estandarizada que toma valores entre 0 y 1.

Cuando  $R^2$  es cero o cercano a cero indica que la variabilidad de  $Y$  es explicada por el error y no por  $X$ . Por el contrario, cuando  $R^2$  es 1 o cercano a 1, la variabilidad de  $Y$  es explicada por la variable  $X$ .

Finalmente, el coeficiente de determinación se define como:

$$R^2 = \frac{SCR}{SCT} = \frac{SCT - SCE}{SCT} = 1 - \frac{SCE}{SCT}$$

Se puede demostrar que  $R^2$  es igual al cuadrado del coeficiente de correlación entre la variable  $Y$  y la variable  $X$ .

### Ejemplo 5.3.1

1. Los siguientes valores corresponden a las edades de un grupo de personas que practican tenis y al peso en kg. de los mismos deportistas.

|        |    |    |    |    |    |    |    |    |    |    |
|--------|----|----|----|----|----|----|----|----|----|----|
| Edades | 18 | 26 | 28 | 34 | 42 | 48 | 52 | 54 | 60 | 36 |
| Peso   | 54 | 64 | 54 | 62 | 70 | 76 | 66 | 76 | 74 | 68 |

- (a) Encuentre la recta de regresión.  
 (b) Calcule el  $R^2$ .

#### Desarrollo:

- (a) La resta de regresión tiene la siguiente forma:

$$y_i = \beta_0 + \beta_1 x_i + e_i$$

Con

$$\hat{\beta}_0 = \bar{y} - \bar{x}\hat{\beta}_1$$

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

Si reemplazamos los valores entregados en la tabla tenemos que:

$$\hat{\beta}_1 = 0,499 \quad \hat{\beta}_0 = 46,5$$

Luego, la recta de regresión es:

$$\hat{y}_i = 46,5 + 0,499x_i$$

- (b) Para obtener el  $R^2$  debemos obtener la suma de cuadrados de la regresión y la suma de cuadrados totales:

$$SCR = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 = 419,9$$

$$SCT = \sum_{i=1}^n (y_i - \bar{y})^2 = 590,4$$

Por lo tanto, el  $R^2 = \frac{SCR}{SCT} = 0,71$ , lo que indica que este modelo explica el 71 % de la variabilidad de los datos.


2. Se presentan los siguientes datos sobre  $x = \%$  de absorción de luz a 5800Å e  $y = \text{pick de fotovoltaje}$ :

|     |      |      |      |      |      |      |      |      |      |
|-----|------|------|------|------|------|------|------|------|------|
| $x$ | 4.0  | 8.7  | 12.7 | 19.1 | 21.4 | 24.6 | 28.9 | 29.8 | 30.5 |
| $y$ | 0.12 | 0.28 | 0.55 | 0.68 | 0.85 | 1.02 | 1.15 | 1.34 | 1.29 |

- Construya una gráfica de dispersión de estos datos. ¿Qué sugiere?
- Obtenga la ecuación de la recta de regresión estimada suponiendo que el modelo de regresión lineal simple es apropiado.
- ¿Qué proporción de la variación observada en pico de fotovoltaje se puede explicar por el modelo de regresión?
- Pronostique el pico de fotovoltaje cuando el porcentaje de absorción sea 19.1 y calcule el valor del residuo correspondiente.

**Desarrollo:**

- Observando el gráfico de dispersión siguiente se sugiere que hay una asociación lineal entre el  $\%$  de absorción de luz y el pick de fotovoltaje.



- La ecuación de la recta estimada

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} \quad y \quad \hat{\beta}_1 = \frac{S_{xy}}{S_{xx}}$$

con la información proporcionada, se obtienen los promedios de  $x$  e  $y$ , resultando:

$$\bar{y} = 0,8088889 \quad y \quad \bar{x} = 19,96667$$

Luego, obtenemos las estimaciones de los parámetros como sigue:

$$S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2 = 746,4$$

$$S_{yy} = \sum_{i=1}^9 (y_i - \bar{y})^2 = 1,514089$$

$$S_{xy} = \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) = 33,32567$$

Resultando finalmente la siguiente recta:

$$\hat{\beta}_0 = -0,08259353 \quad y \quad \hat{\beta}_1 = 0,04464854$$

$$\hat{y}_i = -0,08259353 + 0,04464854 \cdot x_i$$

(c) Se pide la definición de  $R^2$ , que se obtiene de la siguiente forma:

$$R^2 = \frac{SS_R}{S_{yy}} = 1 - \frac{SS_E}{S_{yy}}$$

Donde:

$$\begin{aligned} SS_E &= S_{yy} - \hat{\beta}_1 S_{xy} \\ &= 1,514089 - 0,04464854 \cdot 33,32567 \\ &= 0,02614669 \end{aligned}$$

Por lo tanto

$$\begin{aligned} R^2 &= 1 - \frac{0,02614669}{1,514089} \\ &= 0,9827311 \\ &\approx 98,27\% \end{aligned}$$

(d) El pronóstico cuando el porcentaje de absorción es de 19,9 se calcula con la recta estimada reemplazando el valor dado

$$\begin{aligned} \hat{y} &= -0,08259353 + 0,04464854 \cdot 19,1 \\ &= 0,7701936 \end{aligned}$$

Por lo tanto,

|      |      |           |
|------|------|-----------|
| $x$  | $y$  | $\hat{y}$ |
| 19,1 | 0,68 | 0,7701936 |

Entonces, el residuo se obtiene de restar la diferencia entre el valor observado y el valor estimado,

$$e = 0,68 - 0,7701936 = -0,0901936$$



## Ejercicios 49

1. Los siguientes valores corresponden a las edades de un grupo de personas que practican tenis de mesa y al peso en kg. de los mismos.

|        |    |    |    |    |    |    |    |    |    |    |
|--------|----|----|----|----|----|----|----|----|----|----|
| Edades | 18 | 26 | 28 | 34 | 42 | 48 | 52 | 54 | 60 | 36 |
| Peso   | 54 | 64 | 54 | 62 | 70 | 76 | 66 | 76 | 74 | 68 |

- (a) Indique cuál es la variable respuesta y la variable explicativa.  
 (b) Encuentre la recta de regresión.  
 (c) Calcule el  $R^2$ .  
 (d) ¿Cuál recta de regresión ajustada es apropiada para los datos?

2. Suponga que se tiene interés en ajustar un modelo de regresión lineal simple de la forma:

$$Y_i = \beta_0 + \beta_1 x_i + e_i, \quad i = 1, \dots, n$$

- (a) Encuentre el estimador de mínimos cuadrados de  $\beta_1$ .  
 (b) ¿Cuál es la varianza del estimador encontrado en el inciso (a)?

3. Se presentan los siguientes datos sobre  $x = \%$  de absorción de luz a 5800Å e  $y = \text{pick de fotovoltaje}$ :

|     |      |      |      |      |      |      |      |      |      |
|-----|------|------|------|------|------|------|------|------|------|
| $x$ | 4.0  | 8.7  | 12.7 | 19.1 | 21.4 | 24.6 | 28.9 | 29.8 | 30.5 |
| $y$ | 0.12 | 0.28 | 0.55 | 0.68 | 0.85 | 1.02 | 1.15 | 1.34 | 1.29 |

- (a) Construya una gráfica de dispersión de estos datos. ¿Qué sugiere?  
 (b) Obtenga la ecuación de la recta de regresión estimada suponiendo que el modelo de regresión lineal simple es apropiado.  
 (c) ¿Qué proporción de la variación observada en pico de fotovoltaje se puede explicar por el modelo de regresión?  
 (d) Pronostique el pico de fotovoltaje cuando el porcentaje de absorción sea 19.1 y calcule el valor del residuo correspondiente.

4. Un gerente de una empresa automotriz piensa que si aumentan el porcentaje de comisión pagada al vendedor de automóviles, la venta aumenta. Para verificar este supuesto se realizó un estudio sobre 15 concesionarios similares. Sean:

$X$ : comisiones pagadas a vendedores de autos en un mes %.

$Y$ : Ganancias netas por ventas, en el mismo mes en millones de \$.

- (a) Construya una gráfica de dispersión de estos datos. ¿Qué sugiere?
- (b) Obtenga la ecuación de la recta de regresión estimada.
- (c) ¿Qué puede concluir al respecto? Diría usted que la recta se ajusta bien a los datos?

| Obs | 1    | 2    | 3    | 4    | 5    | 6    | 7   | 8    | 9   | 10   | 11   | 12   | 13   | 14   | 15   |
|-----|------|------|------|------|------|------|-----|------|-----|------|------|------|------|------|------|
| X   | 3.6  | 5.2  | 5.3  | 7.3  | 5.0  | 5.2  | 3.0 | 3.1  | 3.2 | 7.5  | 8.3  | 6.1  | 4.9  | 5.8  | 7.1  |
| Y   | 11.3 | 14.7 | 18.5 | 20.0 | 12.4 | 15.4 | 9.6 | 11.3 | 8.1 | 27.9 | 24.6 | 18.8 | 13.9 | 12.1 | 23.7 |



---

# CONTROL DE CALIDAD

## 6.1. INTRODUCCIÓN

Definimos el “Control Estadístico de la Calidad” como la aplicación de diferentes técnicas estadísticas a procesos industriales (mano de obra, materias primas medidas, máquinas y medio ambiente), procesos administrativos y/o servicios con objeto de verificar si todas y cada una de las partes del proceso y servicio cumplen con ciertas exigencias de calidad y así ayudar a cumplirlas, entendiendo por calidad “la aptitud del producto y/o servicio para su uso”.

La aplicación de técnicas estadísticas al control está basada en el estudio y evaluación de la variabilidad existente en cualquier tipo de proceso que es principalmente el objeto de la Estadística.

### **Causas de las variaciones.**


*Causas no asignables o aleatorias:* debidas al azar, no son identificables y no pueden ser reducidas o eliminadas. Producen variaciones pequeñas.

*Causas asignables:* identificables y que deben ser eliminadas. Producen variaciones grandes.

En función de las causas de las variaciones se establecen los objetivos del Control Estadístico de Calidad, que son los siguientes:

1. Detectar rápidamente la ocurrencia de variabilidad debida a causas asignables.
2. Investigar la(s) causa(s) que la han producido y eliminarla(s).
3. Informar de ella para la toma de decisión oportuna, pues de lo contrario se producirían gran cantidad de unidades de calidad no aceptable, originando una disminución de la capacidad productiva e incremento de costos del producto terminado (supervisor).
4. Eliminar, si es posible, o al menos reducir al máximo la variabilidad del proceso (dirección).

Los métodos de control de calidad se clasifican a través del control estadístico de procesos y en muestro de aceptación.




## 6.2. DEFINICIONES

### Gráficos de Control

Son una herramienta estadística utilizada para detectar variaciones de la calidad de un producto durante un proceso de fabricación.

### Estructura de un gráfico de control

Los gráficos de control de calidad tienen la siguiente estructura:



Lo primero que se debe observar es que este gráfico tiene una línea superior llamada límite superior de control denotada como LS y una línea inferior denotada como LI. La línea central corresponde a la media de la característica que se desea controlar.

### Proceso bajo control

Un proceso bajo control es simplemente aquel cuyo comportamiento con respecto a la variación

es estable en el tiempo. Hay que destacar que “bajo control” no significa que “satisface las especificaciones” o “tolerancia de diseño”. La magnitud de una variación natural puede ser tal que el porcentaje de piezas que se apeguen a las especificaciones sea mucho mayor de lo que se pueda tolerar. En tales casos, puede ser necesaria una reestructuración importante del proceso para mejorar la capacidad de éste.

Hay una fuerte analogía entre la lógica de una gráfica de control y el trabajo previo de pruebas de hipótesis. La hipótesis nula es el proceso está bajo control.

Cuando un proceso bajo control da un punto fuera de los límites de control (una señal fuera de control), ha ocurrido un Error de Tipo I. Por otra parte, un Error de Tipo II ocurre cuando un proceso fuera de control produce un punto dentro de los límites del control.

La apropiada selección del tamaño de muestra y límites de control (región de rechazo) hará que las probabilidades de error asociadas sean adecuadamente pequeñas.

Luego, mediante un gráfico de control se permite determinar si un proceso está bajo o fuera de control. Entonces, se dice que un gráfico está:

- **Bajo control** cuando hay variaciones aleatorias.
- **Fuera de control** si hay variaciones debidas a causas asignables.

## 6.3. CONTROL DE FABRICACIÓN POR VARIABLES

### 6.3.1. Gráfica $\bar{X}$ basada en valores conocidos de los parámetros

Debido a que hay incertidumbre acerca del valor de la variable para cualquier pieza o espécimen particular, se denota  $X$  v.a. Suponga que para un proceso bajo control,  $X$  tiene una distribución normal con  $\mu$  y  $\sigma$  como media y varianza respectivamente.

Si  $\bar{X}$  es la media muestral para una m.a. de tamaño  $n$  seleccionada en un punto de tiempo en particular, se sabe que:

- i)  $E(\bar{X}) = \mu$
- ii)  $S(\bar{X}) = \frac{\sigma}{\sqrt{n}}$

Luego, se deduce que:

$$P(\mu - 3\sigma\bar{x} \leq \bar{X} \leq \mu + 3\sigma\bar{x}) = P(-3 \leq Z \leq 3) = 0,9974$$

Es entonces muy probable que para un proceso bajo control, la media muestral caerá dentro de 3 desviaciones estándar para la media del proceso. Este rango es el usual, pero claramente puede ser modificado.

Ahora, asuma que se conocen los valores de  $\mu$  y  $\sigma$ . Suponga que en cada uno de los puntos de

tiempo 1, 2, 3, ..., existe una muestra aleatoria de tamaño  $n$ .

Denote  $\bar{x}_1, \bar{x}_2, \bar{x}_3, \dots$ , los valores calculados de las medias muestrales correspondientes. Resulta una gráfica  $\bar{X}$  de graficar las  $\bar{x}_1, \bar{x}_2, \bar{x}_3, \dots$  en el tiempo. Es decir, pares ordenados de:

$$(1, \bar{x}_1)(2, \bar{x}_2)(3, \bar{x}_3) \dots$$

Luego, se trazan las rectas horizontales, calculando los límites inferior y superior de control, como sigue:

$$\begin{aligned} LIC &= \text{límite de control inferior} = \mu - 3 \cdot \sigma / \sqrt{n} \\ LSC &= \text{límite de control superior} = \mu + 3 \cdot \sigma / \sqrt{n} \end{aligned}$$

Este gráfico se llama con frecuencia “Gráfica 3 sigma”. Cualquier punto fuera de los límites de control sugiere que el proceso puede haber estado fuera de control en ese tiempo.

### 6.3.2. Gráfica $\bar{X}$ basada en parámetros estimados

Frecuentemente se desconocen los valores de  $\mu$  y  $\sigma$ , de modo que deben estimarse a partir de los datos muestrales antes de determinar los límites de control.

Denote:

- $n$ : el número de observaciones de cada muestra.
- $k$ : número de muestras disponibles.

Los valores típicos de  $n$  son 3, 4, 5, o 6 y se recomienda que  $k$  sea al menos 20. Se supone que las  $k$  muestras se recogieron en un período cuando se pensaba que el proceso estaba bajo control.

Luego,  $\bar{x}_1, \bar{x}_2, \bar{x}_3, \dots, \bar{x}_k$  corresponden a las  $k$  medias muestrales, donde la estimación habitual de  $\mu$  es el promedio de estas medias.

Es decir,

$$\hat{\mu} = \bar{\bar{x}} = \frac{1}{k} \sum_{i=1}^k \bar{x}_i$$

Ahora, para la estimación de  $\sigma$ , se presentan dos métodos diferentes. Uno de ellos se basa en las  $k$  desviaciones estándar muestrales y el otro en los  $k$  rangos muestrales.

En el caso de una población de distribución normal, el estimador de  $\sigma$  basado en  $S$  es insesgado y tiene una varianza más pequeña que el estimador basado en rango muestral. El primer estimador es más eficiente que el último.

La pérdida de eficiencia para el estimador es ligera cuando  $n$  es muy pequeño, pero se hace importante cuando  $n \geq 4$ .

Luego, tenemos que los límites de control basados en las desviaciones estándar muestrales son:

$$LIC = \bar{x} - 3 \cdot \bar{S} / (a_n \sqrt{n})$$

$$LSC = \bar{x} + 3 \cdot \bar{S} / (a_n \sqrt{n})$$

Donde

$$\bar{x} = \sum_{i=1}^n \frac{\bar{x}_i}{k}, \quad \bar{S} = \sum_{i=1}^n \frac{\bar{S}_i}{k}$$

y

$$a_n = \frac{(\sqrt{2\Gamma(n/2)})}{\sqrt{(n-1)\Gamma((n-1)/2)}}$$

| N     | 3     | 4     | 5     | 6     | 7     | 8     |
|-------|-------|-------|-------|-------|-------|-------|
| $a_n$ | 0.886 | 0.921 | 0.940 | 0.952 | 0.959 | 0.965 |

Note que si  $X_1, X_2, \dots, X_n$  forman una muestra aleatoria con distribución normal, se puede obtener una estimación de  $\sigma$  basada en el **rango muestral** dada por

$$\hat{\sigma} = \frac{1}{k} \sum_{i=1}^k \frac{r_i}{b_n} = \frac{\bar{r}}{b_n}$$

| n     | 3     | 4     | 5     | 6     | 7     | 8     |
|-------|-------|-------|-------|-------|-------|-------|
| $b_n$ | 1.693 | 2.058 | 2.325 | 2.536 | 2.706 | 2.844 |

Luego, tenemos que los límites de control basados en los rangos muestrales son:

$$LIC = \bar{x} - 3 \cdot \bar{r} / (b_n \sqrt{n})$$

$$LSC = \bar{x} + 3 \cdot \bar{r} / (b_n \sqrt{n})$$

Donde

$$\bar{r} = \sum_{i=1}^k \frac{\bar{r}_i}{k}$$

y  $r_1, r_2, \dots, r_k$  son los rangos de las  $k$  muestras.



## 6.4. CONTROL DE FABRICACIÓN POR ATRIBUTOS

El término **datos de atributos** se usa en Control de Calidad para describir dos situaciones:

- 1) Cada pieza producida es defectuosa o no defectuosa (se apega o no se apega a las especificaciones).
- 2) Una sola pieza puede tener uno o más defectos, y el número de defectos se contabiliza.

En el primer caso, una gráfica de control está basada en la distribución binomial; en el segundo caso, distribución Poisson.

### 6.4.1. Gráfica $p$ para fracción defectuosa

Suponga que cuando un proceso está bajo control, la probabilidad de que cualquier pieza sea defectuosa es  $p$  y que diferentes piezas son independientes una de otra con respecto a sus condiciones.

Considere una muestra de  $n$  piezas obtenidas en un tiempo dado, y sea  $X$  el número de las piezas defectuosas y  $\hat{p} = \frac{X}{n}$ .

Dado que  $X$  tiene distribución binomial,  $E(X) = np$  y  $Var(X) = p(1 - p)$ .

Luego,  $E(\hat{p}) = p$  y  $Var(\hat{p}) = \frac{p(1-p)}{n}$

Además, si  $np \geq 10$  y  $n(1 - p) \geq 10$ ,  $\hat{p}$  tiene, aproximadamente, distribución normal.

En el caso de  $p$  conocida (o una gráfica basada en un valor objetivo), los límites de control son:

$$LIC = p - 3 \cdot \sqrt{\frac{p(1-p)}{n}}$$

$$LSC = p + 3 \cdot \sqrt{\frac{p(1-p)}{n}}$$

Si cada muestra está formada por  $n$  piezas, el número de piezas defectuosas de la  $i$ -ésima muestra es  $x_i$  y  $\hat{p}_i = \frac{x_i}{n}$ , entonces  $\hat{p}_1, \hat{p}_2, \hat{p}_3, \dots$ , los que se grafican en la gráfica de control.

Generalmente el valor de  $p$  debe estimarse a partir de los datos. Suponga que dispone de  $k$  muestras de lo que se piensa que es un proceso bajo control y que  $\hat{p} = \sum \frac{\hat{p}_i}{k}$ .

La estimación  $\hat{p}$  se utiliza en lugar de  $p$ , luego:

$$LIC = \hat{p} - 3 \cdot \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$$

$$LSC = \hat{p} + 3 \cdot \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$$

Si el límite inferior es negativo, se sustituye por cero.

### 6.4.2. Gráfica $c$ para el número de defectos

En este caso, se consideran situaciones donde la observación de cada punto en el tiempo es el número de defectos en una unidad de tiempo. La unidad puede consistir de una sola pieza (un automóvil) o un grupo de piezas (defectos en un conjunto de 4 llantas).

La gráfica de control para número de defectos está basada en la distribución de probabilidad Poisson.

Entonces:

$Y$  es una v.a. Poisson con parámetro  $\lambda$ , luego la  $E(Y) = V(Y) = \lambda$ .

Además,  $Y$  tiene, aproximadamente, distribución normal cuando  $\lambda$  es grande ( $\lambda > 10$ ). Si  $Y_1, Y_2, \dots, Y_n$  son variables aleatorias Poisson independientes con parámetros  $\lambda_1, \lambda_2, \dots, \lambda_n$  se puede demostrar que  $Y_1 + Y_2 + \dots + Y_n$  tiene una distribución Poisson con parámetro  $\lambda_1, \lambda_2, \dots, \lambda_n$ .

Luego, la gráfica  $c$  para el número de defectos en una unidad tiene línea de centro en  $\bar{x}$  y

$$LIC = \bar{x} - 3 \cdot \sqrt{\bar{x}}$$

$$LSC = \bar{x} + 3 \cdot \sqrt{\bar{x}}$$

Si el límite inferior es negativo, se sustituye por cero.

## 6.5. CONSTRUCCIÓN DE UN GRÁFICO DE CONTROL

**Paso 1:** Se seleccionan  $k$  muestras de tamaño  $n$ .

**Paso 2:** En cada muestra se cuenta el número de defectos presentes (suma de todos los defectos que tengan las piezas de la muestra),  $x_i$ .

**Paso 3:** Se calcula el promedio de defectos por muestra.

**Paso 4:** Se calculan los límites de control.

La interpretación y análisis de estos gráficos de control por variables se realiza a partir del estudio de los siguientes apartados:

- Puntos situados fuera de los límites de control
- Distribución dentro de los límites de control
- Tramos o tendencias

### Ejemplo 6.5.1

1. En una fábrica que produce tuberías se han medido los diámetros (en mm) de 16 tuberías. En la siguiente tabla se muestran los datos obtenidos a lo largo de 8 intervalos de muestreo sucesivo, en cada uno de los cuales se han seleccionado al azar 2 tuberías para medir sus diámetros  $X_{t1}$  y  $X_{t2}$ . Realice el gráfico de control.

| Intervalo ( $t$ ) | $X_{t1}$ | $X_{t2}$ |
|-------------------|----------|----------|
| 1                 | 80       | 82       |
| 2                 | 83       | 81       |
| 3                 | 81       | 80       |
| 4                 | 79       | 80       |
| 5                 | 81       | 79       |
| 6                 | 80       | 80       |
| 7                 | 81       | 81       |
| 8                 | 79       | 81       |

- (a) Asumiendo que los datos vienen de una  $Normal(80,2)$ , realice el gráfico del control de la media. Interprete.
- (b) Dado que se desconoce la distribución, realice un gráfico del control de la media y un control del rango. Interprete. (Indicación: Utilice  $a_2 = 1,13$  para la media y  $b_n = 1,32$  para el rango)
- (c) En ambos gráficos, determine si existe racha, tendencia, periodicidad, inestabilidad y/o superestabilidad.

#### Desarrollo:

El primer paso es determinar los promedios y los rangos de cada intervalo. Así se obtiene lo siguiente:

| Intervalo ( $t$ ) | 1  | 2  | 3    | 4    | 5  | 6  | 7  | 8  |
|-------------------|----|----|------|------|----|----|----|----|
| $\bar{X}$         | 81 | 82 | 80.5 | 79,5 | 80 | 80 | 81 | 80 |
| Rango             | 2  | 2  | 1    | 1    | 2  | 0  | 0  | 2  |


- (a) La información histórica dice que  $X \sim N(80,2)$ , por lo tanto, asintóticamente se tiene la distribución muestral que  $\bar{X} \sim N(80,2/2)$ . Por lo tanto, se tiene que  $\mu = 80, \sigma_{\bar{X}} = 1$ . Luego, los límites del gráfico son:

$$L. Inf = \mu - \sigma_{\bar{X}} = 80 - 1 = 79$$

$$L. Cen = \mu = 80$$

$$L. Sup = \mu + \sigma_{\bar{X}} = 80 + 1 = 81$$

Ahora, se procede a graficar los promedios con los límites obtenidos y resulta lo siguiente



Vemos que la información histórica muestra que todas las observaciones pertenecen al intervalo del control de calidad.

- (b) En este caso, no tenemos información de la distribución y por tanto debemos realizar las estimaciones necesarias. Para el gráfico de la media, necesitamos determinar:

$$Lim = \bar{X} \pm 3 \cdot \hat{\sigma}_{\bar{X}}$$

Entonces,

$$L.Cent = \bar{X} = \frac{1}{8} \sum_{i=1}^8 \bar{X}_i = 80,5$$

$$\bar{R} = \frac{1}{8} \sum_{i=1}^8 R_i = 1,25$$

Luego, para determinar la varianza estimada, sabemos que:

$$\hat{\sigma}_x = \frac{\bar{R}}{a_2} \quad y \quad \hat{\sigma}_{\bar{X}} = \frac{\hat{\sigma}_x}{\sqrt{n}} = \frac{\bar{R}}{a_2 \sqrt{n}}$$

Y por tanto los límites son

$$L.Inf = \bar{X} - 3\sigma_{\bar{X}} = 80,5 - 3 \cdot 0,78 = 78,15$$

$$L.Cen = \bar{X} = 80,5$$

$$L.Sup = \bar{X} + 3\sigma_{\bar{X}} = 80,5 + 3 \cdot 0,78 = 82,85$$

Y el gráfico resulta como sigue:



Vemos que la media se movió a 80,5 y el intervalo se redujo, puesto que la información utilizada es la contenida en la muestra.


Para el gráfico del rango, utilizaremos el promedio del rango, que ya lo tenemos ( $\bar{R} = 1,25$ ). Ahora, los intervalos son:

$$\begin{aligned} L.Inf &= \bar{R} - 3\sigma_R \\ L.Cen &= \bar{R} = 1,25 \\ L.Sup &= \bar{R} + 3\sigma_R \end{aligned}$$

donde,

$$\sigma_R = \frac{\bar{R}}{b_2} = \frac{1,25}{1,32} = 0,94$$

Y por lo tanto, el gráfico de los rangos se ve como sigue:



Donde los puntos están en el control de calidad.

- (c) *Racha*: 7 o más puntos consecutivos a un mismo lado de la línea central (sobre la línea, o bajo la línea).
- Tendencia*: 7 o más puntos en orden creciente o decreciente.
- Periodicidad*: Se repite el mismo patrón de puntos en períodos de longitud fija (cíclicos).
- Inestabilidad*: Fluctuaciones cerca de los límites.
- Superestabilidad*: 16 puntos o más entre  $\pm\sigma$ , o muy cerca de la línea central.

2. Un pequeño restaurante de carretera ha recogido, todos los meses durante dos años, el número de quejas que ha recibido en relación a los servicios que presta:

| 2013   | Ene | Feb | Mar | Abr | May | Jun | Jul | Ago | Sep | Oct | Nov | Dic |
|--------|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|
| Quejas | 3   | 1   | 4   | 6   | 2   | 4   | 6   | 4   | 0   | 4   | 7   | 3   |
| 2014   | Ene | Feb | Mar | Abr | May | Jun | Jul | Ago | Sep | Oct | Nov | Dic |
| Quejas | 4   | 11  | 3   | 4   | 1   | 6   | 3   | 4   | 4   | 0   | 3   | 4   |

Realice un gráfico de control e indique si el proceso se encuentra bajo control o no.

### Desarrollo:

Dado que los datos son de conteo, entonces podemos suponer que el número de quejas sigue una distribución de Poisson con tasa  $\lambda$ . La particularidad de la distribución Poisson, es que la media es igual a la varianza. Luego, los límites están dados por:

$$L.Inf = \lambda - 3\sqrt{\lambda}$$


$$L.Cen = \lambda$$

$$L.Sup = \lambda + 3\sqrt{\lambda}$$

Por tanto,

$$\lambda = \frac{\text{Núm. quejas}}{\text{Núm. obs}} = \frac{91}{24} = 3,79$$

Y por tanto el gráfico se comporta como sigue:



Se evidencia una observación fuera del control de calidad (en particular, Febrero 2014). Luego, como  $\lambda$  fue estimado a partir de las observaciones, debemos ajustarla con el punto fuera de control. Por tanto, el nuevo  $\lambda$  resulta:

$$\lambda = \frac{\text{Núm. quejas}}{\text{Núm. obs}} = \frac{80}{23} = 3,48$$


Y por tanto, los límites son:

$$L.Inf = 3,48 - 3\sqrt{3,48} = 0$$

$$L.Cen = 3,48$$

$$L.Sup = 3,48 + 3\sqrt{3,48} = 9,07$$

*Y el gráfico resulta:*



*Y, ahora, vemos que todas las observaciones están dentro del control de calidad.*

---

# ANOVA Y DISEÑO DE EXPERIMENTOS

## 7.1. INTRODUCCIÓN

Se podría definir el Diseño Estadístico de Experimentos (DEE), también denominado diseño experimental, como una metodología estadística cuyo objetivo es ayudar al experimentador a:

- Seleccionar la estrategia experimental óptima que permita obtener la información buscada (mínimos costos).
- Evaluar los resultados experimentales obtenidos, garantizando la máxima fiabilidad en las conclusiones que se obtengan.

Las situaciones en las que se puede aplicar el DEE son muy numerosas. De forma general, se aplica a sistemas en los cuales se observan una o más variables experimentales dependientes o respuestas ( $y$ ) cuyo valor depende de los valores de una o más variables independientes ( $x$ ) controlables llamadas factores. Las respuestas además pueden estar influidas por otras variables que no son controladas por el experimentador. La relación entre  $x$  e  $y$  no tiene porqué ser conocida.

Ejemplos de sistemas experimentales son:

- Una reacción química cuyo rendimiento ( $y$ ) puede ser función, entre otros, del tiempo de reacción ( $x_1$ ), la temperatura de la reacción ( $x_2$ ) y el tipo de catalizador ( $x_3$ ) utilizado. Otras variables que pueden influir son, por ejemplo, la pureza de los reactivos, la limpieza del material, la velocidad de agitación, etc.
- Un alimento producido por mezcla en distintas proporciones ( $x$ ) de sus ingredientes, lo cual da lugar a diferentes olores y sabores ( $y$ ).



El **Análisis de la Varianza** servirá para:

- Comparar los niveles de un factor y encontrar el “mejor”.
- Determinar si los factores interactúan.
- Determinar los factores más importantes.
- Encontrar la “mejor” combinación de niveles de factores (tratamientos).

### 7.1.1. Definiciones

**Factor:** es cualquier variable cuyo posible efecto sobre los datos desea ser investigado.

**Niveles:** los niveles de un factor serán los tipos o grados específicos del factor que se utilizarán en el estudio.

**Tratamiento:** combinación de los niveles de los factores.

**Tipos de Diseño:** Observacional vs. Experimental.

Los modelos de análisis de varianza son una herramienta estadística versátil para estudiar la relación entre una variable respuesta y una o más variables explicativas. Estos modelos no requieren ningún supuesto sobre la naturaleza de la relación estadística entre la respuesta y las variables explicativas. Tampoco requiere que las variables explicativas sean cuantitativas.

### 7.1.2. Notación

Primero, diremos que un diseño es experimental cuando el modelo posea efectos fijos. Contrariamente, cuando el modelo posea efectos aleatorios, estaremos hablando de un diseño observacional.

La notación utilizada es la siguiente:

- $r$ : número de niveles del factor.
- $n_i$ : número de datos observados en el  $i$ -ésimo nivel del factor,  $i = 1, 2, \dots, r$ .
- $n_t$ : número total de datos.
- $Y_{ij}$ : valor de la respuesta del  $j$ -ésimo caso del  $i$ -ésimo nivel del factor.

## 7.2. Modelo de un factor con efectos fijos (ANOVA one-way)

El análisis de la varianza (ANOVA) es una herramienta estadística de gran utilidad tanto en la industria para el control de procesos como en el laboratorio de análisis para el control de métodos analíticos. Los ejemplos de aplicación son múltiples, pudiéndose comparar múltiples columnas de datos y la estimación de los componentes de variación de un proceso.

Para utilizar el ANOVA de forma satisfactoria deben cumplirse tres tipos de hipótesis:

- Cada conjunto de datos debe ser independiente del resto.
- Los resultados obtenidos para cada conjunto deben seguir una distribución normal.
- Las varianzas de cada conjunto de datos no deben diferir de forma significativa.

Se define el modelo como:

$$Y_{ij} = \mu_i + e_{ij}$$

con  $e_{ij} \stackrel{iid}{\sim} N(0, \sigma^2)$ .

Donde:

$Y_{ij}$  es el valor observado en el j-ésimo caso del nivel i-ésimo del factor.

$$E(Y_{ij}) = \mu_i, \quad V(Y_{ij}) = \sigma.$$

$$Y_{ij} \stackrel{iid}{\sim} N(\mu_i, \sigma^2).$$

### 7.2.1. Interpretación de una media de celda $\mu_i$

**Estudio experimental:** La media del nivel i del factor corresponde a la respuesta media que se obtendría si el i-ésimo tratamiento se aplicara a todas las unidades de la población de unidades experimentales.

**Estudio observacional:** Las medias de niveles del factor corresponden a las medias de las distintas poblaciones asociadas a cada nivel del factor.

### 7.2.2. Interpretación de la varianza $\sigma^2$

Estudio experimental: corresponde a la variabilidad de las respuestas si uno de los tratamientos fuese aplicado a todas las unidades de la población de unidades experimentales.

Estudio observacional:  $\sigma^2$  corresponde a la variabilidad de la población.

Notación:

$$Y_{i.} = \sum_{j=1}^{n_i} Y_{ij}$$

$$Y_{..} = \sum_{i=1}^r \sum_{j=1}^{n_i} Y_{ij}$$

$$\bar{Y}_{i.} = \frac{1}{n_i} \sum_{j=1}^{n_i} Y_{ij} = \frac{Y_{i.}}{n_i}$$

$$\bar{Y}_{..} = \frac{1}{n_r} \sum_{i=1}^r \sum_{j=1}^{n_i} Y_{ij} = \frac{Y_{..}}{n_r}$$

Para la estimación del modelo, debemos recordar que las observaciones tienen una distribución normal de la forma:

$$Y_{ij} \sim N(\mu_i, \sigma^2), \quad i = 1, 2, \dots, r; \quad j = 1, 2, \dots, n_i$$

Por lo tanto, la función verosimilitud está dada por:

$$L(\mu_1, \dots, \mu_r, \sigma^2) = \frac{1}{(2\pi\sigma^2)^{n_T/2}} \cdot \exp\left\{-\frac{1}{2\sigma^2} \sum_{i=1}^r \sum_{j=1}^{n_i} (Y_{ij} - \mu_i)^2\right\}$$

De aquí se desprende que:

$$\hat{\mu}_i = \tilde{\mu}_i = \bar{Y}_{i.}, \quad i = 1, \dots, r, \quad y \quad \hat{\sigma}^2 = \frac{1}{n_T} \sum_{i=1}^r \sum_{j=1}^{n_i} (Y_{ij} - \hat{\mu}_i)^2$$

**Propiedades de los estimadores.** Se puede probar que ambos estimadores son estimadores de mínima varianza entre los estimadores insesgados (propiedades de los estimadores máximo-verosímiles).

### 7.2.3. Residuos del modelo

Lo primero es tener en cuenta que los residuos se encuentran definidos por:

$$e_{ij} = Y_{ij} - \hat{Y}_{ij} = Y_{ij} - \bar{Y}_{i.}$$

Con ellos podremos determinar si el modelo es apropiado. Veremos que la suma de los residuos de cada nivel del factor es cero, como sigue:

$$\begin{aligned} \sum_{j=1}^{n_i} e_{ij} &= \sum_{j=1}^{n_i} (Y_{ij} - \bar{Y}_{i.}) \\ &= Y_{i.} - n_i \bar{Y}_{i.} \\ &= Y_{i.} - Y_{i.} \\ &= 0 \end{aligned}$$

Ahora necesitaremos encontrar la desviación total de una observación:  $Y_{ij} - \bar{Y}_{..}$ . Esta expresión puede ser reescrita sumando ceros de la siguiente manera:

$$\begin{array}{ccccc}
 Y_{ij} - \bar{Y}_{..} & = & (\bar{Y}_{i.} - \bar{Y}_{..}) & + & (Y_{ij} - \bar{Y}_{i.}) \\
 \Downarrow & & \Downarrow & & \Downarrow \\
 \boxed{\text{Desviación total}} & & \boxed{\text{Desviación de la media estimada del nivel con respecto a la media global}} & & \boxed{\text{Desviación con respecto a la media estimada del nivel del factor}}
 \end{array}$$

Posteriormente, elevando al cuadrado y sumando sobre todas las observaciones se obtiene la suma de cuadrados totales.

$$\begin{array}{ccccc}
 \sum_{i=1}^r \sum_{j=1}^{n_i} (Y_{ij} - \bar{Y}_{..})^2 & = & \sum_{i=1}^r \sum_{j=1}^{n_i} (\bar{Y}_{i.} - \bar{Y}_{..})^2 & + & \sum_{i=1}^r \sum_{j=1}^{n_i} (Y_{ij} - \bar{Y}_{i.})^2 \\
 \Downarrow & & \Downarrow & & \Downarrow \\
 \boxed{\text{Suma de cuadrados totales}} & & \boxed{\text{Suma de cuadrados del tratamiento}} & & \boxed{\text{Suma de cuadrados del error}}
 \end{array}$$

Usaremos las siguientes abreviaciones e interpretaremos de la siguiente manera:

**Suma de cuadrados del tratamiento (SCTrat):** es una medida de variación de las medias estimadas de cada nivel del factor respecto de la media global.

**Suma de cuadrados del error (SCE):** es una medida de la variación aleatoria de las observaciones de alrededor de las respectivas medias estimadas de cada nivel del factor.

**Suma de cuadrados totales (SCT):** es una medida de variación de las observaciones alrededor de la media global.

Ahora bien, si el modelo es adecuado esperamos una suma de cuadrados del error pequeña; mientras que la suma de cuadrados del tratamiento será grande.

### 7.3. TABLA ANOVA

A continuación veremos la típica tabla ANOVA donde se dispone la información obtenida en los puntos anteriores y trabajaremos con los conceptos de medias cuadráticas, definidas como:

Media cuadrática de tratamiento:

$$MCTrat = \frac{SCTrat}{r - 1}$$

Media cuadrática del error:

$$MCE = \frac{SCE}{n_T - 1}$$

Ahora, la tabla ANOVA se construye de la siguiente manera:

| Fuente de variación | Grados de libertad (gl) | Suma de cuadrados                                         | Medias cuadráticas     | Test F               |
|---------------------|-------------------------|-----------------------------------------------------------|------------------------|----------------------|
| Tratamiento         | $r - 1$                 | $\sum_{i=1}^r n_i (\bar{Y}_i - \bar{Y}_{..})^2$           | $\frac{SCTrat}{r - 1}$ | $\frac{MCTrat}{MCE}$ |
| Error               | $n_T - r$               | $\sum_{i=1}^r \sum_{j=1}^{n_i} (Y_{ij} - \bar{Y}_i)^2$    | $\frac{SCE}{n_T - 1}$  |                      |
| Total               | $n_T - 1$               | $\sum_{i=1}^r \sum_{j=1}^{n_i} (Y_{ij} - \bar{Y}_{..})^2$ |                        |                      |

Recordemos que el modelo es  $Y_{ij} = \mu_i + e_{ij}$ , por lo tanto, estamos interesados en testear las hipótesis:

$$H_0 : \mu_1 = \mu_2 = \dots = \mu_r$$

$$H_1 : \text{No todas las medias } \mu_i \text{ son iguales}$$

Por otra parte, bajo la hipótesis nula, tanto la media cuadrática de tratamiento (MCTrat) como la media cuadrática del error (MCE) son estimadores insesgados de  $\sigma^2$ .

Definimos el estadístico F como:

$$F = \frac{MCTrat}{MCE} = \frac{SCTrat/(r - 1)}{SCE/(n_T - r)}$$

Se puede demostrar que bajo la hipótesis nula:

- $\frac{SCTrat}{\sigma^2}$  distribuye chi-cuadrado con  $r - 1$  grados de libertad.
- $\frac{SCE}{\sigma^2}$  distribuye chi-cuadrado con  $n_T - r$  grados de libertad.
- $\frac{SCTrat}{\sigma^2}$  y  $\frac{SCE}{\sigma^2}$  son independientes.

Luego, bajo la hipótesis nula,

$$F \sim F_{r-1, n_t-r}$$

**Ejemplo 7.3.1** *Efecto de la suplementación durante la lactancia sobre la ganancia en peso de los cabritos al destete: 15 cabritos recién nacidos fueron asignados al azar en partes iguales a alguno de los siguientes tratamientos:*

- Sin suplementación (control)
- Suplementación con 500 g de alfalfa/día
- Suplementación con 500 g de alfalfa y 125 g de maíz

*Los cabritos fueron pesados al nacimiento y al momento del destete y se calculó la ganancia en peso (y).*

| Control | Suplemento alfalfa | Suplemento alfalfa y maíz |
|---------|--------------------|---------------------------|
| 1.93    | 2.54               | 2.95                      |
| 2.72    | 2.65               | 3.24                      |
| 2.44    | 2.57               | 2.55                      |
| 2.2     | 2.94               | 2.84                      |
| 1.97    | 2.93               | 3.05                      |

$$\begin{aligned} \bar{Y}_{1.} &= 2,252 & \bar{Y}_{2.} &= 2,726 \\ \bar{Y}_{3.} &= 2,926 & \bar{Y}_{..} &= 2,635 \end{aligned}$$

*El modelo será:*

$$Y_{ij} = \mu_i + e_{ij}, \text{ donde } e_{ij} \sim N(0, \sigma^2)$$

*La hipótesis que testaremos será:*

$$\begin{aligned} H_0: & \mu_1 = \mu_2 = \mu_3 \\ H_1: & \text{alguna es distinta} \end{aligned}$$

$$\begin{aligned}
 SCTrat &= \sum_{i=1}^r n_i (\bar{Y}_{i.} - \bar{Y}_{..})^2 \\
 &= 5(2,252 - 2,635)^2 + 5(2,726 - 2,635)^2 + 5(2,926 - 2,635)^2 \\
 &= 1,198
 \end{aligned}$$

$$\begin{aligned}
 SCError &= \sum_{i=1}^r \sum_{j=1}^{n_i} (Y_{ij} - \bar{Y}_{i.})^2 \\
 &= (1,93 - 2,252)^2 + (2,72 - 2,252)^2 + (2,44 - 2,252)^2 + \dots + (2,55 - 2,926)^2 + \dots + (3,05 - 2,926)^2 \\
 &= 0,8557
 \end{aligned}$$

$$\begin{aligned}
 SCTotal &= \sum_{i=1}^r \sum_{j=1}^{n_i} (Y_{ij} - \bar{Y}_{..})^2 \\
 &= (1,93 - 2,635)^2 + (2,72 - 2,635)^2 + (2,44 - 2,635)^2 + \dots + (2,84 - 2,635)^2 + (3,05 - 2,635)^2 \\
 &= 2,054
 \end{aligned}$$

Entonces,

$$MCTrat = \frac{1,198}{2} = 0,5991, \quad MCError = \frac{0,8557}{12} = 0,07131$$

$$F = \frac{MCTrat}{MCError} = \frac{0,5991}{0,07131} = 8,4017$$

Rechazamos  $H_0$  si:

$$\begin{array}{ccc}
 F_c & >& F_{(2,12)1-\alpha} \\
 & \swarrow \searrow & \\
 & \text{Trat, Error} &
 \end{array}$$

$$\begin{aligned}
 8,4017 &\stackrel{?}{>} F_{(2,12)0,95} \\
 8,4017 &> 3,885
 \end{aligned}$$

$\therefore$  Rechazo  $H_0$ , al menos 1 tratamiento difiere del resto, con  $\alpha = 0,5\%$ .

| Fuente de variación | g.l. | Sumas cuadradas | Medias cuadráticas | F   |
|---------------------|------|-----------------|--------------------|-----|
| Tratamientos        | 2    | 1,198           | 1,198/2            | 8,4 |
| Error               | 12   | 0,8557          | 0,8557/12          |     |
| Total               | 14   | 2,054           | -                  |     |

## Ejercicios 50

- Una empresa desea adquirir una máquina para producir cierto artículo. El mercado le ofrece cuatro marcas diferentes A, B, C y D para fabricar dicho artículo. La empresa diseña un experimento para decidir si hay diferencias entre el promedio de artículos producidos por las distintas marcas para lo que envía un operario experto que trabaja durante cuatro horas con cuatro máquinas de cada una de las marcas. Los resultados obtenidos en cuanto al número de unidades producidas fueron los siguientes:

| A  | B  | C  | D  |
|----|----|----|----|
| 20 | 23 | 18 | 19 |
| 22 | 21 | 20 | 17 |
| 19 | 24 | 19 | 19 |
| 17 | 22 | 21 | 23 |

- Determine un modelo estadístico para el promedio de artículos. Utilice los supuestos necesarios.
  - Realice la tabla ANOVA asociada al problema.
  - ¿Existe alguna diferencia entre los promedios de unidades producidas por las diferentes marcas? Utilice una significancia del 5 %.
- Se sabe que un compuesto químico tiene influencia sobre el crecimiento de una especie de planta en el tiempo. Se utilizaron tres tipos de concentraciones y se midió el crecimiento de 4 plantas en cada tipo durante un mes.

| C <sub>1</sub> | C <sub>2</sub> | C <sub>3</sub> |
|----------------|----------------|----------------|
| 7.6            | 7.5            | 4.7            |
| 8.1            | 7.3            | 5.7            |
| 8.3            | 7.0            | 6.3            |
| 7.5            | 6.9            | 6.1            |

- Determine un modelo estadístico para el promedio de artículos. Utilice los supuestos necesarios.
  - Realice la tabla ANOVA asociada al problema.
  - Determine si las concentraciones tienen el mismo efecto sobre la planta con una significancia del 1 %.
- Tres profesores del mismo ramo tienen tres grupos de 10, 12 y 9 estudiantes cada uno a los que han de calificar al final del semestre. La información que se dispone es el promedio de cada sección: 52, 49 y 56 respectivamente. Además un alumno anotó la nota de todos sus compañeros pero al cuadrado, cantidad que sumaba 98000. Realice un diseño experimental para determinar, con la información disponible, si existe diferencia en el promedio de cada sección. Utilice diferentes niveles de significancia para determinar su respuesta. Interprete.



4. En un experimento se compararon tres métodos para enseñar inglés. Para la evaluación, se administró una prueba de vocabulario de 50 preguntas a los 24 estudiantes del experimento repartidos en grupos de igual cantidad. El experto sólo determinó los siguientes datos:

| Fuente      | GL | SC       | CM      | F | Valor-p |
|-------------|----|----------|---------|---|---------|
| Tratamiento |    |          | 323.792 |   | 0.002   |
| Error       | 21 |          |         |   |         |
| Total       |    | 1460.958 |         |   |         |

- a) Complete la Tabla ANOVA.  
b) Interprete el estudio a partir de la información entregada.

5. Un grupo de alumnos del curso MAT031, ansiosos por aprender más sobre el diseño de experimentos, deciden averiguar si hay alguna relación entre el tiempo que tardan en encontrar una guía resuelta en internet y la carrera a la que pertenece. Se denominaron a las carreras A, B, C y D, y lograron contar, en minutos, lo que demoraban algunos alumnos asociados a esas carreras, resumidos en la siguiente tabla.

| A | B | C | D |
|---|---|---|---|
| 4 | 5 | 3 | 4 |
| 1 | 4 | 6 | 6 |
| 4 | 6 | 4 | 2 |
| 1 | 5 | 5 |   |
| 4 | 4 |   |   |
| 1 | 6 |   |   |
|   | 5 |   |   |

Realice el experimento en todas sus etapas; modelo, supuestos, tablas y test. Concluya e interprete.

---

# ANEXOS

## 8.1. ANEXO I: Formulario Distribuciones de Probabilidad

|                           | $\mathbf{P}(X = x)$                                                                               | $\mathbf{E}(X)$     | $\mathbf{V}(X)$       | $\mathbf{M}_X(t)$                          |
|---------------------------|---------------------------------------------------------------------------------------------------|---------------------|-----------------------|--------------------------------------------|
| Bernoulli(p)              | $p^x(1-p)^{1-x}I_{\{0,1\}}(x)$                                                                    | $p$                 | $p(1-p)$              | $(1-p) + pe^t$                             |
| Binomial(n,p)             | $\binom{n}{x}p^x(1-p)^{n-x}I_{\{0,1,\dots,n\}}(x)$                                                | $np$                | $np(1-p)$             | $[(1-p) + pe^t]^n$                         |
| Geométrica(p)             | $p(1-p)^{x-1}I_{\{1,2,\dots\}}(x)$                                                                | $\frac{1}{p}$       | $\frac{1-p}{p^2}$     | $\frac{pe^t}{1-(1-p)e^t}$                  |
| Bin Negativa(r,p)         | $\binom{x-1}{r-1}p^r(1-p)^{x-r}I_{\{r,r+1,\dots\}}(x)$                                            | $\frac{r}{p}$       | $\frac{r(1-p)}{p^2}$  | $\left(\frac{pe^t}{1-(1-p)e^t}\right)^r$   |
| Poisson( $\lambda$ )      | $\frac{\lambda^x e^{-\lambda}}{x!}I_{\{0,1,\dots\}}(x)$                                           | $\lambda$           | $\lambda$             | $e^{\lambda(e^t-1)}$                       |
| Uniforme(a,b)             | $\frac{1}{b-a}I_{[a,b]}(x)$                                                                       | $\frac{a+b}{2}$     | $\frac{(b-a)^2}{12}$  | $\frac{e^{bt}-e^{at}}{(b-a)t}$             |
| Exponencial( $\lambda$ )  | $\lambda e^{-\lambda x}I_{[0,\infty[}(x)$                                                         | $\frac{1}{\lambda}$ | $\frac{1}{\lambda^2}$ | $\frac{\lambda}{\lambda-t}$                |
| Gama( $k, \lambda$ )      | $\frac{\lambda^k}{\Gamma(k)}x^{k-1}e^{-\lambda x}I_{[0,\infty[}(x)$                               | $\frac{k}{\lambda}$ | $\frac{k}{\lambda^2}$ | $\left(\frac{\lambda}{\lambda-t}\right)^k$ |
| Normal( $\mu, \sigma^2$ ) | $\frac{1}{\sqrt{2\pi}\sigma}e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}I_{\mathbb{R}}(x)$ | $\mu$               | $\sigma^2$            | $e^{\mu t + \sigma^2 \frac{t^2}{2}}$       |
| $\chi^2_{(k)}$            | $\frac{2^{-k/2}}{\Gamma(k/2)} \cdot x^{\frac{k}{2}-1}e^{-\frac{x}{2}}I_{\mathbb{R}^+}(x)$         | $k$                 | $2k$                  | $\left(\frac{1}{1-2t}\right)^{k/2}$        |

## 8.2. ANEXO II: Formulario Intrevalos de Confianza

### A. Estimación de la media

Suponga que  $X_1, \dots, X_n$  es una muestra aleatoria de una distribución  $N(\mu, \sigma^2)$  y que se quiere obtener un intervalo de confianza del  $(1 - \alpha)100\%$  para  $\mu$ .

**A1.**  $\sigma^2$  conocido.

| Cantidad Pivotal                                         | Intervalo                                                            |
|----------------------------------------------------------|----------------------------------------------------------------------|
| $Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$ | $\mu \in (\bar{x} \pm \frac{\sigma}{\sqrt{n}} \cdot z_{1-\alpha/2})$ |

**A2.**  $\sigma^2$  desconocido

| Cantidad Pivotal                                    | Intervalo                                                            |
|-----------------------------------------------------|----------------------------------------------------------------------|
| $T = \frac{\bar{X} - \mu}{s/\sqrt{n}} \sim t_{n-1}$ | $\mu \in (\bar{X} \pm \frac{s}{\sqrt{n}} \cdot t_{n-1, 1-\alpha/2})$ |

### B. Comparación de medias

Sean que  $X_1, \dots, X_n$  una muestra aleatoria de una distribución  $N(\mu_1, \sigma_1^2)$  e  $Y_1, \dots, Y_m$  una muestra aleatoria de una distribución  $N(\mu_2, \sigma_2^2)$ , ambas muestras independientes. Se quiere obtener un intervalo de confianza del  $(1 - \alpha)100\%$  para  $\mu_1 - \mu_2$ .

**B1.**  $\sigma_1^2$  y  $\sigma_2^2$  conocidas.

| Cantidad Pivotal                                                                                                    | Intervalo                                                                                                                            |
|---------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------|
| $Z = \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m}}} \sim N(0, 1)$ | $(\mu_1 - \mu_2) \in \left( (\bar{x} - \bar{y}) \pm \sqrt{\frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m}} \cdot z_{1-\alpha/2} \right)$ |

**B2.**  $\sigma_1^2$  y  $\sigma_2^2$  desconocidas pero iguales ( $\sigma_1^2 = \sigma_2^2 = \sigma^2$ ).

| Cantidad Pivotal                                                                                        | Intervalo                                                                                                                     |
|---------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------|
| $Z = \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{s_p \sqrt{\frac{1}{n} + \frac{1}{m}}} \sim t_{n+m-2}$ | $(\mu_1 - \mu_2) \in \left( (\bar{x} - \bar{y}) \pm s_p \sqrt{\frac{1}{n} + \frac{1}{m}} \cdot t_{n+m-2, 1-\alpha/2} \right)$ |

donde

$$s_p^2 = \frac{(n-1)s_1^2 + (m-1)s_2^2}{n+m-2}$$

**B3.**  $\sigma_1^2$  y  $\sigma_2^2$  desconocidas y distintas.

| Cantidad Pivotal                                                                                        | Intervalo                                                                                                                       |
|---------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------|
| $Z = \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{\frac{s_1^2}{n} + \frac{s_2^2}{m}}} \sim t_\nu$ | $(\mu_1 - \mu_2) \in \left( (\bar{x} - \bar{y}) \pm \sqrt{\frac{s_1^2}{n} + \frac{s_2^2}{m}} \cdot t_{\nu, 1-\alpha/2} \right)$ |

donde

$$\nu = \frac{(s_1^2/n + s_2^2/m)^2}{\frac{(s_1^2/n)^2}{n-1} + \frac{(s_2^2/m)^2}{m-1}}$$

### C. Comparación de dos medias para datos pareados.

Sean que  $X_1, \dots, X_n$  una muestra aleatoria de una distribución  $N(\mu_1, \sigma_1^2)$  e  $Y_1, \dots, Y_n$  una muestra aleatoria de una distribución  $N(\mu_2, \sigma_2^2)$ , donde  $X_i$  e  $Y_i$  no son independientes. Se quiere obtener un intervalo de confianza del  $(1 - \alpha)100\%$  para  $\mu_1 - \mu_2$ .

| Cantidad Pivotal                                        | Intervalo                                                                                       |
|---------------------------------------------------------|-------------------------------------------------------------------------------------------------|
| $T = \frac{\bar{D} - \mu_d}{s_d/\sqrt{n}} \sim t_{n-1}$ | $(\mu_1 - \mu_2) \in \left( \bar{d} \pm \frac{s_d}{\sqrt{n}} \cdot t_{n-1, 1-\alpha/2} \right)$ |

donde

$$\begin{aligned} \mu_d &= \mu_1 - \mu_2 & d_i &= x_i - y_i & \bar{D} &= \bar{X} - \bar{Y} \\ s_d^2 &= \frac{1}{n-1} \sum_{i=1}^n (d_i - \bar{d})^2 \end{aligned}$$

**D. Estimación de la varianza.** Suponga que  $X_1, \dots, X_n$  es una muestra aleatoria de una distribución  $N(\mu, \sigma^2)$  y que se quiere obtener un intervalo de confianza del  $(1 - \alpha)100\%$  para  $\sigma^2$ .

| Cantidad Pivotal                                  | Intervalo                                                                                                        |
|---------------------------------------------------|------------------------------------------------------------------------------------------------------------------|
| $Q = \frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2$ | $\sigma^2 \in \left( \frac{(n-1)s^2}{\chi_{n-1, 1-\alpha/2}^2}, \frac{(n-1)s^2}{\chi_{n-1, \alpha/2}^2} \right)$ |

**E. Comparación de varianzas.** Sean que  $X_1, \dots, X_n$  una muestra aleatoria de una distribución  $N(\mu_1, \sigma_1^2)$  e  $Y_1, \dots, Y_m$  una muestra aleatoria de una distribución  $N(\mu_2, \sigma_2^2)$ , ambas muestras independientes y tanto  $\mu_1$  como  $\mu_2$ , valores desconocidos. Se quiere obtener un intervalo de confianza del  $(1 - \alpha)100\%$  para  $\sigma_1^2/\sigma_2^2$ .

| Cantidad Pivotal                                                  | Intervalo                                                                                                                                       |
|-------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------|
| $F = \frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} \sim F_{n-1, m-1}$ | $\sigma_1^2/\sigma_2^2 \in \left( \frac{s_1^2}{s_2^2} \cdot F_{n-1, m-1, \alpha/2}, \frac{s_1^2}{s_2^2} \cdot F_{n-1, m-1, 1-\alpha/2} \right)$ |

**F. Estimación de la proporción** Sean que  $X_1, \dots, X_n$  una muestra aleatoria de una distribución  $Bern(p)$ . Se quiere obtener un intervalo de confianza del  $(1 - \alpha)100\%$  para  $p$ , la proporción de éxito.

| Cantidad Pivotal                                       | Intervalo                                                                                   |
|--------------------------------------------------------|---------------------------------------------------------------------------------------------|
| $Z = \frac{\hat{p} - p}{\sqrt{p(1-p)/n}} \sim N(0, 1)$ | $p \in \left( \hat{p} \pm \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} \cdot z_{1-\alpha/2} \right)$ |

### 8.3. ANEXO III: Formulario Pruebas de Hipótesis

#### A. Hipótesis para la media

Suponga que  $X_1, \dots, X_n$  es una muestra aleatoria de una distribución  $N(\mu, \sigma^2)$  y que se quiere hacer inferencia respecto a  $\mu$ .

##### A1. $\sigma^2$ conocido.

Estadística de prueba:

$$Z_0 = \frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}}$$

| Hipótesis Nula         | Hipótesis Alternativa  | Rechazo $H_0$ si:           |
|------------------------|------------------------|-----------------------------|
| $H_0 : \mu = \mu_0$    | $H_1 : \mu \neq \mu_0$ | $ Z_0  \geq z_{1-\alpha/2}$ |
| $H_0 : \mu \leq \mu_0$ | $H_1 : \mu > \mu_0$    | $Z_0 \geq z_{1-\alpha}$     |
| $H_0 : \mu \geq \mu_0$ | $H_1 : \mu < \mu_0$    | $Z_0 \leq -z_{1-\alpha}$    |

##### A2. $\sigma^2$ desconocido

Estadística de prueba:

$$T_0 = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}$$

| Hipótesis Nula         | Hipótesis Alternativa  | Rechazo $H_0$ si:                |
|------------------------|------------------------|----------------------------------|
| $H_0 : \mu = \mu_0$    | $H_1 : \mu \neq \mu_0$ | $ T_0  \geq t_{n-1, 1-\alpha/2}$ |
| $H_0 : \mu \leq \mu_0$ | $H_1 : \mu > \mu_0$    | $T_0 \geq t_{n-1, 1-\alpha}$     |
| $H_0 : \mu \geq \mu_0$ | $H_1 : \mu < \mu_0$    | $T_0 \leq -t_{n-1, 1-\alpha}$    |

## B. Comparación de medias

Sean que  $X_1, \dots, X_n$  una muestra aleatoria de una distribución  $N(\mu_1, \sigma_1^2)$  e  $Y_1, \dots, Y_m$  una muestra aleatoria de una distribución  $N(\mu_2, \sigma_2^2)$ , ambas muestras independientes. Se quiere hacer inferencia respecto a  $\mu_1 - \mu_2$ .

**B1.**  $\sigma_1^2$  y  $\sigma_2^2$  conocidas.

Estadística de prueba:

$$Z_0 = \frac{(\bar{x} - \bar{y}) - d}{\sqrt{\frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m}}}$$

| Hipótesis Nula               | Hipótesis Alternativa        | Rechazo $H_0$ si:           |
|------------------------------|------------------------------|-----------------------------|
| $H_0 : \mu_1 - \mu_2 = d$    | $H_1 : \mu_1 - \mu_2 \neq d$ | $ z_0  \geq z_{1-\alpha/2}$ |
| $H_0 : \mu_1 - \mu_2 \leq d$ | $H_1 : \mu_1 - \mu_2 > d$    | $z_0 \geq z_{1-\alpha}$     |
| $H_0 : \mu_1 - \mu_2 \geq d$ | $H_1 : \mu_1 - \mu_2 < d$    | $z_0 \leq -z_{1-\alpha}$    |

**B2.**  $\sigma_1^2$  y  $\sigma_2^2$  desconocidas pero iguales ( $\sigma_1^2 = \sigma_2^2 = \sigma^2$ ).

Estadística de prueba:

$$T_0 = \frac{(\bar{x} - \bar{y}) - d}{s_p \sqrt{\frac{1}{n} + \frac{1}{m}}}$$

| Hipótesis Nula               | Hipótesis Alternativa        | Rechazo $H_0$ si:                  |
|------------------------------|------------------------------|------------------------------------|
| $H_0 : \mu_1 - \mu_2 = d$    | $H_1 : \mu_1 - \mu_2 \neq d$ | $ T_0  \geq t_{n+m-2, 1-\alpha/2}$ |
| $H_0 : \mu_1 - \mu_2 \leq d$ | $H_1 : \mu_1 - \mu_2 > d$    | $T_0 \geq t_{n+m-2, 1-\alpha}$     |
| $H_0 : \mu_1 - \mu_2 \geq d$ | $H_1 : \mu_1 - \mu_2 < d$    | $T_0 \leq -t_{n+m-2, 1-\alpha}$    |

donde

$$s_p^2 = \frac{(n-1)s_1^2 + (m-1)s_2^2}{n+m-2}$$



**B3.**  $\sigma_1^2$  y  $\sigma_2^2$  desconocidas y distintas.

Estadística de prueba:

$$T_0 = \frac{(\bar{x} - \bar{y}) - d}{\sqrt{\frac{s_1^2}{n} + \frac{s_2^2}{m}}}$$

| Hipótesis Nula               | Hipótesis Alternativa        | Rechazo $H_0$ si:                |
|------------------------------|------------------------------|----------------------------------|
| $H_0 : \mu_1 - \mu_2 = d$    | $H_1 : \mu_1 - \mu_2 \neq d$ | $ T_0  \geq t_{\nu, 1-\alpha/2}$ |
| $H_0 : \mu_1 - \mu_2 \leq d$ | $H_1 : \mu_1 - \mu_2 > d$    | $T_0 \geq t_{\nu, 1-\alpha}$     |
| $H_0 : \mu_1 - \mu_2 \geq d$ | $H_1 : \mu_1 - \mu_2 < d$    | $T_0 \leq -t_{\nu, 1-\alpha}$    |

donde

$$\nu = \frac{(s_1^2/n + s_2^2/m)^2}{\frac{(s_1^2/n)^2}{n-1} + \frac{(s_2^2/m)^2}{m-1}}$$

### C. Comparación de dos medias para datos pareados.

Sean que  $X_1, \dots, X_n$  una muestra aleatoria de una distribución  $N(\mu_1, \sigma_1^2)$  e  $Y_1, \dots, Y_n$  una muestra aleatoria de una distribución  $N(\mu_2, \sigma_2^2)$ , donde  $X_i$  e  $Y_i$  no son independientes. Se quiere hacer inferencia respecto a  $\mu_1 - \mu_2$ .

Estadística de prueba:

$$T_0 = \frac{(\bar{x} - \bar{y}) - d}{s_d/\sqrt{n}}$$

| Hipótesis Nula               | Hipótesis Alternativa        | Rechazo $H_0$ si:                |
|------------------------------|------------------------------|----------------------------------|
| $H_0 : \mu_1 - \mu_2 = d$    | $H_1 : \mu_1 - \mu_2 \neq d$ | $ T_0  \geq t_{n-1, 1-\alpha/2}$ |
| $H_0 : \mu_1 - \mu_2 \leq d$ | $H_1 : \mu_1 - \mu_2 > d$    | $T_0 \geq t_{n-1, 1-\alpha}$     |
| $H_0 : \mu_1 - \mu_2 \geq d$ | $H_1 : \mu_1 - \mu_2 < d$    | $T_0 \leq -t_{n-1, 1-\alpha}$    |

donde

$$\mu_d = \mu_1 - \mu_2 \quad d_i = x_i - y_i \quad \bar{d} = \bar{x} - \bar{y}$$

$$s_d^2 = \frac{1}{n-1} \sum_{i=1}^n (d_i - \bar{d})^2$$

**D. Prueba para la varianza.** Suponga que  $X_1, \dots, X_n$  es una muestra aleatoria de una distribución  $N(\mu, \sigma^2)$  y que se quiere hacer inferencia respecto a  $\sigma^2$ .

Estadística de prueba:

$$Q_0 = \frac{(n-1)s^2}{\sigma_0^2}$$

| Hipótesis Nula                   | Hipótesis Alternativa            | Rechazo $H_0$ si:                                                       |
|----------------------------------|----------------------------------|-------------------------------------------------------------------------|
| $H_0 : \sigma^2 = \sigma_0^2$    | $H_1 : \sigma^2 \neq \sigma_0^2$ | $Q_0 \leq \chi_{n-1, \alpha/2}^2$ ó $Q_0 \geq \chi_{n-1, 1-\alpha/2}^2$ |
| $H_0 : \sigma^2 \leq \sigma_0^2$ | $H_1 : \sigma^2 > \sigma_0^2$    | $Q_0 \geq \chi_{n-1, 1-\alpha}^2$                                       |
| $H_0 : \sigma^2 \geq \sigma_0^2$ | $H_1 : \sigma^2 < \sigma_0^2$    | $Q_0 \leq \chi_{n-1, \alpha}^2$                                         |

**E. Comparación de varianzas.** Sean que  $X_1, \dots, X_n$  una muestra aleatoria de una distribución  $N(\mu_1, \sigma_1^2)$  e  $Y_1, \dots, Y_m$  una muestra aleatoria de una distribución  $N(\mu_2, \sigma_2^2)$ , ambas muestras independientes y tanto  $\mu_1$  como  $\mu_2$ , valores desconocidos. Se quiere hacer inferencia respecto a  $\sigma_1^2/\sigma_2^2$ .

Estadística de prueba:

$$F_0 = \frac{s_1^2}{s_2^2} \cdot k$$

| Hipótesis Nula                                 | Hipótesis Alternativa                          | Rechazo $H_0$ si:                                                       |
|------------------------------------------------|------------------------------------------------|-------------------------------------------------------------------------|
| $H_0 : \sigma_1^2/\sigma_2^2 = \frac{1}{k}$    | $H_1 : \sigma_1^2/\sigma_2^2 \neq \frac{1}{k}$ | $F_0 \leq F_{n-1, m-1, \alpha/2}$ ó $F_0 \geq F_{n-1, m-1, 1-\alpha/2}$ |
| $H_0 : \sigma_1^2/\sigma_2^2 \leq \frac{1}{k}$ | $H_1 : \sigma_1^2/\sigma_2^2 > \frac{1}{k}$    | $F_0 \geq F_{n-1, m-1, 1-\alpha}$                                       |
| $H_0 : \sigma_1^2/\sigma_2^2 \geq \frac{1}{k}$ | $H_1 : \sigma_1^2/\sigma_2^2 < \frac{1}{k}$    | $F_0 \leq F_{n-1, m-1, \alpha}$                                         |

**F. Prueba para la proporción** Sean que  $X_1, \dots, X_n$  una muestra aleatoria de una distribución  $Bern(p)$ . Se quiere hacer inferencia respecto a  $p$ , la proporción de éxito.

Estadística de prueba:

$$Z_0 = \frac{\hat{p} - p_0}{\sqrt{p_0 \cdot (1 - p_0)/n}}$$

| Hipótesis Nula     | Hipótesis Alternativa | Rechazo $H_0$ si:           |
|--------------------|-----------------------|-----------------------------|
| $H_0 : p = p_0$    | $H_1 : p \neq p_0$    | $ Z_0  \geq z_{1-\alpha/2}$ |
| $H_0 : p \leq p_0$ | $H_1 : p > p_0$       | $Z_0 \geq z_{1-\alpha}$     |
| $H_0 : p \geq p_0$ | $H_1 : p < p_0$       | $Z_0 \leq z_\alpha$         |

**G. Comparación de proporciones** Sean que  $X_1, \dots, X_n$  e  $Y_1, \dots, Y_m$  muestras aleatorias independientes de poblaciones Bernoulli de parámetros  $p_1$  y  $p_2$ , respectivamente. Se quiere hacer inferencia respecto a  $p_1 - p_2$ .

Estadística de prueba:

$$Z_0 = \frac{(\hat{p}_1 - \hat{p}_2) - d}{\sqrt{\hat{p}_1 \cdot (1 - \hat{p}_1)/n + \hat{p}_2 \cdot (1 - \hat{p}_2)/m}}$$

| Hipótesis Nula           | Hipótesis Alternativa    | Rechazo $H_0$ si:           |
|--------------------------|--------------------------|-----------------------------|
| $H_0 : p_1 - p_2 = d$    | $H_1 : p_1 - p_2 \neq d$ | $ Z_0  \geq z_{1-\alpha/2}$ |
| $H_0 : p_1 - p_2 \leq d$ | $H_1 : p_1 - p_2 > d$    | $Z_0 \geq z_{1-\alpha}$     |
| $H_0 : p_1 - p_2 \geq d$ | $H_1 : p_1 - p_2 < d$    | $Z_0 \leq z_\alpha$         |

---

# BIBLIOGRAFÍA

1. Arellano-Valle R. *Apuntes de Probabilidades para el curso EPG3307*. 2007.
2. Casella G, Berger R. *Statistical Inference*. Pacific Grove, CA: Duxbury, 2002.
3. Devore J. Probabilidad y estadística para ingeniería y ciencias. Thomson Learning, México, 2001.
4. Fernández A. *Apuntes de Probabilidad y Estadística*.
5. Freund J, Miller I, Miller M. *Estadística Matemática con Aplicaciones*. Prentice Hall, México, 2000.
6. Lipschutz S, et al. *Introducción a la Probabilidad y Estadística*. Mc Graw Hill, España, 2000.
7. Meyer P. *Probabilidad y Aplicaciones Estadísticas*. Addison-Wesley Iberoamericana, EE.UU., 1986.
8. Novo V. *Problemas de Cálculo de Probabilidades y Estadística*. Ed. Sanz y Torres, España, 2003.
9. Peña , Romo . *Introducción a la Estadística para Ciencias Sociales*. Mc GrAw -Hill, Madrid, 1997.
10. Rice J. *Mathematical Statistics And Data Analysis*. Brooks/Cole, EE.UU., 2007
11. Walpole R, et al. *Probabilidad y Estadística para Ingernieros*. Prentice Hall, México, 1999.