

Fundamentos de Machine Learning

Resumen de notas de clase – Clases 1 a 5

Conceptos, definiciones, resultados y fórmulas centrales

1. Idea central del aprendizaje

El objetivo de Machine Learning es construir métodos que **detecten patrones en datos** y utilicen esos patrones para resolver tareas nuevas. El esquema conceptual de las notas es

Datos/experiencia $\rightarrow$ algoritmo de aprendizaje
 $\rightarrow$ predictor/conocimiento.

El punto clave no es memorizar los datos observados, sino **generalizar** a instancias no vistas.

Overfitting. Un predictor puede ajustarse perfectamente a los datos de entrenamiento y, aun así, tener mal desempeño sobre datos nuevos. Por eso, error de entrenamiento pequeño no implica automáticamente buena generalización.

Las notas ilustran el **sesgo inductivo** mediante los ejemplos de Skinner y García-Koelling: el aprendizaje necesita algún conocimiento o restricción previa que determine qué patrones se consideran plausibles.

Trade-off generalización-sesgo. Aumentar el conocimiento previo restringe los predictores posibles y puede facilitar la generalización; una restricción demasiado fuerte, en cambio, puede impedir representar un buen predictor.

1.1. Tipos de aprendizaje

Según la información disponible:

- **Supervisado:** los datos de entrenamiento vienen con etiquetas.
- **No supervisado:** no hay etiquetas; se buscan estructuras o patrones en los datos.
- **Reforzado:** el aprendizaje recibe información parcial mediante resultados/recompensas.

Según la interacción con el ambiente: activo, pasivo o colaborativo.

Según el contexto: neutro o adversarial.

Según la temporalidad: offline/batch u online.

Machine Learning resulta especialmente útil cuando la tarea es demasiado compleja para programarla mediante reglas explícitas o cuando se necesita **adaptabilidad**.

2. Preliminares de medida y probabilidad

2.1. σ -álgebras y espacios medibles

Sea $\Omega \neq \emptyset$. Una familia $\mathcal{F} \subseteq 2^\Omega$ es una σ -álgebra si:

1. $\Omega \in \mathcal{F}$.
2. $A \in \mathcal{F} \Rightarrow A^c \in \mathcal{F}$.

3. Si $A_1, A_2, \dots \in \mathcal{F}$, entonces $\bigcup_{n \geq 1} A_n \in \mathcal{F}$.

El par $(\Omega, \mathcal{F})$ se llama **espacio medible**.

Si $\mathcal{S} \subseteq 2^\Omega$, la σ -álgebra generada por $\mathcal{S}$ es

$$\sigma(\mathcal{S}) = \bigcap \{ \mathcal{F} : \mathcal{F} \text{ es } \sigma\text{-álgebra y } \mathcal{S} \subseteq \mathcal{F} \}.$$

Es la **más pequeña** σ -álgebra que contiene a $\mathcal{S}$.

Si M es un espacio métrico, la σ -álgebra de Borel es

$$\mathcal{B}(M) = \sigma(\{A \subseteq M : A \text{ abierto}\}).$$

2.2. Medidas de probabilidad

Una medida de probabilidad sobre $(\Omega, \mathcal{F})$ es una función

$$\mathbb{P} : \mathcal{F} \rightarrow [0, 1]$$

tal que $\mathbb{P}(\Omega) = 1$ y es numerablemente aditiva sobre conjuntos disjuntos. El triple $(\Omega, \mathcal{F}, \mathbb{P})$ es un **espacio de probabilidad**.

2.3. Funciones medibles y variables aleatorias

Sean $(\Omega, \mathcal{F})$ y $(E, \mathcal{E})$ espacios medibles. Una función $f : \Omega \rightarrow E$ es **medible** si

$$A \in \mathcal{E} \implies f^{-1}(A) \in \mathcal{F}.$$

Una variable aleatoria real es una función medible

$$X : (\Omega, \mathcal{F}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R})).$$

2.4. Ley o distribución

La ley de X es la medida μ_X en $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ dada por

$$\mu_X(A) = \mathbb{P}(X \in A) = \mathbb{P}(X^{-1}(A)).$$

Equivalentemente,

$$\mu_X = X_{\#}\mathbb{P},$$

es decir, la distribución es el **push-forward** de $\mathbb{P}$ por X .

2.5. Esperanza

Para una función medible g ,

$$\mathbb{E}[g(X)] = \int_{\Omega} g(X(\omega)) d\mathbb{P}(\omega) = \int_{\mathbb{R}} g(x) d\mu_X(x).$$

Casos importantes:

$$\mathbb{E}[g(X)] = \sum_x g(x) \mathbb{P}(X = x) \quad (\text{discreto}),$$

$$\mathbb{E}[g(X)] = \int_{\mathbb{R}} g(x) p_X(x) dx \quad (\text{si existe densidad } p_X).$$

Propiedades destacadas:

$$\mathbb{E}[aX + bY] = a\mathbb{E}[X] + b\mathbb{E}[Y],$$

si $X \leq Y$ c.s., entonces $\mathbb{E}[X] \leq \mathbb{E}[Y]$, y si $X = 0$ c.s., entonces $\mathbb{E}[X] = 0$.

3. Producto, independencia y marginales

Dados $(\Omega_i, \mathcal{F}_i, \mu_i)$, la σ -álgebra producto es

$$\mathcal{F}_1 \otimes \mathcal{F}_2 = \sigma\{A_1 \times A_2 : A_i \in \mathcal{F}_i\},$$

y la medida producto satisface, sobre rectángulos medibles,

$$(\mu_1 \otimes \mu_2)(A_1 \times A_2) = \mu_1(A_1)\mu_2(A_2).$$

Variables aleatorias $X_1, \dots, X_m$ son **independientes** si para todo conjunto medible A_i ,

$$\mathbb{P}(X_1 \in A_1, \dots, X_m \in A_m) = \prod_{i=1}^m \mathbb{P}(X_i \in A_i).$$

Si además $X_i \sim \mu_i$, entonces

$$(X_1, \dots, X_m) \sim \bigotimes_{i=1}^m \mu_i.$$

Son **i.i.d.** si son independientes y todas tienen la misma distribución.

Si $(X, Y) \sim \mu$ es una distribución conjunta, sus marginales son

$$\mu_X = (\pi_X)_\# \mu, \quad \mu_Y = (\pi_Y)_\# \mu.$$

En general,

$$\mu \neq \mu_X \otimes \mu_Y;$$

la igualdad corresponde al caso de independencia.

4. Esperanza condicional

Sea U integrable y $\mathcal{G} \subseteq \mathcal{F}$ una σ -álgebra. La esperanza condicional de U respecto de $\mathcal{G}$ es la única función V (c.s.) tal que:

1. V es $\mathcal{G}$ -medible.
2. Para todo $A \in \mathcal{G}$,

$$\int_A V d\mathbb{P} = \int_A U d\mathbb{P}.$$

Se denota

$$V = \mathbb{E}[U \mid \mathcal{G}].$$

La idea es que $\mathbb{E}[U \mid \mathcal{G}]$ conserva solo la información disponible en $\mathcal{G}$.

Si $\mathcal{G} = \sigma(X)$, escribimos

$$\mathbb{E}[U \mid \mathcal{G}] = \mathbb{E}[U \mid X].$$

Propiedad de torre. Si $\mathcal{H} \subseteq \mathcal{G}$, entonces

$$\mathbb{E}[\mathbb{E}[U \mid \mathcal{G}] \mid \mathcal{H}] = \mathbb{E}[U \mid \mathcal{H}].$$

Condicionar nuevamente a una información más gruesa equivale a condicionar directamente a ella.

4.1. Desagregación de una medida

Sea $(X, Y) \sim \mu$ sobre $\mathbf{X} \times \mathbf{Y}$, con marginal μ_X . Bajo las hipótesis métricas de las notas, existe una familia de medidas $\{\mu_x\}_{x \in \mathbf{X}}$ sobre $\mathbf{Y}$ tal que μ_x representa la **distribución condicional de Y dado $X = x$** y

$$\mu(A \times B) = \int_A \mu_x(B) d\mu_X(x).$$

Además, para una función integrable f ,

$$\int_{\mathbf{X} \times \mathbf{Y}} f(x, y) d\mu(x, y) = \int_{\mathbf{X}} \left[\int_{\mathbf{Y}} f(x, y) d\mu_x(y) \right] d\mu_X(x).$$

El término interior se interpreta como una versión de

$$\mathbb{E}[f(X, Y) \mid X = x].$$

5. Grandes números y concentración

Si $Z_1, Z_2, \dots$ son i.i.d. con $\mathbb{E}[Z_i] = 0$, la Ley de los Grandes Números expresa que

$$\frac{1}{n} \sum_{i=1}^n Z_i \xrightarrow[n \rightarrow \infty]{\text{c.s.}} 0.$$

La dificultad práctica es decidir **cuánto debe valer n** . Las desigualdades de concentración entregan cotas explícitas en función de n, ε y δ .

5.1. Dos herramientas básicas

Union bound:

$$\mathbb{P}\left(\bigcup_i A_i\right) \leq \sum_i \mathbb{P}(A_i).$$

En particular,

$$\mathbb{P}(|X| \geq \varepsilon) \leq \mathbb{P}(X \geq \varepsilon) + \mathbb{P}(X \leq -\varepsilon).$$

Desigualdad de Markov: si $Z \geq 0$ y $a > 0$,

$$\mathbb{P}(Z \geq a) \leq \frac{\mathbb{E}[Z]}{a}.$$

Aplicada a una exponencial, para $\lambda > 0$,

$$\mathbb{P}(X \geq \varepsilon) \leq e^{-\lambda \varepsilon} \mathbb{E}[e^{\lambda X}].$$

Este paso convierte una probabilidad de cola en una cota basada en una función generadora exponencial.

5.2. Lema de Hoeffding

Si $X \in [a, b]$ c.s. y $\mathbb{E}[X] = 0$, entonces para todo $\lambda > 0$,

$$\mathbb{E}[e^{\lambda X}] \leq \exp\left(\frac{\lambda^2(b-a)^2}{8}\right)$$

La demostración de las notas usa la convexidad de $e^{\lambda x}$ para acotar la exponencial por la cuerda que une sus valores en a y b , seguida de una estimación cuadrática del logaritmo de la cota resultante.

5.3. Desigualdad de Hoeffding

Sean $Z_1, \dots, Z_n$ i.i.d., con $Z_i \in [a, b]$ c.s. y $\mathbb{E}[Z_i] = 0$. Entonces

$$\mathbb{P}\left(\left|\frac{1}{n} \sum_{i=1}^n Z_i\right| \geq \varepsilon\right) \leq 2 \exp\left(-\frac{2n\varepsilon^2}{(b-a)^2}\right)$$

Por lo tanto, para garantizar que esta probabilidad sea a lo más δ , basta tomar

$$n \geq \frac{(b-a)^2}{2\varepsilon^2} \log\left(\frac{2}{\delta}\right).$$

Lectura. Un ε más pequeño exige aproximadamente $1/\varepsilon^2$ observaciones; aumentar la confianza de $1-\delta$ afecta solo logarítmicamente mediante $\log(1/\delta)$.

6. Modelo formal de aprendizaje estadístico

El ejemplo conductor de las notas es predecir si una palta está buena o mala usando color y firmeza.

6.1. Objetos del modelo

Dominio $\mathcal{X}$: conjunto de todas las instancias posibles, normalmente descritas por vectores en $\mathbb{R}^d$.

Etiquetas $\mathcal{Y}$: conjunto de salidas posibles, por ejemplo $\{0, 1\}$ o $\{-1, 1\}$.

Entrenamiento:

$$S = ((X_1, Y_1), \dots, (X_m, Y_m)) \in (\mathcal{X} \times \mathcal{Y})^m.$$

Predictor: una función medible $h : \mathcal{X} \rightarrow \mathcal{Y}$.

Las notas imponen inicialmente cuatro supuestos:

1. Los datos X_i son generados desde una distribución desconocida μ sobre $\mathcal{X}$.
2. Existe una función de etiquetado correcto $f : \mathcal{X} \rightarrow \mathcal{Y}$, desconocida para el learner.
3. Más adelante, para clases finitas, se supone **realizabilidad**: existe $h^* \in \mathcal{H}$ con error verdadero cero.
4. La muestra se genera i.i.d.: $X_1, \dots, X_m \sim \mu$ independientemente y $Y_i = f(X_i)$.

6.2. Error verdadero

Para un predictor h ,

$$L_{\mu,f}(h) := \mu(\{x : h(x) \neq f(x)\}) = \mathbb{P}_{X \sim \mu}(h(X) \neq f(X)).$$

Este es el error que realmente interesa, pero depende de la distribución μ y de f , que el algoritmo no conoce.

6.3. Error empírico

Dado $S = ((X_i, Y_i))_{i=1}^m$,

$$L_S(h) := \frac{1}{m} \sum_{i=1}^m \mathbf{1}_{\{h(X_i) \neq Y_i\}} = \frac{|\{i : h(X_i) \neq Y_i\}|}{m}.$$

A diferencia del error verdadero, este sí puede calcularse a partir de los datos.

6.4. ERM

Empirical Risk Minimization selecciona

$$h_S \in \arg \min_h L_S(h).$$

Sin restricciones sobre el conjunto de predictores, ERM puede sobreajustar.

Ejemplo de las notas. En $\mathcal{X} = [0, 2]^2$, un predictor que memoriza las etiquetas de las observaciones y predice 0 fuera de la muestra tiene $L_S(h_S) = 0$. Sin embargo, si la región positiva es $[0, 1]^2$, entonces el error verdadero es $1/4$: el predictor aprendió la muestra, pero no la regla.

7. Clase de hipótesis y sesgo inductivo

Para evitar buscar entre todos los predictores posibles se fija una **clase de hipótesis** $\mathcal{H}$, elegida a partir del conocimiento previo. Entonces

$$\text{ERM}_{\mathcal{H}}(S) \in \arg \min_{h \in \mathcal{H}} L_S(h).$$

Ejemplo de las notas: indicadores de rectángulos

$$\mathcal{H} = \{\mathbf{1}_R : R = [a, b] \times [c, d] \subseteq [0, 2]^2\}.$$

Intuición central. Cuanto más pequeña/restringida es $\mathcal{H}$, menor es la posibilidad de overfitting; pero también puede disminuir la capacidad de encontrar un predictor con error pequeño. Esta es la manifestación formal del sesgo inductivo.

7.1. Supuesto de realizabilidad

Se supone que

$$\exists h^* \in \mathcal{H} \quad \text{tal que} \quad L_{\mu,f}(h^*) = 0.$$

Como $Y_i = f(X_i)$, entonces $L_S(h^*) = 0$ c.s., y por ser h_S un ERM,

$$L_S(h_S) = 0.$$

La pregunta es: ¿qué se puede decir de $L_{\mu,f}(h_S)$?

8. Garantía para clases finitas

Sea $\mathcal{H}$ finita y realizable. Fijemos una precisión $\varepsilon > 0$ y una confianza $1 - \delta$. La clase de hipótesis malas es

$$\mathcal{H}_\varepsilon = \{h \in \mathcal{H} : L_{\mu,f}(h) > \varepsilon\}.$$

Como el ERM es consistente, el evento de falla $\{L_{\mu,f}(h_S) > \varepsilon\}$ solo puede ocurrir si alguna hipótesis mala es consistente con toda la muestra. Para escribir esta inclusión con precisión, definimos

$$M = \{S|_{\mathcal{X}} : \exists h \in \mathcal{H}_\varepsilon \text{ tal que } L_S(h) = 0\}.$$

Entonces

$$\{S|_{\mathcal{X}} : L_{\mu,f}(h_S) > \varepsilon\} \subseteq M \subseteq \bigcup_{h \in \mathcal{H}_\varepsilon} \{S|_{\mathcal{X}} : L_S(h) = 0\}.$$

Fijemos $h \in \mathcal{H}_\varepsilon$. Que $L_S(h) = 0$ significa, por enunciado, que $h(X_i) = f(X_i)$ para cada $i = 1, \dots, m$. Por independencia de los X_i ,

$$\begin{aligned} \mu^m \{S|_{\mathcal{X}} : L_S(h) = 0\} &= \mathbb{P}(h(X_i) = f(X_i), \forall i \in [m]) \\ &= \prod_{i=1}^m \mathbb{P}(h(X_i) = f(X_i)) \\ &= (1 - L_{\mu,f}(h))^m \\ &\leq (1 - \varepsilon)^m \leq e^{-m\varepsilon}, \end{aligned}$$

donde la última desigualdad usa $\log(1+x) \leq x$ con $x = -\varepsilon$. Aplicando la cota de la unión,

$$\begin{aligned} \mathbb{P}(L_{\mu,f}(h_S) > \varepsilon) &\leq \sum_{h \in \mathcal{H}_\varepsilon} \mu^m \{S|_{\mathcal{X}} : L_S(h) = 0\} \\ &\leq |\mathcal{H}_\varepsilon| e^{-m\varepsilon} \leq |\mathcal{H}| e^{-m\varepsilon}. \end{aligned}$$

Para que la última expresión sea a lo más δ , basta exigir

$$m \geq \frac{\log(|\mathcal{H}|/\delta)}{\varepsilon} = \frac{\log|\mathcal{H}| + \log(1/\delta)}{\varepsilon}.$$

Teorema para clases finitas. Si $\mathcal{H}$ es finita y cumple realizabilidad, entonces $\text{ERM}_{\mathcal{H}}$ satisface, para el tamaño muestral anterior,

$$\mathbb{P}_{S \sim \mu^m} (L_{\mu,f}(h_S) \leq \varepsilon) \geq 1 - \delta.$$

Por lo tanto, toda clase finita es PAC-aprendible en el caso realizable.

Una clase más grande requiere más datos; exigir menor error produce una dependencia $1/\varepsilon$, y aumentar la confianza cuesta solo logaritmicamente mediante $\log(1/\delta)$.

9. Aprendizaje PAC

PAC significa *Probably Approximately Correct*: con probabilidad alta, el predictor aprendido es aproximadamente correcto.

Definición (PAC-aprendibilidad realizable). Una clase $\mathcal{H}$ es PAC-aprendible si existen una función de complejidad muestral

$$m_{\mathcal{H}} : (0, 1)^2 \rightarrow \mathbb{N}$$

y un algoritmo A , que a cada muestra S asigna $h_S = A(S) \in \mathcal{H}$, tales que para toda distribución μ sobre $\mathcal{X}$, toda función objetivo $f : \mathcal{X} \rightarrow \mathcal{Y}$ realizable por $\mathcal{H}$, todo $\varepsilon, \delta \in (0, 1)$ y todo $m \geq m_{\mathcal{H}}(\varepsilon, \delta)$,

$$\mathbb{P}_{S \sim \mu^m} (L_{\mu,f}(A(S)) \leq \varepsilon) \geq 1 - \delta.$$

Aquí ε controla la **precisión** y δ la **probabilidad de falla**. El cuantificador “para toda μ ” es esencial: la garantía no depende de conocer la distribución que genera los datos.

Aprendibilidad versus eficiencia. La definición PAC exige que exista un algoritmo con una cantidad finita de datos, pero por sí sola no asegura que pueda ejecutarse en tiempo razonable. Por ejemplo, recorrer toda una clase finita enorme puede ser computacionalmente impracticable.

10. Ejemplo PAC: rectángulos en $\mathbb{R}^2$

Consideremos la clase infinita

$$\mathcal{H}_{\text{rect}} = \{\mathbf{1}_R : R = [a, b] \times [c, d] \subseteq [0, 2]^2\}.$$

Aunque $\mathcal{H}_{\text{rect}}$ no es finita, sí es PAC-aprendible. Bajo realizabilidad existe un rectángulo objetivo R^* tal que $f = \mathbf{1}_{R^*}$.

10.1. Algoritmo de aprendizaje

Dada $S = ((X_i, Y_i))_{i=1}^m$, sea $I = \{i \in [m] : Y_i = 1\}$. Si $I \neq \emptyset$, definimos

$$\begin{aligned} a_S &= \min_{i \in I} X_{i,1}, & b_S &= \max_{i \in I} X_{i,1}, \\ c_S &= \min_{i \in I} X_{i,2}, & d_S &= \max_{i \in I} X_{i,2}, \end{aligned}$$

y tomamos el rectángulo mínimo que contiene todas las observaciones positivas:

$$R_S = [a_S, b_S] \times [c_S, d_S], \quad h_S = \mathbf{1}_{R_S}.$$

Si $I = \emptyset$, se define $h_S \equiv 0$. Como todos los puntos positivos pertenecen a R^* y R^* es un rectángulo alineado con los ejes, se cumple $R_S \subseteq R^*$. Por ello el algoritmo no crea falsos positivos y

$$L_{\mu,f}(h_S) = \mu(R^* \setminus R_S).$$

10.2. Demostración de la garantía

Si $\mu(R^*) \leq \varepsilon$, entonces directamente

$$L_{\mu,f}(h_S) = \mu(R^* \setminus R_S) \leq \mu(R^*) \leq \varepsilon.$$

Supongamos ahora $\mu(R^*) > \varepsilon$. En cada borde de R^* se escoge una franja interior —izquierda, derecha, inferior y superior— de masa $\varepsilon/4$. Si la muestra contiene al menos un punto positivo en cada franja, los cuatro extremos de R_S quedan suficientemente cerca de los de R^* . La región omitida queda contenida en la unión de esas franjas y, por subaditividad,

$$\mu(R^* \setminus R_S) \leq 4 \frac{\varepsilon}{4} = \varepsilon.$$

Para una franja T con $\mu(T) = \varepsilon/4$, la probabilidad de no observar ningún punto de T es

$$\mathbb{P}(S \cap T = \emptyset) = \left(1 - \frac{\varepsilon}{4}\right)^m \leq e^{-m\varepsilon/4}.$$

Por la cota de la unión sobre las cuatro franjas,


$$\mathbb{P}(L_{\mu,f}(h_S) > \varepsilon) \leq 4e^{-m\varepsilon/4}.$$

Para que esta probabilidad sea a lo más δ , basta que

$$m \geq m_{\mathcal{H}_{\text{rect}}}(\varepsilon, \delta) := \left\lceil \frac{4}{\varepsilon} \log \left(\frac{4}{\delta} \right) \right\rceil.$$

Conclusión. La clase de indicadores de rectángulos alineados con los ejes es PAC-aprendible, aun cuando es infinita. Lo decisivo no es solamente la cardinalidad de $\mathcal{H}$, sino que su estructura permita controlar el evento de generalización.

11. Mapa conceptual



12. Fórmulas que conviene memorizar

$$\begin{aligned}
 \mu_X(A) &= \mathbb{P}(X \in A) = X_{\#}\mathbb{P}(A), \\
 \mathbb{E}[g(X)] &= \int g d\mu_X, \\
 \mathbb{E}[U \mid \mathcal{G}] &: \mathcal{G}\text{-medible y } \int_A \mathbb{E}[U \mid \mathcal{G}] d\mathbb{P} = \int_A U d\mathbb{P}, \\
 \mathbb{E}[\mathbb{E}[U \mid \mathcal{G}] \mid \mathcal{H}] &= \mathbb{E}[U \mid \mathcal{H}], \quad \mathcal{H} \subseteq \mathcal{G}, \\
 \mathbb{P}(Z \geq a) &\leq \mathbb{E}[Z]/a, \\
 \mathbb{E}[e^{\lambda X}] &\leq e^{\lambda^2(b-a)^2/8}, \\
 \mathbb{P}\left(\left|\frac{1}{n} \sum Z_i\right| \geq \varepsilon\right) &\leq 2e^{-2n\varepsilon^2/(b-a)^2}, \\
 L_{\mu,f}(h) &= \mathbb{P}_{X \sim \mu}(h(X) \neq f(X)), \\
 L_S(h) &= \frac{1}{m} \sum_{i=1}^m \mathbf{1}_{\{h(X_i) \neq Y_i\}}, \\
 h_S &\in \arg \min_{h \in \mathcal{H}} L_S(h), \\
 m_{\mathcal{H}}(\varepsilon, \delta) &: \mathbb{P}(L_{\mu,f}(A(S)) \leq \varepsilon) \geq 1 - \delta, \\
 m_{\text{finita}} &\geq \frac{\log(|\mathcal{H}|/\delta)}{\varepsilon}, \\
 m_{\text{rect}} &\geq \frac{4}{\varepsilon} \log\left(\frac{4}{\delta}\right).
 \end{aligned}$$

13. Preguntas típicas de prueba

1. Explicar por qué minimizar $L_S(h)$ no garantiza minimizar $L_{\mu,f}(h)$.
2. Definir sesgo inductivo y explicar el trade-off asociado al tamaño de $\mathcal{H}$.
3. Definir σ -álgebra, variable aleatoria y ley $X_{\#}\mathbb{P}$.
4. Distinguir distribución conjunta, marginal, producto e independencia.
5. Definir $\mathbb{E}[U \mid \mathcal{G}]$ y demostrar/usar la propiedad de torre.
6. A partir de Hoeffding, despejar el tamaño muestral necesario para una tolerancia ε y confianza $1 - \delta$.
7. Probar la cota $|\mathcal{H}|e^{-\varepsilon m}$ para clases finitas usando independencia, $(1 - \varepsilon)^m \leq e^{-\varepsilon m}$ y union bound.
8. Enunciar la definición PAC, identificando el papel de ε , δ , $m_{\mathcal{H}}$ y los cuantificadores sobre μ y f .
9. Interpretar el supuesto de realizabilidad y explicar por qué implica $L_S(h_S) = 0$ para ERM.
10. Describir el algoritmo del rectángulo mínimo y demostrar la cota $4e^{-m\varepsilon/4}$ usando las cuatro franjas de borde.

14. Lo mínimo que debes manejar

- Diferencia entre **error verdadero** y **error empírico**.
- Qué hace ERM y por qué puede producir overfitting.
- Por qué introducir una clase $\mathcal{H}$ equivale a incorporar sesgo inductivo.
- Los cuatro supuestos del modelo de aprendizaje presentado en las notas.
- Definiciones de ley, independencia, esperanza condicional y distribución condicional.
- Markov, lema de Hoeffding y desigualdad de Hoeffding.
- Cota fundamental para $\mathcal{H}$ finita:

$$\mathbb{P}(L_{\mu,f}(h_S) > \varepsilon) \leq |\mathcal{H}|e^{-\varepsilon m}.$$

- Tamaño muestral suficiente:

$$m \geq \frac{\log(|\mathcal{H}|/\delta)}{\varepsilon}.$$

- Definición de PAC-aprendibilidad y diferencia entre aprendibilidad estadística y eficiencia computacional.
- Para rectángulos alineados con los ejes, algoritmo del rectángulo mínimo y cota

$$\mathbb{P}(L_{\mu,f}(h_S) > \varepsilon) \leq 4e^{-m\varepsilon/4}.$$