

Aprendizaje de Máquinas

Notas de clase

Teoría del aprendizaje y modelos lineales

UOH

Aprendizaje de Máquinas

Aprendizaje PAC, convergencia uniforme y predictores lineales

1 Aprendizaje supervisado

1.1 Instancias, etiquetas e hipótesis

Definición 1.1 (Elementos del modelo). El espacio de instancias se denota por $\mathcal{X}$ y el conjunto de etiquetas o valores de salida por $\mathcal{Y}$. Una hipótesis es una función medible

$$h : \mathcal{X} \longrightarrow \mathcal{Y}.$$

La clase $\mathcal{H}$ reúne las hipótesis que el algoritmo puede seleccionar. En clasificación binaria se utiliza $\mathcal{Y} = \{0, 1\}$; para los semiespacios se usará la codificación $\{-1, 1\}$.

Definición 1.2 (Muestra de entrenamiento). En el modelo con etiquetado determinista se fija una distribución μ sobre $\mathcal{X}$ y una función de etiquetado $f : \mathcal{X} \rightarrow \mathcal{Y}$. Se observan

$$S = ((x_1, y_1), \dots, (x_m, y_m)), \quad y_i = f(x_i),$$

donde $x_1, \dots, x_m$ son independientes e idénticamente distribuidos con ley μ . Se abrevia esta condición como *i.i.d.*

La muestra de instancias es $S_X = (x_1, \dots, x_m) \sim \mu^m$, donde $\mu^m = \mu \otimes \dots \otimes \mu$ es la medida producto. Escribimos $[m] = \{1, \dots, m\}$.

Idea 1.1 (Qué conoce el algoritmo). El algoritmo recibe la muestra S y devuelve una hipótesis h_S . La distribución μ y la función f son desconocidas. La muestra y la salida h_S son aleatorias; μ , f y $\mathcal{H}$ se mantienen fijas al estudiar una garantía probabilística.

1.2 Error verdadero y error empírico

Definición 1.3 (Error verdadero). El error de clasificación de una hipótesis h es

$$L_{\mu,f}(h) = \mathbb{P}_{X \sim \mu}(h(X) \neq f(X)).$$

Equivalentemente,

$$L_{\mu,f}(h) = \int_{\mathcal{X}} \mathbf{1}_{\{h(x) \neq f(x)\}} d\mu(x).$$

Mide la probabilidad de equivocarse en una instancia nueva.

Definición 1.4 (Error empírico). El error sobre la muestra es

$$L_S(h) = \frac{1}{m} \sum_{i=1}^m \mathbf{1}_{\{h(x_i) \neq y_i\}}.$$

También puede escribirse

$$L_S(h) = \frac{|\{i \in [m] : h(x_i) \neq y_i\}|}{m}.$$

Se cuentan las clasificaciones *incorrectas*. La fracción de aciertos es $1 - L_S(h)$.

Definición 1.5 (Minimización del riesgo empírico). Un algoritmo $\text{ERM}_{\mathcal{H}}$ selecciona

$$h_S \in \arg \min_{h \in \mathcal{H}} L_S(h).$$

La sigla ERM corresponde a *empirical risk minimization*. Puede haber varias hipótesis minimizadoras; basta seleccionar una.

Definición 1.6 (Supuesto de realizabilidad). El par (μ, f) es realizable por $\mathcal{H}$ si existe $h^* \in \mathcal{H}$ tal que

$$L_{\mu,f}(h^*) = 0.$$

Es decir, $h^* = f$ μ -casi seguramente. Esto permite que difieran en un conjunto de probabilidad cero.

Proposición 1.1 (Consistencia del ERM realizable). Bajo el supuesto de realizabilidad, todo ERM satisface $L_S(h_S) = 0$ con probabilidad uno.

Demostración. Por enunciado existe h^* con $\mu(h^* \neq f) = 0$. Para cada i , $\mathbb{P}(h^*(X_i) \neq f(X_i)) = 0$. Por la cota de la unión,

$$\mathbb{P}(\exists i \in [m] : h^*(X_i) \neq f(X_i)) \leq \sum_{i=1}^m 0 = 0.$$

Por tanto, $L_S(h^*) = 0$ casi seguramente. Como h_S minimiza el error empírico y este es no negativo,

$$0 \leq L_S(h_S) \leq L_S(h^*) = 0.$$

Así, $L_S(h_S) = 0$. □

2 Aprendizaje PAC realizable

2.1 Definición y complejidad de muestreo

Definición 2.1 (Clase PAC-aprendible). Una clase $\mathcal{H}$ es PAC-aprendible en el modelo realizable si existen un algoritmo $S \mapsto h_S \in \mathcal{H}$ y una función

$$m_{\mathcal{H}} : (0, 1)^2 \longrightarrow \mathbb{N}$$

tales que, para toda distribución μ y función f realizables por $\mathcal{H}$, para todo $\varepsilon, \delta \in (0, 1)$ y todo $m \geq m_{\mathcal{H}}(\varepsilon, \delta)$,

$$\mathbb{P}_{S \sim \mu^m} (L_{\mu, f}(h_S) \leq \varepsilon) \geq 1 - \delta.$$

La sigla PAC significa *probably approximately correct*: probablemente aproximadamente correcto.

- ε controla la precisión: el error verdadero debe ser pequeño.
- δ controla la probabilidad de falla: la confianza es $1 - \delta$.
- $m_{\mathcal{H}}$ es una cota de complejidad de muestreo.

La garantía debe valer para toda distribución admisible, con una misma cota que depende de ε, δ y de la clase, no de una distribución particular.

2.2 Garantía para clases finitas

Teorema 2.1 (ERM sobre una clase finita). Sean $\mathcal{H}$ finita y no vacía, y (μ, f) realizables por $\mathcal{H}$. Si

$$m \geq \frac{\ln(|\mathcal{H}|/\delta)}{\varepsilon},$$

entonces cualquier $\text{ERM}_{\mathcal{H}}$ satisface

$$\mathbb{P}(L_{\mu, f}(h_S) > \varepsilon) \leq \delta.$$

En particular, se puede tomar

$$m_{\mathcal{H}}(\varepsilon, \delta) = \left\lceil \frac{\ln(|\mathcal{H}|/\delta)}{\varepsilon} \right\rceil.$$

Todos los logaritmos de estas cotas son naturales.

Demostración. Fijemos $\mu, f, \varepsilon, \delta$. Definimos la clase de hipótesis malas

$$\mathcal{H}_{\varepsilon} = \{h \in \mathcal{H} : L_{\mu, f}(h) > \varepsilon\}.$$

También definimos el evento

$$M = \{S_X : \exists h \in \mathcal{H}_{\varepsilon}, L_S(h) = 0\}.$$

Por la proposición anterior, el ERM tiene error empírico cero casi seguramente. Por eso, si su error verdadero excede ε , alguna hipótesis mala es consistente con toda la muestra: la propia h_S . Así,

$$\{L_{\mu, f}(h_S) > \varepsilon\} \subseteq M \quad \text{salvo un evento nulo.}$$

Como

$$M = \bigcup_{h \in \mathcal{H}_{\varepsilon}} \{L_S(h) = 0\},$$

la monotonía de la probabilidad y la cota de la unión dan

$$\mathbb{P}(L_{\mu, f}(h_S) > \varepsilon) \leq \sum_{h \in \mathcal{H}_{\varepsilon}} \mathbb{P}(L_S(h) = 0). \quad (1)$$

Ahora fijemos una sola $h \in \mathcal{H}_{\varepsilon}$. Su error empírico es cero exactamente cuando acierta en cada instancia:

$$\{L_S(h) = 0\} = \bigcap_{i=1}^m \{h(X_i) = f(X_i)\}.$$

Como las instancias son i.i.d., por enunciado, y h está fija,

$$\begin{aligned} \mathbb{P}(L_S(h) = 0) &= \prod_{i=1}^m \mathbb{P}(h(X_i) = f(X_i)) \\ &= (1 - L_{\mu, f}(h))^m \\ &\leq (1 - \varepsilon)^m. \end{aligned}$$

La factorización también se ve en la integral producto:

$$\begin{aligned} \int_{\mathcal{X}^m} \prod_{i=1}^m \mathbf{1}_{\{h(x_i)=f(x_i)\}} d\mu^m(x_1, \dots, x_m) \\ = \prod_{i=1}^m \int_{\mathcal{X}} \mathbf{1}_{\{h(x_i)=f(x_i)\}} d\mu(x_i). \end{aligned}$$

Se aplica Tonelli porque los indicadores son no negativos. Cada factor depende de una única coordenada; las integrales de 1 sobre las demás coordenadas valen 1.

La desigualdad $\ln(1 + u) \leq u$, válida para $u > -1$, aplicada a $u = -\varepsilon$, entrega

$$(1 - \varepsilon)^m = e^{m \ln(1 - \varepsilon)} \leq e^{-m\varepsilon}.$$

Sustituyendo en (1),

$$\begin{aligned} \mathbb{P}(L_{\mu, f}(h_S) > \varepsilon) &\leq |\mathcal{H}_{\varepsilon}| e^{-m\varepsilon} \\ &\leq |\mathcal{H}| e^{-m\varepsilon}. \end{aligned}$$

Por enunciado, $m\varepsilon \geq \ln(|\mathcal{H}|/\delta)$. Por tanto,

$$|\mathcal{H}| e^{-m\varepsilon} \leq |\mathcal{H}| e^{-\ln(|\mathcal{H}|/\delta)} = \delta.$$

Esto prueba la afirmación. $\square$

Idea 2.1 (Implementación y alcance). Para una clase finita se puede recorrer toda $\mathcal{H}$, calcular $L_S(h)$ y elegir un minimizador. En el caso realizable basta detenerse en la primera hipótesis con error empírico cero. El procedimiento existe, pero recorrer una clase grande puede ser costoso: la garantía de muestreo no asegura eficiencia computacional.

Idea 2.2 (Por qué primero se fija una hipótesis). La independencia se usa para una h elegida antes de ver la muestra. No se puede aplicar directamente ese producto a h_S , pues depende de todos los datos. La unión sobre las hipótesis malas permite controlar precisamente esa elección dependiente de la muestra.

3 Aprendizaje de rectángulos

3.1 La clase y el algoritmo

Definición 3.1 (Rectángulos paralelos a los ejes). En $\mathcal{X} = [0, 2]^2$, consideramos los rectángulos

$$R = [a, b] \times [c, d], \quad 0 \leq a \leq b \leq 2, \quad 0 \leq c \leq d \leq 2.$$

Denotamos por $\mathcal{R}$ la familia de estos rectángulos. La clase de hipótesis es

$$\mathcal{H}_{\text{rect}} = \{\mathbf{1}_R : R \in \mathcal{R}\}.$$

Se admite también $R = \emptyset$, cuya hipótesis predice siempre 0. Esta convención permite definir el algoritmo cuando no hay ejemplos positivos. La clase es infinita, aunque cada rectángulo tiene solo cuatro parámetros.

Por enunciado se supone realizabilidad: existe

$$R^* = [a^*, b^*] \times [c^*, d^*] \quad \text{tal que} \quad f = \mathbf{1}_{R^*} \quad \mu\text{-c.s.}$$

El algoritmo no conoce R^* . Si el rectángulo objetivo es vacío, todos los ejemplos son negativos casi seguramente y el algoritmo devuelve el conjunto vacío, con error cero.

Idea 3.1 (Rectángulo mínimo de los positivos). Dada la muestra S , definimos


$$I = \{i \in [m] : y_i = 1\}.$$

Si $I \neq \emptyset$ y $x_i = (x_{i,1}, x_{i,2})$, tomamos

$$a = \min_{i \in I} x_{i,1}, \quad b = \max_{i \in I} x_{i,1},$$

$$c = \min_{i \in I} x_{i,2}, \quad d = \max_{i \in I} x_{i,2}.$$

Se devuelve $h_S = \mathbf{1}_{R_S}$, donde $R_S = [a, b] \times [c, d]$. Si $I = \emptyset$, se devuelve $R_S = \emptyset$.



Los puntos son positivos y las cruces negativos. R_S se construye usando solo los positivos.

Proposición 3.1 (Inclusión y error del rectángulo aprendido). Con probabilidad uno,

$$R_S \subseteq R^*, \quad L_S(\mathbf{1}_{R_S}) = 0,$$

y

$$L_{\mu, f}(\mathbf{1}_{R_S}) = \mu(R^* \setminus R_S).$$

Demostración. Como $f = \mathbf{1}_{R^*}$ casi seguramente, por enunciado, la probabilidad de que alguno de los m ejemplos tenga una etiqueta distinta de $\mathbf{1}_{R^*}(x_i)$ es cero, por la cota de la unión. Trabajemos en el evento de probabilidad uno donde todas coinciden.

Cada punto positivo pertenece a R^* . Sus coordenadas quedan entre los extremos del rectángulo objetivo, de modo que sus mínimos y máximos también. Por ello $R_S \subseteq R^*$. Todo positivo está en R_S por construcción y ningún negativo puede estar en él, pues los negativos están fuera de R^* . Esto prueba la consistencia, también cuando $I = \emptyset$.

Las dos hipótesis solo difieren en la diferencia simétrica $R_S \Delta R^*$. Debido a la inclusión, esta diferencia es $R^* \setminus R_S$. Los puntos donde $f \neq \mathbf{1}_{R^*}$ tienen medida cero y no cambian el error. $\square$

3.2 Control geométrico del error

Teorema 3.1 (Garantía PAC para rectángulos). El algoritmo anterior satisface

$$\mathbb{P}(L_{\mu, f}(h_S) > \varepsilon) \leq 4e^{-m\varepsilon/4}.$$

En particular, $\mathcal{H}_{\text{rect}}$ es PAC-aprendible con

$$m_{\text{rect}}(\varepsilon, \delta) = \left\lceil \frac{4 \ln(4/\delta)}{\varepsilon} \right\rceil.$$

Demostración. Fijemos $\varepsilon, \delta \in (0, 1)$.

Caso 1: $\mu(R^*) \leq \varepsilon$. Por la proposición anterior,

$$L_{\mu, f}(h_S) = \mu(R^* \setminus R_S) \leq \mu(R^*) \leq \varepsilon.$$

En este caso la garantía se cumple con probabilidad uno.

Caso 2: $\mu(R^*) > \varepsilon$. Pongamos $q = \varepsilon/4$. La idea de la pizarra es retirar una banda de masa pequeña por cada lado de R^* , formando un rectángulo interior R_ε . Si R_S contiene ese rectángulo interior, el error no supera ε .

Definimos los umbrales de la primera coordenada mediante

$$a_\varepsilon = \inf\{s \in [a^*, b^*] : \mu(R^* \cap \{x_1 \leq s\}) \geq q\},$$

$$b_\varepsilon = \sup\{s \in [a^*, b^*] : \mu(R^* \cap \{x_1 \geq s\}) \geq q\}.$$

Análogamente, para la segunda coordenada,

$$c_\varepsilon = \inf\{s \in [c^*, d^*] : \mu(R^* \cap \{x_2 \leq s\}) \geq q\},$$

$$d_\varepsilon = \sup\{s \in [c^*, d^*] : \mu(R^* \cap \{x_2 \geq s\}) \geq q\}.$$

Los conjuntos usados para estos umbrales no son vacíos porque $\mu(R^*) > \varepsilon > q$. Los umbrales son cuantiles de las medidas de las coordenadas restringidas a R^* .

Por continuidad de la medida en sucesiones monótonas,

$$\begin{aligned} \mu(R^* \cap \{x_1 < a_\varepsilon\}) &\leq q, \\ \mu(R^* \cap \{x_1 \leq a_\varepsilon\}) &\geq q. \end{aligned} \quad (2)$$

Para justificarlo, antes del primer umbral toda masa acumulada es menor que q ; al aproximarse al umbral por la izquierda se obtiene la primera cota. Al aproximarse por la derecha, los conjuntos $\{x_1 \leq s\}$ decrecen hasta $\{x_1 \leq a_\varepsilon\}$ y sus masas son al menos q . Esto da la segunda cota. Si el umbral coincide con un extremo, la misma conclusión se obtiene directamente o con una de esas aproximaciones. Las otras tres coordenadas laterales se tratan de igual modo.

Definimos


$$R_\varepsilon = [a_\varepsilon, b_\varepsilon] \times [c_\varepsilon, d_\varepsilon].$$

Fuera de este rectángulo interior debe incumplirse al menos una de las cuatro desigualdades que lo definen. Aplicando las cotas del tipo (2),

$$\begin{aligned} \mu(R^* \setminus R_\varepsilon) &\leq \mu(R^* \cap \{x_1 < a_\varepsilon\}) \\ &\quad + \mu(R^* \cap \{x_1 > b_\varepsilon\}) \\ &\quad + \mu(R^* \cap \{x_2 < c_\varepsilon\}) \\ &\quad + \mu(R^* \cap \{x_2 > d_\varepsilon\}) \\ &\leq 4q = \varepsilon. \end{aligned}$$

Así, $\mu(R_\varepsilon) \geq \mu(R^*) - \varepsilon > 0$; en particular, el rectángulo interior no es vacío. Si $R_\varepsilon \subseteq R_S$, entonces

$$\mu(R^* \setminus R_S) \leq \mu(R^* \setminus R_\varepsilon) \leq \varepsilon. \quad (3)$$



Cada banda cerrada tiene masa al menos $\varepsilon/4$. La masa total excluida del rectángulo interior es a lo sumo ε .

Control de la probabilidad de falla. Las bandas cerradas son

$$R_a = R^* \cap \{x_1 \leq a_\varepsilon\}, \quad R_b = R^* \cap \{x_1 \geq b_\varepsilon\},$$

$$R_c = R^* \cap \{x_2 \leq c_\varepsilon\}, \quad R_d = R^* \cap \{x_2 \geq d_\varepsilon\}.$$

Cada una tiene masa al menos q . Si la muestra contiene un punto en cada banda, esos puntos son positivos casi seguramente. Entonces los extremos de R_S satisfacen

$$a \leq a_\varepsilon, \quad b \geq b_\varepsilon, \quad c \leq c_\varepsilon, \quad d \geq d_\varepsilon,$$

y por ello $R_\varepsilon \subseteq R_S$. Equivalentemente, esta inclusión pide que existan índices positivos, no necesariamente distintos, tales que

$$\begin{aligned} x_{i_a,1} &\leq a_\varepsilon, & x_{i_b,1} &\geq b_\varepsilon, \\ x_{i_c,2} &\leq c_\varepsilon, & x_{i_d,2} &\geq d_\varepsilon. \end{aligned}$$

Si la inclusión falla, al menos una banda no recibió observaciones. Sea

$$A_j = \{X_i \notin R_j \text{ para todo } i \in [m]\}, \quad j \in \{a, b, c, d\}.$$

Por (3) y la cota de la unión,

$$\begin{aligned} \mathbb{P}(L_{\mu,f}(h_S) > \varepsilon) &\leq \mathbb{P}(R_\varepsilon \not\subseteq R_S) \\ &\leq \mathbb{P}(A_a) + \mathbb{P}(A_b) + \mathbb{P}(A_c) + \mathbb{P}(A_d). \end{aligned}$$

Para cada banda, la independencia de los X_i da

$$\mathbb{P}(A_j) = \prod_{i=1}^m \mathbb{P}(X_i \notin R_j) = (1 - \mu(R_j))^m \leq (1 - q)^m.$$

No hace falta que los cuatro eventos A_j sean independientes. Por tanto,

$$\mathbb{P}(L_{\mu,f}(h_S) > \varepsilon) \leq 4(1 - \varepsilon/4)^m \leq 4e^{-m\varepsilon/4}.$$

Para que la última expresión sea a lo sumo δ , basta exigir

$$-\frac{m\varepsilon}{4} \leq \ln(\delta/4), \quad \text{es decir,} \quad m \geq \frac{4 \ln(4/\delta)}{\varepsilon}.$$

El último despeje invierte el signo al multiplicar por $-4/\varepsilon$. $\square$

Idea 3.2 (Masas de las bandas). En el dibujo de clase se representan bandas de masa exactamente $\varepsilon/4$. Las desigualdades anteriores permiten conservar la prueba cuando la distribución tiene masa en líneas o puntos, donde esa igualdad puede ser imposible. La masa que se retira usa bandas abiertas en el corte; el evento de recibir una observación usa bandas cerradas.

4 Modelo agnóstico y predictor de Bayes

4.1 Etiquetas que no son deterministas

En general, una misma instancia puede recibir etiquetas distintas: por ejemplo, tanto $(x, 0)$ como $(x, 1)$ pueden ser posibles. Por eso se considera directamente una distribución conjunta μ sobre $\mathcal{X} \times \mathcal{Y}$ y una muestra

$$S = ((X_1, Y_1), \dots, (X_m, Y_m)) \sim \mu^m.$$

Ya no se supone que $Y = f(X)$ ni que alguna hipótesis tenga error cero.

Definición 4.1 (Riesgos de clasificación en el modelo agnóstico). Para $h : \mathcal{X} \rightarrow \mathcal{Y}$ medible,

$$L_\mu(h) = \mathbb{P}_{(X,Y) \sim \mu}(h(X) \neq Y),$$

$$L_S(h) = \frac{1}{m} \sum_{i=1}^m \mathbf{1}_{\{h(X_i) \neq Y_i\}}.$$

El primer riesgo se calcula con la distribución conjunta; el segundo, con las etiquetas observadas.

Definición 4.2 (Marginal y distribución condicional). La marginal de las instancias es μ_X . La distribución de la etiqueta dado $X = x$ se denota por $\mu(\cdot | x)$. En espacios usuales de aprendizaje, como subconjuntos borelianos de $\mathbb{R}^d$, se trabaja con versiones medibles de estas distribuciones condicionales. Para un conjunto medible $A \subseteq \mathcal{X} \times \mathcal{Y}$,

$$\mu(A) = \int_{\mathcal{X}} \int_{\mathcal{Y}} \mathbf{1}_A(x, y) d\mu(y | x) d\mu_X(x).$$

En particular,

$$L_\mu(h) = \int_{\mathcal{X}} \int_{\mathcal{Y}} \mathbf{1}_{\{h(x) \neq y\}} d\mu(y | x) d\mu_X(x). \quad (4)$$

Primero se promedia el error sobre las posibles etiquetas de una instancia; después, sobre las instancias.

4.2 La mejor decisión para cada instancia

En clasificación binaria, $\mathcal{Y} = \{0, 1\}$. Escribamos

$$\eta(x) = \mathbb{P}(Y = 1 | X = x).$$

Entonces $\mathbb{P}(Y = 0 | X = x) = 1 - \eta(x)$. El riesgo condicional de h es

$$\begin{aligned} r_h(x) &= \int_{\mathcal{Y}} \mathbf{1}_{\{h(x) \neq y\}} d\mu(y | x) \\ &= \mathbf{1}_{\{h(x)=0\}} \eta(x) + \mathbf{1}_{\{h(x)=1\}} (1 - \eta(x)). \end{aligned}$$

Predicción en x	Probabilidad de error
$h(x) = 0$	$\eta(x)$
$h(x) = 1$	$1 - \eta(x)$

Definición 4.3 (Predictor de Bayes). El predictor de Bayes es la función

$$f_\mu(x) = \begin{cases} 1, & \eta(x) \geq \frac{1}{2}, \\ 0, & \eta(x) < \frac{1}{2}. \end{cases}$$

Se elige la etiqueta con mayor probabilidad condicional. En el empate $\eta(x) = 1/2$, ambas decisiones tienen el mismo error; la definición anterior escoge 1. La función es medible porque $f_\mu = \mathbf{1}_{\{x: \eta(x) \geq 1/2\}}$ y η es medible.

Proposición 4.1 (Optimalidad de Bayes). Si $\mathcal{L}_0(\mathcal{X}, \{0, 1\})$ denota la clase de todos los clasificadores medibles, entonces

$$L_\mu(f_\mu) = \min_{h \in \mathcal{L}_0(\mathcal{X}, \{0, 1\})} L_\mu(h).$$

Demostración. Fijemos un clasificador medible h y dividamos el espacio en

$$\begin{aligned} \mathcal{X}^+ &= \{x : h(x) = f_\mu(x)\}, \\ \mathcal{X}^- &= \{x : h(x) \neq f_\mu(x)\}. \end{aligned}$$

Estos conjuntos son disjuntos y su unión es $\mathcal{X}$. Por (4),

$$L_\mu(h) = \int_{\mathcal{X}^+} r_h(x) d\mu_X(x) + \int_{\mathcal{X}^-} r_h(x) d\mu_X(x).$$

En $\mathcal{X}^+$ las predicciones coinciden, luego $r_h = r_{f_\mu}$. En $\mathcal{X}^-$ las etiquetas son opuestas, porque solo hay dos posibilidades. Se consideran los dos valores de $f_\mu(x)$:

■ Si $f_\mu(x) = 1$, entonces $\eta(x) \geq 1/2$ y $h(x) = 0$. Por ello

$$r_h(x) = \eta(x) \geq \frac{1}{2} \geq 1 - \eta(x) = r_{f_\mu}(x).$$

- Si $f_\mu(x) = 0$, entonces $\eta(x) < 1/2$ y $h(x) = 1$. En consecuencia,

$$r_h(x) = 1 - \eta(x) > \frac{1}{2} > \eta(x) = r_{f_\mu}(x).$$

Por tanto, en todo el espacio $r_h(x) \geq r_{f_\mu}(x)$. Integrando esta desigualdad en $\mathcal{X}^-$ y usando la igualdad en $\mathcal{X}^+$,

$$\begin{aligned} L_\mu(h) &\geq \int_{\mathcal{X}^+} r_{f_\mu}(x) d\mu_X(x) + \int_{\mathcal{X}^-} r_{f_\mu}(x) d\mu_X(x) \\ &= L_\mu(f_\mu). \end{aligned}$$

Como f_μ es medible, pertenece a la clase sobre la cual se minimiza, y alcanza el mínimo. $\square$

Corolario 4.1 (Riesgo de Bayes). El menor error de clasificación posible es

$$L_\mu(f_\mu) = \int_{\mathcal{X}} \min\{\eta(x), 1 - \eta(x)\} d\mu_X(x).$$

Puede ser positivo. Por ejemplo, si $\eta(x) = 1/2$ casi seguramente, todo clasificador tiene error $1/2$. En el caso determinista, $\eta(x)$ solo toma los valores 0 y 1 casi seguramente, y el riesgo de Bayes es cero.

Idea 4.1 (Papel de la clase de hipótesis). El predictor de Bayes minimiza entre *todas* las funciones medibles. Si se restringe la búsqueda a $\mathcal{H}$, puede ocurrir que $f_\mu \notin \mathcal{H}$. Entonces el objetivo razonable es acercarse al mejor riesgo dentro de esa clase:

$$\inf_{h \in \mathcal{H}} L_\mu(h) \geq L_\mu(f_\mu).$$

Además, el algoritmo no conoce η ni μ ; debe aprender a partir de la muestra.

5 Modelo general y funciones de pérdida

5.1 Un lenguaje común para distintas tareas

Definición 5.1 (Modelo general de aprendizaje). Se consideran los siguientes elementos:

- Un espacio de instancias $\mathcal{X}$ y un espacio de salidas $\mathcal{Y}$.
- Una clase $\mathcal{H}$ de funciones $h : \mathcal{X} \rightarrow \mathcal{Y}$.
- Un dominio de observaciones $\mathcal{Z}$, que no necesariamente coincide con $\mathcal{X} \times \mathcal{Y}$.
- Una muestra $S = (z_1, \dots, z_m) \in \mathcal{Z}^m$, generada i.i.d. por una distribución desconocida μ sobre $\mathcal{Z}$.

- Una función de pérdida medible

$$\ell : \mathcal{H} \times \mathcal{Z} \longrightarrow \mathbb{R}_+.$$

El riesgo verdadero y el empírico son

$$L_\mu(h) = \mathbb{E}_{Z \sim \mu}[\ell(h, Z)],$$

$$L_S(h) = \frac{1}{m} \sum_{i=1}^m \ell(h, z_i).$$

Para las garantías siguientes se consideran riesgos bien definidos y finitos; la acotación de la pérdida se indicará cuando sea necesaria.

Ejemplo 5.1 (Pérdida de clasificación). Con $\mathcal{Z} = \mathcal{X} \times \mathcal{Y}$,

$$\ell(h, (x, y)) = \mathbf{1}_{\{h(x) \neq y\}}.$$

La pérdida vale 1 si hay error y 0 si hay acierto. Su esperanza es la probabilidad de equivocarse.

5.2 Regresión y pérdida cuadrática

En regresión, por enunciado del modelo, $\mathcal{X} \subseteq \mathbb{R}^d$ y $\mathcal{Y} \subseteq \mathbb{R}$. La predicción debe aproximar un valor numérico. Usar solamente $\mathbb{P}(h(X) \neq Y)$ no mide el tamaño de la discrepancia.

Ejemplo 5.2 (Por qué no basta contar desaciertos). Si el objetivo es $f(x) = 0$ y $h(x) = c \neq 0$ para todo x , entonces

$$\|h - f\|_\infty = |c|, \quad \mathbb{P}(h(X) \neq f(X)) = 1.$$

El error uniforme puede ser arbitrariamente pequeño al tomar c cercano a cero, pero la pérdida de clasificación sigue siendo 1.

Definición 5.2 (Pérdida cuadrática). Para $z = (x, y)$ se toma

$$\ell(h, (x, y)) = (h(x) - y)^2.$$

En este caso,

$$L_\mu(h) = \mathbb{E}_{(X,Y) \sim \mu}[(h(X) - Y)^2],$$

$$L_S(h) = \frac{1}{m} \sum_{i=1}^m (h(x_i) - y_i)^2.$$

Los errores grandes se penalizan más que los pequeños. Esta pérdida no está acotada en general.

Idea 5.1 (Promediar y elevar al cuadrado). La comparación algebraica de la pizarra se expresa como

$$\left(\frac{a+b}{2}\right)^2 \leq \frac{a^2 + b^2}{2}.$$

En efecto,

$$\frac{a^2 + b^2}{2} - \left(\frac{a+b}{2}\right)^2 = \frac{a^2 - 2ab + b^2}{4} = \frac{(a-b)^2}{4} \geq 0.$$

La igualdad ocurre si y solo si $a = b$. Por eso el promedio de los errores al cuadrado no coincide, en general, con el cuadrado del error promedio. El primero no permite que errores de signos opuestos se cancelen.

5.3 Otras tareas: un ejemplo con ajedrez

El modelo general también permite formular tareas distintas de la clasificación con etiquetas individuales. En aprendizaje no supervisado, por ejemplo, las observaciones no vienen acompañadas de una etiqueta objetivo por instancia.

Ejemplo 5.3 (Pérdida de una estrategia). En el ejemplo de ajedrez de la pizarra, $\mathcal{X}$ representa estados del tablero y $\mathcal{Y}$ movimientos posibles. Una hipótesis $h : \mathcal{X} \rightarrow \mathcal{Y}$ actúa como una estrategia. El dominio $\mathcal{Z}$ describe secuencias o escenarios de juego con un resultado final, que permiten evaluar si la estrategia gana o pierde. Se define

$$\ell(h, z) = \begin{cases} 1, & \text{si la estrategia } h \text{ pierde en } z, \\ 0, & \text{en otro caso.} \end{cases}$$

Con una distribución μ fijada sobre esos escenarios,

$$L_\mu(h) = \mathbb{E}_{Z \sim \mu}[\ell(h, Z)] = \mathbb{P}_{Z \sim \mu}(h \text{ pierde}).$$

Este ejemplo ilustra por qué $\mathcal{Z}$ puede ser distinto de $\mathcal{X} \times \mathcal{Y}$. La función de pérdida evalúa el resultado del escenario, no necesariamente una predicción aislada.

6 Aprendizaje PAC agnóstico

Definición 6.1 (PAC agnóstico). Una clase $\mathcal{H}$ es PAC-aprendible agnósticamente respecto de $\mathcal{Z}$ y ℓ si existen un algoritmo $S \mapsto h_S \in \mathcal{H}$ y una función $m_{\mathcal{H}} : (0, 1)^2 \rightarrow \mathbb{N}$ tales que, para toda distribución μ sobre $\mathcal{Z}$ y todos $\varepsilon, \delta \in (0, 1)$, si $m \geq m_{\mathcal{H}}(\varepsilon, \delta)$, entonces

$$\mathbb{P}_{S \sim \mu^m} \left(L_\mu(h_S) \leq \inf_{h \in \mathcal{H}} L_\mu(h) + \varepsilon \right) \geq 1 - \delta.$$

No se impone realizabilidad. La exigencia es que el *exceso de riesgo* respecto de la mejor hipótesis de la clase sea a lo sumo ε , con confianza $1 - \delta$.

Idea 6.1 (Ínfimo y mínimo). Se escribe $\inf$ porque, en una clase arbitraria, el mejor riesgo puede no alcanzarse. Si hay una hipótesis minimizadora,

se puede reemplazar el ínfimo por un mínimo. Para clases finitas no vacías con riesgos finitos, el mínimo sí se alcanza.

El evento de éxito y el de falla son complementarios:

$$\begin{aligned} \mathbb{P} \left(L_\mu(h_S) \leq \inf_{\mathcal{H}} L_\mu + \varepsilon \right) &\geq 1 - \delta \\ \iff \mathbb{P} \left(L_\mu(h_S) > \inf_{\mathcal{H}} L_\mu + \varepsilon \right) &\leq \delta. \end{aligned}$$

Esta distinción fija la orientación de las desigualdades probabilísticas.

Idea 6.2 (Cómo probar aprendibilidad). Se puede construir directamente un algoritmo y demostrar una cota de muestreo, como se hizo con rectángulos. Otra posibilidad es demostrar convergencia uniforme de los riesgos empíricos: esa propiedad garantizará que ERM aprende.

7 Convergencia uniforme

7.1 De una hipótesis fija a toda la clase

Si h está fija y $\ell(h, Z)$ es integrable, la ley de los grandes números da

$$L_S(h) = \frac{1}{m} \sum_{i=1}^m \ell(h, Z_i) \longrightarrow \mathbb{E}[\ell(h, Z)] = L_\mu(h)$$

en probabilidad, y también casi seguramente bajo las hipótesis usuales i.i.d. Esto justifica la idea de que, para una muestra grande, el riesgo empírico aproxima al verdadero.

Sin embargo, ERM selecciona h_S después de observar los datos. Por eso interesa que la aproximación sea válida simultáneamente para todas las hipótesis que el algoritmo puede elegir.

Definición 7.1 (Muestra representativa). Una muestra S es α -representativa respecto de $\mathcal{H}, \mu, \ell$ si

$$|L_S(h) - L_\mu(h)| \leq \alpha \quad \text{para todo } h \in \mathcal{H}.$$

Equivalentemente,

$$\sup_{h \in \mathcal{H}} |L_S(h) - L_\mu(h)| \leq \alpha.$$

La palabra *uniforme* significa que el control vale para toda la clase, con el mismo margen α .

Lema 7.1 (ERM sobre una muestra representativa). Si S es $\varepsilon/2$ -representativa y $h_S \in \arg \min_{h \in \mathcal{H}} L_S(h)$, entonces

$$L_\mu(h_S) \leq \inf_{h \in \mathcal{H}} L_\mu(h) + \varepsilon.$$

Demostración. Sea $r = \inf_{h \in \mathcal{H}} L_\mu(h)$. Para cada $n \in \mathbb{N}$, por definición de ínfimo existe $h_n \in \mathcal{H}$ tal que

$$L_\mu(h_n) \leq r + \frac{1}{n}.$$

No se está suponiendo que el ínfimo sea alcanzado. Se tiene

$$\begin{aligned} L_\mu(h_S) &\leq L_S(h_S) + \frac{\varepsilon}{2} \\ &\leq L_S(h_n) + \frac{\varepsilon}{2} \\ &\leq L_\mu(h_n) + \varepsilon \\ &\leq r + \frac{1}{n} + \varepsilon. \end{aligned}$$

La primera y la tercera desigualdad usan la representatividad, por enunciado. La segunda usa que h_S minimiza L_S sobre $\mathcal{H}$, también por enunciado. La última usa la elección de h_n . Como la cota vale para todo n , al hacer $n \rightarrow \infty$ resulta $L_\mu(h_S) \leq r + \varepsilon$. $\square$

Definición 7.2 (Propiedad de convergencia uniforme). La clase $\mathcal{H}$ tiene la propiedad de convergencia uniforme respecto de $\mathcal{Z}$ y ℓ si existe

$$m_{\mathcal{H}}^{\text{UC}} : (0, 1)^2 \rightarrow \mathbb{N}$$

tal que, para toda distribución μ sobre $\mathcal{Z}$ y todos $\alpha, \delta \in (0, 1)$, cuando $m \geq m_{\mathcal{H}}^{\text{UC}}(\alpha, \delta)$,

$$\mathbb{P}_{S \sim \mu^m}(S \text{ es } \alpha\text{-representativa}) \geq 1 - \delta.$$

Se sobreentiende que los eventos considerados son medibles.

Proposición 7.1 (Convergencia uniforme implica PAC agnóstico). Si $\mathcal{H}$ tiene convergencia uniforme y se puede seleccionar un ERM, entonces es PAC-aprendible agnósticamente mediante ERM, con

$$m_{\mathcal{H}}(\varepsilon, \delta) = m_{\mathcal{H}}^{\text{UC}}(\varepsilon/2, \delta).$$

Demostración. Por enunciado de convergencia uniforme, si $m \geq m_{\mathcal{H}}^{\text{UC}}(\varepsilon/2, \delta)$, el evento

$$E = \{S : S \text{ es } \varepsilon/2\text{-representativa}\}$$

tiene probabilidad al menos $1 - \delta$. El lema anterior prueba la inclusión

$$E \subseteq \left\{ S : L_\mu(h_S) \leq \inf_{h \in \mathcal{H}} L_\mu(h) + \varepsilon \right\}.$$

Si $E \subseteq F$, entonces $\mathbb{P}(E) \leq \mathbb{P}(F)$. En consecuencia, el evento de la derecha tiene probabilidad al menos $1 - \delta$, que es exactamente la garantía PAC agnóstica. $\square$

8 Clases finitas y concentración

8.1 Desigualdad de Hoeffding

Teorema 8.1 (Hoeffding). Sean $\Theta_1, \dots, \Theta_m$ variables i.i.d. con media $\theta = \mathbb{E}[\Theta_i]$, y supongamos, por enunciado, que

$$\mathbb{P}(a \leq \Theta_i \leq b) = 1, \quad a < b.$$

Para todo $\alpha > 0$,

$$\mathbb{P}\left(\left|\frac{1}{m} \sum_{i=1}^m \Theta_i - \bar{\theta}\right| > \alpha\right) \leq 2 \exp\left(-\frac{2m\alpha^2}{(b-a)^2}\right).$$

Esta desigualdad de concentración proporciona una cota explícita para un tamaño de muestra finito.

Si la pérdida satisface $0 \leq \ell(h, z) \leq 1$ y fijamos h , podemos tomar

$$\Theta_i = \ell(h, Z_i), \quad \bar{\theta} = L_\mu(h), \quad a = 0, \quad b = 1.$$

Entonces

$$\mathbb{P}(|L_S(h) - L_\mu(h)| > \alpha) \leq 2e^{-2m\alpha^2}. \quad (5)$$

La acotación debe valer uniformemente para las hipótesis y observaciones consideradas.

8.2 Convergencia uniforme de clases finitas

Teorema 8.2 (Clase finita y pérdida en $[0, 1]$). Si $\mathcal{H}$ es finita y no vacía, y $\ell : \mathcal{H} \times \mathcal{Z} \rightarrow [0, 1]$, entonces

$$m_{\mathcal{H}}^{\text{UC}}(\alpha, \delta) = \left\lceil \frac{\ln(2|\mathcal{H}|/\delta)}{2\alpha^2} \right\rceil$$

es una cota de complejidad de convergencia uniforme.

Demostración. El evento de que la muestra no sea α -representativa es

$$\begin{aligned} M &= \{S : \exists h \in \mathcal{H}, |L_S(h) - L_\mu(h)| > \alpha\} \\ &= \bigcup_{h \in \mathcal{H}} \{S : |L_S(h) - L_\mu(h)| > \alpha\}. \end{aligned}$$

Al aplicar la cota de la unión y luego (5),

$$\begin{aligned} \mathbb{P}(M) &\leq \sum_{h \in \mathcal{H}} \mathbb{P}(|L_S(h) - L_\mu(h)| > \alpha) \\ &\leq \sum_{h \in \mathcal{H}} 2e^{-2m\alpha^2} = 2|\mathcal{H}|e^{-2m\alpha^2}. \end{aligned}$$

Si $m \geq \ln(2|\mathcal{H}|/\delta)/(2\alpha^2)$, entonces

$$\mathbb{P}(M) \leq 2|\mathcal{H}| \exp(-\ln(2|\mathcal{H}|/\delta)) = \delta.$$

Tomando complementos,

$$\mathbb{P}(S \text{ es } \alpha\text{-representativa}) = 1 - \mathbb{P}(M) \geq 1 - \delta.$$

La cota obtenida no depende de μ , por lo que verifica la propiedad de convergencia uniforme. $\square$

Corolario 8.1 (Aprendizaje agnóstico de clases finitas). Bajo las hipótesis del teorema anterior, ERM aprende agnósticamente con

$$m_{\mathcal{H}}(\varepsilon, \delta) = \left\lceil \frac{2 \ln(2|\mathcal{H}|/\delta)}{\varepsilon^2} \right\rceil.$$

En efecto, por la proposición 7.1 se reemplaza α por $\varepsilon/2$:

$$\frac{\ln(2|\mathcal{H}|/\delta)}{2(\varepsilon/2)^2} = \frac{\ln(2|\mathcal{H}|/\delta)}{\varepsilon^2/2} = \frac{2 \ln(2|\mathcal{H}|/\delta)}{\varepsilon^2}.$$

Idea 8.1 (Pérdidas acotadas en otro intervalo). Si $\ell \in [a, b]$, la misma prueba incluye el factor $(b-a)^2$:

$$m_{\mathcal{H}}^{\text{UC}}(\alpha, \delta) = \left\lceil \frac{(b-a)^2 \ln(2|\mathcal{H}|/\delta)}{2\alpha^2} \right\rceil.$$

Decir únicamente que la pérdida es acotada no permite omitir su rango. La fórmula sin ese factor corresponde al caso normalizado $[0, 1]$. La pérdida cuadrática de regresión requiere cotas adicionales sobre los datos y las predicciones para poder aplicar directamente este resultado.

8.3 Parámetros y precisión finita

Idea 8.2 (Una clase implementada en un computador). Supongamos que una clase está descrita por p parámetros y que cada uno se almacena usando 64 bits. Cada parámetro admite, a lo sumo, 2^{64} codificaciones, y por tanto

$$|\mathcal{H}_{\text{comp}}| \leq (2^{64})^p = 2^{64p}.$$

Se trata de una cota superior: distintas codificaciones pueden representar la misma hipótesis.

Si esta clase se fija antes de observar los datos y la pérdida está en $[0, 1]$, la cota agnóstica anterior permite tomar

$$m_{\mathcal{H}_{\text{comp}}}(\varepsilon, \delta) \leq \left\lceil \frac{2(64p \ln 2 + \ln(2/\delta))}{\varepsilon^2} \right\rceil.$$

El desarrollo del numerador es

$$2 \ln(2 \cdot 2^{64p}/\delta) = 128p \ln 2 + 2 \ln(2/\delta).$$

Así, el tamaño suficiente de muestra crece linealmente con el número de parámetros almacenados, dentro de esta cota de conteo. Como $\ln 2 < 1$, reemplazar $128p \ln 2$ por $128p$ entrega una cota más simple y algo mayor.

Este argumento se refiere a la clase con precisión finita. La clase matemática con parámetros reales puede ser infinita y requiere un análisis propio. Tampoco se concluye eficiencia computacional del ERM.

9 Predictores lineales

9.1 Funciones afines y transformación de la salida

Definición 9.1 (Clase de funciones afines). Para $\mathcal{X} \subseteq \mathbb{R}^d$, consideramos

$$L_d = \{h_{w,b} : w \in \mathbb{R}^d, b \in \mathbb{R}\}, \quad h_{w,b}(x) = w^\top x + b.$$

El vector w contiene los pesos y b es el término independiente, también llamado sesgo. En el lenguaje de aprendizaje se habla de modelos lineales aunque, si $b \neq 0$, la función de x sea afín.

Definición 9.2 (Clase inducida por una transformación). Sea $\phi : \mathbb{R} \rightarrow \mathcal{Y}$ una función. Se define

$$\mathcal{H}_\phi = \{\phi \circ h : h \in L_d\},$$

de modo que una predicción tiene la forma

$$x \mapsto \phi(w^\top x + b).$$

La elección de ϕ determina el tipo de salida:

- **Signo:** $\phi(t) = \text{sgn}(t)$ produce una etiqueta en $\{-1, 1\}$ y da lugar a clasificadores de semiespacios.
- **Identidad:** $\phi(t) = t$ produce un número real y da lugar a regresión lineal.
- **Función logística:**

$$\phi(t) = \sigma(t) = \frac{1}{1 + e^{-t}}$$

produce un valor en $(0, 1)$, que puede usarse para modelar una probabilidad de clase.

En el último caso, las etiquetas de clasificación pueden seguir siendo binarias; la salida del predictor antes de decidir una clase es una probabilidad. El modelo queda determinado por la transformación y la función de pérdida con la que se entrene.

9.2 Coordenadas aumentadas

Definición 9.3 (Vector aumentado). Se incorpora el término independiente agregando una coordenada:

$$\hat{x} = \begin{pmatrix} x \\ 1 \end{pmatrix} \in \mathbb{R}^{d+1}, \quad \hat{w} = \begin{pmatrix} w \\ b \end{pmatrix} \in \mathbb{R}^{d+1}.$$

Entonces

$$\hat{w}^\top \hat{x} = w^\top x + b.$$

Esta notación permite tratar pesos y sesgo como un único vector de parámetros. La última coordenada de cada observación aumentada es siempre 1.

9.3 Semiespacios y frontera de decisión

Usaremos la convención

$$\text{sgn}(t) = \begin{cases} 1, & t \geq 0, \\ -1, & t < 0. \end{cases}$$

Definición 9.4 (Clasificadores de semiespacios).

La clase de semiespacios afines es

$$S_d = \{x \mapsto \text{sgn}(w^\top x + b) : w \in \mathbb{R}^d, b \in \mathbb{R}\}.$$

Cuando $w \neq 0$, el hiperplano

$$\{x : w^\top x + b = 0\}$$

es la frontera de decisión; el vector w es normal a él. Un lado recibe etiqueta 1 y el otro, etiqueta -1 . Si $w = 0$, el predictor es constante.


En dos dimensiones, la frontera es la recta

$$w_1 x_1 + w_2 x_2 + b = 0.$$

Si $w_2 \neq 0$, puede despejarse como

$$x_2 = -\frac{w_1}{w_2} x_1 - \frac{b}{w_2},$$

y su intersección con el eje vertical es $(0, -b/w_2)$.



Un hiperplano separa las dos regiones de decisión. Los puntos y las cruces representan las dos clases.

10 ERM para semiespacios

10.1 Separación estricta y normalización

Sea $S = ((x_i, y_i))_{i=1}^m$, con $y_i \in \{-1, 1\}$. El desarrollo de la clase supone una muestra *estrictamente separable*: por enunciado existen $\bar{w}, \bar{b}$ tales que

$$y_i(\bar{w}^\top x_i + \bar{b}) > 0 \quad \text{para todo } i \in [m].$$

La condición asegura simultáneamente clasificación correcta y ausencia de observaciones sobre la frontera.

Con $\bar{v} = (\bar{w}, \bar{b})$ y $\hat{x}_i = (x_i, 1)$, definimos

$$\gamma = \min_{i \in [m]} y_i \bar{v}^\top \hat{x}_i.$$

Como la muestra es finita y todos los términos son estrictamente positivos, $\gamma > 0$. Al tomar

$$v = \frac{\bar{v}}{\gamma},$$

resulta

$$y_i v^\top \hat{x}_i \geq 1 \quad \text{para todo } i \in [m].$$

Multiplicar los parámetros por una constante positiva no cambia el signo de las predicciones.

10.2 Formulación matricial y algoritmo

Formemos la matriz de restricciones

$$B = \begin{pmatrix} y_1 \hat{x}_1^\top \\ \vdots \\ y_m \hat{x}_m^\top \end{pmatrix} \in \mathbb{R}^{m \times (d+1)}.$$

Las condiciones anteriores equivalen al sistema de desigualdades lineales

$$Bv \geq \mathbf{1}_m,$$

donde la desigualdad se interpreta coordenada a coordenada.

Proposición 10.1 (ERM mediante factibilidad lineal). Si la muestra es estrictamente separable, el siguiente procedimiento devuelve una hipótesis de S_d con error empírico cero:

1. Aumentar cada observación: $\hat{x}_i = (x_i, 1)$.
2. Construir B con filas $y_i \hat{x}_i^\top$.
3. Encontrar un vector v que satisfaga $Bv \geq \mathbf{1}_m$.

4. Escribir $v = (w, b)$ y devolver

$$h_S(x) = \text{sgn}(w^\top x + b).$$

Demostración. La normalización anterior demuestra que el sistema es factible, por el supuesto de separación estricta del enunciado. Si v es cualquier solución, para cada i :

- Si $y_i = 1$, se obtiene $v^\top \hat{x}_i \geq 1 > 0$, luego $h_S(x_i) = 1$.
- Si $y_i = -1$, se obtiene $v^\top \hat{x}_i \leq -1 < 0$, luego $h_S(x_i) = -1$.

Todas las etiquetas se predicen correctamente, de modo que $L_S(h_S) = 0$. Dado que el riesgo empírico es no negativo, este valor es un mínimo global y h_S es un ERM. $\square$

El paso central es un problema de factibilidad lineal en $d + 1$ incógnitas y m restricciones. La conclusión anterior corresponde a muestras separables. Si las restricciones son incompatibles, no existe una solución con ese margen para la muestra dada.

11 Regresión lineal y ecuaciones normales

11.1 Minimización de la pérdida cuadrática

Para datos $S = ((x_i, y_i))_{i=1}^m$ con $x_i \in \mathbb{R}^d$ y $y_i \in \mathbb{R}$, se usa la clase L_d y la transformación identidad. El ERM busca

$$(\hat{w})_S \in \arg \min_{\hat{w} \in \mathbb{R}^{d+1}} F(\hat{w}),$$

donde

$$F(\hat{w}) = \frac{1}{m} \sum_{i=1}^m (y_i - \hat{w}^\top \hat{x}_i)^2.$$

El factor $1/m$ no cambia el conjunto de minimizadores.

11.2 Derivación por el gradiente

Para cada residuo $r_i(\hat{w}) = y_i - \hat{w}^\top \hat{x}_i$,

$$\nabla r_i(\hat{w}) = -\hat{x}_i, \quad \nabla(r_i(\hat{w})^2) = -2r_i(\hat{w})\hat{x}_i.$$

Por tanto,

$$\nabla F(\hat{w}) = -\frac{2}{m} \sum_{i=1}^m (y_i - \hat{w}^\top \hat{x}_i) \hat{x}_i.$$

La condición de primer orden $\nabla F(\hat{w}) = 0$ equivale a

$$\sum_{i=1}^m (\hat{w}^\top \hat{x}_i) \hat{x}_i = \sum_{i=1}^m y_i \hat{x}_i.$$

Como $(\hat{w}^\top \hat{x}_i) \hat{x}_i = \hat{x}_i \hat{x}_i^\top \hat{w}$, resulta

$$\left(\sum_{i=1}^m \hat{x}_i \hat{x}_i^\top \right) \hat{w} = \sum_{i=1}^m y_i \hat{x}_i.$$

Definición 11.1 (Ecuaciones normales). Definamos

$$A = \sum_{i=1}^m \hat{x}_i \hat{x}_i^\top \in \mathbb{R}^{(d+1) \times (d+1)},$$

$$c = \sum_{i=1}^m y_i \hat{x}_i \in \mathbb{R}^{d+1}.$$

Las ecuaciones normales son

$$\boxed{A\hat{w} = c.}$$

En particular, A se construye sumando productos exteriores de los vectores aumentados.

11.3 Por qué las ecuaciones dan un mínimo

Proposición 11.1 (Convexidad y suficiencia).

La función F es convexa. Cualquier solución de las ecuaciones normales es un minimizador global del riesgo empírico.

Demostración. La matriz A es simétrica y, para todo $q \in \mathbb{R}^{d+1}$,

$$q^\top A q = \sum_{i=1}^m (q^\top \hat{x}_i)^2 \geq 0.$$

Por lo tanto, es semidefinida positiva. Además,

$$\nabla^2 F(\hat{w}) = \frac{2}{m} A \succeq 0,$$

lo que prueba la convexidad. Si $\hat{w}$ satisface $A\hat{w} = c$, entonces $\nabla F(\hat{w}) = 0$; para una función convexa diferenciable, esa condición es suficiente para alcanzar un mínimo global. $\square$

Idea 11.1 (Existencia y unicidad). Las ecuaciones normales siempre tienen solución. En efecto, si $q \in \ker A$, entonces

$$0 = q^\top A q = \sum_{i=1}^m (q^\top \hat{x}_i)^2,$$

de modo que $q^\top \hat{x}_i = 0$ para todo i . Así,

$$q^\top c = \sum_{i=1}^m y_i q^\top \hat{x}_i = 0.$$

Por ello $c \in (\ker A)^\perp = \text{Im } A$, donde la última igualdad usa que A es simétrica. Esto demuestra que $A\hat{w} = c$ es compatible.

La solución es única si y solo si los vectores $\hat{x}_1, \dots, \hat{x}_m$ generan $\mathbb{R}^{d+1}$. En ese caso, A es definida positiva e invertible, y formalmente

$$\hat{w} = A^{-1}c.$$

Si A es singular, puede haber distintos vectores de parámetros minimizadores; todos resuelven las ecuaciones normales. Para calcularlos basta resolver el sistema lineal, sin suponer de antemano que la matriz tiene inversa.

11.4 Algoritmo de regresión lineal

1. Construir $\hat{x}_i = (x_i, 1)$ para cada observación.
2. Calcular

$$A = \sum_{i=1}^m \hat{x}_i \hat{x}_i^\top, \quad c = \sum_{i=1}^m y_i \hat{x}_i.$$

3. Resolver $A\hat{w} = c$.
4. Separar $\hat{w} = (w, b)$ y devolver

$$h_S(x) = w^\top x + b.$$

La optimalidad obtenida se refiere al riesgo empírico cuadrático. Para relacionarlo con el riesgo sobre datos nuevos se necesitan hipótesis que permitan controlar la generalización, como las estudiadas en las secciones anteriores.

12 Síntesis de las garantías

Las siguientes cotas corresponden a muestras i.i.d. y a una confianza $1 - \delta$. En cada caso se toma el entero superior.

■ Clase finita realizable, pérdida de clasificación:

$$m \geq \frac{\ln |\mathcal{H}| + \ln(1/\delta)}{\varepsilon} \implies L_{\mu,f}(h_S) \leq \varepsilon$$

con probabilidad al menos $1 - \delta$.

■ Rectángulos realizables en el plano:

$$m \geq \frac{4}{\varepsilon} \ln \frac{4}{\delta} \implies L_{\mu,f}(h_S) \leq \varepsilon$$

con probabilidad al menos $1 - \delta$.

■ Clase finita, pérdida en $[0, 1]$:

$$m \geq \frac{\ln(2|\mathcal{H}|/\delta)}{2\alpha^2}$$

garantiza simultáneamente

$$|L_S(h) - L_\mu(h)| \leq \alpha \quad (\forall h \in \mathcal{H})$$

con probabilidad al menos $1 - \delta$.

■ ERM agnóstico, clase finita y pérdida en $[0, 1]$:

$$m \geq \frac{2 \ln(2|\mathcal{H}|/\delta)}{\varepsilon^2}$$

garantiza

$$L_\mu(h_S) \leq \inf_{h \in \mathcal{H}} L_\mu(h) + \varepsilon$$

con probabilidad al menos $1 - \delta$.

En el caso realizable, el riesgo de referencia es cero. En el caso agnóstico, se compara con el menor riesgo alcanzable dentro de $\mathcal{H}$. La representatividad de la muestra es el paso que permite trasladar la minimización empírica a esa comparación.

Procedencia y organización

Este apunte desarrolla el contenido de las 46 páginas del archivo `doc.pdf`. Las fotografías repetidas o superpuestas se integraron en una sola exposición; la página 12 no contiene materia. Se ordenaron los temas por dependencia conceptual y se hicieron explícitos los pasos intermedios de las demostraciones.

Se normalizaron los signos de las probabilidades de éxito y falla, el conteo de errores empíricos y el uso de ínfimo o mínimo. La prueba de rectángulos explicita cómo tratar masa sobre los bordes, y la cota de Hoeffding conserva el rango de la pérdida. Las aclaraciones de notación y álgebra completan los desarrollos de pizarra.