

MMD3001 Inferencia Estadística**Profesor:** David Sossa A.**Ayudante:** Juan I. Riquelme

Ayudantía 11: Test de Bondad de Ajuste

P1. Se observan los siguientes $n = 8$ datos:

1,41, 0,26, 1,97, 0,33, 0,55, 0,77, 1,46, 1,18.

¿Existe evidencia para sugerir que los datos no fueron muestreados aleatoriamente desde una distribución uniforme en $(0, 2)$?

P2. A cada persona en una muestra aleatoria de $n = 10$ empleados se le preguntó por X , el tiempo diario perdido en el trabajo realizando actividades no laborales, tales como navegar por internet y enviar correos a amigos. Los datos obtenidos, medidos en minutos, fueron los siguientes:

108, 112, 117, 130, 111, 131, 113, 113, 105, 128.

¿Es razonable asumir que estos datos provienen de una distribución normal con media 120 y desviación estándar 10?

P3. La calle Blanco Encalada posee 4 pistas. Se observaron 1000 autos pasar la calle y se anotó en qué pista estos autos iban:

Pista	1	2	3	4
Cantidad de Autos	294	276	238	192

Queremos responder a la pregunta: ¿Tienen los automovilistas preferencia por alguna pista? Construya un Test de Bondad de Ajuste para responder esta pregunta. Considere para esto, variables aleatorias X_i a valores en $\{1, 2, 3, 4\}$ e hipótesis

$$p_1 = p_2 = p_3 = p_4 = \frac{1}{4}.$$

Use $\alpha = 0,05$.

Repaso CC2

P4. Sea $X_1, \dots, X_{25}$ una muestra aleatoria de la distribución normal $\mathcal{N}(\mu, 16)$. Suponga que una realización de la muestra da una media $\bar{x} = 18$. Se pide:

- Encuentre un intervalo de 90 % de confianza para μ .
- Considere las hipótesis

$$H_0 : \mu = 20 \quad \text{vs.} \quad H_1 : \mu \neq 20.$$

Haga un test de hipótesis para determinar si se rechaza H_0 con un nivel de significancia del 5 %.

- P5.** Al discutir los efectos del cambio climático en su ciudad natal, usted argumenta que los inviernos son notoriamente más fríos que hace dos décadas, mientras que una amiga suya plantea que eso no es posible porque los efectos del cambio climático son a más largo plazo. Para zanjar la discusión, se accede a los datos de la temperatura más fría del año entre 1989 y 1996, y lo mismo entre 2009 y 2016, obteniendo promedios de 2, 5 y 1, 2 y desviaciones estándar de 1, 0 y 1, 0, respectivamente. Suponiendo muestras normales con igual varianza, plantee las hipótesis correspondientes, calcule el p -valor del test, e indique su conclusión para un nivel de 5 %.
- P6.** El voltaje de salida de un cierto circuito eléctrico debería ser 130 de acuerdo a las especificaciones técnicas. Se toma una muestra de 40 mediciones independientes del voltaje de este circuito, y se obtiene un promedio de 128,6 y una desviación estándar, es decir, la raíz del estimador insesgado de la varianza, de 2,1. Realice un test a nivel 5 % para la hipótesis de que la esperanza del voltaje es igual a 130 versus la alternativa de que es estrictamente menor que 130. ¿Cuál es el p -valor del test?
- P7.** Considere la muestra aleatoria $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Poisson}(\lambda)$, con $\lambda > 0$. Considere las hipótesis

$$H_0 : \lambda \leq \lambda_0, \quad H_1 : \lambda > \lambda_0, \quad (1)$$

donde $\lambda_0 > 0$ es un valor conocido. Denotemos $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$.

- Sea $\ell(\lambda) = \ell(X_1, \dots, X_n; \lambda)$ la función log-verosimilitud del modelo. Demuestre que $\ell(\lambda)$ es creciente en $(0, \bar{X}_n)$ y decreciente en $(\bar{X}_n, \infty)$. A partir de ello, calcule $\max_{0 < \lambda \leq \lambda_0} \ell(\lambda)$.
- Describa la expresión $-2(\max_{0 < \lambda \leq \lambda_0} \ell(\lambda) - \max_{\lambda > 0} \ell(\lambda))$ e indique su distribución asintótica bajo H_0 .
- Describa el test de razón de verosimilitud de nivel α para las hipótesis (1).
- Supongamos que una realización de la muestra aleatoria nos da una media $\bar{x}_n$ tal que $\bar{x}_n \leq \lambda_0$. ¿Qué conclusión permite deducir el test de razón de verosimilitud para (1)?

Desarrollo P1 y P2

P1. Se observan los siguientes $n = 8$ datos:

1,41, 0,26, 1,97, 0,33, 0,55, 0,77, 1,46, 1,18.

¿Existe evidencia para sugerir que los datos no fueron muestreados aleatoriamente desde una distribución uniforme $\text{Unif}(0, 2)$?

Sol: Sea $X \sim \text{Uniforme}(0, 2)$. Entonces su función de densidad está dada por

$$f(x) = \frac{1}{2}, \quad F_0(x) = \mathbb{P}(X \leq x) = \int_0^x \frac{1}{2} dt = \frac{x}{2} \quad 0 < x < 2.$$

Así, $F_0(x) = \begin{cases} 0, & x < 0, \\ \frac{x}{2}, & 0 \leq x < 2, \\ 1, & x \geq 2. \end{cases}$ Queremos contrastar las hipótesis $H_0 : F(x) = F_0(x)$ contra $H_1 : F(x) \neq F_0(x)$, donde F es la función de distribución desconocida desde la cual fueron

muestreados los datos. Para aplicar el test de Kolmogorov-Smirnov, primero ordenamos los datos:

$$0,26, 0,33, 0,55, 0,77, 1,18, 1,41, 1,46, 1,97.$$

Como $n = 8$, la función de distribución empírica satisface

$$F_n(y_k) = \frac{k}{8}, \quad k = 1, \dots, 8.$$

Construimos la siguiente tabla:

k	y_k	$F_n(y_{k-1})$	$F_0(y_k)$	$F_n(y_k)$	$ F_n(y_{k-1}) - F_0(y_k) $	$ F_0(y_k) - F_n(y_k) $
1	0,26	0,000	0,130	0,125	0,130	0,005
2	0,33	0,125	0,165	0,250	0,040	0,085
3	0,55	0,250	0,275	0,375	0,025	0,100
4	0,77	0,375	0,385	0,500	0,010	0,115
5	1,18	0,500	0,590	0,625	0,090	0,035
6	1,41	0,625	0,705	0,750	0,080	0,045
7	1,46	0,750	0,730	0,875	0,020	0,145
8	1,97	0,875	0,985	1,000	0,090	0,015

El estadístico de Kolmogorov-Smirnov es

$$D_n = \sup_x |F_n(x) - F_0(x)|.$$

En este caso, el mayor valor de las diferencias calculadas es $D_8 = 0,145$. Para $n = 8$ y nivel de significancia $\alpha = 0,05$, el valor crítico de la tabla de Kolmogorov-Smirnov es aproximadamente $d_{8,0,05} = 0,46$. Como

$$D_8 = 0,145 < 0,46,$$

no rechazamos la hipótesis nula.

Por lo tanto, no existe evidencia estadística suficiente para afirmar que los datos no provienen de una distribución uniforme $\text{Unif}(0, 2)$.

P2. A cada persona en una muestra aleatoria de $n = 10$ empleados se le preguntó por X , el tiempo diario perdido en el trabajo realizando actividades no laborales, tales como navegar por internet y enviar correos a amigos. Los datos obtenidos, medidos en minutos, son los siguientes:

$$108, 112, 117, 130, 111, 131, 113, 113, 105, 128.$$

¿Es razonable asumir que estos datos provienen de una distribución normal con media 120 y desviación estándar 10?

Sol: Queremos aplicar un test de Kolmogorov-Smirnov para estudiar si los datos son compatibles con la distribución $X \sim \mathcal{N}(120, 10^2)$. Por lo tanto, consideramos las hipótesis

$$H_0 : F(x) = F_0(x) \quad v.s \quad H_1 : F(x) \neq F_0(x),$$

donde F_0 corresponde a la función de distribución acumulada de una normal con media 120 y desviación estándar 10. Es decir,

$$F_0(x) = \mathbb{P}(X \leq x) = \mathbb{P}\left(Z \leq \frac{x - 120}{10}\right),$$

donde $Z \sim \mathcal{N}(0, 1)$. Primero ordenamos los datos:

105, 108, 111, 112, 113, 113, 117, 128, 130, 131.

Para calcular el estadístico de Kolmogorov-Smirnov, usamos

$$D_n = \sup_x |F_n(x) - F_0(x)|.$$

En particular, evaluamos las diferencias entre la función de distribución empírica F_n y la función de distribución teórica F_0 en los datos ordenados. Por ejemplo, para el primer dato ordenado $y_1 = 105$, tenemos

$$F_0(y_1) = \mathbb{P}(X \leq 105) = \mathbb{P}\left(Z \leq \frac{105 - 120}{10}\right) = \mathbb{P}(Z \leq -1,5).$$

Usando tabla normal estándar, $\mathbb{P}(Z \leq -1,5) \approx 0,0668$. La siguiente tabla resume los cálculos necesarios:

k	y_k	$F_n(y_{k-1})$	$F_0(y_k)$	$F_n(y_k)$	$ F_n(y_{k-1}) - F_0(y_k) $	$ F_0(y_k) - F_n(y_k) $
1	105	0,0	0,0668	0,1	0,0668	0,0332
2	108	0,1	0,1151	0,2	0,0151	0,0849
3	111	0,2	0,1841	0,3	0,0159	0,1159
4	112	0,3	0,2119	0,4	0,0881	0,1881
5	113	0,4	0,2420	0,6	0,1580	0,3580
6	113	0,6	0,2420	0,6	0,3580	0,3580
7	117	0,6	0,3821	0,7	0,2179	0,3179
8	128	0,7	0,7881	0,8	0,0881	0,0119
9	130	0,8	0,8413	0,9	0,0413	0,0587
10	131	0,9	0,8643	1,0	0,0357	0,1357

Las últimas dos columnas contienen todas las diferencias que debemos revisar. El mayor valor observado es

$$D_{10} = 0,3580.$$

Para $n = 10$ y nivel de significancia $\alpha = 0,10$, el valor crítico de la tabla de Kolmogorov-Smirnov es aproximadamente

$$d_{10,0,10} = 0,37.$$

Como $D_{10} = 0,3580 < 0,37$, no rechazamos la hipótesis nula al nivel $\alpha = 0,10$. Por lo tanto, no hay evidencia suficiente para rechazar el supuesto de que los datos provienen de una distribución normal con media 120 y desviación estándar 10.

En conclusión, a nivel 10 %, es razonable asumir que $X \sim \mathcal{N}(120, 10^2)$.