

ING2602-1 Métodos Numéricos

Profesor: Gonzalo Flores

Ayudante: Juan I. Riquelme




Ayudantía 3: Punto Flotante

P1. Ya que en el computador solamente se pueden representar una cantidad finita de números, utilizamos conjuntos finitos F , llamados punto flotante. Un conjunto de punto flotante F se define mediante una base $\beta \in \mathbb{N}$, en un intervalo $[L, U]$ del exponente $E \in \mathbb{Z}$ y una precisión $p \in \mathbb{N}$.

Consideramos un *conjunto de punto flotante normalizado* con los siguientes valores:

$$\beta = 3, \quad L = -1, \quad U = 2, \quad p = 2.$$



- Explicar qué significa *normalizado*. Si se refiere a una definición, hay que darla también.
- Dar una cota superior para el error relativo al representar un número en el sistema dado, suponiendo que se emplea la regla de redondeo.
- Al representar el número 20 en el sistema dado, dar el error relativo, utilizando truncamiento y redondeo.
- Al representar el número 0,2 en el sistema dado, dar el error relativo, utilizando truncamiento y redondeo.
- Comparar el error relativo de la parte 4) con la cota superior de 2). Explique el fenómeno.
- Cambiar uno de los valores L , U , o p para evitar el fenómeno al representar el número 0,2.
- En general, ¿se puede evitar ese fenómeno en un sistema de punto flotante? Justifique la respuesta.

P2. Consideremos el siguiente sistema de punto flotante:

$$\beta = 10, \quad L = -2, \quad U = 2, \quad p = 3.$$

- ¿Es posible representar el número 0,00625 en este sistema? Justifique.
- En caso de que el número anterior no sea posible representarlo, encuentre su forma normalizada y redondee a 2 cifras significativas.
- ¿Cuál es el error relativo y absoluto de esta representación?

P3. Dado el sistema $\beta = 2$, $p = 5$, $L = -4$ y $U = 3$, se tienen los siguientes elementos a sumar:

$$x = 1,1011_2 \times 2^1, \quad y = 1,0010_2 \times 2^{-2}.$$

- Represente x e y en este sistema utilizando redondeo.
- Realice la suma aritmética de punto flotante.

P4. Represente en sistema binario al número $x = 13,875$ y calcule el error relativo si solo consideramos una precisión de 5 cifras significativas (recordar que si la parte entera es 0 las cifras significativas son solo decimales).

Resumen

Definición 1 (Sistema de punto flotante.). Un sistema de punto flotante queda determinado por

$$F(\beta, p, L, U),$$

donde β es la base, p la cantidad de cifras significativas y $L \leq E \leq U$ es el rango permitido para el exponente.

Un número normalizado distinto de cero tiene la forma

$$x = \pm(d_0.d_1 \dots d_{p-1})_\beta \beta^E,$$

donde

$$d_0 \neq 0, \quad L \leq E \leq U.$$

Por lo tanto, **normalizar** significa escribir el número de manera que la primera cifra de la mantisa sea distinta de cero. Por ejemplo,

$$202_3 = 2,02_3 \times 3^2.$$

Definición 2 (Rango representable.). En un sistema $F(\beta, p, L, U)$,

$$x_{\min} = \beta^L, \quad x_{\max} = (\beta - \beta^{1-p})\beta^U.$$

Un número normalizado es representable si su exponente satisface $L \leq E \leq U$.

Definición 3 (Errores.). Si x es el valor exacto y $\text{fl}(x)$ su aproximación,

$$E_{\text{abs}} = |x - \text{fl}(x)|, \quad E_{\text{rel}} = \frac{|x - \text{fl}(x)|}{|x|}.$$

Con redondeo, $E_{\text{rel}} \leq \frac{1}{2}\beta^{1-p}$, mientras que con truncamiento, $E_{\text{rel}} < \beta^{1-p}$.

Definición 4 (Subdesborde y desborde.). Se produce **subdesborde** si

$$0 < |x| < \beta^L,$$

y **desborde** si $|x| > x_{\max}$.

La cota de redondeo anterior supone que no ocurre ninguno de estos fenómenos. Disminuir L permite representar números más pequeños, aumentar U números más grandes y aumentar p mejora la precisión.

Definición 5 (Conversión de base.). Para convertir a base β , se usan divisiones sucesivas por β para la parte entera y multiplicaciones sucesivas por β para la parte decimal. Luego se normaliza:

$$(d_0.d_1d_2\dots)_\beta \beta^E, \quad d_0 \neq 0.$$

Definición 6 (Suma en punto flotante.). Para sumar

$$x = m_x\beta^{E_x}, \quad y = m_y\beta^{E_y},$$

se igualan los exponentes, se suman las mantisas y finalmente se **normaliza y redondea** a p cifras significativas.