




Ayudantía 3: Punto Flotante

P1. Ya que en el computador solamente se pueden representar una cantidad finita de números, utilizamos conjuntos finitos F , llamados punto flotante. Un conjunto de punto flotante F se define mediante una base $\beta \in \mathbb{N}$, en un intervalo $[L, U]$ del exponente $E \in \mathbb{Z}$ y una precisión $p \in \mathbb{N}$.

Consideramos un *conjunto de punto flotante normalizado* con los siguientes valores:

$$\beta = 3, \quad L = -1, \quad U = 2, \quad p = 2.$$



- Explique qué significa que un número esté normalizado. Si se refiere a una definición, debe proporcionarla.
Sol: revisar material en subido en un correo.
- Dé una cota superior para el error relativo al representar un número en el sistema dado, suponiendo que se emplea la regla de redondeo.
- Al representar el número 20 en el sistema dado, determine el error relativo utilizando truncamiento y redondeo.
- Al representar el número 0,2 en el sistema dado, determine el error relativo utilizando truncamiento y redondeo.
- Compare el error relativo de la parte anterior con la cota superior obtenida en la parte 2. Explique el fenómeno.
- Cambie uno de los valores L , U o p para evitar el fenómeno al representar el número 0,2.
- En general, ¿se puede evitar este fenómeno en un sistema de punto flotante? Justifique su respuesta.

P2. Consideremos el siguiente sistema de punto flotante:

$$\beta = 10, \quad L = -2, \quad U = 2, \quad p = 3.$$

- ¿Es posible representar el número 0,00625 en este sistema? Justifique.

Sol: Escribimos el número en forma normalizada:

$$0,00625 = 6,25 \times 10^{-3}.$$

La mantisa tiene $p = 3$ cifras significativas, pero el exponente es $E = -3$. Como los exponentes permitidos deben satisfacer $-2 \leq E \leq 2$, se tiene que $E = -3 < L = -2$. Por lo tanto, el número no puede representarse como número normalizado en este sistema y se produce subdesborde.

- b) En caso de que el número anterior no sea posible representarlo, encuentre su forma normalizada y redondee a 2 cifras significativas.

Sol: La forma normalizada es $0,00625 = 6,25 \times 10^{-3}$. Redondeando a 2 cifras significativas,

$$6,25 \times 10^{-3} \approx 6,3 \times 10^{-3} = 0,0063.$$

Por lo tanto, $\text{fl}(0,00625) = 0,0063$. Sin embargo, esta aproximación sigue teniendo exponente $E = -3$, por lo que tampoco pertenece al sistema $\mathcal{F}(10, 3, -2, 2)$.

- c) ¿Cuál es el error relativo y absoluto de esta representación?

Sol: El valor exacto es $x = 0,00625$ y su aproximación es $\text{fl}(x) = 0,0063$. El error absoluto es

$$E_{\text{abs}} = |x - \text{fl}(x)| = |0,00625 - 0,0063| = 0,00005 = 5 \times 10^{-5}.$$

El error relativo es

$$E_{\text{rel}} = \frac{|x - \text{fl}(x)|}{|x|} = \frac{0,00005}{0,00625} = 0,008.$$

En porcentaje, $E_{\text{rel}} = 0,8 \%$.

P3. Dado el sistema $\beta = 2$, $p = 5$, $L = -4$ y $U = 3$, se tienen los siguientes elementos a sumar:

$$x = (1,1011)_2 \times 2^1, \quad y = (1,0010)_2 \times 2^{-2}.$$

- a) Represente x e y en este sistema utilizando redondeo.

Sol: Ambos números están normalizados, tienen 5 cifras significativas y sus exponentes se encuentran dentro del intervalo permitido:

$$-4 \leq 1 \leq 3, \quad -4 \leq -2 \leq 3.$$

Por lo tanto, no es necesario modificar sus mantisas:

$$\text{fl}(x) = (1,1011)_2 \times 2^1, \quad \text{fl}(y) = (1,0010)_2 \times 2^{-2}.$$

Así, ambos números se representan exactamente en el sistema.

- b) Realice la suma aritmética de punto flotante.

Sol: Para sumar los números, primero igualamos sus exponentes. Como

$$(1,0010)_2 \times 2^{-2} = (0,0010010)_2 \times 2^1,$$

obtenemos

$$\begin{aligned} x + y &= (1,1011000)_2 \times 2^1 + (0,0010010)_2 \times 2^1 \\ &= (1,1101010)_2 \times 2^1. \end{aligned}$$

Como $p = 5$, conservamos los primeros 5 dígitos significativos:

$$\underbrace{1,1101}_{\text{se conserva}} \quad \underbrace{010}_{\text{se descarta}}.$$

La primera cifra descartada es 0, por lo que no se aumenta la última cifra conservada. En consecuencia,

$$\text{fl}(x + y) = (1,1101)_2 \times 2^1.$$

En base decimal,

$$\begin{aligned} (1,1101)_2 \times 2^1 &= (1 + 2^{-1} + 2^{-2} + 0 \cdot 2^{-3} + 2^{-4}) 2 \\ &= \left(1 + \frac{1}{2} + \frac{1}{4} + \frac{1}{16}\right) 2 \\ &= 3,625. \end{aligned}$$

P4. Represente en sistema binario al número $x = 13,875$ y calcule el error relativo si solo consideramos una precisión de 5 cifras significativas.

Sol: Separamos la parte entera y la parte decimal:

$$13 = (1101)_2, \quad 0,875 = \frac{1}{2} + \frac{1}{4} + \frac{1}{8} = (0,111)_2.$$

Por lo tanto,

$$13,875 = (1101,111)_2.$$

La forma normalizada es

$$13,875 = (1,101111)_2 \times 2^3.$$

Con una precisión de $p = 5$, conservamos

$$\underbrace{1,1011}_{\text{se conserva}} \quad \underbrace{11}_{\text{se descarta}}.$$

Como la primera cifra descartada es 1, redondeamos hacia arriba:

$$(1,101111)_2 \times 2^3 \approx (1,1100)_2 \times 2^3.$$

El valor aproximado en base decimal es

$$\begin{aligned} (1,1100)_2 \times 2^3 &= (1 + 2^{-1} + 2^{-2}) 2^3 \\ &= \left(1 + \frac{1}{2} + \frac{1}{4}\right) 8 \\ &= 14. \end{aligned}$$

El error absoluto es

$$E_{\text{abs}} = |13,875 - 14| = 0,125.$$

Por consiguiente, el error relativo es

$$\begin{aligned} E_{\text{rel}} &= \frac{|13,875 - 14|}{13,875} \\ &= \frac{0,125}{13,875} = \frac{1}{111} \approx 0,009009. \end{aligned}$$

Resumen

Definición 1 (Sistema de punto flotante.). Un sistema de punto flotante queda determinado por

$$\mathcal{F}(\beta, p, L, U),$$

donde β es la base, p la cantidad de cifras significativas y $L \leq E \leq U$ es el rango permitido para el exponente.

Un número normalizado distinto de cero tiene la forma

$$x = \pm(d_0.d_1 \dots d_{p-1})_\beta \beta^E,$$

donde

$$d_0 \neq 0, \quad L \leq E \leq U.$$

Por lo tanto, **normalizar** significa escribir el número de manera que la primera cifra de la mantisa sea distinta de cero. Por ejemplo,

$$202_3 = 2,02_3 \times 3^2.$$

Definición 2 (Rango representable.). En un sistema $\mathcal{F}(\beta, p, L, U)$,

$$x_{\min} = \beta^L, \quad x_{\max} = (\beta - \beta^{1-p})\beta^U.$$

Un número normalizado es representable si su exponente satisface $L \leq E \leq U$.

Definición 3 (Errores.). Si x es el valor exacto y $\text{fl}(x)$ su aproximación,

$$E_{\text{abs}} = |x - \text{fl}(x)|, \quad E_{\text{rel}} = \frac{|x - \text{fl}(x)|}{|x|}.$$

Con redondeo, $E_{\text{rel}} \leq \frac{1}{2}\beta^{1-p}$, mientras que con truncamiento, $E_{\text{rel}} < \beta^{1-p}$.

Definición 4 (Subdesborde y desborde.). Se produce **subdesborde** si

$$0 < |x| < \beta^L,$$

y **desborde** si $|x| > x_{\max}$.

La cota de redondeo anterior supone que no ocurre ninguno de estos fenómenos. Disminuir L permite representar números más pequeños, aumentar U números más grandes y aumentar p mejora la precisión.

Definición 5 (Conversión de base.). Para convertir a base β , se usan divisiones sucesivas por β para la parte entera y multiplicaciones sucesivas por β para la parte decimal. Luego se normaliza:

$$(d_0.d_1d_2\dots)_\beta \beta^E, \quad d_0 \neq 0.$$

Definición 6 (Suma en punto flotante.). Para sumar

$$x = m_x \beta^{E_x}, \quad y = m_y \beta^{E_y},$$

se igualan los exponentes, se suman las mantisas y finalmente se **normaliza y redondea** a p cifras significativas.

1. Conversión de una parte entera. Para convertir un entero decimal a base β , se divide repetidamente por β hasta que el cociente nos de 0, luego se guardan los restos y se leen desde la última división hacia la primera.

Ejemplo 1: convertir 20 a base 3

Las divisiones sucesivas son

Dividendo	Cociente	Resto
20	6	2
6	2	0
2	0	2

Leyendo los restos de abajo hacia arriba se obtiene $20 = (202)_3$. La comprobación es $2 \cdot 3^2 + 0 \cdot 3 + 2 = 18 + 2 = 20$.

2. Conversión de una parte fraccionaria. Para convertir una fracción decimal a base β , se multiplica repetidamente por β . La parte entera obtenida en cada paso es el próximo dígito; luego se continúa con la nueva parte fraccionaria.

Ejemplo 2: convertir $0,2 = 1/5$ a base 3

El procedimiento se escribe separando la parte entera de la parte decimal:

Fracción actual	Multiplicación por 3	Dígito
$1/5$	$3/5 = 0 + 3/5$	0
$3/5$	$9/5 = 1 + 4/5$	1
$4/5$	$12/5 = 2 + 2/5$	2
$2/5$	$6/5 = 1 + 1/5$	1

Como reaparece $1/5$, el patrón se repite. Por tanto,

$$0,2 = (0.\overline{0121})_3 = (1,210121 \dots)_3 \times 3^{-2}.$$

La segunda igualdad es la forma normalizada: se desplaza el punto hasta que el primer dígito sea distinto de cero y se compensa con la potencia 3^{-2} .

¿Por qué lo anterior tiene sentido? Es decir, por qué? $(0.\overline{0121})_3 = (0,012101210121 \dots)_3$. Expandiendo la misma representación que teníamos anteriormente:

$$\begin{aligned} \frac{1}{5} &= \frac{1}{3} \left(\frac{3}{5} \right) \\ &= \frac{1}{3} \left(0 + \frac{1}{3} \left(\frac{9}{5} \right) \right) \\ &= \frac{1}{3} \left(0 + \frac{1}{3} \left(1 + \frac{1}{3} \left(\frac{12}{5} \right) \right) \right) \\ &= \frac{1}{3} \left(0 + \frac{1}{3} \left(1 + \frac{1}{3} \left(2 + \frac{1}{3} \left(\frac{6}{5} \right) \right) \right) \right) \\ &= \frac{1}{3} \left(0 + \frac{1}{3} \left(1 + \frac{1}{3} \left(2 + \frac{1}{3} \left(1 + \frac{1}{5} \right) \right) \right) \right). \end{aligned}$$

$$(0.\overline{0121})_3 = 0 \cdot 3^{-1} + 1 \cdot 3^{-2} + 2 \cdot 3^{-3} + 1 \cdot 3^{-4} \\ + 0 \cdot 3^{-5} + 1 \cdot 3^{-6} + 2 \cdot 3^{-7} + 1 \cdot 3^{-8} + \dots$$

Vemos que obtenemos los mismos decimales constructivamente, como el bloque 0121 se repite cada cuatro posiciones, podemos escribir ya para que estemos más convencidos:

$$(0.\overline{0121})_3 = \sum_{k=0}^{\infty} \left(3^{-(4k+2)} + 2 \cdot 3^{-(4k+3)} + 3^{-(4k+4)} \right).$$

Sacando el factor 3^{-4k} , obtenemos

$$(0.\overline{0121})_3 = \sum_{k=0}^{\infty} 3^{-4k} \left(3^{-2} + 2 \cdot 3^{-3} + 3^{-4} \right).$$

Por lo tanto

$$(0.\overline{0121})_3 = \frac{16}{81} \sum_{k=0}^{\infty} 3^{-4k}.$$

La suma anterior es geométrica con razón $3^{-4} = 1/81$. En consecuencia,

$$\sum_{k=0}^{\infty} 3^{-4k} = \frac{1}{1 - 3^{-4}} = \frac{1}{1 - \frac{1}{81}} = \frac{81}{80}.$$

Así,

$$(0.\overline{0121})_3 = \frac{16}{81} \cdot \frac{81}{80} = \frac{16}{80} = \frac{1}{5} = 0,2.$$

Veamos ahora la forma normalizada. Al expandir,

$$(1,210121\dots)_3 = 1 \cdot 3^0 + 2 \cdot 3^{-1} + 1 \cdot 3^{-2} + 0 \cdot 3^{-3} \\ + 1 \cdot 3^{-4} + 2 \cdot 3^{-5} + 1 \cdot 3^{-6} + \dots$$

Multiplicando toda la suma por 3^{-2} , resulta

$$(1,210121\dots)_3 \times 3^{-2} = 1 \cdot 3^{-2} + 2 \cdot 3^{-3} + 1 \cdot 3^{-4} + 0 \cdot 3^{-5} \\ + 1 \cdot 3^{-6} + 2 \cdot 3^{-7} + 1 \cdot 3^{-8} + \dots$$

Esta es exactamente la expansión de

$$(0,01210121\dots)_3 = (0.\overline{0121})_3.$$

Por lo tanto,

$$\frac{1}{5} = 0,2 = (0.\overline{0121})_3 = (1,210121\dots)_3 \times 3^{-2}.$$

Observación 1. En este cálculo estamos utilizando el sistema de numeración posicional en base $\beta = 3$. No se está considerando todavía un sistema de punto flotante ni restricciones sobre la precisión o el exponente.

Por lo tanto tenemos un sistema posicional en base β donde los números normalizados tienen la forma

$$x = \pm(d_0, d_1 d_2 \dots)_\beta \times \beta^E,$$

donde

$$d_0 \neq 0, \quad d_i \in \{0, 1, \dots, \beta - 1\}, \quad E \in \mathbb{Z}.$$

En efecto

$$\frac{1}{5} = 0,2 = (0.\overline{0121})_3 = (1,210121\dots)_3 \times 3^{-2}.$$

Ahora si teniendo este ejemplo recordemos la definición

Definición del sistema $\mathcal{F}(\beta, p, L, U)$

Un número no nulo del sistema tiene la forma

$$x = \pm(d_0.d_1 \dots d_{p-1})_\beta \times \beta^E$$

donde $L \leq E \leq U$, $d_0 \in \{1, \dots, \beta - 1\}$ y $d_i \in \{0, \dots, \beta - 1\}$ para $i \geq 1$. Además, se agrega el número 0 al sistema.

El sistema se llama **normalizado** porque se exige $d_0 \neq 0$. Esto impide desperdiciar dígitos significativos con ceros iniciales y permite fijar de manera clara el exponente. El cero es la única excepción y se representa de forma especial.

Parámetro	Significado
β	Base del sistema y cantidad de dígitos disponibles.
p	Número de dígitos significativos almacenados.
L	Menor exponente permitido; controla cuán cerca de cero se puede llegar.
U	Mayor exponente permitido; controla cuán grandes pueden ser los números.

Observación 2. En el ejemplo anterior se trabaja con precisión ilimitada, es decir, la cantidad de dígitos significativos no está restringida (dígitos significativos p). Por esta razón, podemos representar exactamente

$$\frac{1}{5} = (0,2)_{10} = (0.\overline{0121})_3 = (1,210121\dots)_3 \times 3^{-2}.$$

En esta representación se utiliza la base $\beta = 3$, el primer dígito significativo es $d_0 = 1$ y el exponente puede ser cualquier número entero, es decir, $E \in \mathbb{Z}$. Por lo tanto, no existen exponentes mínimo y máximo finitos.

Menor y mayor número positivo normalizado

El menor se obtiene usando $d_0 = 1$, los demás dígitos iguales a cero y el exponente $E = L$. El mayor usa todos los dígitos iguales a $\beta - 1$ y $E = U$. Así,

$$x_{\min} = \beta^L, \quad x_{\max} = (\beta - \beta^{1-p})\beta^U.$$

Ejemplo

Consideremos el sistema $\mathcal{F}(3, 2, -1, 2)$. En este sistema se utiliza base $\beta = 3$, se conservan $p = 2$ dígitos significativos y los exponentes permitidos satisfacen

$$-1 \leq E \leq 2.$$

El menor número positivo normalizado es

$$x_{\min} = 3^{-1} = \frac{1}{3}.$$

El mayor número positivo representable es

$$x_{\max} = (3 - 3^{-1})3^2 = 24.$$

Por consiguiente, los números positivos normalizados de $\mathcal{F}(3, 2, -1, 2)$ se encuentran en el intervalo

$$\frac{1}{3} \leq x \leq 24.$$

Cuántos números contiene el sistema

Para cada exponente hay $\beta - 1$ posibilidades para d_0 y β^{p-1} para los restantes dígitos. Como existen $U - L + 1$ exponentes, dos signos y el cero, se tiene

$$|\mathcal{F}| = 2(\beta - 1)\beta^{p-1}(U - L + 1) + 1.$$

Error absoluto, error relativo y cota de redondeo

Si x es el valor exacto y $\text{fl}(x)$ es el número almacenado, el error absoluto y el error relativo son, respectivamente,

$$E_{\text{abs}} = |x - \text{fl}(x)|, \quad E_{\text{rel}} = \frac{|x - \text{fl}(x)|}{|x|}, \quad x \neq 0.$$

El error absoluto conserva la escala del problema. El error relativo mide qué fracción del tamaño de x se perdió y, por eso, es más útil para comparar errores en números de magnitudes distintas.

Cota del error relativo por redondeo

Si x está dentro del rango normalizado y el redondeo no causa subdesborde ni desborde, entonces

$$\frac{|x - \text{fl}(x)|}{|x|} \leq u, \quad u = \frac{1}{2}\beta^{1-p}.$$

El número u se denomina unidad de redondeo del sistema.

¿Por qué? créanme.

Subdesborde

Ocurre cuando un número no nulo tiene una magnitud demasiado *pequeña* para ser representado como número normalizado; en el modelo del ejercicio, $0 < |x| < x_{\min}$.

Desborde

Ocurre cuando la magnitud es demasiado *grande*; en el modelo simplificado, $|x| > x_{\max}$.

En el sistema $\mathcal{F}(3, 2, -1, 2)$, se tiene $x_{\min} = \frac{1}{3}$ y $x_{\max} = 24$. Dos ejemplos breves son:

Subdesborde

Consideremos $x = \frac{1}{5}$. Como

$$0 < \left| \frac{1}{5} \right| < \frac{1}{3} = x_{\min},$$

el número $\frac{1}{5}$ produce subdesborde.

Desborde

Consideremos $x = 30$. Como

$$|30| > 24 = x_{\max},$$

el número 30 produce desborde.

Observación 3. Los números que producen subdesborde o desborde no pueden representarse como números normalizados dentro del sistema de punto flotante considerado. En efecto, si

$$0 < |x| < x_{\min},$$

el número produce subdesborde, mientras que si

$$|x| > x_{\max},$$

produce desborde. En ambos casos, $x \notin \mathcal{F}(\beta, p, L, U)$. Por ejemplo, en el sistema $\mathcal{F}(3, 2, -1, 2)$,

$$0, 2 = \frac{1}{5} \notin \mathcal{F}(3, 2, -1, 2) \quad \text{y} \quad 30 \notin \mathcal{F}(3, 2, -1, 2),$$

pues $\frac{1}{5}$ produce subdesborde y 30 produce desborde. En efecto la conversión exacta es

$$0, 2 = (0.\overline{0121})_3 = (1, 210121 \dots)_3 \times 3^{-2}.$$

El exponente normalizado sería $E = -2$, pero por enunciado solo se permiten exponentes $E \geq L = -1$. Por tanto, ocurre subdesborde.

Observación 4. Las condiciones

$$x_{\min} \leq |x| \leq x_{\max}$$

permiten determinar si un número no nulo se encuentra dentro del rango del sistema, es decir, si no produce subdesborde ni desborde. Sin embargo, esto no garantiza que pueda representarse de manera exacta, pues también debe tener a lo más p dígitos significativos en base β . Si tiene más de p dígitos significativos, será necesario truncarlo o redondearlo.

Por ejemplo, en $\mathcal{F}(3, 2, -1, 2)$, el número

$$\frac{1}{5} = (1,210121 \dots)_3 \times 3^{-2}$$

no puede representarse, porque su exponente $E = -2$ es menor que $L = -1$; por lo tanto, produce subdesborde. Del mismo modo, 30 tampoco puede representarse, pues $30 > x_{\max} = 24$, de modo que produce desborde.

Ejemplo final

Sigamos trabajando con

$$\beta = 3, \quad L = -1, \quad U = 2, \quad p = 2.$$

Un número no nulo de $\mathcal{F}$ se escribe como

$$x = \pm(d_0.d_1)_3 \times 3^E, \quad -1 \leq E \leq 2,$$

donde $d_0 \in \{1, 2\}$ y $d_1 \in \{0, 1, 2\}$. Es normalizado porque el primer dígito significativo satisface $d_0 \neq 0$. El cero se agrega de manera especial. Por redondeo, la unidad de redondeo es

$$u = \frac{1}{2}\beta^{1-p} = \frac{1}{2}3^{1-2} = \frac{1}{6}.$$

Esta cota vale siempre que el número esté en el rango normalizado y que el redondeo no produzca subdesborde ni desborde. Es decir, como ya habíamos determinado también, los números positivos normalizados de $\mathcal{F}(3, 2, -1, 2)$ se encuentran en el intervalo

$$\frac{1}{3} \leq x \leq 24.$$

Vimos al principio de todo que $20 = (202)_3$. Su forma normalizada correcta es

$$20 = (2,02)_3 \times 3^2.$$

Como $p = 2$, solo pueden conservarse dos dígitos significativos. Al truncar se obtiene $(2,0)_3 \times 3^2 = (2 \cdot 3^0 + 0 \cdot 3^{-1}) 3^2 = 2 \cdot 3^2 + 0 \cdot 3^1 = 18$. Al redondear, los candidatos vecinos son 18 y $(2,1)_3 \times 3^2 = (2 \cdot 3^0 + 1 \cdot 3^{-1}) 3^2 = 2 \cdot 3^2 + 1 \cdot 3^1 = 18 + 3 = 21$; como 20 está más cerca de 21, se obtiene 21. Los errores relativos son

$$E_{\text{rel}}^{\text{trunc}} = \frac{|20 - 18|}{20} = \frac{1}{10}, \quad E_{\text{rel}}^{\text{red}} = \frac{|20 - 21|}{20} = \frac{1}{20}.$$

El error por redondeo $1/20$ respeta la cota $1/6$, tal como corresponde.